

Mapa Conceptual

Estadística II

Explicaciones Intuitivas

Laboratorios 1 al 7

Centro de Investigación y Docencia Económicas
Licenciatura en Economía — 4º Semestre

Donovan Díaz Moreno

Junio 2026

Sobre este documento

Este documento unifica las guías de lectura previa de los siete laboratorios de Estadística II en una sola narrativa continua. No es un resumen: cada capítulo conserva la profundidad de la guía original, pero añade conexiones explícitas entre laboratorios —las **suturas**— que muestran cómo cada concepto hereda de los anteriores y prepara los siguientes.

El formato pedagógico es consistente en todo el documento: cajas de color para cada función cognitiva (pregunta, caso real, herramienta, tarjeta de repaso, autoevaluación), ejemplos con datos mexicanos reales, y referencias a ejercicios detallados para profundizar.

Este documento se rige por las recomendaciones GAISE 2016 (American Statistical Association) y por el marco SLRT de delMas (2002): cada concepto se presenta en tres registros —idea intuitiva, procedimiento de cómputo, e interpretación en contexto.

Índice general

1. Prólogo: Las cuatro preguntas que mueven la estadística	9
1.1. El economista frente a los datos	9
1.2. Las cuatro preguntas	9
1.2.1. Pregunta 1: ¿Apunto al valor correcto?	9
1.2.2. Pregunta 2: ¿Con cuánta precisión?	10
1.2.3. Pregunta 3: ¿Cómo construyo un buen estimador?	10
1.2.4. Pregunta 4: ¿Qué tan seguro estoy?	10
1.3. El arco completo: de estimar a modelar	11
1.4. La tabla de herencia conceptual	12
1.5. Cómo leer este documento	13
1.6. El mapa de decisiones	14
1.7. Lo que dicen los expertos	14
1.8. Los datos son mexicanos	16
1.9. La ruta técnica mínima (si vas con prisa)	17
 I Los cimientos: del “qué” al “cómo”	 19
2. Propiedades de los estimadores: el control de calidad	21
2.1. La fábrica de estimadores: por qué necesitas un control de calidad	21
2.1.1. La analogía que organiza todo el laboratorio	21
2.1.2. La conexión con tu plan de estudios	22
2.1.3. Dos conceptos previos que necesitas dominar	22
2.2. Sesgo (Inssegamiento): ¿tu estimador apunta al valor correcto?	24
2.2.1. El caso que estremeció a la estadística	24
2.2.2. La herramienta: definición y procedimiento	24
2.2.3. El mito del inssegamiento	26
2.3. Eficiencia: entre estimadores inssegados, ¿cuál es más preciso?	28
2.3.1. El caso que muestra el poder de ponderar bien	28
2.3.2. La herramienta: varianza, eficiencia relativa y la cota de Cramér-Rao	29
2.4. Consistencia: ¿tu estimador mejora con más datos?	33
2.4.1. El caso: no todo estimador converge	33
2.4.2. La herramienta: convergencia en probabilidad	34
2.4.3. La segunda confusión más común: ¿inssegado y consistente no son lo mismo?	35
2.5. Suficiencia: ¿puedes comprimir los datos sin perder información?	37

2.5.1.	El caso: compresión sin pérdida	37
2.5.2.	La herramienta: el teorema de factorización	37
2.5.3.	Conexión con eficiencia: el teorema de Rao-Blackwell	39
2.6.	Las cuatro propiedades: mapa de decisiones	41
3.	Métodos de estimación: Máxima Verosimilitud y Momentos	43
3.1.	Máxima Verosimilitud (MLE): el método del detective	43
3.1.1.	El caso que revela la lógica del MLE	43
3.1.2.	El algoritmo MLE en 4 pasos	44
3.1.3.	MLE para la Poisson: cuando el resultado es el promedio	44
3.1.4.	MLE para la Gamma: cuando el resultado no es obvio	46
3.1.5.	El MLE para la Normal y la tensión con el Lab 1	47
3.2.	Método de Momentos (MOM): el método del calibrador	50
3.2.1.	El caso donde MOM brilla	50
3.2.2.	El algoritmo MOM en 3 pasos	50
3.2.3.	MOM para la Exponencial: cuando MOM = MLE	52
3.2.4.	MOM para la varianza Normal: divide entre n , no $n - 1$	52
3.3.	Propiedades asintóticas: ¿por qué MLE domina la econometría moderna?	53
3.3.1.	La trifecta asintótica del MLE	54
3.3.2.	El mapa de decisiones: MLE vs. MOM	55
3.3.3.	La conexión con el tradeoff sesgo-varianza	55
3.3.4.	Dónde aparecen estos métodos en tu carrera	57
II	La incertidumbre: de la estimación puntual a la decisión	59
4.	Intervalos de confianza: la estimación deja de ser un solo número	61
4.1.	Motivación: por qué un solo número no basta	61
4.2.	Las seis preguntas de una evaluación económica	64
4.3.	IC para la media μ con σ conocida (z-interval)	64
4.3.1.	Intuición: de la muestra a la población	65
4.3.2.	IC para la media con σ desconocida (t-interval)	66
4.4.	IC para diferencia de medias $\mu_1 - \mu_2$	68
4.5.	IC para proporción π	70
4.6.	IC para diferencia de proporciones	71
4.7.	IC para la varianza σ^2 (chi-cuadrada)	73
4.8.	IC para razón de varianzas σ_1^2/σ_2^2 (F)	75
4.9.	Mapa de decisiones: ¿qué IC uso?	76
	Sutura: IC y prueba de hipótesis	78
	Autoevaluación	79
5.	Pruebas de hipótesis: los datos emiten un veredicto	81
5.1.	La dualidad IC $\leftrightarrow$ Prueba: dos caras de la misma moneda	81
5.2.	Motivación: de la estimación al veredicto	82
5.3.	La lógica de las pruebas de hipótesis	83
5.3.1.	Errores Tipo I y Tipo II, potencia	83
5.4.	Prueba para una media μ (Z y t)	84

5.4.1. Prueba Z para μ con σ conocida	85
5.4.2. Prueba para μ con σ desconocida (n grande)	86
5.4.3. Prueba t para μ con muestra pequeña	86
5.5. Prueba para una proporción π	87
5.6. Prueba para una varianza σ^2 (χ^2)	89
5.7. Prueba para diferencia de medias	90
5.7.1. Prueba t pooled (varianzas iguales, muestras pequeñas)	90
5.7.2. Prueba Z para diferencia de medias (muestras grandes)	91
5.8. Prueba para razón de varianzas y la secuencia $F \rightarrow t$	93
5.8.1. La secuencia $F \rightarrow t$: primero varianzas, luego medias	94
Mapa de decisiones	95
5.9. De la prueba t al ANOVA: cuando comparar dos grupos no es suficiente	96
Autoevaluación	98

III Comparar y modelar: de una variable a relaciones entre variables 101

6. ANOVA de una vía: comparar muchos grupos sin inflar el error	103
6.1. El problema de las muchas comparaciones	103
6.1.1. El costo de hacer demasiadas pruebas	103
6.2. La intuición de ANOVA: señal contra ruido	105
6.2.1. La metáfora de la señal y el ruido	105
6.3. El modelo de una vía y la descomposición de varianza	107
6.3.1. El modelo estadístico	107
6.3.2. La identidad fundamental	107
6.3.3. Notación y reglas nemotécnicas	108
6.4. La prueba F : el corazón de ANOVA	110
6.4.1. ¿Por qué el estadístico F es un cociente de varianzas?	110
6.4.2. Conexión con la prueba t	111
6.5. Los supuestos de ANOVA y qué hacer si fallan	113
6.5.1. Los tres supuestos, en orden de importancia	113
6.6. Más allá del rechazo: comparaciones múltiples	115
6.6.1. El dilema post-ANOVA	115
6.7. ANOVA en la práctica: flujo completo	117
6.7.1. Los 7 pasos del análisis ANOVA	117
6.7.2. El tamaño del efecto: η^2	118
6.8. Anexo: ANOVA con variables dummy es regresión	120
6.8.1. La equivalencia fundamental	120
6.8.2. La unificación de la estadística	120
6.8.3. Lo que esto significa para tu formación	121
6.9. Autoevaluación del capítulo	122
7. ANOVA de dos vías y pruebas χ^2: controlando factores y probando distribuciones	125
7.1. Del ANOVA de una vía al de dos vías: la intuición de los bloques	125
7.1.1. ¿Por qué controlar? El sesgo de variable omitida	125

7.2.	La tabla ANOVA de dos vías: tres fuentes de variación	128
7.3.	Las dos pruebas F: interpretación dual	131
7.3.1.	Qué significa cada F	131
7.4.	Los supuestos del ANOVA de dos vías y el nuevo: aditividad	134
7.4.1.	El modelo aditivo y sus límites	134
7.4.2.	“Controlando por” en español	135
7.5.	χ^2 bondad de ajuste: más allá de comparar medias	137
7.5.1.	El salto conceptual: de parámetros a distribuciones	137
7.5.2.	La Ley de Benford: el 1 no es como los demás	138
7.6.	χ^2 de independencia: asociación entre variables categóricas	140
7.6.1.	De bondad de ajuste a independencia	140
7.7.	Flujo completo: integrando ANOVA dos vías y χ^2	143
7.8.	Autoevaluación del capítulo	145
8.	Regresión lineal simple: modelando relaciones entre variables	149
8.1.	Herencia de todo el curso: lo que los seis laboratorios anteriores construyeron para este momento	149
8.2.	El dataset: escolaridad e ingreso en 32 estados mexicanos	151
8.3.	El modelo poblacional: $y = \beta_0 + \beta_1 x + u$	153
8.4.	Mínimos Cuadrados Ordinarios (MCO): encontrar la recta óptima	157
8.5.	Bondad de ajuste: R^2 y la descomposición de la varianza	161
8.6.	Los supuestos que hacen que MCO funcione: Gauss-Markov	165
8.7.	Inferencia sobre $\hat{\beta}_1$: ¿es la asociación estadísticamente distinguible de cero?	169
8.8.	Asociación no es causalidad: el error más común —y más grave— en regresión	172
8.9.	Síntesis PPDAC: el ciclo completo de nuestro análisis	175
8.10.	Lo que sigue: sutura al Laboratorio 8 y más allá	177
8.11.	Autoevaluación: ¿entiendes la regresión o solo la calculas?	179
9.	Epílogo: El arco completo	181
9.1.	Las 4 preguntas, respondidas desde la cima	181
9.1.1.	Pregunta 1: ¿Apunto al valor correcto?	181
9.1.2.	Pregunta 2: ¿Con cuánta precisión?	181
9.1.3.	Pregunta 3: ¿Cómo construyo un buen estimador?	181
9.1.4.	Pregunta 4: ¿Qué tan seguro estoy?	182
9.1.5.	La quinta pregunta: ¿Cómo se relacionan las variables?	182
9.2.	El mapa de decisiones completo	182
9.3.	La tabla de herencia conceptual (versión completa)	184
9.4.	La escalera conceptual	186
9.5.	Lo que falta: hacia el Lab 8 y la econometría	186
9.6.	Limitaciones y trabajo futuro	187
9.7.	Cierre: el economista frente a los datos, una vez más	188
A.	Tabla de notación unificada	191
A.1.	Símbolos generales	191
A.2.	Parámetros poblacionales	191
A.3.	Estimadores y estadísticos	192
A.4.	Operadores y funciones	192

A.5. Distribuciones	193
A.6. Descomposición de varianza (ANOVA y regresión)	193
A.7. Valores críticos y notación de inferencia	194
B. Referencias bibliográficas	195

1. Prólogo: Las cuatro preguntas que mueven la estadística

*“Si tu única herramienta es un martillo, todo problema parece un clavo.” —
Atribuido a Abraham Maslow*

1.1. El economista frente a los datos

Imagina que eres economista en el Banco de México. Tu jefe te pide estimar la inflación del próximo trimestre. Tienes acceso a la Encuesta Nacional de Ingresos y Gastos de los Hogares (ENIGH), a los datos del INEGI, a las series del Banco de México, y a los reportes de coyuntura de la CEPAL.

Tienes los datos. Tienes una pregunta. ¿Qué haces?

No hay *una* respuesta. Hay un **camino** que atraviesa siete laboratorios. Este documento es el mapa de ese camino.

1.2. Las cuatro preguntas

Todo problema estadístico serio se reduce a cuatro preguntas fundamentales. No son preguntas técnicas: son preguntas de sentido común que cualquier persona se haría frente a datos inciertos.

1.2.1. Pregunta 1: ¿Apunto al valor correcto?

Antes de leer: hazte esta pregunta

Si repito mi procedimiento muchas veces, ¿en promedio acierto?

Esta es la pregunta por el **sesgo**. Un estimador insesgado es como una báscula calibrada: a veces marca un poco más, a veces un poco menos, pero en promedio coincide con el peso real.

Caso Real: La encuesta del Literary Digest (1936)

En 1936, la revista *Literary Digest* predijo que Alf Landon ganaría las elecciones presidenciales de Estados Unidos con el 57 % de los votos. La realidad: Franklin D.

Roosevelt ganó con el 62 %. ¿Qué falló? La encuesta usó directorios telefónicos y registros de automóviles para seleccionar su muestra —en plena Gran Depresión, eso excluía sistemáticamente a los votantes más pobres. El error no fue aleatorio: fue **sistemático**. Eso es el sesgo: un error que no desaparece por más datos que recolectes.

El Laboratorio 1 te enseña a detectar cuándo un estimador apunta al blanco y cuándo está sistemáticamente desviado.

1.2.2. Pregunta 2: ¿Con cuánta precisión?

Antes de leer: hazte esta pregunta

Entre varios estimadores que aciertan en promedio, ¿cuál fluctúa menos?

Esta es la pregunta por la **eficiencia**. Imagina dos encuestas para medir el desempleo: la ENOE (cara pero precisa) y una encuesta telefónica rápida (barata pero ruidosa). Ambas son insesgadas —en promedio aciertan—. Pero la ENOE da resultados más estables, con menos fluctuación de una medición a otra. La ENOE es más **eficiente**.

El Laboratorio 1 te da los criterios para comparar estimadores. Pero no te dice *cómo encontrarlos*. Para eso necesitas la Pregunta 3.

1.2.3. Pregunta 3: ¿Cómo construyo un buen estimador?

Antes de leer: hazte esta pregunta

No quiero que me den un estimador ya hecho para verificarlo. Quiero un método sistemático para fabricar estimadores que tengan buenas propiedades.

Esta pregunta la responde el Laboratorio 2 con dos métodos: **Máxima Verosimilitud** (MLE) y **Método de Momentos** (MOM).

MLE pregunta: “¿Qué valor del parámetro hace que los datos que observé sean los más probables?” MOM pregunta: “¿Qué valor del parámetro hace que los momentos teóricos coincidan con los muestrales?”

Ambos te dan una receta. Pero el resultado es un **número**. Un solo número. ¿Qué tan seguro estás de ese número?

1.2.4. Pregunta 4: ¿Qué tan seguro estoy?

Antes de leer: hazte esta pregunta

Mi estimador dice que la inflación será del 4.2 %. ¿Es 4.2 % exacto? ¿O podría ser 2 %? ¿O 7 %?

Esta pregunta —la **incertidumbre**— es el corazón de los Laboratorios 3 y 4.

El Laboratorio 3 te da **intervalos de confianza**: en vez de un número, produces una banda. “Con 95 % de confianza, la inflación estará entre 3.1 % y 5.3 %.”

El Laboratorio 4 te da **pruebas de hipótesis**: los datos emiten un veredicto. “¿Es la inflación mayor al 3 % que prometió el gobernador? Los datos dicen que sí, con $p = 0.02$.”

Pero intervalo de confianza y prueba de hipótesis no son herramientas separadas: son **dos caras de la misma moneda**. Si el IC del 95 % para μ NO contiene a μ_0 , la prueba de hipótesis rechaza $H_0 : \mu = \mu_0$ al 5 %. Esta dualidad es uno de los hilos conductores de este documento.

1.3. El arco completo: de estimar a modelar

Las cuatro preguntas cubren la primera mitad del curso. Pero hay una **quinta pregunta** que emerge cuando dejas de mirar una variable aislada y empiezas a mirar **relaciones entre variables**:

“¿Afecta X a Y ? ¿Cuánto? ¿En qué dirección?”

Esta pregunta requiere un nuevo conjunto de herramientas:

- **ANOVA** (Laboratorios 5 y 6): cuando tu X es categórica (región, grupo de edad, tipo de política) y tu Y es numérica (ingreso, inflación, tasa de homicidios), ANOVA te dice si las medias de Y difieren entre categorías de X .
- **Regresión** (Laboratorio 7): cuando tanto X como Y son numéricas (escolaridad e ingreso, publicidad y ventas), la regresión modela la relación y te da una pendiente: “por cada año adicional de escolaridad, el ingreso aumenta en promedio \$2,380 pesos.”

Y aquí está el secreto que este documento revela: **la regresión contiene a ANOVA, y ANOVA contiene a la prueba t**. No son herramientas separadas —son una escalera conceptual.




Figura 1.1: El arco de los 7 laboratorios. Las flechas indican dependencia conceptual: cada lab construye sobre los anteriores. Las líneas verticales son las transiciones entre partes.

1.4. La tabla de herencia conceptual

Cada laboratorio no existe en aislamiento. La tabla siguiente muestra, para cada par de laboratorios, qué concepto del laboratorio de la fila se **hereda y se usa** en el laboratorio de la columna. Una celda en blanco significa que no hay dependencia directa, o que la dependencia es indirecta a través de otro laboratorio.

Cuadro 1.1: Matriz de herencia conceptual entre laboratorios. Leer por filas: “El Lab X aporta al Lab Y el concepto...”

Origen	Lab 3	Lab 4	Lab 5	Lab 6–7
Lab 1	Sesgo y eficiencia de $\bar{X}$ determinan ancho del IC	Insesgamiento justifica H_0 ; consistencia garantiza convergencia	$\text{Var}(\bar{X})$ es la base de SC_Dentro; eficiencia $\rightarrow$ potencia	Gauss-Markov usa insesgamiento; R^2 es descomposición de varianza
Lab 2	MLE provee estimadores puntuales para construir IC	MLE $\rightarrow$ prueba de razón de verosimilitudes	MOM para varianzas entre/dentro grupos	MCO es MLE bajo normalidad (Lab 7)
Lab 3	—	Dualidad IC $\leftrightarrow$ prueba: IC sin $\mu_0 \Rightarrow$ rechazo	IC para diferencia de medias $\rightarrow$ ANOVA	IC para β_1 (Lab 7)
Lab 4	—	—	Prueba t para 2 grupos $\rightarrow$ prueba F para k grupos	Prueba t para β_1 (Lab 7)
Lab 5	—	—	—	ANOVA con dummies = regresión (Lab 7)

Esta tabla es una promesa. Cada capítulo de este documento **demuestra** las conexiones que esta tabla anuncia. Cuando llegues al final, podrás regresar a esta tabla y verificar que cada celda tiene sentido.

1.5. Cómo leer este documento

Ruta de lectura

Este documento está diseñado para dos modos de lectura:

Modo secuencial (recomendado la primera vez): Lee los capítulos en orden. Cada capítulo asume los anteriores. Las cajas de **sutura** (azul claro) conectan explícitamente cada laboratorio con el siguiente. Las cajas de **herencia** (gris) recuerdan qué conceptos de laboratorios anteriores se están usando.

Modo referencia: Si ya conoces el material y buscas una conexión específica, usa la tabla de herencia (13) como índice de conexiones. Cada celda referenciada tiene su desarrollo completo en la sección indicada.

Las cajas de color son consistentes en todo el documento:


- **Amarillo** = Pregunta provocadora (activa tu conocimiento previo antes de leer)
- **Verde** = Caso real con datos mexicanos
- **Azul** = La herramienta estadística explicada
- **Naranja** = Tarjeta de repaso para estudio espaciado
- **Rojo** = Pregunta de autoevaluación
- **Gris** = Conexión con los ejercicios del laboratorio

- **Violeta** = Definición formal
- **Azul claro** = Sutura entre laboratorios (nuevo en este documento)

Al final de cada capítulo encontrarás una sección de **Autoevaluación** con preguntas que verifican tu comprensión conceptual. Intenta responderlas sin consultar el texto. Si no puedes, esa sección es la que necesitas releer.

1.6. El mapa de decisiones

Antes de sumergirnos en los detalles, aquí está la pregunta que organiza todo el curso:



1.7. Lo que dicen los expertos

GAISE 2016: el estándar internacional

En 2016, la American Statistical Association publicó las directrices **GAISE** (*Guidelines for Assessment and Instruction in Statistics Education*), el estándar internacional para la enseñanza de estadística universitaria. Sus seis recomendaciones son:

1. Enseñar pensamiento y alfabetización estadística por encima de la memorización.
2. Usar datos reales siempre que sea posible.
3. **Enfatizar la comprensión conceptual por encima de la procedimental.**
4. Adoptar un enfoque de aprendizaje activo.
5. Analizar datos con tecnología, no solo a mano.
6. Evaluar para apoyar el aprendizaje, no solo para calificar.

La recomendación 3 es la que guía este documento. En las notas de clase, los teoremas definen formalmente las propiedades de cada herramienta. Aquí, nuestro objetivo es que entiendas *qué significan* esos teoremas —por qué fueron inventados, qué problema resuelven, y dónde los volverás a ver— no solo que los apliques mecánicamente.

George Cobb, en un influyente artículo para la American Statistical Association, argumentó que la enseñanza de estadística introductoria dedica demasiado tiempo a la mecánica de los procedimientos y muy poco a lo que realmente importa: la comprensión conceptual de la incertidumbre, la variación y la inferencia (Cobb 2015, *The American Statistician*, 69(4), 266–268).

El marco SLRT: tres registros, un solo concepto

Este documento toma esa crítica en serio. Cada concepto se presenta en el marco **SLRT** de delMas (2002): tres registros —idea intuitiva, procedimiento de cómputo, e interpretación en contexto mexicano. Las cajas naranja (intuición), azul (cómputo) y verde (contexto) te guían a través de estos tres registros. Chance (2002) complementa esta distinción al diferenciar entre alfabetización, razonamiento y pensamiento estadístico: la alfabetización te permite leer una tabla, el razonamiento te permite explicar por qué una diferencia es significativa, y el pensamiento te permite decidir qué herramienta aplicar en un problema nuevo. Las autoevaluaciones de cada capítulo progresan deliberadamente a través de estos tres niveles.

PPDAC: el ciclo de la investigación estadística

Wild y Pfannkuch (1999) propusieron el ciclo **PPDAC** (*Problem, Plan, Data, Analysis, Conclusions*) como modelo para la investigación estadística empírica: Problema → Plan → Datos → Análisis → Conclusiones. Aunque este documento se concentra en las etapas de Análisis y Conclusiones (los 7 laboratorios cubren el *cómo* analizar y el *cómo* concluir), las secciones de contexto mexicano al inicio de cada capítulo modelan las etapas de Problema y Plan. La estructura completa —pregunta provocadora, caso real, herramienta, autoevaluación— replica el ciclo PPDAC a escala de cada tema: primero entiendes el problema, luego ves los datos, después aprendes la herramienta, y finalmente formulas conclusiones.

Mapas conceptuales en educación científica

La idea de usar mapas conceptuales para organizar y comunicar estructuras de conocimiento no es nueva: fue desarrollada por Novak y su grupo en Cornell durante la década de 1970, basada en la psicología del aprendizaje significativo de Ausubel (Novak y Gowin 1984; Novak y Cañas 2008). Un mapa conceptual representa conceptos como nodos y las

relaciones entre ellos como arcos etiquetados, formando proposiciones del tipo “concepto A —se relaciona con— concepto B.” La tabla de herencia conceptual de este documento (Sección 1.4) y las suturas entre capítulos (cajas azul claro) son, en esencia, un mapa conceptual en formato tabular y narrativo: explicitan *qué* concepto viaja de un laboratorio a otro y *cómo* se transforma. La innovación de este documento no es inventar los mapas conceptuales, sino aplicarlos sistemáticamente a la secuencia curricular de Estadística II para hacer explícitas conexiones que suelen quedar implícitas en los planes de estudio.

Currículo integrado vs. herramientas aisladas

La literatura en educación estadística coincide en que uno de los obstáculos más persistentes para los estudiantes es la fragmentación: aprenden la prueba t , el ANOVA y la regresión como técnicas separadas, sin percibir que comparten una arquitectura común (Garfield y Ben-Zvi 2008). La tabla de herencia conceptual y las suturas de este documento son una respuesta directa a ese diagnóstico. No se trata de enseñar más contenido, sino de enseñar el mismo contenido con una estructura explícita de dependencias, de modo que el estudiante vea el curso como un sistema y no como un catálogo.

1.8. Los datos son mexicanos

Los ejemplos de este documento se basan en datos mexicanos, pero conviene precisar su naturaleza. Para que puedas evaluar el alcance de cada ejercicio, adoptamos la siguiente clasificación:

- **Datos reales:** provienen directamente de fuentes oficiales (ENOE, ENIGH, CONEVAL, SESNSP, Yahoo Finance) sin modificaciones. Se indica explícitamente la fuente, el año y la variable.
- **Datos estilizados:** contruidos a partir de patrones documentados en fuentes oficiales (ej. medias regionales, proporciones por decil), pero sin corresponder a una tabla publicada específica. Son representativos del fenómeno pero no replican un valor puntual de la fuente.
- **Datos contruidos:** creados con fines pedagógicos para ilustrar un procedimiento de cálculo. Son numéricamente consistentes pero no pretenden representar una medición real (ej. el ejemplo con 5 estados en el Lab 7, o los tiempos de espera en ventanilla bancaria del Lab 2).
- **Vectores hard-codeados:** datos incrustados directamente en el código R del documento, sin referencia a un archivo externo. Permiten ejecutar el ejemplo sin depender de archivos locales.

Esta clasificación es importante: un intervalo de confianza sobre la pobreza poblacional usando la ENIGH está calibrado por un diseño muestral complejo (estratos, conglomerados, ponderadores) que las fórmulas i.i.d. de este curso no modelan. Los ejemplos con datos de encuestas oficiales ilustran la *lógica* del procedimiento; la inferencia formal requeriría incorporar el diseño muestral (algo que se cubre en cursos avanzados de muestreo).

Las fuentes utilizadas son:

- **INEGI**: Censo de Población, ENOE (Encuesta Nacional de Ocupación y Empleo), ENIGH (Encuesta Nacional de Ingresos y Gastos de los Hogares)
- **CONEVAL**: Medición de la Pobreza Multidimensional
- **Banco de México**: Series de inflación y tipo de cambio
- **SESNSP**: Incidencia delictiva por entidad federativa
- **Yahoo Finance**: Datos históricos IPC México y S&P 500

Esto no es decorativo. La estadística existe para responder preguntas reales con datos reales. Cada herramienta que aprendas en este curso tiene una aplicación directa a problemas que enfrentan el Banco de México, la SHCP, el CONEVAL, el IMSS, y cualquier institución que tome decisiones basadas en evidencia.

1.9. La ruta técnica mínima (si vas con prisa)

Ruta de lectura

El núcleo operativo de este documento son:

- Las **tarjetas de repaso** al final de cada sección (naranja)
- Las **preguntas de autoevaluación** al final de cada capítulo (rojo)
- Las cajas de **sutura** entre capítulos (azul claro) —si solo quieres ver cómo se conectan los labs
- El **epílogo** con el mapa de decisiones completo

Si tu prioridad inmediata es resolver los ejercicios de un laboratorio específico, ve directo a ese capítulo. Las suturas y el resto del documento son para cuando quieras entender *por qué* ese laboratorio existe en el contexto del curso completo.

Tarjeta de repaso

Las 4 preguntas en una línea cada una:

1. **Sesgo**: ¿En promedio acierto? (Lab 1)
2. **Eficiencia**: ¿Cuánto fluctúo? (Lab 1)
3. **Construcción**: ¿Cómo fabrico un buen estimador? (Lab 2)
4. **Incertidumbre**: ¿Qué tan seguro estoy? (Labs 3–4)

Y la pregunta que las trasciende: **¿Cómo se relacionan las variables?** (Labs 5–7)

Parte I

Los cimientos: del “qué” al “cómo”

2. Propiedades de los estimadores: el control de calidad

Antes de leer: hazte esta pregunta

Si el Banco de México te pide estimar la inflación mensual y tres analistas te dan estimaciones diferentes, ¿cómo decides cuál es la mejor? ¿Basta con que “suene razonable” o necesitas criterios formales para evaluar cada estimador? Y si ninguno de los tres es perfecto, ¿puedes construir uno mejor?

2.1. La fábrica de estimadores: por qué necesitas un control de calidad

2.1.1. La analogía que organiza todo el laboratorio

Imagina que eres economista del Banco de México y tu jefe te pide estimar la inflación mensual. Tienes tres analistas que te dan estimaciones diferentes usando métodos distintos. Cuatro preguntas naturales surgen antes de elegir cuál reportar:

1. **¿Alguno apunta al valor correcto *en promedio*?** Si repitieras el procedimiento de estimación muchas veces, ¿el centro de gravedad de las estimaciones coincidiría con la inflación real? → **Sesgo** (Sección 2.2).
2. **¿Cuál es el más preciso?** Entre los que apuntan bien, ¿cuál fluctúa menos de una estimación a otra? → **Eficiencia** (Sección 2.3).
3. **Si consigo más datos, ¿las estimaciones convergen al valor real?** ¿Mejorarían mis estimaciones con el tiempo o el error es incorregible? → **Consistencia** (Sección 2.4).
4. **¿Puedo comprimir los datos sin perder información?** Si el INEGI tiene 130 millones de registros, ¿puedo resumirlos en dos números sin sacrificar nada relevante para la estimación? → **Suficiencia** (Sección 2.5).

Estas cuatro preguntas son los **cuatro pilares del control de calidad de los estimadores**. No son abstracciones matemáticas: son los criterios que usarás para evaluar *todo* estimador que encuentres en tu carrera, desde OLS en econometría hasta los parámetros de una red neuronal.

2.1.2. La conexión con tu plan de estudios

En econometría, estas preguntas reaparecen constantemente:

- El teorema de **Gauss-Markov** dice que OLS es BLUE (*Best Linear Unbiased Estimator*): “insesgado” es del Lab 1, Sección 2.2; “best” (mínima varianza) es del Lab 1, Sección 2.3. La demostración de Gauss-Markov usa la misma lógica de tu Ejercicio 2.1.
- Cuando en Econometría I (5to semestre) leas que “con n grande, OLS es consistente”, estás aplicando la Sección 2.4.
- Cuando uses un **estadístico suficiente** ($\bar{X}$, S^2) en vez de los datos originales para estimar una media, estás aplicando la Sección 2.5.
- En Microeconometría (7mo semestre), las propiedades asintóticas del MLE (consistencia, eficiencia, normalidad) que introduces en el Lab 2 dependen de que entiendas primero qué significan esos conceptos —y eso es el Lab 1.

La herramienta estadística

El lugar del Lab 1 en el arco del curso.

El Lab 1 es el **control de calidad** de los estimadores. Su función no es fabricar estimadores (eso es el Lab 2, con MLE y Momentos) ni cuantificar la incertidumbre (eso es el Lab 3, con intervalos de confianza). Su función es darte los criterios para responder: “¿este estimador es bueno?”

La distinción es crucial:

- **Lab 1:** Te dan un estimador y tú lo evalúas. Es como recibir un coche terminado y verificar que cumple normas de seguridad.
- **Lab 2:** Tú fabricas el estimador. Es como aprender a ensamblar el coche.
- **Lab 3:** Tú cuantificas cuánto confiar en el estimador. Es como calcular el margen de error del velocímetro.

Los tres se necesitan mutuamente. Sin el Lab 1, no sabrías si el estimador que fabricaste en el Lab 2 es bueno. Sin el Lab 2, no tendrías un estimador que evaluar. Sin el Lab 3, tendrías una estimación puntual sin saber qué tan confiable es.

2.1.3. Dos conceptos previos que necesitas dominar

Antes de entrar a las cuatro propiedades, dos conceptos de Estadística I son indispensables. Si no los tienes frescos, esta es tu oportunidad de recuperarlos.

Definición: Valor Esperado (Esperanza)

Definición formal (Notas de clase, Definición 4.1; Casella y Berger 2002, §2.2).
Para una variable aleatoria continua X con densidad $f(x)$:

$$E[X] = \int_{-\infty}^{\infty} x f(x) dx$$

Para una variable discreta: $E[X] = \sum_x x P(X = x)$.

En español: El valor esperado es el “centro de gravedad” de la distribución. Si pudieras repetir el experimento infinitas veces, $E[X]$ es el promedio al que convergerían tus resultados. No es un valor que *tiene* que ocurrir; es un promedio hipotético sobre infinitas repeticiones.

Checkpoint ✓ ¿ $E[X]$ es un número fijo o una variable aleatoria? (Es un número fijo —una constante que depende de la distribución, no de la muestra.)

Definición: Estimador vs. Estimación

Definición formal (Notas de clase, Definición 7.1; Casella y Berger 2002, §7.1). Un **estimador** $\hat{\theta} = g(X_1, \dots, X_n)$ es una función de las variables aleatorias de la muestra — es decir, es una **variable aleatoria**. Una **estimación** $\hat{\theta}(\mathbf{x}) = g(x_1, \dots, x_n)$ es el número que obtienes al evaluar esa función con datos concretos.

En español: El estimador es la “receta”; la estimación es el “platillo” que resulta con ingredientes específicos. Antes de tomar la muestra, $\bar{X}$ es una variable aleatoria (no sabes qué valor tendrá). Después de observar $x_1 = 3, x_2 = 5, x_3 = 4$, la estimación es $\bar{x} = 4$ —un número fijo.

La confusión más común del Lab 1: ¿ $\bar{X}$ es un número o una variable aleatoria? Antes de tomar la muestra, $\bar{X} = \frac{1}{n} \sum X_i$ es una variable aleatoria —tiene una distribución, una esperanza, una varianza. Después de observar datos concretos, la estimación $\bar{x}$ es un número fijo. **Toda la Sección 2.2 opera en el mundo de “antes”:** cuando escribimos $E[\hat{\theta}]$, preguntamos qué haría el estimador *en promedio sobre todas las muestras posibles*, no qué valor obtuviste con tu muestra particular.

✓ Verifica tu comprensión

Antes de continuar, verifica:

- ¿Puedes explicar la diferencia entre estimador y estimación con tus propias palabras?
- ¿Entiendes por qué $E[\bar{X}] = \mu$ no significa que $\bar{x} = \mu$ en tu muestra particular?

Si no puedes responder ambas, relee el **definición** de arriba. Es la base sobre la que se construye todo el laboratorio.

2.2. Sesgo (Insesgamiento): ¿tu estimador apunta al valor correcto?

Antes de leer: hazte esta pregunta

En 1936, la revista *Literary Digest* realizó la encuesta electoral más grande de la historia: 2.4 millones de respuestas. Predijo que Alf Landon derrotaría a Roosevelt por un margen aplastante. Roosevelt ganó con el 62 % de los votos. **¿Cómo puede una encuesta con millones de datos estar tan equivocada?**

2.2.1. El caso que estremeció a la estadística

Caso Real: El desastre del Literary Digest (1936)

La revista *Literary Digest* envió 10 millones de cuestionarios usando listas de suscriptores de revistas, registros de teléfonos y clubes de automóviles. En plena Gran Depresión, estas listas sobrerrepresentaban a personas de alto ingreso —que votaban Republicano—. El estimador de la proporción de votos tenía un **sesgo sistemático**: no importaba cuántas respuestas acumularan, cada nueva respuesta venía de la misma población sesgada.

Mientras tanto, George Gallup usó una muestra de solo 50,000 personas, pero diseñada para ser representativa. Su predicción acertó. La diferencia no fue el tamaño de muestra (n), sino la **propiedad del estimador**: Gallup usó un estimador aproximadamente insesgado; *Literary Digest* usó uno sesgado.

La lección para el Lab 1: Un estimador puede tener $n = 2,400,000$ y seguir siendo malo si $E[\hat{\theta}] \neq \theta$. El insesgamiento no se “cura” con más datos —se necesita un estimador que apunte al valor correcto *por construcción*.

Una precisión conceptual: en rigor, el fallo del *Literary Digest* fue un **sesgo de selección** —un error del marco muestral: *a quién se encuesta*—. Eso no es idéntico al **sesgo estadístico** $E[\hat{\theta}] - \theta$, que es una propiedad matemática del estimador *bajo un modelo de muestreo dado*. La relación es de causa a efecto: un marco no representativo induce $E[\hat{\theta}] \neq \theta$. Bajo muestreo aleatorio, $\bar{X}$ es insesgado; es el marco defectuoso —no la fórmula— lo que introduce el sesgo.

Fuente: Bryson, Maurice C. (1976). “The Literary Digest Poll: Making Statistics History”. *The American Statistician*, 30(4), 184–185.

2.2.2. La herramienta: definición y procedimiento

La herramienta estadística

Sesgo e insesgamiento. La primera propiedad que verificamos de un estimador.

Si $\hat{\theta}$ es un estimador del parámetro θ , su **sesgo** es la diferencia entre lo que el estimador “apunta” en promedio y el valor real:

$$\text{Sesgo}(\hat{\theta}) = E[\hat{\theta}] - \theta$$

Si $\text{Sesgo}(\hat{\theta}) = 0$, el estimador es **insesgado**: $E[\hat{\theta}] = \theta$.

Intuición: Piensa en un arquero que tira 100 flechas. Si el *centro de masa* de las flechas está en el blanco, el arquero es insesgado —aunque las flechas estén dispersas (eso sería varianza alta, no sesgo)—. Si el centro de masa está 5 cm a la derecha del blanco, el sesgo es 5 cm, sin importar cuántas flechas tire.

El test de insesgamiento: Para verificar si $\hat{\theta}$ es insesgado, el procedimiento siempre es:

1. Calcular $E[\hat{\theta}]$ usando la definición de esperanza y las propiedades de la distribución.
2. Verificar si $E[\hat{\theta}] = \theta$ para *todo* valor posible de θ .
3. Si la igualdad solo se cumple para valores específicos de θ (como $\theta = 0,5$), el estimador **no** es insesgado.

Ejemplo del Lab 1 (Ejercicio 1.3): Para Bernoulli, con $X = \sum_{i=1}^n X_i$ el número de éxitos (de modo que $E[X] = n\theta$) y $\hat{\theta} = (X + 1)/(n + 2)$:

$$E[\hat{\theta}] = \frac{E[X] + 1}{n + 2} = \frac{n\theta + 1}{n + 2} \neq \theta \quad (\text{excepto si } \theta = 0,5)$$

Es **sesgado**. El sesgo es $\frac{n\theta+1}{n+2} - \theta = \frac{1-2\theta}{n+2}$. Nota que cuando $n \rightarrow \infty$, el sesgo $\rightarrow 0$: es **asintóticamente insesgado**, lo cual será relevante en la Sección 2.4.

Definición: Sesgo de un estimador

Definición formal (Notas de clase, Definición 7.1; Wackerly et al. 2015, Sec. 8.2). El **sesgo** de un estimador $\hat{\theta}$ del parámetro θ es:

$$B(\hat{\theta}) = E[\hat{\theta}] - \theta$$

En español: El sesgo mide cuánto se equivoca tu estimador “en promedio”. Si repitieras el experimento infinitas veces y promediarás todas las estimaciones, ¿cuánto se desviarían del valor real?

Checkpoint ✓ Si $E[\hat{\theta}] = \theta + 3$, ¿es insesgado? (No: el sesgo es +3. Siempre sobreestima por 3 unidades.)

Definición: Estimador insesgado

Definición formal (Notas de clase, Definición 7.6; Wackerly et al. 2015, Sec. 8.2). Un estimador $\hat{\theta}$ es **insesgado** para θ si $E[\hat{\theta}] = \theta$ para **todo** valor de θ en el espacio paramétrico.

En español: “Apunta al valor correcto en promedio, sin importar cuál sea ese valor.” La clave es el “para todo θ ”: si solo funciona cuando $\theta = 5$, no es insesgado.

Checkpoint ✓ ¿Todo estimador insesgado es “bueno”? (No necesariamente: $\hat{\mu} = X_1$ —tomar solo la primera observación— es insesgado para μ , pero tiene varianza enorme. Un buen estimador necesita más que insesgamiento.)

Definición: Error Cuadrático Medio (ECM/MSE)

Definición formal (Notas de clase, Definición 7.2; Wackerly et al. 2015, Sec. 8.3).

$$\text{MSE}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + [\text{Sesgo}(\hat{\theta})]^2$$

En español: El MSE combina dos fuentes de error: la dispersión (varianza) y la desviación sistemática (sesgo al cuadrado). Un estimador puede tener sesgo pequeño pero varianza enorme, o viceversa. El MSE los unifica en una sola métrica.

Checkpoint ✓ Si un estimador es insesgado, ¿ $\text{MSE} = \text{Var}$? (Sí: si $\text{Sesgo} = 0$, entonces $\text{MSE} = \text{Var} + 0^2 = \text{Var}$.)

2.2.3. El mito del insesgamiento

Existe una creencia común —y equivocada— de que “insesgado siempre es mejor”. La realidad es más matizada.

Imagina dos tiradores. El **Tirador A** apunta al centro del blanco (insesgado), pero sus disparos están muy dispersos. El **Tirador B** apunta 2 cm a la derecha (sesgado), pero agrupa todos sus tiros en un radio pequeño. ¿A quién prefieres? Depende: si te importa que *algún* disparo dé en el centro, tal vez A. Pero si te importa que en promedio los disparos estén más cerca del centro, B gana —porque su error total ($\text{sesgo}^2 + \text{varianza}$) es menor.

Eso es exactamente lo que mide el MSE. En Econometría II (6to semestre), verás que Ridge y Lasso introducen sesgo *a propósito* para reducir la varianza —y el resultado es un MSE menor. El principio nace aquí.

Ejemplo trabajado: Demostración de insesgamiento para un estimador combinado (Ejercicio 2.1, parte i)

Contexto: Quieres estimar el ingreso promedio de los hogares mexicanos y tienes dos encuestas: la ENIGH (precisa pero costosa, varianza pequeña) y una encuesta rápida por teléfono (barata pero ruidosa, varianza grande). ¿**Cómo combinarlas?**

El estimador propuesto: $\hat{\mu} = \omega \bar{X}_1 + (1 - \omega) \bar{X}_2$, donde $0 \leq \omega \leq 1$, $\bar{X}_1$ y $\bar{X}_2$ son

las medias de dos muestras independientes de tamaño n de poblaciones normales con la misma media μ pero varianzas σ_1^2 y σ_2^2 respectivamente.

Paso 1: Aplicar la esperanza:

$$E[\hat{\mu}] = E[\omega \bar{X}_1 + (1 - \omega) \bar{X}_2]$$

Paso 2: Linealidad de la esperanza (las constantes ω y $1 - \omega$ salen):

$$E[\hat{\mu}] = \omega E[\bar{X}_1] + (1 - \omega) E[\bar{X}_2]$$

Paso 3: Para cualquier muestra aleatoria, $E[\bar{X}] = \mu$ (Teorema 4.6 de las notas):

$$E[\hat{\mu}] = \omega(\mu) + (1 - \omega)(\mu)$$

Paso 4: Simplificar:

$$E[\hat{\mu}] = \omega\mu + \mu - \omega\mu = \mu$$

Conclusión: $E[\hat{\mu}] = \mu$ para *todo* valor de μ , sin importar la elección de ω . **El estimador es insesgado para cualquier ponderación.**

Interpretación económica: Puedes combinar las dos encuestas como quieras (50-50, 80-20, 30-70) y el estimador seguirá apuntando al ingreso promedio real. Pero eso no significa que *todas* las combinaciones sean igualmente buenas. La cuestión de *cuál* ponderación es óptima —la que minimiza la varianza— es el corazón de la eficiencia y se resuelve en la Sección 2.3.

Tarjeta de repaso

Frente: ¿Qué es el sesgo de un estimador?

Reverso: $B(\hat{\theta}) = E[\hat{\theta}] - \theta$. Es la diferencia entre lo que el estimador “apunta en promedio” y el parámetro real. Si $B = 0$, es insesgado.

Frente: ¿Por qué la encuesta del *Literary Digest* (1936) falló con 2.4 millones de datos?

Reverso: Porque el estimador era sesgado: la muestra sobrerrepresentaba personas de alto ingreso. El sesgo no se corrige con más datos de la misma población sesgada. n grande no salva a un estimador que apunta al lugar equivocado.

Frente: ¿Insesgado = bueno?

Reverso: No necesariamente. X_1 (primera observación) es insesgado para μ pero ignora $n - 1$ datos. El MSE combina sesgo y varianza: $MSE = \text{Sesgo}^2 + \text{Var}$. A veces un estimador sesgado con varianza mucho menor tiene mejor MSE.

Pregunta de autoevaluación

Un economista tiene dos estimadores de la tasa de inflación π . El estimador A tiene $E[\hat{\pi}_A] = \pi + 2$ y $\text{Var}(\hat{\pi}_A) = 1$. El estimador B tiene $E[\hat{\pi}_B] = \pi$ y $\text{Var}(\hat{\pi}_B) = 10$.

a) A es mejor porque tiene menor varianza.

- b) B es mejor porque es insesgado, y los estimadores insesgados siempre son preferibles.
- c) Depende: $\text{MSE}(A) = 1 + 4 = 5$ y $\text{MSE}(B) = 10 + 0 = 10$. Por MSE, A es mejor a pesar de ser sesgado.
- d) No se pueden comparar porque uno es sesgado y otro no.

Respuesta: c). $\text{MSE}(A) = \text{Var}(A) + \text{Sesgo}^2(A) = 1 + 4 = 5$. $\text{MSE}(B) = \text{Var}(B) + 0 = 10$. El estimador sesgado tiene *menor* error cuadrático medio. Si elegiste (b), caíste en el mito de que insesgado siempre es mejor —el MSE muestra que a veces un poco de sesgo con mucha menos varianza es un mejor tradeoff. Este es el principio detrás de la regularización (Ridge, Lasso) en econometría y ML.

Conexión con los ejercicios

Resuelve los **Ejercicios 1.1–1.6** (Sesgo e insesgamiento). En cada ejercicio, el procedimiento es el mismo: (1) calcular $E[\hat{\theta}]$, (2) verificar si $= \theta$. Presta especial atención al Ej. 1.1 —la condición $\sum a_i = 1$ es la base de todo estimador lineal insesgado, incluyendo OLS en econometría.

2.3. Eficiencia: entre estimadores insesgados, ¿cuál es más preciso?

Antes de leer: hazte esta pregunta

Consensus Economics publica pronósticos macroeconómicos combinando las predicciones de más de 30 instituciones (FMI, Banco Mundial, bancos centrales, firmas privadas). Cada institución produce un pronóstico insesgado del PIB. **¿Debes promediar todos con el mismo peso, o dar más peso a los más precisos?**

2.3.1. El caso que muestra el poder de ponderar bien

Caso Real: Combinación óptima de pronósticos (Consensus Economics)

Consensus Economics recopila pronósticos del FMI, Banco de México, Goldman Sachs, y docenas de otras instituciones. Cada pronóstico es un estimador aproximadamente insesgado del PIB real. Pero unos son más precisos (menor varianza) que otros.

Timmermann (2006) demostró que la combinación óptima pondera cada pronóstico de forma inversamente proporcional a su varianza: se da más peso a los más precisos.

La fórmula resultante es *exactamente* la del Ejercicio 2.1:

$$\hat{\mu} = \omega \bar{X}_1 + (1 - \omega) \bar{X}_2, \quad \omega^* = \frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2}$$

Si $\sigma_1^2 = \sigma_2^2$, el peso óptimo es $\omega^* = 0,5$ (promedio simple). Si $\sigma_1^2 \ll \sigma_2^2$, casi todo el peso va al primer pronóstico.

Supuesto clave: esta ponderación óptima supone que ambos pronósticos son *insesgados* y que sus errores **no están correlacionados**. Con errores correlacionados, el peso óptimo depende de la matriz de covarianzas completa.

La conexión: Esto no es un truco ad hoc. Es la aplicación directa de un principio estadístico: entre estimadores insesgados, queremos el de menor varianza. Buscamos el **más eficiente**.

Fuente: Timmermann, Allan (2006). “Forecast Combinations”. En *Handbook of Economic Forecasting*, vol. 1, eds. G. Elliott, C.W.J. Granger y A. Timmermann, 135–196. Amsterdam: Elsevier.

2.3.2. La herramienta: varianza, eficiencia relativa y la cota de Cramér-Rao

La herramienta estadística

Eficiencia y la Cota de Cramér-Rao.

Si dos estimadores son insesgados, el más **eficiente** es el que tiene menor varianza. Pero ¿cuánta varianza es “la mínima posible”? La **Cota de Cramér-Rao (CRLB)** establece un piso:

$$\text{Var}(\hat{\theta}) \geq \frac{1}{nI(\theta)} = \text{CRLB}$$

donde $I(\theta)$ es la **Información de Fisher**:

$$I(\theta) = -\text{E} \left[\frac{\partial^2 \ln f(X|\theta)}{\partial \theta^2} \right] = \text{E} \left[\left(\frac{\partial \ln f(X|\theta)}{\partial \theta} \right)^2 \right]$$

Interpretación: La Información de Fisher mide cuánta “señal” sobre θ contiene cada observación. Más información $\Rightarrow$ menor varianza mínima posible $\Rightarrow$ estimadores más precisos con los mismos datos.

Ejemplo del Lab 1 (Ejercicio 2.2, Exponencial): Para $f(x|\beta) = \frac{1}{\beta} e^{-x/\beta}$ (aquí β es el parámetro de *escala*, $\text{E}[X] = \beta$):

- $I(\beta) = 1/\beta^2$, así que $\text{CRLB} = \beta^2/n$.
- $\text{Var}(\bar{X}) = \beta^2/n = \text{CRLB}$ exactamente.
- $\bar{X}$ **alcanza la cota**: es el estimador insesgado de mínima varianza posible.
- En contraste, X_1 tiene varianza β^2 —igual a la CRLB multiplicada por n . Desperdicia la información de las otras $n - 1$ observaciones.

Importante: ¿qué significa **NO** alcanzar la CRLB? Si un estimador insesgado no alcanza la CRLB, **no implica que exista uno mejor**. No alcanzar la cota mantiene la pregunta de optimalidad abierta: la CRLB puede ser simplemente inalcanzable para todo estimador insesgado de esa familia paramétrica, y aun así el tuyo podría ser el MVUE. Alcanzarla es **suficiente** para ser MVUE; no alcanzarla **no** es evidencia de que el estimador sea subóptimo.

Definición: Eficiencia relativa

Definición formal (Notas de clase, Definición 7.7; Wackerly et al. 2015, Sec. 8.3). Sean $\hat{\theta}_1$ y $\hat{\theta}_2$ estimadores insesgados de θ . La **eficiencia relativa** de $\hat{\theta}_1$ con respecto a $\hat{\theta}_2$ es:

$$\text{eff}(\hat{\theta}_1, \hat{\theta}_2) = \frac{\text{Var}(\hat{\theta}_2)}{\text{Var}(\hat{\theta}_1)}$$

Si $\text{eff} > 1$, $\hat{\theta}_1$ es más eficiente. Si $\text{eff} < 1$, $\hat{\theta}_2$ es más eficiente.

Checkpoint ✓ Si $\text{eff}(\hat{\theta}_1, \hat{\theta}_2) = 0,8$, ¿cuál es más eficiente? ($\hat{\theta}_2$: su varianza está en el numerador y es menor, lo cual hace el cociente < 1 .)

Definición: Cota de Cramér-Rao (CRLB)

Definición formal (Notas de clase, Teorema 7.2; Wackerly et al. 2015, Sec. 8.4). Sea $X_1, \dots, X_n$ una muestra aleatoria de $f(x|\theta)$ que satisface las condiciones de regularidad. Para cualquier estimador insesgado $\hat{\theta}$ de θ :

$$\text{Var}(\hat{\theta}) \geq \frac{1}{nI(\theta)}$$

Condiciones de regularidad: (i) La familia de densidades tiene soporte común (no depende de θ). (ii) Se puede intercambiar derivada e integral.

En español: Hay un límite físico a la precisión de cualquier estimador insesgado, igual que hay un límite a cuánto puedes comprimir un archivo (comunicación: Shannon). Si un estimador alcanza esa cota, es imposible hacerlo mejor sin renunciar al insesgamiento.

Checkpoint ✓ ¿La CRLB aplica a la distribución Uniforme(0, θ)? (No: el soporte $[0, \theta]$ depende de θ , violando la condición de regularidad.)

Definición: MVUE (Minimum Variance Unbiased Estimator)

Definición formal (Notas de clase, Definición 7.11; Wackerly et al. 2015, Sec. 8.4). Un estimador $\hat{\theta}$ es **MVUE** si:

1. Es insesgado: $E[\hat{\theta}] = \theta$.
2. Tiene la menor varianza posible entre todos los estimadores insesgados.

Si un estimador insesgado alcanza la CRLB, es MVUE. Pero un estimador puede

ser MVUE sin alcanzar la CRLB —basta con que ningún otro estimador insesgado tenga varianza menor, incluso si la CRLB es inalcanzable.

Checkpoint ✓ ¿Un estimador puede ser insesgado pero NO MVUE? (Sí: X_1 es insesgado para μ , pero $\bar{X}$ tiene menor varianza. X_1 es insesgado pero no MVUE.)

Ejemplo trabajado: Minimización de la varianza y peso óptimo (Ejercicio 2.1, parte ii)

Contexto: Retomamos el estimador combinado $\hat{\mu} = \omega \bar{X}_1 + (1 - \omega) \bar{X}_2$ de la Sección 2.2. Ya sabemos que es insesgado para cualquier ω . Ahora buscamos el ω que minimiza su varianza.

Paso 1: Construir la varianza del estimador:

$$\text{Var}(\hat{\mu}) = \text{Var}(\omega \bar{X}_1 + (1 - \omega) \bar{X}_2)$$

Paso 2: Como las muestras son independientes, las varianzas se suman y las constantes salen al cuadrado:

$$\text{Var}(\hat{\mu}) = \omega^2 \text{Var}(\bar{X}_1) + (1 - \omega)^2 \text{Var}(\bar{X}_2)$$

Paso 3: Sustituir $\text{Var}(\bar{X}) = \sigma^2/n$:

$$V(\omega) = \omega^2 \left(\frac{\sigma_1^2}{n} \right) + (1 - \omega)^2 \left(\frac{\sigma_2^2}{n} \right)$$

Paso 4: Derivar respecto a ω e igualar a cero:

$$\frac{dV}{d\omega} = \frac{2\omega\sigma_1^2}{n} - \frac{2(1 - \omega)\sigma_2^2}{n} = 0$$

Paso 5: Resolver (multiplicar por $n/2$, agrupar, despejar):

$$\begin{aligned}\omega\sigma_1^2 &= (1 - \omega)\sigma_2^2 \\ \omega\sigma_1^2 &= \sigma_2^2 - \omega\sigma_2^2 \\ \omega(\sigma_1^2 + \sigma_2^2) &= \sigma_2^2\end{aligned}$$

$$\boxed{\omega^* = \frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2}}$$

Conclusión: El peso óptimo es inversamente proporcional a la varianza: damos más peso a la fuente más precisa. Si $\sigma_1^2 = 4$ y $\sigma_2^2 = 9$, entonces $\omega^* = 9/13 \approx 0,692$ —la primera encuesta recibe $\approx 69\%$ del peso. Con $n = 20$ observaciones en cada encuesta, $V(\omega^*) = \frac{2,769}{20} \approx 0,1385$, mientras que con pesos iguales $V(0,5) = \frac{3,25}{20} = 0,1625$: una mejora del 14.8%.

Interpretación económica: La lógica es la misma que la diversificación de portafolios de Markowitz (1952). No pones el mismo dinero en todos los activos; pones más donde el riesgo (varianza) es menor. Aquí no inviertes dinero, inviertes *confianza*: más peso donde la señal es más clara.

Nota didáctica

La economía mexicana en este ejemplo. La ENIGH (Encuesta Nacional de Ingresos y Gastos de los Hogares) del INEGI tiene un diseño muestral riguroso que produce estimaciones con varianza relativamente baja, pero es costosa y se levanta cada dos años. Una encuesta telefónica rápida puede hacerse mensualmente pero con mayor varianza. El Ejercicio 2.1 te da la fórmula para combinarlas óptimamente: más peso a la ENIGH, menos a la telefónica — exactamente la lógica que usa el CONEVAL para sus estimaciones de pobreza multidimensional.

Tarjeta de repaso

Frente: ¿Qué es la Cota de Cramér-Rao?

Reverso: $\text{Var}(\hat{\theta}) \geq 1/[nI(\theta)]$. Es una *cota inferior* para la varianza de cualquier estimador insesgado. Si un estimador insesgado la alcanza, es MVUE. Pero **no alcanzarla no implica que exista uno mejor**: la cota puede ser inalcanzable para todo estimador insesgado. No alcanzarla deja la pregunta de optimalidad abierta.

Frente: ¿La CRLB aplica siempre?

Reverso: No. Requiere condiciones de regularidad: el soporte no puede depender de θ . Si depende (como en la Uniforme(0, θ)), la CRLB no aplica —lo cual no significa que el estimador sea malo, sino que necesitas otros criterios para evaluarlo.

Frente: ¿Qué es la eficiencia relativa?

Reverso: $\text{eff}(\hat{\theta}_1, \hat{\theta}_2) = \text{Var}(\hat{\theta}_2)/\text{Var}(\hat{\theta}_1)$. Si > 1 , $\hat{\theta}_1$ es más eficiente (menor varianza). Compara la precisión de dos estimadores insesgados.

Pregunta de autoevaluación

Para una distribución Exponencial con $f(x|\beta) = \frac{1}{\beta}e^{-x/\beta}$, comparas $\hat{\theta}_1 = X_1$ (primera observación) y $\hat{\theta}_2 = \bar{X}$ (media muestral) con $n = 10$.

- Ambos son igualmente eficientes porque estiman el mismo parámetro.
- $\hat{\theta}_2$ es 10 veces más eficiente: $\text{eff}(\hat{\theta}_2, \hat{\theta}_1) = \text{Var}(X_1)/\text{Var}(\bar{X}) = \beta^2/(\beta^2/10) = 10$.
- $\hat{\theta}_1$ es más eficiente porque usa menos datos y por tanto tiene menos “ruido”.
- No se puede comparar la eficiencia porque la Exponencial no satisface la CRLB.

Respuesta: b). $\text{Var}(\hat{\theta}_1) = \beta^2$ y $\text{Var}(\hat{\theta}_2) = \beta^2/10$. La eficiencia relativa es 10: $\bar{X}$ es 10 veces más precisa que X_1 . Además, $\text{Var}(\bar{X}) = \beta^2/n = \text{CRLB}$: la media muestral *alcanza* la cota. Si elegiste (d), la Exponencial *sí* satisface las condiciones de regularidad.

Conexión con los ejercicios

Resuelve los **Ejercicios 2.1–2.3** (Eficiencia). En el Ejercicio 2.1, encontrarás la ponderación óptima —la misma lógica que usa Consensus Economics—. En el Ejercicio 2.2, verificarás que $\bar{X}$ alcanza la CRLB para la Exponencial. En el Ejercicio 2.3, descubrirás que la CRLB **no aplica** cuando el soporte depende de θ .

2.4. Consistencia: ¿tu estimador mejora con más datos?

Alerta de notación: la Exponencial cambia de parametrización aquí. En la Sección 2.3 la Exponencial se escribió por *escala*: $f(x|\beta) = \frac{1}{\beta}e^{-x/\beta}$ con $E[X] = \beta$, y ahí $\bar{X}$ es MVUE para β . De esta sección en adelante se escribe por *tasa*: $f(x|\lambda) = \lambda e^{-\lambda x}$ con $E[X] = 1/\lambda$, y entonces $\bar{X} \xrightarrow{P} 1/\lambda \neq \lambda$, de modo que $\bar{X}$ *no* es consistente para λ . **No es contradicción:** el símbolo designa cantidades distintas (escala vs. tasa). La doble convención replica la de los ejercicios.

Antes de leer: hazte esta pregunta

Las encuestas electorales semanas antes de una elección son imprecisas. Conforme se acerca el día de la votación, se hacen más encuestas con muestras más grandes, y los estimadores convergen al resultado real. **¿Es esta convergencia automática, o depende de qué estimador uses?**

2.4.1. El caso: no todo estimador converge

Caso Real: Convergencia de encuestas electorales (Silver 2012)

Nate Silver documenta en *The Signal and the Noise* cómo los promedios de encuestas convergen al resultado real conforme se acerca la elección. El “embudo” de predicciones se estrecha: la incertidumbre disminuye sistemáticamente.

Pero no todos los estimadores convergen. En el Ejercicio 3.1, verás tres estimadores de la tasa λ de una Exponencial:

- $\hat{\theta}_1 = \bar{X}$: converge a $1/\lambda$, no a λ . **No es consistente.**
- $\hat{\theta}_2 = X_1$: su varianza no cambia con n . **No es consistente.**
- $\hat{\theta}_3 = \sum X_i$: su esperanza diverge a ∞ . **No es consistente.**

Ninguno de los tres candidatos propuestos funciona. El estimador consistente correcto sería $1/\bar{X}$, que converge a $1/(1/\lambda) = \lambda$ por la LGN y el Teorema del Mapeo Continuo.

La lección: La convergencia con más datos no es gratis. Una vía *suficiente* (la que usarás en los ejercicios) es que (1) el estimador sea asintóticamente insesgado y (2) su varianza tienda a cero; la definición formal de consistencia es la convergencia

en probabilidad.

2.4.2. La herramienta: convergencia en probabilidad

La herramienta estadística

Consistencia. La propiedad que conecta muestras finitas con el comportamiento asintótico.

Un estimador $\hat{\theta}_n$ es **consistente** para θ si, para todo $\varepsilon > 0$:

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) = 0$$

Esto se escribe $\hat{\theta}_n \xrightarrow{P} \theta$ (convergencia en probabilidad).

Condición suficiente (Teorema 7.4 de las notas): bajo momentos finitos, un estimador es consistente si:

1. $\lim_{n \rightarrow \infty} E[\hat{\theta}_n] = \theta$ (asintóticamente insesgado).
2. $\lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0$ (la varianza se colapsa).

Importante: que la varianza $\rightarrow 0$ es una condición **suficiente, no necesaria** para la consistencia. La definición formal es la convergencia en probabilidad. La condición de varianza decreciente es simplemente la más práctica de verificar en este curso. Existen estimadores consistentes cuya varianza no tiende a cero (aunque son poco comunes en modelos paramétricos estándar).

¿Por qué esta condición funciona? Si el estimador “apunta bien” (sesgo $\rightarrow 0$) y “se concentra cada vez más” (varianza $\rightarrow 0$), la masa de probabilidad se acumula alrededor del valor real. Es la formalización de “con más datos, la estimación converge”.

$\bar{X}$ es el “estimador modelo”: $E[\bar{X}] = \mu$ (insesgado por siempre) y $\text{Var}(\bar{X}) = \sigma^2/n \rightarrow 0$. Es consistente para μ por la Ley de los Grandes Números (LGN).

Definición: Consistencia

Definición formal (Notas de clase, Definición 7.14; Wackerly et al. 2015, Sec. 8.5).

Un estimador $\hat{\theta}_n$ es **consistente** para θ si $\hat{\theta}_n \xrightarrow{P} \theta$ cuando $n \rightarrow \infty$:

$$\forall \varepsilon > 0 : \quad \lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) = 0$$

En español: Con suficientes datos, tu estimador está “tan cerca como quieras” del valor real, con probabilidad “tan alta como quieras”. No garantiza que acierte exactamente, sino que la probabilidad de error grande se vuelve negligible.

Checkpoint ✓ ¿Inssegado implica consistente? (No. X_1 es insesgado para μ pero su varianza no cambia con n : $\text{Var}(X_1) = \sigma^2$ siempre. No es consistente. La varianza $\rightarrow 0$ es una condición suficiente, no la definición, y aquí esa varianza no se colapsa.)

2.4.3. La segunda confusión más común: ¿insesgado y consistente no son lo mismo?

No. Y confundirlos es uno de los errores más frecuentes en exámenes. La diferencia es sutil pero crucial:

- **Insesgamiento** es una propiedad para un n fijo: $E[\hat{\theta}_n] = \theta$ para todo n .
- **Consistencia** es una propiedad asintótica: $\hat{\theta}_n \xrightarrow{P} \theta$ cuando $n \rightarrow \infty$.

El contraejemplo definitivo: $\hat{\theta} = X_1$ (usar solo la primera observación). Es insesgado ($E[X_1] = \mu$), pero *no* consistente: su varianza σ^2 nunca disminuye sin importar cuántos datos tengas. En la dirección opuesta: el MLE de σ^2 (dividir entre n) es sesgado, pero *sí* consistente —el sesgo $\sigma^2/n \rightarrow 0$.

En Econometría I (5to semestre), verás que la consistencia de OLS importa más que su insesgamiento. ¿Por qué? Porque en la práctica trabajas con muestras grandes, y lo que necesitas es que el estimador *converja* al valor real —no que acierte “en promedio” con cualquier n .

Ejemplo trabajado: Consistencia para la Exponencial (Ejercicio 3.1)

Contexto: Para $X_i \sim \text{Exp}(\lambda)$ con densidad $f(x|\lambda) = \lambda e^{-\lambda x}$ (λ es la *tasa*, $E[X] = 1/\lambda$), se proponen tres estimadores de λ y se evalúa su consistencia.

Estimador 1: $\hat{\theta}_1 = \bar{X}$

$$E[\bar{X}] = 1/\lambda \neq \lambda, \quad \text{Var}(\bar{X}) = \frac{1/\lambda^2}{n} \rightarrow 0$$

El sesgo NO tiende a cero ($E[\bar{X}] \rightarrow 1/\lambda$, no a λ). Por lo tanto, **no es consistente**. $\bar{X}$ converge a $1/\lambda$, no a λ . Confundir escala con tasa es el error más común del Lab 1.

Estimador 2: $\hat{\theta}_2 = X_1$

$$E[X_1] = 1/\lambda \neq \lambda, \quad \text{Var}(X_1) = 1/\lambda^2 \not\rightarrow 0$$

Ni el sesgo ni la varianza convergen. Doblemente no consistente. Usar una sola observación ignora el resto de la información.

Estimador 3: $\hat{\theta}_3 = \sum_{i=1}^n X_i$

$$E[\hat{\theta}_3] = n/\lambda \rightarrow \infty, \quad \text{Var}(\hat{\theta}_3) = n/\lambda^2 \rightarrow \infty$$

La esperanza diverge. **No es consistente**. Sumar sin dividir entre n produce un estimador que explota.

El estimador consistente: $\hat{\theta} = 1/\bar{X}$. Por la Ley de los Grandes Números, $\bar{X} \xrightarrow{P} 1/\lambda$. Por el Teorema del Mapeo Continuo, $1/\bar{X} \xrightarrow{P} 1/(1/\lambda) = \lambda$. **Consistente**.

Lección: La consistencia requiere que el estimador converja *al parámetro correcto*. $\bar{X}$ es consistente *para la media*, no para la tasa. La parametrización importa.

Tarjeta de repaso

Frente: ¿Qué dos condiciones son *suficientes* para consistencia?

Reverso: (1) $E[\hat{\theta}_n] \rightarrow \theta$ (asintóticamente insesgado). (2) $\text{Var}(\hat{\theta}_n) \rightarrow 0$ (varianza se colapsa). Ambas juntas implican convergencia en probabilidad. Importante: son condiciones suficientes, no la definición. La definición es $\hat{\theta}_n \xrightarrow{P} \theta$.

Frente: ¿ $\hat{\theta} = X_1$ (primera observación) es consistente para μ ?

Reverso: No. Es insesgado ($E[X_1] = \mu$), pero $\text{Var}(X_1) = \sigma^2$ no depende de n . No importa cuántos datos tengas, X_1 ignora todos los demás. La varianza nunca converge a 0.

Pregunta de autoevaluación

Para la distribución Exponencial $f(x|\lambda) = \lambda e^{-\lambda x}$ (donde $E[X] = 1/\lambda$), se proponen tres estimadores de λ .

- a) $\hat{\theta} = \bar{X}$ es consistente porque la media muestral siempre es consistente.
- b) Ninguno de $\bar{X}$, X_1 , $\sum X_i$ es consistente para λ : el primero converge a $1/\lambda$, el segundo no mejora con n , y el tercero diverge. Un estimador consistente sería $1/\bar{X}$.
- c) $\hat{\theta} = \sum X_i$ es consistente porque usa todos los datos.
- d) Los tres son consistentes porque todos son funciones de los datos.

Respuesta: b). $\bar{X} \xrightarrow{P} E[X] = 1/\lambda \neq \lambda$: converge, pero al valor equivocado. X_1 no usa información de $n > 1$. $\sum X_i$ tiene $E = n/\lambda \rightarrow \infty$. El estimador consistente es $1/\bar{X} \xrightarrow{P} 1/(1/\lambda) = \lambda$ por el Teorema del Mapeo Continuo.

Conexión con los ejercicios

Resuelve el **Ejercicio 3.1** (Consistencia para la Exponencial). Verifica las dos condiciones suficientes (asintóticamente insesgado y varianza $\rightarrow 0$) para cada candidato. Cuando los tres fallen, pregúntate: ¿qué transformación de $\bar{X}$ convergiría a λ ?

2.5. Suficiencia: ¿puedes comprimir los datos sin perder información?

Antes de leer: hazte esta pregunta

El INEGI tiene los microdatos del Censo de Población (130 millones de registros individuales). Un investigador solo necesita la media y la varianza de los ingresos. **¿Puede descartar los 130 millones de registros y quedarse solo con $\bar{X}$ y S^2 sin perder información sobre los parámetros?**

2.5.1. El caso: compresión sin pérdida

Caso Real: Compresión de datos del INEGI (concepto)

El INEGI almacena microdatos de la Encuesta Nacional de Ingresos y Gastos de los Hogares (ENIGH): millones de registros individuales. Pero para estimar la media y varianza del ingreso (asumiendo normalidad), bastan dos números: $\bar{X}$ y S^2 .

¿Se pierde información al comprimir millones de datos en dos estadísticos? **No**, si esos estadísticos son **suficientes**. La densidad conjunta de todos los datos, vista como función de los parámetros, depende de los datos *solo a través de* $\bar{X}$ y S^2 . Todo lo demás es “ruido” que no aporta información adicional sobre μ y σ^2 .

La analogía: Es como comprimir una imagen sin pérdida (PNG vs. BMP). El archivo PNG es más pequeño, pero contiene *exactamente* la misma información visual. Un estadístico suficiente es la “compresión sin pérdida” de los datos.

Fuente conceptual: Fisher, R.A. (1922). “On the Mathematical Foundations of Theoretical Statistics”. El concepto de suficiencia fue introducido por Fisher para formalizar la idea de “capturar toda la información relevante”.

2.5.2. La herramienta: el teorema de factorización

La herramienta estadística

Suficiencia y el Teorema de Factorización de Fisher-Neyman.

Un estadístico $T(\mathbf{X})$ es **suficiente** para θ si la densidad conjunta se puede escribir como:

$$f(\mathbf{x}|\theta) = g(T(\mathbf{x}), \theta) \cdot h(\mathbf{x})$$

donde g depende de los datos **solo a través de** $T(\mathbf{x})$, y h no depende de θ .

¿Cómo se usa en la práctica? Escribe la verosimilitud conjunta y trata de factorizarla. Si puedes separar una parte que depende de los datos solo vía T (y contiene toda la dependencia en θ) de otra parte que no depende de θ , entonces T es suficiente.

Ejemplo del Lab 1 (Ejercicio 4.1, Exponencial):

$$f(\mathbf{x}|\lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum x_i}$$

$$= \underbrace{\lambda^n e^{-\lambda n \bar{x}}}_{g(\bar{x}, \lambda)} \cdot \underbrace{1}_{h(\mathbf{x})}$$

Los datos aparecen solo vía $\bar{X}$ (o equivalentemente, $\sum X_i$). Por Fisher-Neyman, $\bar{X}$ es suficiente para λ .

Ejemplo del Lab 1 (Ejercicio 4.2, Bernoulli):

$$f(\mathbf{x}|p) = \prod_{i=1}^3 p^{x_i} (1-p)^{1-x_i} = p^{\sum x_i} (1-p)^{3-\sum x_i}$$

- $T_1 = \sum X_i$: la densidad depende de $\mathbf{x}$ solo vía $\sum X_i$. **Suficiente.**
- $T_2 = X_1 + 2X_2 + 3X_3$: conocer T_2 no determina $\sum X_i$ (por ejemplo, $T_2 = 3$ podría ser $(0, 0, 1)$ con $\sum = 1$ o $(1, 1, 0)$ con $\sum = 2$). La densidad no se puede escribir como función de T_2 y p solamente. **No suficiente.**

Definición: Estadístico suficiente

Definición formal (Notas de clase, Definición 7.15; Wackerly et al. 2015, Sec. 8.6). Un estadístico $T = T(X_1, \dots, X_n)$ es **suficiente** para θ si la distribución condicional de $\mathbf{X}$ dado $T = t$ no depende de θ .

En español: Si conoces el valor del estadístico suficiente, los datos originales no te dan información *adicional* sobre θ . El estadístico “absorbe” toda la información relevante.

Checkpoint ✓ ¿Para qué sirve saber que T es suficiente? (1) Puedes trabajar con T en vez de con los n datos originales. (2) Cualquier estimador basado en T aprovecha toda la información disponible sobre θ .)

Definición: Teorema de Factorización de Fisher-Neyman

Definición formal (Notas de clase, Teorema 7.5; Wackerly et al. 2015, Teorema 8.7).

$T(\mathbf{X})$ es suficiente para θ si y solo si la densidad conjunta se puede escribir como:

$$f(\mathbf{x}|\theta) = g(T(\mathbf{x}), \theta) \cdot h(\mathbf{x})$$

En español: Para verificar suficiencia, escribe la verosimilitud conjunta y trata de separarla en dos partes: una que contiene toda la dependencia en θ y solo mira los datos vía T (esa es g), y otra que depende de los datos pero *no* de θ (esa es h). Si puedes hacer esta separación, T es suficiente.

Checkpoint ✓ Si la verosimilitud depende de los datos solo a través de $T(\mathbf{x})$, ¿ T es

suficiente? (Sí: puedes tomar $h(\mathbf{x}) = 1$ y la factorización se satisface trivialmente.)

Ejemplo trabajado: Factorización de Fisher-Neyman para la Exponencial (Ejercicio 4.1)

Enunciado: Mostrar que $\bar{X}$ es un estadístico suficiente para λ en la distribución Exponencial con $f(x|\lambda) = \lambda e^{-\lambda x}$, $x > 0$.

Paso 1: Construir la densidad conjunta. Como las X_i son IID:

$$f(x_1, \dots, x_n|\lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i}$$

Paso 2: Álgebra de la productoria:

$$f(\mathbf{x}|\lambda) = \lambda^n \cdot e^{-\lambda x_1} \cdot e^{-\lambda x_2} \dots e^{-\lambda x_n} = \lambda^n e^{-\lambda \sum_{i=1}^n x_i}$$

Paso 3: Identificar el estadístico dentro de la expresión. Dado que $\sum x_i = n\bar{x}$:

$$f(\mathbf{x}|\lambda) = \lambda^n e^{-\lambda n\bar{x}}$$

Paso 4: Factorizar según Fisher-Neyman. La expresión depende de los datos solo a través de $\bar{x}$:

$$g(\bar{x}, \lambda) = \lambda^n e^{-\lambda n\bar{x}}, \quad h(\mathbf{x}) = 1$$

Conclusión: $\bar{X}$ es suficiente para λ . El haber llegado a $h(\mathbf{x}) = 1$ significa algo muy poderoso: **toda** la dependencia en el parámetro λ ocurre exclusivamente a través de la media muestral. Si yo te digo que el promedio de 10 datos de una exponencial es 5, tienes exactamente la misma información sobre λ que si te dictara la lista de los 10 valores individuales.

Verificación numérica: Con datos $\{0,42, 0,15, 0,08, 0,51, 0,17\}$ y $\lambda = 3$:

$$\bar{x} = 0,266, \quad L(\lambda) = 3^5 \cdot e^{-3(1,33)} = 243 \cdot e^{-3,99} = 4,496$$

Usando solo $\bar{x}$: $g(0,266, 3) = 3^5 \cdot e^{-5 \cdot 3 \cdot 0,266} = 243 \cdot e^{-3,99} = 4,496$. Idéntico. **Suficiencia en acción.**

2.5.3. Conexión con eficiencia: el teorema de Rao-Blackwell

Nota didáctica

La suficiencia no es una propiedad aislada: se conecta directamente con la eficiencia a través del **Teorema de Rao-Blackwell**. Si tienes un estimador insesgado $\hat{\theta}$ y un estadístico suficiente T , puedes “mejorar” tu estimador calculando $E[\hat{\theta}|T]$. El resultado es insesgado y su varianza es $\leq$ la original. Es decir: condicionar en el suficiente *nunca* empeora tu estimador, y generalmente lo mejora.

En la práctica: si sabes que $\bar{X}$ es suficiente para λ en la Exponencial, cualquier estimador que no sea función de $\bar{X}$ (como X_1) puede mejorarse condicionándolo en $\bar{X}$. El resultado será más eficiente. Este teorema es una de las razones por las que la suficiencia importa: no es solo compresión de datos; es una herramienta para construir mejores estimadores.

Tarjeta de repaso

Frente: ¿Cómo verificas si un estadístico es suficiente?

Reverso: Usa el Teorema de Factorización de Fisher-Neyman: escribe $f(\mathbf{x}|\theta) = g(T(\mathbf{x}), \theta) \cdot h(\mathbf{x})$. Si puedes separar la densidad conjunta en una parte que depende de θ solo vía T y otra que no depende de θ , entonces T es suficiente.

Frente: ¿ $\bar{X}$ es suficiente para μ en la distribución Normal?

Reverso: Sí (cuando σ^2 es conocido). La densidad conjunta $f(\mathbf{x}|\mu) \propto \exp\{-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2\}$ se puede reescribir usando $\sum (x_i - \mu)^2 = n(\bar{x} - \mu)^2 + \sum (x_i - \bar{x})^2$, de modo que los datos aparecen solo vía $\bar{x}$ en la parte que depende de μ .

Pregunta de autoevaluación

Para una muestra de 3 observaciones Bernoulli(p), $T_1 = X_1 + X_2 + X_3$ y $T_2 = X_1 + 2X_2 + 3X_3$.

- Ambos son suficientes porque usan las tres observaciones.
- T_1 es suficiente y T_2 no: la verosimilitud $p^{\sum x_i}(1-p)^{3-\sum x_i}$ depende de los datos solo vía $\sum X_i = T_1$, pero no puede escribirse como función de T_2 y p solamente.
- T_2 es suficiente porque contiene “más información” (pesos 1, 2, 3 en vez de 1, 1, 1).
- Ninguno es suficiente porque $n = 3$ es muy pequeño.

Respuesta: b). La verosimilitud Bernoulli depende de los datos solo a través de $\sum X_i$. $T_2 = X_1 + 2X_2 + 3X_3$ no determina $\sum X_i$ unívocamente (ej: $T_2 = 3$ puede provenir de $(0, 0, 1)$ con $\sum = 1$ o de $(1, 1, 0)$ con $\sum = 2$). Si elegiste (c), “más información” empírica requiere que la factorización funcione, y no funciona con T_2 .

Conexión con los ejercicios

Resuelve los **Ejercicios 4.1–4.3** (Suficiencia). En el Ejercicio 4.1, aplica Fisher-Neyman a la Exponencial. En el Ejercicio 4.2, compara T_1 vs. T_2 para Bernoulli. En el Ejercicio 4.3, usa la identidad $\sum (x_i - \mu)^2 = n(\bar{x} - \mu)^2 + \sum (x_i - \bar{x})^2$ para factorizar la Normal.

2.6. Las cuatro propiedades: mapa de decisiones

Propiedad	Pregunta que responde	Fórmula clave	En econometría
Sesgo	¿Apunta al valor correcto en promedio?	$B(\hat{\theta}) = E[\hat{\theta}] - \theta$	OLS es insesgado bajo Gauss-Markov
Eficiencia	¿Es el más preciso entre los insesgados?	$\text{Var}(\hat{\theta}) \geq \frac{1}{nI(\theta)}$	OLS es BLUE (mínima varianza lineal)
Consistencia	¿Mejora con más datos?	$\hat{\theta}_n \xrightarrow{P} \theta$	“Con n grande, OLS converge”
Suficiencia	¿Usa toda la información?	Factorización $f = g(T, \theta) \cdot h$	$(\bar{X}, S^2)$ resumen la Normal

Tarjeta de repaso

Regla nemotécnica para las 4 propiedades:

- **Sesgo:** ¿Se desvía del objetivo?
- **Eficiencia:** ¿Es el de menor varianza?
- **Consistencia:** ¿Converge con más datos?
- **Suficiencia:** ¿Se puede comprimir sin pérdida?

Las relaciones entre ellas:

- Insesgado $\nRightarrow$ Consistente (ej: X_1).
- Consistente $\nRightarrow$ Insesgado (puede ser asintóticamente insesgado pero sesgado para n finito).
- MVUE = Insesgado + Eficiente (menor varianza posible).
- Suficiente + Insesgado = base para construir MVUE (Teorema de Rao-Blackwell).

Conexión: Lab 1 $\rightarrow$ Lab 2

Del control de calidad a la línea de producción.

En el Lab 1 aprendiste a **evaluar** estimadores. Sabes qué significa que un estimador sea insesgado, eficiente, consistente y suficiente. Puedes tomar cualquier estimador que te den y someterlo a estas cuatro pruebas.

Pero hay una pregunta que el Lab 1 deliberadamente no responde: **¿de dónde sale el estimador?** En todos los ejercicios del Lab 1, el estimador aparecía dado: “considera $\hat{\theta} = \bar{X}$ ”, “supón que $\hat{\theta} = \omega \bar{X}_1 + (1 - \omega) \bar{X}_2$ ”. Tu trabajo era verificar sus propiedades.

El Lab 2 cambia el rol: ahora **tú fabricas el estimador**. No te dan $\hat{\theta}$; tú lo construyes desde cero usando dos métodos sistemáticos:

- **Máxima Verosimilitud (MLE):** “¿Qué valor de θ hace mis datos más plausibles?”
- **Método de Momentos (MOM):** “¿Qué valor de θ iguala los momentos teóricos con los muestrales?”

Las cuatro propiedades del Lab 1 son los criterios con los que evaluarás los estimadores que fabriques en el Lab 2. La pregunta “¿es insesgado?” que practicaste en la Sección 2.2 la aplicarás al MLE de σ^2 . La pregunta “¿es eficiente?” de la Sección 2.3 te dirá por qué MLE es asintóticamente mejor que MOM. La pregunta “¿es consistente?” de la Sección 2.4 es la razón por la que los econométristas prefieren MLE con muestras grandes. Y la pregunta “¿es suficiente?” de la Sección 2.5 explica por qué $\bar{X}$ aparece como MLE en tantas distribuciones.

En el Lab 1 verificaste; en el Lab 2 construyes. Es la diferencia entre el inspector de calidad y el ingeniero de producción. Ambos roles son indispensables, y los necesitas a los dos.

3. Métodos de estimación: Máxima Verosimilitud y Momentos

Herencia conceptual: Del Lab 1: insesgamiento, eficiencia, consistencia, suficiencia son las propiedades que MLE y MOM buscan garantizar

En el Lab 1 aprendiste a **evaluar** estimadores: sabes qué significa que sean insesgados, eficientes, consistentes y suficientes. Pero en todos los ejercicios del Lab 1 el estimador aparecía dado: “considera $\hat{\theta} = \bar{X}$ ”. Este capítulo te enseña a **construirlos** desde cero. Los dos métodos que aprenderás —Máxima Verosimilitud y Método de Momentos— producen estimadores cuyas propiedades luego evaluarás con las herramientas del Lab 1. La pregunta ya no es “¿este estimador es bueno?”, sino “¿cómo encuentro un estimador que sea bueno?”

3.1. Máxima Verosimilitud (MLE): el método del detective

Antes de leer: hazte esta pregunta

Un hospital del IMSS registra el número de accidentes laborales reportados por mes en una zona industrial de Monterrey. Los datos de los últimos 8 meses son: 3, 5, 2, 4, 4, 6, 3, 5 accidentes. Estos datos sugieren una distribución Poisson con parámetro λ desconocido. **¿Qué valor de λ hace que estos datos sean los más probables posible?**

3.1.1. El caso que revela la lógica del MLE

Caso Real: Accidentes laborales en la industria mexicana (IMSS, 2022–2023)

El Instituto Mexicano del Seguro Social (IMSS) registra mensualmente los accidentes de trabajo por sector económico. En la industria manufacturera, el número de accidentes por planta por mes es un dato de **conteo**: 0, 1, 2, 3, ... (nunca negativo, nunca fraccionario).

La distribución Poisson es el modelo natural para datos de conteo: eventos discretos

que ocurren a una tasa promedio λ en un periodo fijo. El IMSS necesita estimar esa tasa para diseñar políticas de prevención. Si λ es alto, la planta necesita intervención; si es bajo, las medidas actuales funcionan. (El modelo Poisson supone que los accidentes ocurren a **tasa constante** y de forma **independiente** entre sí; si hubiera “rachas” o estacionalidad marcada, el modelo tendría que ajustarse.)

La pregunta: Observaste $n = 8$ meses de datos: $k_1 = 3, k_2 = 5, k_3 = 2, k_4 = 4, k_5 = 4, k_6 = 6, k_7 = 3, k_8 = 5$. ¿Cuál es la mejor estimación de la tasa λ ?

3.1.2. El algoritmo MLE en 4 pasos

Antes de resolver el caso, aquí está el procedimiento sistemático que aplicarás a *cualquier* distribución:

La herramienta estadística

Algoritmo MLE (4 pasos):

1. **Construir** la función de verosimilitud: $L(\theta) = \prod_{i=1}^n f(x_i|\theta)$.
2. **Aplicar logaritmo:** $\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(x_i|\theta)$.
3. **Derivar e igualar a cero** (condición de primer orden): $\frac{d\ell}{d\theta} = 0$.
4. **Verificar** que es un máximo (condición de segundo orden): $\frac{d^2\ell}{d\theta^2} < 0$.

¿Por qué el logaritmo? $\ln$ es estrictamente creciente: el valor de θ que maximiza $L(\theta)$ es el mismo que maximiza $\ln L(\theta)$. Pero trabajar con sumas ($\ln$ de un producto = suma de $\ln$) es algebraicamente mucho más simple que derivar productos. Sin el logaritmo, el MLE para una Normal con $n = 100$ requeriría derivar un producto de 100 exponenciales; con el logaritmo, es una suma de 100 términos.

3.1.3. MLE para la Poisson: cuando el resultado es el promedio

Ejemplo trabajado: MLE para la distribución Poisson (Ejercicio 1.1)

Enunciado: Encontrar el estimador de máxima verosimilitud $\hat{\lambda}$ para una muestra IID Poisson con $p(k|\lambda) = \frac{e^{-\lambda}\lambda^k}{k!}$.

Paso 1 — Verosimilitud:

$$L(\lambda) = \prod_{i=1}^n \frac{e^{-\lambda}\lambda^{k_i}}{k_i!} = \frac{e^{-n\lambda} \cdot \lambda^{\sum k_i}}{\prod k_i!}$$

Paso 2 — Log-verosimilitud:

$$\ell(\lambda) = -n\lambda + \left(\sum_{i=1}^n k_i \right) \ln \lambda - \underbrace{\sum \ln(k_i!)}_{\text{no depende de } \lambda}$$

Paso 3 — Condición de primer orden:

$$\frac{d\ell}{d\lambda} = -n + \frac{\sum k_i}{\lambda} = 0 \implies \boxed{\hat{\lambda}_{\text{MLE}} = \frac{\sum k_i}{n} = \bar{k}}$$

Paso 4 — Condición de segundo orden:

$$\frac{d^2\ell}{d\lambda^2} = -\frac{\sum k_i}{\lambda^2} < 0 \quad \checkmark$$

Con los datos del IMSS: $\hat{\lambda} = (3 + 5 + 2 + 4 + 4 + 6 + 3 + 5)/8 = 32/8 = 4,0$ accidentes/mes.

Interpretación: El MLE de una Poisson es simplemente el promedio muestral. Es uno de los resultados más elegantes de la estadística: la estimación más plausible de la tasa promedio es, precisamente, el promedio observado. La intuición es satisfactoria: el método matemático confirma lo que el sentido común sugeriría.

Definición: Estimador de Máxima Verosimilitud (MLE)

Definición formal (Notas de clase, Sección 7.3; Casella y Berger 2002, Definición 7.2.2).

Sea $L(\theta|\mathbf{x}) = \prod_{i=1}^n f(x_i|\theta)$ la función de verosimilitud. El **estimador de máxima verosimilitud** es:

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} L(\theta|\mathbf{x}) = \arg \max_{\theta} \ell(\theta|\mathbf{x})$$

En español: El MLE es el valor del parámetro que, si fuera el valor “verdadero”, haría que los datos observados fueran los más probables posible. No es el valor más probable del parámetro (eso sería inferencia bayesiana); es el valor que mejor “explica” los datos.

Checkpoint $\checkmark$ ¿El MLE siempre es insesgado? (No. El ejemplo clásico: el MLE de σ^2 para la Normal divide entre n , no entre $n - 1$. Es sesgado —pero consistente y asintóticamente eficiente.)

Definición: Función de Verosimilitud

Definición formal (Notas de clase, Sección 7.3; Casella y Berger 2002, §7.2.2).

Sea $\mathbf{x} = (x_1, \dots, x_n)$ una realización de una muestra aleatoria IID de $f(x|\theta)$. La **función de verosimilitud** es:

$$L(\theta|\mathbf{x}) = \prod_{i=1}^n f(x_i|\theta)$$

Es la densidad conjunta, pero vista como función de θ (el parámetro) con los datos $\mathbf{x}$ fijos.

En español: La verosimilitud responde: “dado que *ya observé* estos datos, ¿qué tan plausible es cada valor posible del parámetro?” No es una probabilidad de los datos, sino una función de plausibilidad del parámetro.

Checkpoint ✓ ¿La verosimilitud $L(\theta|\mathbf{x})$ es una probabilidad? (No. Es una función de θ que mide plausibilidad, no probabilidad. No integra a 1 sobre θ .)

La confusión más común del Lab 2: “¿verosimilitud y probabilidad no son lo mismo?” La diferencia está en *qué se mueve y qué se fija*:

- **Probabilidad:** θ es fijo, x varía. Preguntas: “dado que $\lambda = 3$, ¿cuál es la probabilidad de observar $k = 5$?”
- **Verosimilitud:** x es fijo, θ varía. Preguntas: “dado que observé $k = 5$, ¿qué tan plausible es $\lambda = 3$ vs. $\lambda = 5$?”

Es la **misma fórmula** ($f(x|\theta)$), pero vista desde lados opuestos.

3.1.4. MLE para la Gamma: cuando el resultado no es obvio

Caso Real: Duración del desempleo en México (ENOE-INEGI, 2023)

La Encuesta Nacional de Ocupación y Empleo (ENOE) del INEGI registra cuánto tiempo tardan los desempleados en encontrar trabajo. Estos tiempos son siempre positivos y su distribución es asimétrica hacia la derecha: la mayoría encuentra trabajo en pocas semanas, pero una proporción no despreciable tarda meses.

Si el tiempo de desempleo se modela como la suma de dos fases exponenciales independientes (ej: búsqueda activa + proceso de selección), la distribución resultante es una Gamma con parámetro de forma $\alpha = 2$ y parámetro de escala β desconocido. El gobierno necesita estimar β para calibrar sus programas de empleo.

Datos estilizados (semanas de desempleo, 6 observaciones): $\{6,2; 9,1; 7,5; 8,3; 5,8; 10,1\}$.

Ejemplo trabajado: MLE para la distribución Gamma con forma conocida (Ejercicio 1.2)

Enunciado: La densidad Gamma con $\alpha = 2$ es $f(x|\beta) = \frac{1}{\beta^2} x e^{-x/\beta}$ para $x > 0$, con $E[X] = 2\beta$. Encontrar $\hat{\beta}_{MLE}$.

Paso 1 — Verosimilitud:

$$L(\beta) = \prod_{i=1}^n \frac{1}{\beta^2} x_i e^{-x_i/\beta} = \beta^{-2n} \left(\prod x_i \right) e^{-\sum x_i/\beta}$$

Paso 2 — Log-verosimilitud:

$$\ell(\beta) = -2n \ln \beta + \underbrace{\sum \ln x_i}_{\text{constante}} - \frac{1}{\beta} \sum x_i$$

Paso 3 — Derivar:

$$\frac{d\ell}{d\beta} = -\frac{2n}{\beta} + \frac{\sum x_i}{\beta^2} = 0 \implies \boxed{\hat{\beta}_{\text{MLE}} = \frac{\sum x_i}{2n} = \frac{\bar{x}}{2}}$$

Paso 4 — Verificar máximo:

$$\left. \frac{d^2\ell}{d\beta^2} \right|_{\hat{\beta}} = \frac{2n}{\beta^2} - \frac{2\sum x_i}{\beta^3} \Big|_{\hat{\beta}} = -\frac{2n}{\hat{\beta}^2} < 0 \quad \checkmark$$

Con los datos ENOE: $\bar{x} = 47,0/6 = 7,833$. Entonces $\hat{\beta} = 7,833/2 = 3,917$ semanas. Cada “fase” del proceso de búsqueda dura en promedio $\approx 3,9$ semanas.

¿Por qué $\bar{x}/2$ y no $\bar{x}$? Porque si $X \sim \text{Gamma}(2, \beta)$, entonces $E[X] = 2\beta$, no β . El promedio muestral estima 2β ; para estimar β , divides entre 2. Es la misma lógica que practicaste en el Lab 1: si tu estimador “apunta” a 2β , lo corriges para que apunte a β .

Nota didáctica

¿Cuándo el MLE NO tiene solución cerrada? En la Gamma con ambos parámetros desconocidos (α y β), la condición de primer orden para α involucra la función digamma $\psi(\alpha) = \frac{d}{d\alpha} \ln \Gamma(\alpha)$, que no tiene inversa algebraica. Ahí el MLE requiere optimización numérica (Newton-Raphson). Este es un ejemplo de por qué el software es indispensable en la práctica: los ejercicios de este curso usan casos con solución cerrada para que entiendas la lógica, pero los problemas reales rara vez son tan amables.

3.1.5. El MLE para la Normal y la tensión con el Lab 1**Caso Real: Calificaciones estandarizadas (CENEVAL, 2023)**

El Examen Nacional de Ingreso (EXANI) del CENEVAL evalúa a estudiantes que buscan ingresar a instituciones de educación superior en México. Con cientos de miles de aplicaciones, las calificaciones se modelan con distribución Normal: $X \sim N(\mu, \sigma^2)$. **Datos estilizados** (5 estudiantes): $\{78, 85, 92, 88, 72\}$.

La herramienta estadística

MLE para la Normal: dos parámetros. Ahora hay dos parámetros: necesitamos derivadas parciales y un sistema de dos ecuaciones.

Paso 1 — Verosimilitud:

$$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\}$$

Paso 2 — Log-verosimilitud:

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

Paso 3a — Derivar respecto a μ :

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \quad \Rightarrow \quad \boxed{\hat{\mu}_{\text{MLE}} = \bar{x}}$$

Paso 3b — Derivar respecto a σ^2 :

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0 \quad \Rightarrow \quad \boxed{\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

La tensión con el Lab 1: En el Lab 1 aprendiste que el estimador insesgado de σ^2 divide entre $n - 1$ (corrección de Bessel). Pero el MLE divide entre n . **¿Cuál es “correcto”?**

Ambos. Cada uno optimiza un criterio diferente:

- $S^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$: Insesgado ($E[S^2] = \sigma^2$). Prioriza la propiedad del Lab 1.
- $\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$: Maximiza la verosimilitud. Es sesgado ($E[\hat{\sigma}^2] = \frac{n-1}{n} \sigma^2$), pero consistente y asintóticamente eficiente.

Con $n = 5$: la diferencia es del 20 % ($1/5$ vs. $1/4$). Con $n = 1000$: la diferencia es del 0.1 %. **Moraleja:** la distinción importa con muestras pequeñas; con muestras grandes, MLE e insesgamiento convergen.

Con los datos CENEVAL: $\bar{x} = 83,0$.

$$\hat{\sigma}_{\text{MLE}}^2 = \frac{(78 - 83)^2 + (85 - 83)^2 + (92 - 83)^2 + (88 - 83)^2 + (72 - 83)^2}{5} = 51,2$$

$$S^2 = \frac{256}{4} = 64,0$$

La diferencia: 51.2 vs. 64.0 —un 20 % menos.

Definición: MLE para la Normal (dos parámetros)

Proposición (Notas de clase, Sección 7.3; Casella y Berger 2002, Ejemplo 7.2.7). Si $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ IID:

$$\hat{\mu}_{\text{MLE}} = \bar{X} = \frac{1}{n} \sum X_i, \quad \hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$$

$\hat{\mu}_{\text{MLE}}$ es insesgado. $\hat{\sigma}_{\text{MLE}}^2$ es sesgado: $E[\hat{\sigma}_{\text{MLE}}^2] = \frac{n-1}{n} \sigma^2 < \sigma^2$.

Checkpoint ✓ Con $n = 100$, ¿cuánto sesgo tiene $\hat{\sigma}_{MLE}^2$? (Sesgo = $-\sigma^2/n = -\sigma^2/100$. Subestima por solo 1 %.)

Tarjeta de repaso

Frente: ¿Cuál es el algoritmo MLE en 4 pasos?

Reverso: (1) Construir $L(\theta) = \prod f(x_i|\theta)$. (2) Aplicar $\ln$: $\ell = \sum \ln f(x_i|\theta)$. (3) Derivar e igualar a cero: $\ell'(\theta) = 0 \Rightarrow \hat{\theta}$. (4) Verificar máximo: $\ell''(\hat{\theta}) < 0$.

Frente: ¿Por qué el MLE de σ^2 divide entre n y no $n - 1$?

Reverso: Porque MLE maximiza la verosimilitud, no busca insesgamiento. Dividir entre n maximiza $L(\mu, \sigma^2)$. Dividir entre $n - 1$ corrige el sesgo. Ambos son “correctos”: cada uno optimiza un criterio diferente. La diferencia desaparece cuando n es grande.

Pregunta de autoevaluación

Un investigador estima los parámetros de una Normal con $n = 5$ estudiantes. Obtiene $\hat{\mu}_{MLE} = 83$ y $\hat{\sigma}_{MLE}^2 = 51,2$. Su colega dice: “Tu estimador de la varianza está mal —debería ser 64.” ¿Quién tiene razón?

- a) El investigador: MLE es siempre el estimador correcto.
- b) El colega: $S^2 = 64$ es siempre el estimador correcto.
- c) Ambos están “correctos”: 51.2 es el MLE y 64.0 es el estimador insesgado. La elección depende del criterio de optimización.
- d) Ninguno: el verdadero estimador divide entre $n + 1$.

Respuesta: c). $51,2 = 256/5$ (MLE) y $64,0 = 256/4$ (insesgado). No hay un solo estimador correcto: hay un estimador para cada criterio. Con n grande, la diferencia desaparece.

Conexión con los ejercicios

Resuelve los **Ejercicios 1.1–1.3** (MLE). El Ejercicio 1.1 (Poisson) es el más sencillo. El Ejercicio 1.2 (Gamma) introduce la idea de que $E[X] \neq \theta$. El Ejercicio 1.3 (Normal) es el más largo y el más importante: practica derivadas parciales y revela la tensión MLE vs. insesgamiento.

3.2. Método de Momentos (MOM): el método del calibrador

Antes de leer: hazte esta pregunta

Tienes una distribución con una densidad complicada. Calcular la verosimilitud y derivarla es un infierno algebraico. **¿Existe un camino más simple para estimar el parámetro sin necesidad de optimizar?**

3.2.1. El caso donde MOM brilla

Caso Real: Tiempos de espera en ventanilla bancaria (ejemplo construido)

Una cadena bancaria mexicana necesita modelar el tiempo de espera (normalizado entre 0 y 1, donde 1 es el tiempo máximo aceptable) de sus clientes en ventanilla. Los ingenieros proponen la densidad:

$$f(x|\theta) = (\theta^2 + \theta) x^{\theta-1} (1-x), \quad 0 \leq x \leq 1, \quad \theta > 0$$

Con θ grande, la mayor parte de la masa se concentra cerca de $x = 1$ (tiempos largos); con θ pequeño, se concentra cerca de $x = 0$ (tiempos cortos). El banco quiere estimar θ para saber si su servicio es rápido (θ bajo) o lento (θ alto).

El problema: El MLE de esta distribución requiere resolver una ecuación cuadrática que involucra $\sum \ln x_i$. El Método de Momentos, en cambio, llega a una fórmula directa.

3.2.2. El algoritmo MOM en 3 pasos

La herramienta estadística

Algoritmo MOM (3 pasos):

1. **Calcular** los momentos teóricos: $\mu'_k = E[X^k]$ (tantos como parámetros haya).
2. **Igualar** cada momento teórico a su equivalente muestral: $E[X^k] = m'_k = \frac{1}{n} \sum X_i^k$.
3. **Despejar** los parámetros del sistema de ecuaciones resultante.

La lógica: Si tu modelo predice que $E[X] = g(\theta)$, y en la muestra observas que el promedio es $\bar{x}$, simplemente igualas: $g(\theta) = \bar{x}$ y despejas θ . Es la lógica de la calibración: ajustas el modelo hasta que sus predicciones coincidan con la realidad observada.

Ejemplo trabajado: MOM para la distribución personalizada (Ejercicio 2.1)

Enunciado: Encontrar el estimador de momentos para la densidad $f(x|\theta) = (\theta^2 + \theta)x^{\theta-1}(1-x)$ en $[0, 1]$.

Paso 1 — Momento teórico:

$$\begin{aligned} E[X] &= \int_0^1 x \cdot (\theta^2 + \theta)x^{\theta-1}(1-x) dx \\ &= (\theta^2 + \theta) \int_0^1 (x^\theta - x^{\theta+1}) dx \\ &= (\theta^2 + \theta) \left[\frac{1}{\theta+1} - \frac{1}{\theta+2} \right] \\ &= (\theta^2 + \theta) \cdot \frac{1}{(\theta+1)(\theta+2)} = \frac{\theta}{\theta+2} \end{aligned}$$

Paso 2 — Igualar al momento muestral:

$$\frac{\hat{\theta}}{\hat{\theta} + 2} = \bar{x}$$

Paso 3 — Despejar:

$$\hat{\theta} = \bar{x}(\hat{\theta} + 2) = \bar{x}\hat{\theta} + 2\bar{x} \implies \boxed{\hat{\theta}_{\text{MOM}} = \frac{2\bar{x}}{1 - \bar{x}}}$$

Ejemplo: Si $\bar{x} = 0,40$, entonces $\hat{\theta} = 2(0,40)/(0,60) = 1,333$.

¿Por qué MOM es más simple aquí? La log-verosimilitud de esta distribución produce una ecuación cuadrática en θ que involucra $\sum \ln x_i$ y requiere seleccionar la raíz positiva. MOM llega en un paso a una fórmula directa. En distribuciones como la Gamma con forma desconocida, la ventaja de MOM es aún más dramática: el MLE no tiene solución cerrada para α , mientras que MOM da fórmulas directas.

Definición: Método de Momentos

Definición formal (Notas de clase, Sección 7.3; Casella y Berger 2002, §7.2.1).

Sea X una variable aleatoria con distribución que depende de k parámetros $\theta_1, \dots, \theta_k$. Los **estimadores de momentos** se obtienen igualando los primeros k momentos teóricos a los muestrales:

$$E[X^j] = \frac{1}{n} \sum_{i=1}^n X_i^j, \quad j = 1, \dots, k$$

y resolviendo el sistema de k ecuaciones con k incógnitas.

En español: Si tu modelo predice $E[X] = g(\theta)$ y observas $\bar{x}$, igualas y despejas. Si hay dos parámetros, necesitas dos ecuaciones (primer y segundo momento).

Checkpoint ✓ ¿El Método de Momentos siempre da un estimador único? (No necesariamente. Si el sistema tiene múltiples soluciones, el estimador no es único. En la práctica esto es raro para distribuciones estándar.)

3.2.3. MOM para la Exponencial: cuando MOM = MLE

La herramienta estadística

MOM para la Exponencial. Para $f(x|\lambda) = \lambda e^{-\lambda x}$ (λ es la *tasa*):

Paso 1: $E[X] = \int_0^\infty x \cdot \lambda e^{-\lambda x} dx = 1/\lambda$ (integración por partes).

Paso 2: $1/\hat{\lambda} = \bar{x}$.

Paso 3: $\hat{\lambda}_{\text{MOM}} = 1/\bar{x}$.

¿MOM = MLE aquí? Sí. El MLE de la Exponencial también es $\hat{\lambda}_{\text{MLE}} = 1/\bar{x}$. Ambos métodos producen el mismo estimador. ¿Pasa siempre? No. En la distribución personalizada del Ejercicio 2.1, MOM y MLE difieren.

¿Cuándo coinciden? En la **familia exponencial** la condición de primer orden del MLE iguala el *estadístico suficiente* con su esperanza. Eso equivale a igualar momentos **cuando ese estadístico suficiente es precisamente el momento muestral** —como en Poisson ($\bar{k}$), Exponencial ($\bar{x}$), Bernoulli ($\bar{x}$) y Normal ($\bar{x}$, $\frac{1}{n} \sum (x_i - \bar{x})^2$). La Gamma lo ilustra: coincide si la forma α es conocida, pero *no* si α se estima.

3.2.4. MOM para la varianza Normal: divide entre n , no $n - 1$

Nota didáctica

Un punto que genera confusión constante. Para la Normal, el MOM de σ^2 se obtiene igualando el segundo momento:

$$E[X^2] = \sigma^2 + \mu^2 = \frac{1}{n} \sum X_i^2$$

Sustituyendo $\mu = \bar{x}$:

$$\hat{\sigma}_{\text{MOM}}^2 = \frac{1}{n} \sum X_i^2 - \bar{x}^2 = \frac{1}{n} \sum (X_i - \bar{x})^2$$

El MOM divide entre n , igual que el MLE. El estimador S^2 (entre $n - 1$) *no* proviene del Método de Momentos: surge de la corrección de Bessel para lograr insesgamiento, que es un criterio distinto.

Esto es importante porque algunos estudiantes asumen erróneamente que “MOM = insesgado” o que “ S^2 es el estimador de momentos.” No es así. MOM, como MLE, prioriza la coincidencia momentos teóricos-muestrales; el insesgamiento es un objetivo separado que se aborda con la corrección de Bessel ($n - 1$).

Tarjeta de repaso

Frente: ¿Cuál es la ventaja principal del Método de Momentos sobre MLE?

Reverso: Simplicidad algebraica. MOM evita la optimización: solo necesitas calcular $E[X^k]$ e igualar al momento muestral. Es especialmente útil cuando la log-verosimilitud no tiene solución cerrada (Gamma con forma desconocida).

Frente: ¿Cuál es la desventaja principal?

Reverso: MOM suele ser **menos eficiente** que MLE: produce estimadores con mayor varianza. MLE alcanza la cota de Cramér-Rao asintóticamente; MOM no necesariamente. A cambio, MOM es computacionalmente más simple.

Frente: ¿MOM para σ^2 divide entre n o $n - 1$?

Reverso: Divide entre n (igual que MLE). S^2 (entre $n - 1$) es la corrección de Bessel para insesgamiento, no el estimador de momentos.

Pregunta de autoevaluación

Un actuario necesita estimar θ de una distribución cuya log-verosimilitud no tiene solución cerrada. Con $\bar{x} = 0,60$ aplica MOM usando la densidad $f(x|\theta) = (\theta^2 + \theta)x^{\theta-1}(1-x)$.

- a) $\hat{\theta} = 0,60$ porque el estimador de momentos siempre iguala $\hat{\theta}$ al promedio muestral.
- b) $\hat{\theta} = 2(0,60)/(1 - 0,60) = 3,0$.
- c) $\hat{\theta} = 2(0,60)/(0,60) = 2,0$.
- d) No se puede aplicar MOM porque la distribución no es estándar.

Respuesta: b). La fórmula derivada es $\hat{\theta} = 2\bar{x}/(1-\bar{x})$. Si elegiste (a), confundiste el estimador de momentos con el promedio —solo para distribuciones donde $E[X] = \theta$ el MOM da $\hat{\theta} = \bar{x}$ (como la Poisson). Aquí $E[X] = \theta/(\theta + 2) \neq \theta$.

Conexión con los ejercicios

Resuelve los **Ejercicios 2.1–2.2** (MOM). El Ejercicio 2.1 (distribución personalizada) te guía por el cálculo de $E[X]$. El Ejercicio 2.2 (Exponencial) te muestra el caso donde MOM = MLE. Compara ambos: ¿en qué se parecen y en qué se diferencian los procedimientos?

3.3. Propiedades asintóticas: ¿por qué MLE domina la econometría moderna?

3.3.1. La trífectora asintótica del MLE

La herramienta estadística

¿Por qué todo el mundo usa MLE? No es por el álgebra —como viste, a veces MOM es más simple—. Es por lo que ocurre cuando $n \rightarrow \infty$.

Bajo condiciones de regularidad, el MLE satisface tres propiedades que lo convierten en el estándar de la estadística aplicada:

1. **Consistencia:** $\hat{\theta}_{\text{MLE}} \xrightarrow{P} \theta$. Con más datos, el MLE converge al valor real.
2. **Eficiencia asintótica:** $\text{Var}(\hat{\theta}_{\text{MLE}}) \rightarrow 1/[nI(\theta)]$. Con muestras grandes, ningún otro estimador puede ser más preciso. El MLE alcanza la cota de Cramér-Rao asintóticamente.
3. **Normalidad asintótica:** $\sqrt{n}(\hat{\theta}_{\text{MLE}} - \theta) \xrightarrow{D} N(0, 1/I(\theta))$. El MLE se comporta como una Normal cuando n es grande, lo cual permite construir intervalos de confianza y pruebas de hipótesis (Labs 3–4).

¿Y MOM? MOM también es consistente y asintóticamente normal bajo condiciones generales. Pero generalmente **no** alcanza la cota de Cramér-Rao: es menos eficiente que MLE. La ventaja de MOM es puramente computacional: cuando MLE no tiene solución cerrada, MOM da una fórmula directa.

La regla práctica:

- **Usa MLE** cuando puedas: tiene las mejores propiedades asintóticas. Es el estándar en econometría, bioestadística y machine learning.
- **Usa MOM** cuando MLE no tenga solución cerrada y necesites una estimación rápida, o como valor inicial para optimización numérica del MLE.
- **Si coinciden** (Poisson, Exponencial, Bernoulli), usa el que más te convenga —el resultado es idéntico.

Definición: Propiedades Asintóticas del MLE

Teorema (Casella y Berger 2002, §10.1; Notas de clase, Sección 7.3).

Bajo condiciones de regularidad, el MLE satisface:

1. **Consistencia:** $\hat{\theta}_{\text{MLE}} \xrightarrow{P} \theta$.
2. **Eficiencia asintótica:** $\text{Var}(\hat{\theta}_{\text{MLE}}) \rightarrow \text{CRLB}$.
3. **Normalidad asintótica:** $\sqrt{n}(\hat{\theta}_{\text{MLE}} - \theta) \xrightarrow{D} N(0, 1/I(\theta))$.

En español: Con suficientes datos, el MLE (1) converge al valor real, (2) es lo más preciso posible, y (3) se comporta como una Normal. Por eso es el método dominante.

Checkpoint ✓ ¿El MLE siempre tiene las mejores propiedades? (Solo asintóticamente. Con muestras pequeñas, puede haber estimadores mejores para criterios específicos como insesgamiento.)

3.3.2. El mapa de decisiones: MLE vs. MOM

Criterio	MLE	MOM
Pregunta que res-ponde	¿Qué θ hace mis datos más plausibles?	¿Qué θ iguala momentos teóricos y muestrales?
Álgebra	Derivar log-verosimilitud; verificar máximo	Calcular $E[X^k]$; despejar
Solución cerrada	No siempre (Gamma con α desconocida, efectos mixtos)	Casi siempre (para 1–2 parámetros)
Propiedades asintóticas	Consistente, eficiente, normal asintótico	Consistente, normal, pero menos eficiente
Sesgo	Puede ser sesgado (ej: $\hat{\sigma}^2$ divide entre n)	Depende de la distribución
En econometría	Logit/Probit, GARCH, modelos de duración	GMM (Hansen 1982, Nobel 2013)
En ML/IA	Cross-entropy loss, MSE loss	GANs (moment matching)

3.3.3. La conexión con el tradeoff sesgo-varianza

Nota didáctica

El tradeoff central de la estadística aplicada. En la Normal, el MLE de σ^2 divide entre n (sesgado pero con menor ECM en muestras finitas) mientras que el estimador insesgado divide entre $n - 1$. Esta tensión ilustra el principio más importante del Lab 2:

$$\underbrace{\text{MSE}}_{\text{Error total}} = \underbrace{(\text{Sesgo})^2}_{\text{Del Lab 1, Sec. 1}} + \underbrace{\text{Var}}_{\text{Del Lab 1, Sec. 2}}$$

El MLE prioriza minimizar la varianza (asintóticamente) a costa de aceptar sesgo en muestras finitas. La corrección de Bessel ($n - 1$) prioriza eliminar el sesgo a costa de aumentar la varianza. Ninguna elección es universalmente “correcta”: depende de si tu función de pérdida penaliza más el sesgo o la varianza.

En Econometría II (6to semestre), verás que Ridge y Lasso generalizan exactamente esta idea: introducen sesgo deliberadamente para reducir la varianza, produciendo mejores predicciones fuera de muestra. El principio que nace en el Lab 1 y se materializa en el Lab 2 es el mismo que gobierna la regularización en machine learning.

Ejemplo trabajado: Comparación numérica MLE vs. insesgado para σ^2

Contexto: Para una Normal con $\sigma^2 = 100$, comparamos el MLE ($\hat{\sigma}_n^2$) y el estimador insesgado (S^2) para distintos tamaños de muestra.

n	$\hat{\sigma}_{MLE}^2$ (sesgo)	S^2 (insesgado)	Diferencia
5	E = 80 (subestima 20 %)	E = 100 (insesgado)	20 %
10	E = 90 (subestima 10 %)	E = 100 (insesgado)	10 %
30	E = 96,7 (subestima 3.3 %)	E = 100 (insesgado)	3.3 %
100	E = 99 (subestima 1 %)	E = 100 (insesgado)	1 %

Moraleja: Con $n \geq 30$, la diferencia práctica es menor al 3.3 %. En la práctica econométrica moderna, donde n suele ser grande, se usa MLE sin pensarlo dos veces. La corrección de Bessel solo importa con muestras pequeñas.

Ejemplo con datos mexicanos: El CONEVAL estima la varianza del ingreso con la ENIGH ($n \approx 70,000$ hogares). La diferencia entre dividir entre n o $n - 1$ es del orden de 0,0014 % —completamente despreciable.

Tarjeta de repaso

Frente: ¿Qué propiedades tiene el MLE con muestras grandes?

Reverso: La “trifecta asintótica”: (1) Consistente ($\rightarrow$ valor real), (2) Eficiente (alcanza Cramér-Rao), (3) Normal asintótico. Estas propiedades justifican que MLE sea el método dominante en econometría y ciencia de datos.

Frente: ¿Cuándo usar MOM en vez de MLE?

Reverso: Cuando MLE no tiene solución cerrada (ej: Gamma con α desconocido), o cuando necesitas una estimación rápida con álgebra simple. MOM sacrifica eficiencia asintótica por simplicidad computacional.

Frente: ¿MOM y MLE siempre coinciden?

Reverso: No. Coinciden en varias distribuciones de la familia exponencial (Poisson, Exponencial, Bernoulli, Normal) cuando el estadístico suficiente es el momento muestral. Pero difieren en distribuciones como la del Ejercicio 2.1 o la Gamma con forma desconocida.

Pregunta de autoevaluación

Un econometrista tiene datos de ingresos que asume normales con $n = 50$. Calcula $\hat{\sigma}_{MLE}^2 = 250$ y $S^2 = 255,1$.

- Alguien cometió un error de cálculo.
- $\hat{\sigma}_{MLE}^2$ divide entre $n = 50$ y S^2 divide entre $n - 1 = 49$. Son estimadores distintos del mismo parámetro.
- $\hat{\sigma}_{MLE}^2$ usa la mediana y S^2 usa la media.

d) La diferencia se debe al redondeo.

Respuesta: b). $\hat{\sigma}_{MLE}^2 = \sum (x_i - \bar{x})^2 / n$ y $S^2 = \sum (x_i - \bar{x})^2 / (n - 1)$. Con $n = 50$, la diferencia es $1/50 = 2\%$. Si elegiste (a), ambos son correctos —solo optimizan criterios distintos.

3.3.4. Dónde aparecen estos métodos en tu carrera

Nota didáctica

MLE está en todas partes:

- **Logit/Probit** (Microeconometría, 7mo semestre): la probabilidad de que un hogar sea pobre se estima maximizando una log-verosimilitud Bernoulli.
- **GARCH** (Macroeconometría, 8vo semestre): la volatilidad financiera se modela con MLE.
- **Redes neuronales**: la función de pérdida *cross-entropy* es la log-verosimilitud negativa de una Bernoulli. Entrenar una red es hacer MLE con millones de parámetros.
- **AIC/BIC**: los criterios de información para seleccionar modelos se basan en la log-verosimilitud evaluada en el MLE.

MOM está en la econometría moderna:

- **GMM** (Econometría II, 6to semestre): el Método Generalizado de Momentos de Hansen (1982, Nobel 2013) generaliza $E[X] = \bar{X}$ a condiciones de momentos $E[g(X, \theta)] = 0$.
- **Variables instrumentales**: un caso particular de GMM que verás en econometría.

Conexión: Lab 2 → Lab 3

De la estimación puntual a la incertidumbre.

El Lab 2 te enseñó a **construir** estimadores. Ahora tienes dos métodos —MLE y MOM— que producen un **número**: $\hat{\lambda} = 4,0$ accidentes/mes, $\hat{\beta} = 3,92$ semanas, $\hat{\mu} = 83$ puntos en el CENEVAL.

Pero un número, por sí solo, es peligroso. $\hat{\mu} = 83$ no te dice si la media real podría ser 70 u 95. $\hat{\lambda} = 4,0$ no te dice si la tasa de accidentes está fuera de control o dentro de lo normal. Para responder esas preguntas necesitas **cuantificar la incertidumbre**. El Lab 3 te da la herramienta para hacerlo: los **intervalos de confianza**. En vez de reportar un solo número, reportas una banda: “con 95 % de confianza, la calificación promedio está entre 75.2 y 90.8”.

¿De dónde sale esa banda? De la **distribución muestral** del estimador. En el Lab 1 aprendiste que $\hat{\theta}$ es una variable aleatoria (antes de observar los datos). En el Lab 2 aprendiste a construir $\hat{\theta}$. En el Lab 3 aprenderás que $\hat{\theta}$ tiene una distribución (bajo ciertos supuestos, una *t* de Student o una Normal) y que puedes usar esa

distribución para construir una banda alrededor de tu estimación puntual.

Los tres labs forman una secuencia lógica:

1. **Lab 1:** ¿Qué hace que un estimador sea bueno? → Propiedades.
2. **Lab 2:** ¿Cómo construyo un estimador? → MLE y MOM.
3. **Lab 3:** ¿Qué tan seguro estoy de mi estimación? → Intervalos de confianza.

El estimador puntual del Lab 2 es la materia prima del Lab 3. Sin un buen estimador, el intervalo de confianza es basura. Y sin un intervalo de confianza, el estimador puntual es un número sin contexto. Los necesitas a los dos.

Parte II

La incertidumbre: de la estimación puntual a la decisión

4. Intervalos de confianza: la estimación deja de ser un solo número

Herencia conceptual: Del Lab 2: los estimadores puntuales (MLE y MOM) ahora reciben una banda de incertidumbre

En el Lab 2 aprendiste a *construir* estimadores: Máxima Verosimilitud te dio $\hat{\theta}$ como “el valor que hace los datos más probables”; Método de Momentos te dio $\hat{\theta}$ como “el valor que iguala momentos teóricos y muestrales”. Ambos producen un **número**. Un solo número.

Este capítulo responde a la pregunta obvia: *¿qué tan seguro estás de ese número?* Si CONEVAL reporta que la pobreza en México es del 36.3 %, ¿podría ser 35 %? ¿O 40 %? El intervalo de confianza (IC) transforma tu estimador puntual en una **banda de incertidumbre** cuantificada. Esa banda es la herencia directa del Lab 2: cada $\hat{\theta}$ que supiste construir ahora recibe un margen de error.

4.1. Motivación: por qué un solo número no basta

Antes de leer: hazte esta pregunta

CONEVAL dice que el ingreso promedio trimestral de un hogar mexicano es de \$57,000 pesos. Pero CONEVAL no entrevistó a *todos* los hogares, sino a una muestra de aproximadamente 105,000. ¿Qué tan lejos podría estar ese \$57,000 del ingreso *real* de los 35 millones de hogares? ¿Y si la pobreza reportada es 36.3 %? ¿Podría ser realmente 40 %?

Caso Real: Midiendo la pobreza en México (CONEVAL, 2022)

El problema: México tiene más de 35 millones de hogares. Visitar cada uno es imposible. CONEVAL usa la Encuesta Nacional de Ingresos y Gastos de los Hogares (ENIGH), que entrevista a aproximadamente $n = 105,000$ hogares. De esa muestra calculan el ingreso promedio ($\bar{X} = \$57,000$ MXN trimestrales) y la proporción en pobreza ($\hat{\theta} = 0.363$). Pero estos números cambian si tomas una muestra diferente.

La pregunta estadística: ¿Cuánto puede variar ese promedio muestral respecto al ingreso promedio *real* de los 35 millones de hogares? ¿Cuál es el margen de error

de ese 36.3%? CONEVAL necesita dar un rango creíble, no solo un número suelto, para que los legisladores tomen decisiones informadas. Si la proporción real fuera 40%, las conclusiones de política serían muy diferentes.

La intuición es simple: cada vez que tomas una muestra y calculas un promedio, obtienes un número distinto. Si repitieras el procedimiento muchas veces, los promedios formarían un patrón. Ese patrón es la **distribución muestral**, y su dispersión —el **error estándar**— mide cuánta incertidumbre tiene tu estimación. El intervalo de confianza toma esa dispersión y construye una banda alrededor de tu estimador.

Definición: Distribución Muestral

Definición formal (Casella y Berger 2002, §5.2; Notas de clase, Definición 7.1). Sea $T = T(X_1, \dots, X_n)$ una función de las variables aleatorias de una muestra aleatoria. La distribución de probabilidad de T se llama **distribución muestral** de T .

En español: Cada vez que tomas una muestra y calculas algo con ella (un promedio, una varianza, una proporción), obtienes un número distinto. Si pudieras repetir el muestreo infinitas veces, el patrón que forman esos números —su centro, dispersión y forma— es la distribución muestral. Esta idea es *el* concepto central de toda la inferencia estadística: cada coeficiente de regresión que verás en econometría tiene su propia distribución muestral.

Checkpoint ✓ *¿La distribución muestral describe tus datos, o describe los posibles valores de tu estadístico si repitieras el muestreo?* (Lo segundo. Los datos tienen su propia distribución; la distribución muestral describe al estimador.)

Definición: Error Estándar

Definición formal (Casella y Berger 2002, §7.3.2; Notas de clase, Definición 7.13). Sea $\hat{\theta}$ un estimador de θ . El **error estándar** de $\hat{\theta}$ es la desviación estándar de su distribución muestral:

$$\text{se}(\hat{\theta}) = \sqrt{\text{Var}(\hat{\theta})}$$

Para la media muestral: $\text{se}(\bar{X}) = \sigma/\sqrt{n}$. Cuando σ es desconocido, se estima con $\hat{\sigma}/\sqrt{n}$.

En español: El error estándar mide cuánto varía tu estimador de muestra a muestra. NO es la dispersión de los datos; es la dispersión de los posibles resultados de tu estimación. Cada tabla de regresión en cada paper de economía reporta errores estándar. Si no entiendes qué miden, no puedes leer la literatura empírica.

Checkpoint ✓ *Si duplicas el tamaño de muestra, ¿el error estándar se reduce a la mitad?* (No: se reduce por factor $\sqrt{2} \approx 1.41$, porque se divide entre $\sqrt{n}$.)

Definición: Intervalo de Confianza

Definición formal (Neyman 1937; Casella y Berger 2002, §9.2.1).

Sean $X_1, \dots, X_n$ variables aleatorias con distribución que depende de un parámetro desconocido θ . Dos funciones $L(X_1, \dots, X_n)$ y $U(X_1, \dots, X_n)$ forman un **intervalo de confianza al nivel $1 - \alpha$** si:

$$P(L(X_1, \dots, X_n) \leq \theta \leq U(X_1, \dots, X_n)) = 1 - \alpha$$

donde L y U son los extremos del intervalo (aleatorios), mientras que θ es fijo (no aleatorio).

Lo que significa y lo que NO significa:

- ✓ “Si repito este procedimiento 100 veces con 100 muestras distintas, alrededor de 95 de los 100 intervalos contendrán a θ .”
- ✗ “Hay 95 % de probabilidad de que θ esté en este intervalo particular.” — Esto es incorrecto porque θ no es aleatorio: o está en el intervalo, o no está.

Analogía: Una máquina lanza aros hacia un poste fijo. El poste no se mueve; el aro sí (cada aro = cada muestra). Una máquina del 95 % acierta 95 de cada 100 lanzamientos. Que **tu** aro particular haya atrapado el poste es verdadero o falso —no tiene probabilidad— pero confías en la máquina porque sabes su tasa de acierto.

Checkpoint ✓ *Después de calcular un IC del 95 % y obtener (52,000; 62,000), ¿hay 95 % de probabilidad de que μ esté ahí?* (No: μ está o no está. La confianza es del procedimiento, no del intervalo particular.)

Definición: Teorema del Límite Central (TLC)

Definición formal (Notas de clase, Teorema 5.5; Casella y Berger 2002, Teorema 5.5.15).

Sean $X_1, \dots, X_n$ variables aleatorias iid con $E[X_i] = \mu$ y $\text{Var}(X_i) = \sigma^2 < \infty$. Entonces:

$$Z_n = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{D} N(0, 1) \quad \text{cuando } n \rightarrow \infty$$

En español: Sin importar la forma de la distribución original de los datos, el promedio muestral estandarizado se comporta como una Normal cuando la muestra es suficientemente grande ($n \geq 30$, regla práctica). Esto justifica usar la Normal (o la t) para construir ICs incluso con datos no normales.

Checkpoint ✓ *¿El TLC dice que los datos se vuelven normales con muestras grandes?* (No: los datos mantienen su distribución original. Lo que se vuelve normal es la distribución del promedio $\bar{X}$.)

Tarjeta de repaso**Los tres pilares de todo IC:**

1. **Distribución muestral:** el patrón que sigue tu estimador si repitieras el muestreo.
2. **Error estándar:** la dispersión de esa distribución muestral ($\sigma/\sqrt{n}$ para $\bar{X}$).
3. **Nivel de confianza:** la tasa de acierto del procedimiento a largo plazo, NO la probabilidad de un intervalo particular.

Sin estos tres conceptos, las fórmulas que siguen son solo recetas. Con ellos, cada fórmula es una consecuencia natural.

4.2. Las seis preguntas de una evaluación económica

Una evaluación de programa genera una cadena de preguntas estadísticas. Supón que el gobierno implementa un programa piloto de becas en cinco estados y, un año después, necesita un informe de evaluación. El informe debe responder, en este orden:

1. **¿Cuánto ganan en promedio los beneficiarios?** Solo tienes una muestra. La respuesta no es un número, sino un *intervalo* (Sección 4.3).
2. **¿Ganan más que quienes no recibieron la beca?** Necesitas comparar dos promedios. (Sección 4.4).
3. **¿Qué fracción de los beneficiarios salió de la pobreza?** Variable binaria: intervalo para una *proporción* (Sección 4.5).
4. **¿Es esa fracción mayor entre beneficiarios?** Diferencia de proporciones (Sección 4.6).
5. **¿Los ingresos son más predecibles?** Dispersión: IC para la *varianza* (Sección 4.7).
6. **¿Es la dispersión distinta entre estados?** Razón de varianzas (Sección 4.8).

Las seis herramientas comparten la misma lógica —estimar un parámetro, medir la incertidumbre, construir un intervalo— pero difieren en la distribución muestral que usan (t , Z , χ^2 o F) y en el valor de referencia que indica si hay o no diferencia (cero para diferencias, uno para razones).

4.3. IC para la media μ con σ conocida (z-interval)

4.3.1. Intuición: de la muestra a la población

Antes de leer: hazte esta pregunta

Tienes una muestra de 36 tiempos de ensamblaje en una fábrica. El promedio muestral es 19.44 minutos. ¿Es ese el tiempo *real* de ensamblaje? ¿Qué tan lejos podría estar el verdadero promedio μ de tu $\bar{X} = 19,44$?

Cuando conoces σ , la lógica es directa. Por el TLC (o por normalidad de los datos), el promedio muestral estandarizado sigue una distribución Normal:

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

De esta relación despejas μ para obtener el intervalo:

$$\bar{X} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

Ejemplo trabajado: IC para la media con σ conocida — Auditoría salarial

Una auditoría laboral muestrea 40 trabajadores. El salario promedio observado es $\bar{X} = 12,20$ USD/hora. La desviación estándar poblacional es conocida: $\sigma = 2,50$. Construye un IC al 95 % para el verdadero salario promedio μ .

Paso 1: Identificar los datos. $n = 40$, $\bar{X} = 12,20$, $\sigma = 2,50$, $\alpha = 0,05$, $z_{0,025} = 1,96$.

Paso 2: Calcular el error estándar:

$$se(\bar{X}) = \frac{\sigma}{\sqrt{n}} = \frac{2,50}{\sqrt{40}} = \frac{2,50}{6,3246} = 0,3953$$

Paso 3: Construir el intervalo:

$$\begin{aligned} IC_{95\%} &= \bar{X} \pm z_{0,025} \cdot se(\bar{X}) \\ &= 12,20 \pm 1,96 \times 0,3953 \\ &= 12,20 \pm 0,7748 \\ &= [11,43, 12,97] \end{aligned}$$

Interpretación: Con 95 % de confianza, el salario promedio real está entre \$11.43 y \$12.97 por hora. Nota que el estándar de \$13.20/hora NO está en este intervalo —esto será clave en el Lab 4.

En R

```
# IC para la media con sigma conocida
x_bar <- 12.20; sigma <- 2.50; n <- 40; alpha <- 0.05
z_crit <- qnorm(1 - alpha/2)          # 1.96
se <- sigma / sqrt(n)                 # 0.3953
ic_lower <- x_bar - z_crit * se       # 11.425
ic_upper <- x_bar + z_crit * se       # 12.975
```

```
cat("IC 95%: [", ic_lower, ", ", ic_upper, "]\n")
```

4.3.2. IC para la media con σ desconocida (t-interval)

La herramienta estadística

Cuando **no** conoces σ , estimas $\hat{\sigma}$ de la muestra. Esto introduce una fuente adicional de incertidumbre. La distribución t -Student compensa esa incertidumbre extra con colas más pesadas:

$$\bar{X} - t_{\alpha/2, n-1} \cdot \frac{\hat{\sigma}}{\sqrt{n}} < \mu < \bar{X} + t_{\alpha/2, n-1} \cdot \frac{\hat{\sigma}}{\sqrt{n}}$$

¿Por qué t y no Z ? Porque $\hat{\sigma}$ es una estimación, no el valor real. La t tiene colas más pesadas que la Normal: asigna más probabilidad a valores extremos, compensando la incertidumbre de estimar σ . Cuando $n \geq 30$, la t se aproxima a la Normal y la diferencia se vuelve despreciable.

Regla de decisión:

- σ conocida $\Rightarrow$ usa Z (Normal).
- σ desconocida, $n \geq 30 \Rightarrow$ usa Z (TLC).
- σ desconocida, $n < 30$ y población normal $\Rightarrow$ usa t_{n-1} .

Precisión importante: cuando estimas σ con $\hat{\sigma}$, la distribución **exacta** del estadístico es t de Student, no Z . La regla “ $n \geq 30 \Rightarrow Z$ ” es una **aproximación asintótica** que aprovecha que $t_{n-1} \rightarrow N(0, 1)$ conforme n crece. Es válida para fines prácticos, pero conviene recordar que t es la distribución exacta y Z , la aproximación. En la transición hacia la econometría —donde estimarás σ rutinariamente— la t es el estándar; Z aparece como su límite para muestras grandes.

Ejemplo trabajado: IC para la media con σ desconocida — Tiempos de ensamblaje

Una fábrica mide $n = 36$ tiempos de ensamblaje: $\sum X_i = 700$, $\sum X_i^2 = 14,856$. Construye un IC al 96 % para μ .

Paso 1: Calcular estimadores puntuales.

$$\bar{X} = \frac{700}{36} = 19,444$$

$$\hat{\sigma}^2 = \frac{14,856 - 36(19,444)^2}{35} = \frac{14,856 - 13,608,9}{35} = \frac{1,247,1}{35} = 35,632$$

$$\hat{\sigma} = \sqrt{35,632} = 5,969$$

Paso 2: Identificar $\alpha/2$. Con 96 % de confianza, $\alpha = 0,04$, $\alpha/2 = 0,02$. De la tabla t : $t_{0,02, 35} = 2,133$.

Paso 3: Error estándar y margen:

$$se(\bar{X}) = \frac{5,969}{\sqrt{36}} = 0,995, \quad \text{Margen} = 2,133 \times 0,995 = 2,122$$

Paso 4: IC: $19,444 \pm 2,122 = [17,322, 21,566]$.

Interpretación: Con 96 % de confianza, el tiempo promedio real de ensamblaje está entre 17.3 y 21.6 minutos. El intervalo es relativamente ancho porque $n = 36$ es moderado y el nivel de confianza es alto (96 %).

Definición: Distribución t -Student

Definición formal (Notas de clase, Teorema 8.3; Casella y Berger 2002, §5.3.2).

Si $Z \sim N(0, 1)$ e $Y \sim \chi^2_{[\nu]}$ son independientes, entonces:

$$T = \frac{Z}{\sqrt{Y/\nu}} \sim t_{[\nu]}$$

Para la media muestral de una población normal: $T = \frac{\bar{X} - \mu}{\hat{\sigma}/\sqrt{n}} \sim t_{[n-1]}$, donde

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

En español: La t -Student surge cuando reemplazas σ (que no conoces) por $\hat{\sigma}$ (que estimas). Tiene colas más pesadas porque absorbe dos fuentes de incertidumbre: la del muestreo y la de estimar σ .

Tarjeta de repaso

Frente: ¿Cuándo uso t -Student en vez de Z para un IC de la media?

Reverso: Cuando **no conozco** la varianza poblacional σ^2 (que es casi siempre). Si $n \geq 30$, el TLC justifica usar Z como aproximación. Si $n < 30$ y la población es aproximadamente normal, usa t_{n-1} .

Frente: ¿Qué pasa con el ancho del intervalo si duplico n ?

Reverso: El error estándar es $\hat{\sigma}/\sqrt{n}$. Si n se duplica, $\sqrt{n}$ crece por factor $\sqrt{2} \approx 1,41$. El intervalo se reduce en $\approx 29\%$. Para *reducir a la mitad* el ancho, necesitas *cuadruplicar* n .

Pregunta de autoevaluación

Un investigador tiene $n = 25$ tiempos de espera con $\hat{\sigma}$ estimada y quiere un IC al 95 %. Su colega dice: “la muestra es grande, usa Z .” ¿Tiene razón? ¿Qué consecuencia tendría?

Respuesta: No. Con $n = 25$ y σ desconocida, debe usar $t_{[0,025,24]} \approx 2,064$. Con Z , usaría 1,96, produciendo un intervalo artificialmente angosto que subestima la incertidumbre real. Reportaría más precisión de la que tiene.

4.4. IC para diferencia de medias $\mu_1 - \mu_2$

Antes de leer: hazte esta pregunta

En 1992, Nueva Jersey subió su salario mínimo de \$4.25 a \$5.05. Pensilvania no lo subió. La teoría económica predice que subir el salario mínimo destruye empleo. ¿Cómo verificas estadísticamente si eso pasó?

Caso Real: ¿El salario mínimo destruye empleo? (Card & Krueger, 1994)

David Card y Alan Krueger visitaron 410 restaurantes de comida rápida en Nueva Jersey (NJ) y Pensilvania (PA). Midieron el empleo promedio después del cambio:

	NJ ($n_1 = 331$)	PA ($n_2 = 79$)
Empleo promedio	$\bar{X}_1 = 21,03$	$\bar{X}_2 = 21,17$
Desv. estándar	$\hat{\sigma}_1 = 9,33$	$\hat{\sigma}_2 = 7,82$

La diferencia observada: $\bar{X}_1 - \bar{X}_2 = -0,14$ empleados. Es ínfima. Pero ¿podría ser solo ruido muestral? Para saberlo, necesitas un IC para $\mu_1 - \mu_2$.

La herramienta estadística

El **IC para la diferencia de medias** te dice si la brecha observada es real o ruido. Hay tres variantes:

Caso 1: Varianzas conocidas (poco común en la práctica):

$$(\bar{X}_1 - \bar{X}_2) \pm z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

Caso 2: Varianzas desconocidas e iguales (varianza agrupada):

$$\hat{\sigma}_p^2 = \frac{(n_1 - 1)\hat{\sigma}_1^2 + (n_2 - 1)\hat{\sigma}_2^2}{n_1 + n_2 - 2}, \quad (\bar{X}_1 - \bar{X}_2) \pm t_{\alpha/2, n_1+n_2-2} \hat{\sigma}_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

Caso 3: Varianzas desconocidas y posiblemente desiguales (Welch):

$$(\bar{X}_1 - \bar{X}_2) \pm t_{\alpha/2, \nu} \sqrt{\frac{\hat{\sigma}_1^2}{n_1} + \frac{\hat{\sigma}_2^2}{n_2}}, \quad \nu \text{ por Satterthwaite}$$

Referencia clave: el cero. Si el IC incluye al cero, no hay evidencia de diferencia. Si está completamente por encima o por debajo de cero, la diferencia es significativa.

En Card & Krueger: Con $n_1 = 331$, $n_2 = 79$ (ambos > 30), usamos aproximación Normal:

$$se = \sqrt{\frac{9,33^2}{331} + \frac{7,82^2}{79}} = \sqrt{0,263 + 0,774} = \sqrt{1,037} = 1,018$$

$$IC_{95\%} = -0,14 \pm 1,96 \times 1,018 = -0,14 \pm 1,996 = [-2,14, 1,86]$$

El intervalo cruza el cero. **No hay evidencia de que el salario mínimo destruyera empleo.** Este resultado revolucionó el debate en economía laboral.

Ejemplo trabajado: IC para diferencia de medias con Z — Llantas

Se comparan dos tipos de llantas con $n_1 = n_2 = 100$. $\bar{X}_1 = 26,400$ km, $\bar{X}_2 = 25,100$ km. Varianzas conocidas: $\sigma_1^2 = 1,440,000$, $\sigma_2^2 = 1,960,000$. IC al 99 %.

Paso 1: $\alpha = 0,01$, $\alpha/2 = 0,005$, $z_{0,005} = 2,575$.

Paso 2: Diferencia: $26,400 - 25,100 = 1,300$. Error estándar:

$$\sqrt{\frac{1,440,000}{100} + \frac{1,960,000}{100}} = \sqrt{14,400 + 19,600} = \sqrt{34,000} = 184,39$$

Paso 3: Margen: $2,575 \times 184,39 = 474,80$.

Paso 4: IC: $1,300 \pm 474,80 = [825,20, 1,774,80]$. Como todo el intervalo es positivo, las llantas tipo A duran significativamente más.

Tarjeta de repaso

Frente: ¿Cómo interpreto un IC para $\mu_1 - \mu_2$ que incluye al cero?

Reverso: Que los promedios de ambas poblaciones podrían ser iguales. No hay evidencia estadística de diferencia. Ej: Card & Krueger no encontraron diferencia significativa en empleo.

Frente: ¿Cuándo uso varianza agrupada ($\hat{\sigma}_p$)?

Reverso: Cuando (1) las muestras son pequeñas ($n_1, n_2 < 30$) Y (2) asumo varianzas poblacionales iguales ($\sigma_1^2 = \sigma_2^2$). Para verificar ese supuesto, una opción es la prueba F (Sección 4.8), aunque conviene advertir que la prueba F tiene baja potencia para detectar heterocedasticidad con muestras pequeñas, por lo que “no rechazar” $H_0 : \sigma_1^2 = \sigma_2^2$ no equivale a demostrar que las varianzas son iguales. En la práctica contemporánea se prefiere directamente la versión de Welch, que no asume varianzas iguales.

Pregunta de autoevaluación

Con Card & Krueger: $n_1 = 331$, $n_2 = 79$, $\hat{\sigma}_1 = 9,33$, $\hat{\sigma}_2 = 7,82$. Un estudiante propone usar varianza agrupada con t . ¿Es correcto?

Respuesta: No, por dos razones. (1) Las muestras son grandes, así que la aproximación Normal vía TLC es válida y t es innecesaria. (2) Las desviaciones difieren ($9,33 \neq 7,82$), lo que sugiere varianzas posiblemente desiguales. Usar varianza agrupada distorsionaría el error estándar.

4.5. IC para proporción π

Antes de leer: hazte esta pregunta

CONEVAL reporta que el 36.3 % de la población mexicana vive en pobreza multidimensional. Ese dato viene de una encuesta, no de un censo. ¿Cuál es el margen de error de ese 36.3 %? ¿Podría la proporción real ser 40 %?

Caso Real: ¿Cuántos mexicanos son pobres? (CONEVAL, 2022)

CONEVAL utiliza la ENIGH con $n = 105,000$ viviendas. Cada hogar se clasifica como “en pobreza” o “no en pobreza”: una variable Bernoulli. La proporción observada es $\hat{\theta} = 0,363$. Pero ¿qué tan preciso es este número?

La herramienta estadística

El **IC para una proporción** usa la misma lógica que el IC para la media, pero con una diferencia crucial: la varianza de una Bernoulli es función directa de θ :

$$\hat{\theta} \pm z_{\alpha/2} \cdot \sqrt{\frac{\hat{\theta}(1 - \hat{\theta})}{n}}$$

¿Por qué Z y no t ? Porque la varianza de una Bernoulli es $\theta(1 - \theta)$: una vez que estimas θ , la varianza queda determinada. No hay un parámetro de dispersión independiente que estimar.

El dato CONEVAL: Con $\hat{\theta} = 0,363$ y $n = 105,000$:

$$se = \sqrt{\frac{0,363 \times 0,637}{105,000}} = \frac{0,481}{324,04} = 0,00148$$

$$IC_{95\%} = 0,363 \pm 1,96 \times 0,00148 = [0,360, 0,366]$$

El margen de error es de solo $\pm 0,3$ puntos porcentuales. La muestra enorme de CONEVAL produce estimaciones muy precisas.

Nota crucial: La varianza $\hat{\theta}(1 - \hat{\theta})$ es máxima cuando $\hat{\theta} = 0,5$. Para encuestas electorales, esto significa que las elecciones cerradas tienen el *mayor* margen de error posible —justo cuando más importa la precisión.

Ejemplo trabajado: IC para proporción — Cuentas por cobrar

Una muestra de $n = 20$ cuentas por cobrar contiene 14 en cumplimiento ($\hat{\theta} = 0,70$). Construye un IC al 95 % para la proporción real de cuentas en cumplimiento.

Paso 1: $\alpha = 0,05$, $z_{0,025} = 1,96$.

Paso 2: Error estándar:

$$se = \sqrt{\frac{0,70 \times 0,30}{20}} = \sqrt{\frac{0,21}{20}} = \sqrt{0,0105} = 0,1025$$

Paso 3: IC: $0,70 \pm 1,96 \times 0,1025 = 0,70 \pm 0,201 = [0,499, 0,901]$.

Interpretación: Con solo 20 observaciones, el IC es extremadamente ancho (de 50 % a 90 %). Esto ilustra por qué las encuestas necesitan muestras grandes: con $n = 20$, la precisión es casi nula. Compáralo con el IC de CONEVAL con $n = 105,000$.

Tarjeta de repaso

Frente: ¿De dónde sale la varianza en un IC para proporciones?

Reverso: De la distribución Bernoulli. Si $X \sim \text{Bernoulli}(\theta)$, entonces $\text{Var}(X) = \theta(1 - \theta)$. Como no conocemos θ , usamos $\hat{\theta}(1 - \hat{\theta})$. Esta varianza es **máxima** cuando $\hat{\theta} = 0,5$ y se reduce cuando $\hat{\theta}$ se acerca a 0 o 1.

Pregunta de autoevaluación

¿Por qué el error estándar de una proporción es mayor cuando $\hat{\theta} = 0,50$ que cuando $\hat{\theta} = 0,10$? ¿Qué implicación tiene para encuestas electorales?

Respuesta: $\hat{\theta}(1 - \hat{\theta})$ es máximo en $0,50 \times 0,50 = 0,25$, mientras que $0,10 \times 0,90 = 0,09$. Para encuestas electorales, las elecciones cerradas (candidatos cerca del 50 %) tienen el mayor margen de error. Precisamente cuando más importa la precisión, la estadística da menos certeza.

4.6. IC para diferencia de proporciones

Antes de leer: hazte esta pregunta

Si envías dos currículums idénticos, uno con nombre “Emily” y otro con “Lakisha”, ¿reciben la misma tasa de respuesta? Si no, ¿cómo demuestras estadísticamente discriminación?

Caso Real: ¿Emily o Lakisha? (Bertrand & Mullainathan, 2004)

Bertrand y Mullainathan enviaron $\approx 5,000$ currículums a ofertas reales en Boston y Chicago. Los currículums eran idénticos; solo los nombres cambiaban:

	Nombres “blancos”	Nombres “afroamericanos”
Enviados	$n_1 \approx 2,435$	$n_2 \approx 2,435$
Tasa de callback	$\hat{\theta}_1 = 9,65 \%$	$\hat{\theta}_2 = 6,45 \%$

La diferencia: $\hat{\theta}_1 - \hat{\theta}_2 = 3,20$ puntos porcentuales. Los nombres “blancos” recibieron 50 % más llamadas. ¿Podría ser casualidad?

La herramienta estadística

El IC para diferencia de proporciones:

$$(\hat{\theta}_1 - \hat{\theta}_2) \pm z_{\alpha/2} \sqrt{\frac{\hat{\theta}_1(1 - \hat{\theta}_1)}{n_1} + \frac{\hat{\theta}_2(1 - \hat{\theta}_2)}{n_2}}$$

Cálculo con Bertrand & Mullainathan:

$$\begin{aligned} \text{se} &= \sqrt{\frac{0,0965 \times 0,9035}{2435} + \frac{0,0645 \times 0,9355}{2435}} \\ &= \sqrt{0,0000358 + 0,0000248} = \sqrt{0,0000606} = 0,00778 \end{aligned}$$

$$\text{IC}_{95\%} = 0,032 \pm 1,96 \times 0,00778 = [0,017, 0,047]$$

El intervalo NO cruza el cero y es completamente positivo. La diferencia es real: dos personas con calificaciones idénticas reciben trato desigual según su nombre. La estadística lo demuestra con 95 % de confianza.

Regla para sumar varianzas: Aunque estás *restando* proporciones, las varianzas se *suman*. Para muestras independientes: $\text{Var}(A - B) = \text{Var}(A) + \text{Var}(B)$. La incertidumbre se acumula, nunca se cancela.

Tarjeta de repaso

Frente: ¿Por qué sumo varianzas si estoy *restando* proporciones?

Reverso: Porque las muestras son independientes. $\text{Var}(A - B) = \text{Var}(A) + \text{Var}(B)$. Restar medias o proporciones **siempre suma varianzas** cuando los grupos son independientes. La incertidumbre se acumula, nunca se cancela.

Pregunta de autoevaluación

Si Bertrand y Mullainathan hubieran enviado solo 50 currículums por grupo en vez de 2,435, ¿cómo cambiaría el IC? ¿Llegarían a la misma conclusión?

Respuesta: Con $n = 50$, el error estándar sería $\approx 0,0537$ (casi 7 veces mayor). El IC al 95 % sería $0,032 \pm 0,105 = [-0,073, 0,137]$, que **sí cruza el cero**. Con solo 50 observaciones, la misma diferencia real no es detectable. El tamaño de muestra grande fue esencial.

4.7. IC para la varianza σ^2 (chi-cuadrada)

Antes de leer: hazte esta pregunta

Dos fondos de inversión prometen un rendimiento promedio de 8 % anual. Pero uno fluctúa entre 2 % y 14 %, y el otro entre 6 % y 10 %. ¿Cuál es más riesgoso? El promedio es igual; lo que cambia es la dispersión. ¿Cómo medimos la incertidumbre sobre esa dispersión?

Caso Real: Varianza = Riesgo (Markowitz, 1952)

Harry Markowitz ganó el Premio Nobel por demostrar que los inversionistas no solo se preocupan por el rendimiento promedio: también les importa cuánto varía. La varianza de los retornos es la medida matemática del riesgo.

Tomemos 10 días de rendimientos del IPC México (enero 2026, Yahoo Finance):

+1.36	+0.01	-0.23	+1.00	+0.83	+1.03	-0.61	+1.61	-1.12	+0.74
-------	-------	-------	-------	-------	-------	-------	-------	-------	-------

La varianza muestral es $\hat{\sigma}^2 = 0,809$. Pero ¿cuál es la varianza *real* del IPC?

La herramienta estadística

Aquí ocurre un cambio fundamental. En las secciones anteriores, los intervalos eran simétricos: “estimación $\pm$ algo”. Para la varianza, **eso ya no funciona**.

¿Por qué? La varianza muestral es un promedio de cuadrados, siempre ≥ 0 . Su distribución muestral es la **Chi-cuadrada** (χ^2): asimétrica, con cola derecha larga, que empieza en cero. El IC se construye con divisiones, no con sumas/restas:

$$\frac{(n-1)\hat{\sigma}^2}{\chi^2_{[\alpha/2, n-1]}} < \sigma^2 < \frac{(n-1)\hat{\sigma}^2}{\chi^2_{[1-\alpha/2, n-1]}}$$

Truco de examen: El límite inferior usa el valor χ^2 *más grande* (cola derecha) y el superior usa el *más pequeño* (cola izquierda). Parece al revés, pero tiene sentido: divides entre un número grande $\Rightarrow$ resultado pequeño (límite inferior), y divides entre número chico $\Rightarrow$ resultado grande (límite superior).

Nota importante: Los ICs para varianzas son **sensibles al supuesto de normalidad**. Con datos muy asimétricos y n pequeño, la cobertura real puede diferir del nivel nominal.

Definición: Distribución Chi-Cuadrada (χ^2)

Definición formal (Casella y Berger 2002, Definición 5.3.1).

Si $Z_1, \dots, Z_\nu$ son iid $N(0, 1)$, entonces:

$$\sum_{i=1}^{\nu} Z_i^2 \sim \chi^2_{[\nu]}$$

Para la varianza muestral de una población normal: $\frac{(n-1)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{[n-1]}$.

En español: La χ^2 es la distribución de una suma de normales al cuadrado. Como los cuadrados son siempre ≥ 0 , la χ^2 es asimétrica con cola derecha larga. Con más grados de libertad, se vuelve más simétrica.

Ejemplo trabajado: IC para la varianza — Desviación estándar de horas de estudio

Una muestra de $n = 21$ personas tiene desviación estándar muestral $\hat{\sigma} = 7$ horas. IC al 90 % para σ^2 .

Paso 1: $n = 21$, gl = 20. $\hat{\sigma}^2 = 49$. $\alpha = 0,10$, $\alpha/2 = 0,05$.

Paso 2: Valores críticos: $\chi^2_{[0,05, 20]} = 31,410$, $\chi^2_{[0,95, 20]} = 10,851$.

Paso 3: Numerador: $(n-1)\hat{\sigma}^2 = 20 \times 49 = 980$.

Paso 4: IC:

$$\frac{980}{31,410} < \sigma^2 < \frac{980}{10,851} \Rightarrow 31,20 < \sigma^2 < 90,32$$

Interpretación: El intervalo es marcadamente asimétrico respecto a $\hat{\sigma}^2 = 49$: el límite inferior está a 17.8 unidades, pero el superior a 41.3 unidades. Para la desviación estándar: $\sqrt{31,20} = 5,59 < \sigma < \sqrt{90,32} = 9,50$.

Tarjeta de repaso

Frente: ¿Por qué el IC para la varianza usa χ^2 y no Normal/ t ?

Reverso: Porque la varianza muestral es un promedio de cuadrados (≥ 0 siempre). La Normal y la t van de $-\infty$ a $+\infty$, lo cual no tiene sentido para una cantidad no negativa. La χ^2 va de 0 a $+\infty$: es la distribución natural de $(n-1)\hat{\sigma}^2/\sigma^2$ bajo normalidad.

Frente: ¿El IC para la varianza es simétrico?

Reverso: No. La χ^2 es asimétrica. No puedes escribirlo como " $\hat{\sigma}^2 \pm$ algo". Los límites no equidistan de $\hat{\sigma}^2$.

Pregunta de autoevaluación

Un analista calcula $\hat{\sigma}^2 = 0,809$ con $n = 10$. ¿El IC al 90 % para σ^2 será más ancho o más estrecho que uno para μ con los mismos datos?

Respuesta: Será *mucho* más ancho relativo al estimador puntual. Los ICs para varianzas son inherentemente menos precisos que los de medias porque la χ^2 con pocos grados de libertad es muy dispersa. Con $n-1 = 9$ gl, la asimetría es pronunciada. Para ICs angostos para varianzas, necesitas muestras más grandes que para medias.

4.8. IC para razón de varianzas σ_1^2/σ_2^2 (F)

Antes de leer: hazte esta pregunta

¿Es más riesgoso invertir en la Bolsa Mexicana (IPC) o en la estadounidense (S&P 500)? Para comparar dispersiones, no restamos varianzas —las dividimos. ¿Por qué?

Caso Real: IPC México vs. S&P 500 (Yahoo Finance, enero 2026)

Comparemos la volatilidad diaria de ambos índices durante 10 sesiones:

	IPC (%)	S&P 500 (%)
Varianza muestral	$\hat{\sigma}_{\text{IPC}}^2 = 0,809$	$\hat{\sigma}_{\text{SP}}^2 = 0,178$

La razón: $\hat{\sigma}_{\text{IPC}}^2/\hat{\sigma}_{\text{SP}}^2 = 0,809/0,178 = 4,54$. El IPC fue 4.5 veces más volátil. Pero ¿es esta diferencia real o ruido de una muestra de solo 10 días?

La herramienta estadística

La **distribución F de Fisher** es la herramienta para comparar varianzas. Surge del cociente de dos χ^2 independientes divididas por sus grados de libertad.

¿Por qué dividir y no restar? Porque la razón es invariante ante cambios de escala. Si conviertes todos los datos de pesos a dólares, la razón de varianzas no se altera. Y si $\sigma_1^2 = \sigma_2^2$, la razón es **exactamente 1**: un punto de referencia limpio.

$$\frac{\hat{\sigma}_2^2}{\hat{\sigma}_1^2} \cdot \frac{1}{f_{[\alpha/2, n_2-1, n_1-1]}} < \frac{\sigma_2^2}{\sigma_1^2} < \frac{\hat{\sigma}_2^2}{\hat{\sigma}_1^2} \cdot f_{[\alpha/2, n_1-1, n_2-1]}$$

Alerta roja de examen: Los grados de libertad se invierten en cada extremo. En el límite inferior, el subíndice de f tiene $(n_2 - 1, n_1 - 1)$. En el superior, tiene $(n_1 - 1, n_2 - 1)$. Es el error más común.

Propiedad recíproca: $f_{[1-\alpha/2, \nu_1, \nu_2]} = 1/f_{[\alpha/2, \nu_2, \nu_1]}$. Con esto, solo necesitas la cola derecha de las tablas F .

Interpretación: Si el IC incluye al 1, las varianzas podrían ser iguales. Si excluye al 1, hay evidencia de diferencia significativa en dispersión.

Definición: Distribución F de Fisher

Definición formal (Casella y Berger 2002, Definición 5.3.6).

Si $U \sim \chi_{[\nu_1]}^2$ y $V \sim \chi_{[\nu_2]}^2$ son independientes, entonces:

$$F = \frac{U/\nu_1}{V/\nu_2} \sim F_{[\nu_1, \nu_2]}$$

Para razones de varianzas: $\frac{\hat{\sigma}_1^2/\sigma_1^2}{\hat{\sigma}_2^2/\sigma_2^2} \sim F_{[n_1-1, n_2-1]}$.

En español: La F es un cociente de dos χ^2 ajustadas. Siempre es positiva. Tiene dos conjuntos de grados de libertad (numerador y denominador). El orden importa: $F_{[5,10]} \neq F_{[10,5]}$.

Ejemplo trabajado: IC para razón de varianzas — IPC vs. S&P 500

Con $\hat{\sigma}_{\text{IPC}}^2 = 0,809$ ($n_1 = 10$), $\hat{\sigma}_{\text{SP}}^2 = 0,178$ ($n_2 = 10$). IC al 90 % para $\sigma_{\text{IPC}}^2/\sigma_{\text{SP}}^2$.

Paso 1: $\alpha = 0,10$, $\alpha/2 = 0,05$. gl: $\nu_1 = 9$, $\nu_2 = 9$. Razón muestral: $0,809/0,178 = 4,545$.

Paso 2: Valores críticos: $f_{[0,05,9,9]} \approx 3,179$. Por propiedad recíproca: $f_{[0,95,9,9]} = 1/3,179 = 0,3145$.

Paso 3: IC:

$$4,545 \times \frac{1}{3,179} < \frac{\sigma_{\text{IPC}}^2}{\sigma_{\text{SP}}^2} < 4,545 \times 3,179$$

$$1,43 < \frac{\sigma_{\text{IPC}}^2}{\sigma_{\text{SP}}^2} < 14,45$$

Interpretación: El IC no incluye al 1 (está completamente por encima). Con 90 % de confianza, el IPC es más volátil que el S&P 500. Pero el intervalo es enormemente ancho (1,43 a 14,45) debido a solo 10 observaciones por índice.

Tarjeta de repaso

Frente: ¿Cuál es el “número mágico” en un IC para razones de varianzas?

Reverso: El 1. Si $\sigma_1^2/\sigma_2^2 = 1$, las varianzas son iguales. Si el IC excluye al 1, las dispersiones son estadísticamente diferentes.

Frente: ¿Cuál es el error más común con la distribución F en exámenes?

Reverso: Invertir los grados de libertad. En el límite inferior: gl ($n_2 - 1, n_1 - 1$). En el superior: gl ($n_1 - 1, n_2 - 1$). La propiedad recíproca salva cuando las tablas solo tienen cola derecha.

Pregunta de autoevaluación

Un analista calcula $\hat{\sigma}_{\text{IPC}}^2/\hat{\sigma}_{\text{SP}}^2 = 4,54$ con $n_1 = n_2 = 10$. IC al 90 %: (1,43, 14,45). ¿Qué concluye? Si aumenta la muestra a $n = 100$, ¿cómo cambiaría?

Respuesta: El IC no incluye al 1 $\Rightarrow$ el IPC es significativamente más volátil. Con $n = 100$, el intervalo sería mucho más angosto (la F se concentra con más gl), probablemente (2,5, 8,2). Más datos $\Rightarrow$ más precisión, igual que con medias y proporciones.

4.9. Mapa de decisiones: ¿qué IC uso?

Cuando enfrentes un problema de IC en un examen, sigue este árbol:

¿Qué estoy estimando?	Distribución	Referencia clave
Una media μ	t o Z	— (construyo el rango)
Diferencia de medias $\mu_1 - \mu_2$	t o Z	0 : si cruza, no hay diferencia
Una proporción θ	Z	— (rango entre 0 y 1)
Diferencia de proporciones $\theta_1 - \theta_2$	Z	0 : si cruza, no hay diferencia
Una varianza σ^2	χ^2	— (siempre positivo, asimétrico)
Razón de varianzas σ_1^2/σ_2^2	F	1 : si incluye, varianzas iguales

Tarjeta de repaso

Regla para elegir distribución:

- Z : σ conocida, o $n \geq 30$ (TLC), o proporciones.
- t : σ desconocida con $n < 30$ y población normal.
- χ^2 : varianzas (sumas de cuadrados, ≥ 0 , asimétrica).
- F : razones de varianzas (cociente de χ^2 , dos conjuntos de gl).

✓ Verifica tu comprensión

Verifica tu comprensión antes de pasar al Lab 4:

1. Un IC al 95 % para μ es $[4,1, 6,3]$. ¿Significa que hay 95 % de probabilidad de que μ esté ahí? (No: la confianza es del procedimiento.)
2. Un IC para $\mu_1 - \mu_2$ cruza el cero. ¿Hay diferencia significativa? (No.)
3. ¿Por qué el IC para σ^2 no es simétrico? (La χ^2 es asimétrica.)
4. Un IC para σ_1^2/σ_2^2 es $[0,3, 0,8]$. ¿Son iguales las varianzas? (No: el intervalo excluye al 1.)
5. ¿Por qué el IC para proporciones usa Z y no t ? (La varianza Bernoulli es función de θ ; no hay parámetro de dispersión separado.)

Sutura: Los intervalos de confianza y las pruebas de hipótesis son dos caras de la misma moneda

Conexión: Lab 3 → Lab 4

Hasta aquí, cada herramienta del Lab 3 ha producido un **rango**: “ μ está entre A y B con 95 % de confianza”, “ $\mu_1 - \mu_2$ está entre C y D ”. Esos rangos son informativos, pero no emiten un **veredicto**.

El Lab 4 transforma cada rango en una decisión binaria: rechazar o no rechazar una hipótesis. La conexión es profunda y exacta:

$$\theta_0 \notin \text{IC}_{1-\alpha} \iff \text{Rechazar } H_0 : \theta = \theta_0 \text{ al nivel } \alpha$$

En español: El IC reúne todos los valores del parámetro que *no serían rechazados* por la prueba correspondiente. Si tu IC al 95 % para μ es $[11,43, 12,97]$ y alguien afirma que $\mu = 13,20$, puedes responder: “Ese valor está *fuera* de mi IC, así que lo rechazaría al 5 %.” No necesitas hacer una prueba aparte: el IC ya contiene el veredicto.

Esta dualidad explica por qué cada tipo de IC tiene un “número de referencia” natural:

- **Diferencia de medias/proporciones:** referencia = 0. Si el IC excluye al 0, rechazas $H_0 : \mu_1 = \mu_2$.
- **Razón de varianzas:** referencia = 1. Si el IC excluye al 1, rechazas $H_0 : \sigma_1^2 = \sigma_2^2$.
- **Una sola media/proporción:** la referencia la especifica el problema (μ_0, θ_0).

Todo lo que aprendiste sobre distribuciones muestrales (t, Z, χ^2, F), errores estándar y niveles de confianza en este capítulo se transfiere **directamente** al Lab 4. Lo único que cambia es la pregunta: ya no “¿cuál es el rango?” sino “¿la evidencia es suficiente para rechazar?”

El Lab 3 te dio la regla para medir. El Lab 4 te dará la regla para decidir.

Tarjeta de repaso

Lo que te llevas de este capítulo al Lab 4:

1. **Distribución muestral** de cada estimador ($\bar{X}, \hat{\theta}, \hat{\sigma}^2, \hat{\sigma}_1^2/\hat{\sigma}_2^2$).
2. **Error estándar** de cada uno: la dispersión de esa distribución.
3. **Valores críticos** de Z, t, χ^2 y F —los mismos que usarás en pruebas de hipótesis.
4. **Dualidad IC–prueba:** el IC al 95 % contiene exactamente los valores de θ_0 que *no* serían rechazados al 5 %.

Autoevaluación: ¿entendiste la lógica, no solo las fórmulas?

Pregunta de autoevaluación

Escenario A. Un hospital quiere saber si su nuevo sistema de citas redujo el tiempo de espera. Antes: $n = 20$, $\bar{X} = 45$ min, $\hat{\sigma} = 12$. Después: $n = 20$, $\bar{X} = 38$ min, $\hat{\sigma} = 10$. Varianzas desconocidas.

- (a) Para un IC de $\mu_{\text{antes}} - \mu_{\text{después}}$, ¿qué distribución usarías?
- (b) El IC al 95 % es $(-1,2, 15,2)$. ¿Qué concluyes?

Respuesta: (a) t con varianza agrupada (muestras pequeñas, varianzas posiblemente iguales). (b) El IC cruza el cero: no hay evidencia suficiente de que el nuevo sistema reduzca el tiempo de espera.

Pregunta de autoevaluación

Escenario B. CONEVAL reporta $\hat{\theta} = 0,363$ con $n = 105,000$. El IC al 95 % es $(0,360, 0,366)$. Un político dice: “Hay 95 % de probabilidad de que la pobreza real esté entre 36.0 % y 36.6 %.” ¿Es correcta su interpretación?

Respuesta: No. La interpretación correcta es: “Si repitiéramos el procedimiento de muestreo muchas veces, el 95 % de los intervalos construidos contendrían la verdadera proporción de pobreza.” El intervalo particular que calculó CONEVAL o contiene a θ o no lo contiene —no hay probabilidad involucrada. La confianza es del método, no del intervalo.

Pregunta de autoevaluación

Escenario C. Un IC al 90 % para σ_1^2/σ_2^2 es $(0,45, 0,92)$. ¿Son iguales las varianzas poblacionales? ¿Qué distribución usarías para comparar las medias?

Respuesta: El IC excluye al 1 (está completamente por debajo). Las varianzas son significativamente distintas. Para comparar medias, usarías t de Welch (no pooled), porque el supuesto de varianzas iguales no se sostiene.

5. Pruebas de hipótesis: los datos emiten un veredicto

5.1. La dualidad IC $\leftrightarrow$ Prueba: dos caras de la misma moneda

Herencia conceptual: Del Lab 3: cada IC contiene un veredicto; cada prueba de hipótesis tiene un IC dual

En el Lab 3 aprendiste a construir bandas de incertidumbre alrededor de tus estimadores: $\bar{X} \pm t_{\alpha/2} \cdot \hat{\sigma} / \sqrt{n}$. Cada banda respondía “el parámetro está en este rango, con esta confianza”. Pero un rango no siempre basta. Un comité legislativo no pregunta “¿cuál es el rango del ingreso promedio?” — pregunta “¿funciona o no?” Esa pregunta exige un **veredicto**: rechazar o no rechazar una hipótesis.

La conexión entre ambos laboratorios es matemáticamente exacta. **Todo** lo que aprendiste sobre distribuciones muestrales (t , Z , χ^2 , F) y errores estándar se transfiere directamente. La diferencia es *qué* pregunta respondes:

- Lab 3: “¿En qué rango está el parámetro?”
- Lab 4: “¿Es compatible el parámetro con un valor específico?”

Y la dualidad formal:

$$\theta_0 \notin \text{IC}_{1-\alpha} \iff \text{Rechazar } H_0 : \theta = \theta_0 \text{ al nivel } \alpha$$

En español: El IC reúne todos los valores que *no serían rechazados*. Si un valor cae fuera del IC, lo rechazas. Si cae dentro, no puedes rechazarlo. Esta correspondencia es el puente entre los dos capítulos.

5.2. Motivación: de la estimación al veredicto

Antes de leer: hazte esta pregunta

CONEVAL dice que el 36.3 % de los mexicanos vive en pobreza. Pero un diputado afirma que en su estado la pobreza supera el 40 %. No te pregunta “¿cuál es el rango?” Te pregunta: “¿mis datos me dan razón o no?” ¿Cómo conviertes datos en un veredicto?

En 2016, la American Statistical Association (ASA) publicó una declaración histórica sobre el uso del p -value en la investigación científica (Wasserstein y Lazar 2016, *The American Statistician*, 70(2), 129–133). Su mensaje central: un p -value no mide la probabilidad de que una hipótesis sea cierta, ni la magnitud de un efecto, ni la importancia práctica de un resultado. Mide una sola cosa: **qué tan sorprendentes son tus datos si la hipótesis nula fuera cierta.**

Caso Real: CONEVAL y la meta de pobreza: ¿se superó el umbral?

En 2022, CONEVAL reportó que el 36.3 % de la población mexicana vivía en pobreza multidimensional. Supón que una organización afirma que en una región específica, la pobreza supera el 40 %, basándose en una encuesta de $n = 500$ hogares donde 215 están en pobreza ($\hat{\theta} = 0.43$).

La pregunta no es “¿entre qué valores está la proporción real?” —eso lo resolviste en el Lab 3 con un IC—. La pregunta es: **“¿los datos constituyen evidencia suficiente para afirmar que la pobreza regional supera el 40 %?”** Esa pregunta exige una prueba de hipótesis.

Definición: Hipótesis nula (H_0) e hipótesis alternativa (H_a)

Referencia: Casella y Berger (2002, §8.1); Notas de clase, Definición 9.1.

Una **prueba de hipótesis** es un procedimiento que usa datos muestrales para decidir entre dos afirmaciones mutuamente excluyentes sobre un parámetro poblacional:

- H_0 (hipótesis nula): la afirmación “por defecto”. Se asume cierta hasta que la evidencia diga lo contrario. Tiene **presunción de inocencia**.
- H_a (hipótesis alternativa): lo que el investigador quiere probar. Requiere evidencia suficiente para ser aceptada.

Analogía judicial: H_0 = “el acusado es inocente.” H_a = “el acusado es culpable.” El juez no empieza asumiendo culpabilidad; la carga de la prueba recae en la fiscalía. Igualmente, H_0 tiene presunción de inocencia. Los datos son la evidencia. Tu estadístico de prueba es el fiscal. Y el veredicto es “rechazar H_0 ” (culpable) o “no rechazar H_0 ” (no probado).

La asimetría fundamental: “No rechazar H_0 ” no es evidencia *a favor* de H_0 — es ausencia de evidencia suficiente en contra. Un estudio con muestra pequeña puede “no rechazar” simplemente porque le falta potencia, no porque H_0 sea verdadera.

Checkpoint ✓ ¿“No rechazar H_0 ” significa que H_0 es cierta? (No. Significa que la evidencia no fue suficiente para descartarla. Es como “no culpable” —no es lo mismo que “inocente”).

5.3. La lógica de las pruebas de hipótesis

5.3.1. Errores Tipo I y Tipo II, potencia

Definición: Errores Tipo I y Tipo II

Referencia: Casella y Berger (2002, §8.3.1); Notas de clase, Definición 9.2.

Al tomar una decisión basada en datos, puedes equivocarte de dos maneras:

	H_0 verdadera	H_0 falsa
No rechazar H_0	Decisión correcta ($1 - \alpha$)	Error Tipo II (β)
Rechazar H_0	Error Tipo I (α)	Decisión correcta ($1 - \beta$)

- **Error Tipo I** (α): Rechazar H_0 cuando es cierta. “Condenar a un inocente.” Tú controlas α (usualmente 0.05, 0.01 o 0.10).
- **Error Tipo II** (β): No rechazar H_0 cuando es falsa. “Absolver a un culpable.” β depende de n , del efecto real y de α .
- **Potencia** ($1 - \beta$): Probabilidad de rechazar H_0 cuando efectivamente es falsa. Más datos $\rightarrow$ más potencia.

En español: α y β se contraponen. Reducir α (ser más exigente para condenar) aumenta β (más culpables se escapan). La única manera de reducir *ambos* es aumentar n —más evidencia.

Checkpoint ✓ Si eliges $\alpha = 0,01$ en vez de $\alpha = 0,05$, ¿qué pasa con β ? (β aumenta: al ser más estricto para rechazar, reduces la probabilidad de detectar un efecto real —salvo que compenses con más observaciones.)

Definición: El p-value

Referencia: Casella y Berger (2002, §8.3.4); Wasserstein y Lazar (2016).

El **p-value** es la probabilidad de observar un estadístico de prueba tan extremo o más extremo que el obtenido, *asumiendo que H_0 es cierta*.

En español: El p-value responde: “Si H_0 fuera cierta, ¿qué tan sorprendente sería lo que vi en mis datos?” Un p-value pequeño ($< \alpha$) $\Rightarrow$ los datos son muy improbables bajo $H_0 \Rightarrow$ rechazamos H_0 . Un p-value grande $\Rightarrow$ los datos son compatibles con H_0 .

Regla de decisión: Rechazar H_0 si p-value $< \alpha$. Esta regla produce *exactamente* el mismo resultado que comparar el estadístico de prueba con el valor crítico.

Lo que el p-value NO es (Wasserstein y Lazar 2016):

- **No** es la probabilidad de que H_0 sea cierta.
- **No** es la probabilidad de que los resultados se deban al azar.
- **No** mide la importancia práctica o sustantiva del resultado.
- Un p-value de 0.06 **no** significa “casi significativo” — α se fija *antes* de ver los datos.

Checkpoint ✓ Si el p-value es 0.03 y $\alpha = 0,05$, ¿rechazas H_0 ? (Sí: $0,03 < 0,05$. Pero si $\alpha = 0,01$, no rechazarías. La conclusión depende del α elegido *a priori*.)

Tarjeta de repaso

Los 4 pasos de toda prueba de hipótesis:

1. **Formular hipótesis.** H_0 con el valor de referencia (μ_0); H_a según lo que quieres probar.
2. **Fijar α y calcular el estadístico de prueba.** α se fija **antes** de ver los datos.
3. **Comparar.** Estadístico con valor crítico, o p-value con α . Mismo veredicto.
4. **Concluir en contexto.** “Se rechaza/no se rechaza H_0 . [Interpretación en términos del problema].”

Regla nemotécnica para el p-value: “Si el p es bajo, H_0 se va.” (p-value $< \alpha \Rightarrow$ rechazar.)

✓ Verifica tu comprensión

Verifica que entiendes los fundamentos antes de seguir:

1. ¿Por qué “no rechazar H_0 ” no es lo mismo que “ H_0 es cierta”?
2. ¿Cuál es la diferencia entre α (Error Tipo I) y el p-value?
3. Si duplicas n , ¿qué pasa con β ? ¿Y con la potencia?

5.4. Prueba para una media μ (Z y t)

Antes de leer: hazte esta pregunta

Una auditoría laboral muestrea 40 trabajadores. El salario promedio es \$12.20/hora. La STPS fija un salario mínimo sectorial de \$13.20/hora, y la varianza histórica es conocida: $\sigma = 2,50$. ¿Hay evidencia suficiente para afirmar que la empresa paga por debajo de la norma?

5.4.1. Prueba Z para μ con σ conocida

Caso Real: Auditorías salariales STPS/IMSS (México)

La Secretaría del Trabajo y Previsión Social (STPS) y el IMSS realizan verificaciones periódicas de cumplimiento de tabuladores salariales. Cuando una auditoría detecta que el promedio observado cae por debajo del umbral legal, la carga de la prueba recae en la empresa. La pregunta estadística es exactamente la del ejercicio: ¿los datos muestrales son suficientemente extremos bajo H_0 para rechazar la hipótesis de cumplimiento?

La herramienta estadística

Estadístico de prueba Z :

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$$

Regla de decisión según H_a :

H_a	Región de rechazo	p-value
$\mu < \mu_0$ (cola izq.)	$Z \leq -z_\alpha$	$P(Z \leq Z_{\text{obs}})$
$\mu > \mu_0$ (cola der.)	$Z \geq z_\alpha$	$P(Z \geq Z_{\text{obs}})$
$\mu \neq \mu_0$ (dos colas)	$ Z \geq z_{\alpha/2}$	$2 P(Z \geq Z_{\text{obs}})$

Ejemplo trabajado: Prueba Z para una media — Auditoría salarial

$H_0 : \mu = 13,20$ vs. $H_a : \mu < 13,20$ (la empresa paga por debajo). $\alpha = 0,05$.

Paso 1: Estadístico de prueba:

$$Z = \frac{12,20 - 13,20}{2,50/\sqrt{40}} = \frac{-1,00}{0,3953} = -2,53$$

Paso 2: Valor crítico: $z_{0,05} = -1,645$ (cola izquierda). Como $-2,53 \leq -1,645$, rechazamos H_0 .

Paso 3: p-value = $P(Z \leq -2,53) \approx 0,0057$. $0,0057 < 0,05 \Rightarrow$ mismo veredicto.

Conclusión: Existe evidencia estadística suficiente al 5 % para afirmar que la empresa paga por debajo de la norma de \$13.20/hora.

Dualidad IC: El IC al 95 % del Lab 3 fue $[11,43, 12,97]$. $\mu_0 = 13,20$ **no** pertenece al IC $\Rightarrow$ rechazar H_0 . Mismo veredicto, distinta presentación.

5.4.2. Prueba para μ con σ desconocida (n grande)

Ejemplo trabajado: Prueba Z con σ estimada — Contactos de ventas

Una supervisora afirma que su equipo hace ≤ 15 contactos/semana. Muestra: $n = 36$, $\bar{X} = 17$, $\hat{\sigma} = 9$. $\alpha = 0,05$.

$H_0 : \mu = 15$ vs. $H_a : \mu > 15$ (cola derecha).

$$Z = \frac{17 - 15}{9/\sqrt{36}} = \frac{2}{1,5} = 1,333$$

Valor crítico: $z_{0,05} = 1,645$. Como $1,333 < 1,645$, **no se rechaza** H_0 . p-value = $P(Z \geq 1,333) \approx 0,091 > 0,05$.

Conclusión: Con 36 observaciones, la diferencia de 2 contactos no es suficiente para contradecir a la supervisora al 5%. Si aumentáramos n , la misma diferencia podría volverse significativa.

5.4.3. Prueba t para μ con muestra pequeña

Cuando $n < 30$ y σ es desconocida, usas la distribución t de Student. El estadístico es estructuralmente idéntico al caso Z , pero con $\hat{\sigma}$ y valores críticos de la tabla t :

$$T = \frac{\bar{X} - \mu_0}{\hat{\sigma}/\sqrt{n}} \sim t_{n-1} \text{ bajo } H_0$$

La lógica de decisión es la misma, pero los valores críticos $t_{\alpha, n-1}$ son mayores que z_α para el mismo α —reflejando la incertidumbre adicional de estimar σ .

Tarjeta de repaso

Frente: Árbol de decisión para prueba de una media.

Reverso:

1. ¿ σ conocida? $\rightarrow$ usa Z siempre.
2. ¿ σ desconocida, $n \geq 30$? $\rightarrow$ usa Z (TLC).
3. ¿ σ desconocida, $n < 30$, población normal? $\rightarrow$ usa t_{n-1} .

Nota: cuando estimas σ , la distribución **exacta** es t . La regla “ $n \geq 30 \Rightarrow Z$ ” es una aproximación asintótica basada en que $t_{n-1} \rightarrow N(0, 1)$ con n grande. En econometría, donde siempre estimas σ , la t es el estándar; Z es su caso límite.

Pregunta de autoevaluación

Un regulador ambiental monitorea plomo en agua. Norma: $\mu_0 = 15$ ppb. Muestra: $n = 25$, $\bar{X} = 17,4$, $\sigma = 5$ conocida. $\alpha = 0,01$.

- (a) Plantea H_0 y H_a . (Una cola derecha: $H_0 : \mu = 15$, $H_a : \mu > 15$.)
- (b) Calcula Z y el p-value. ($Z = 2,40$, p-value $\approx 0,0082$.)
- (c) ¿Se rechaza H_0 ? (Sí: $0,0082 < 0,01$.)

- (d) Si el regulador usa $\alpha = 0,001$, ¿cambia la conclusión? ¿Cuál es el costo? (No se rechazaría. Costo: aumenta β —más riesgo de dejar pasar contaminación real.)

5.5. Prueba para una proporción π

Antes de leer: hazte esta pregunta

CONEVAL reporta 67 % de prevalencia nacional de exceso de peso. Una investigadora muestrea 100 adultos en una región y encuentra 70 con exceso de peso. ¿Es esto evidencia de que la región supera el nivel nacional?

Caso Real: ENSANUT y el sobrepeso en adultos mexicanos

La Encuesta Nacional de Salud y Nutrición (ENSANUT 2012) reportó que aproximadamente el 67 % de los adultos mexicanos presentaba exceso de peso (sobrepeso + obesidad). Cuando un investigador evalúa una región específica, la pregunta no es “¿cuál es la proporción?” sino “¿la región supera el umbral nacional?”

La herramienta estadística

Estadístico Z para una proporción:

$$Z = \frac{\hat{\theta} - \theta_0}{\sqrt{\theta_0(1 - \theta_0)/n}} \quad \text{o equivalentemente:} \quad Z = \frac{X - n\theta_0}{\sqrt{n\theta_0(1 - \theta_0)}}$$

Regla crucial: En el denominador usas θ_0 (el valor de H_0), **no** $\hat{\theta}$. ¿Por qué? Porque la prueba asume que H_0 es cierta. Si H_0 dice $\theta = \theta_0$, la varianza bajo H_0 es $\theta_0(1 - \theta_0)$, no $\hat{\theta}(1 - \hat{\theta})$.

Contraste con el IC: En el IC del Lab 3 sí usas $\hat{\theta}$ en el error estándar, porque ya no asumes un valor específico.

Ejemplo trabajado: Prueba para una proporción — Exceso de peso regional

$H_0 : \theta = 0,67$ vs. $H_a : \theta > 0,67$, $\alpha = 0,01$. $n = 100$, $X = 70$ (70 personas con exceso de peso).

$$Z = \frac{70 - 100(0,67)}{\sqrt{100(0,67)(0,33)}} = \frac{70 - 67}{\sqrt{22,11}} = \frac{3}{4,702} = 0,638$$

Valor crítico: $z_{0,01} = 2,33$. $0,638 < 2,33 \Rightarrow$ **no se rechaza H_0** . p-value = $P(Z \geq 0,638) \approx 0,26 \gg 0,01$.

Conclusión: Observar 70 de 100 personas con exceso de peso es perfectamente compatible con una prevalencia del 67 %. La diferencia de +3 personas está dentro

del ruido muestral esperado. No hay evidencia de que la región supere el nivel nacional.

Ejemplo trabajado: Prueba bilateral para proporción — Participación electoral

El INE reporta que la participación histórica en elecciones presidenciales ronda el 67 %. Un politólogo muestrea $n = 300$ votantes y encuentra 192 que votaron ($\hat{\theta} = 0,64$). ¿Cambió la participación?

$H_0 : \theta = 0,67$ vs. $H_a : \theta \neq 0,67$ (dos colas), $\alpha = 0,05$.

$$Z = \frac{192 - 300(0,67)}{\sqrt{300(0,67)(0,33)}} = \frac{192 - 201}{\sqrt{66,33}} = \frac{-9}{8,144} = -1,105$$

Valor crítico bilateral: $z_{0,025} = \pm 1,96$. $|-1,105| = 1,105 < 1,96 \Rightarrow$ **no se rechaza**.
p-value = $2 \times P(Z \leq -1,105) \approx 0,269 > 0,05$.

Conclusión: No hay evidencia suficiente de que la participación haya cambiado respecto al 67 % histórico. La diferencia observada (–3 puntos porcentuales) es compatible con fluctuación muestral.

Tarjeta de repaso

Frente: ¿Por qué el denominador de la prueba para proporciones usa θ_0 y no $\hat{\theta}$?

Reverso: Porque la prueba evalúa los datos *asumiendo que H_0 es cierta*. Si H_0 postula $\theta = \theta_0$, la varianza bajo H_0 es $\theta_0(1 - \theta_0)/n$. Usar $\hat{\theta}$ sería calcular la variabilidad bajo el supuesto de que H_a es cierta —incoherente con la lógica de la prueba.

Recordatorio: En el IC del Lab 3 **sí** usas $\hat{\theta}$ porque estimas la varianza sin asumir un valor específico.

Pregunta de autoevaluación

CONEVAL encuesta $n = 500$ hogares: 310 en pobreza ($\hat{\theta} = 0,62$). Referencia nacional: $\theta_0 = 0,578$.

- (a) Prueba bilateral con $\alpha = 0,05$. ($Z = 1,901$, p-value = 0,057; no se rechaza al 5 % —barely.)
- (b) ¿Cómo cambiaría con una prueba de cola derecha? (p-value = 0,029 < 0,05 $\Rightarrow$ sí se rechazaría. La dirección de H_a importa.)

5.6. Prueba para una varianza σ^2 (χ^2)

Antes de leer: hazte esta pregunta

Dos máquinas empacan harina con el mismo peso promedio (1,000 g). Una varía entre 995 y 1,005 g; la otra, entre 960 y 1,040 g. Para el consumidor, ¿son equivalentes? ¿Qué herramienta detecta la diferencia si el promedio no basta?

Caso Real: Volatilidad del IPC México vs. benchmark de riesgo (2024)

Con datos de Yahoo Finance para 2024 ($n = 249$ días), la varianza de los retornos diarios del IPC México fue $\hat{\sigma}^2 = 0,9091 \%$. Un modelo de riesgo establece que la volatilidad “normal” es $\sigma_0^2 = 1,0 \%$. ¿Fue 2024 un año inusualmente tranquilo? $H_0 : \sigma^2 = 1,0$ vs. $H_a : \sigma^2 < 1,0$ (cola izquierda), $\alpha = 0,05$.

$$\chi^2 = \frac{(249 - 1)(0,9091)}{1,0} = 225,46$$

Valor crítico: $\chi_{0,95,248}^2 \approx 213$. Como $225,46 > 213$, **no se rechaza** H_0 . La varianza observada es menor que 1.0, pero no lo suficiente para ser estadísticamente significativo. 2024 no fue inusualmente tranquilo.

La herramienta estadística

Estadístico χ^2 para una varianza:

$$\chi^2 = \frac{(n - 1)\hat{\sigma}^2}{\sigma_0^2} \sim \chi_{n-1}^2 \text{ bajo } H_0 \text{ (población normal)}$$

La χ^2 es asimétrica: A diferencia de Z (simétrica alrededor de 0), los valores críticos izquierdo y derecho son distintos en magnitud. En pruebas bilaterales, debes buscar ambos por separado.

Regiones de rechazo:

- $H_a : \sigma^2 > \sigma_0^2 \Rightarrow$ rechazar si $\chi^2 \geq \chi_{\alpha, n-1}^2$
- $H_a : \sigma^2 < \sigma_0^2 \Rightarrow$ rechazar si $\chi^2 \leq \chi_{1-\alpha, n-1}^2$
- $H_a : \sigma^2 \neq \sigma_0^2 \Rightarrow$ rechazar si $\chi^2 \notin [\chi_{1-\alpha/2}^2, \chi_{\alpha/2}^2]$

Supuesto sensible: Esta prueba requiere normalidad de la población. Es más sensible a violaciones de este supuesto que las pruebas para medias.

Ejemplo trabajado: Prueba χ^2 para varianza — Precisión de máquina de empaque

El proveedor afirma que una máquina tiene $\sigma_0^2 = 0,4$. Una muestra de $n = 8$ piezas da $\hat{\sigma}^2 = 0,018$. ¿Es la máquina más precisa de lo que afirma el proveedor? $H_0 : \sigma^2 = 0,4$ vs. $H_a : \sigma^2 < 0,4$, $\alpha = 0,05$.

$$\chi^2 = \frac{7 \times 0,018}{0,4} = 0,315$$

Valor crítico: $\chi^2_{0,95,7} \approx 2,167$. Como $0,315 < 2,167$, se **rechaza** H_0 . p-value $\approx 0,00001$.

Conclusión: La varianza observada (0.018) es tan extraordinariamente pequeña comparada con $\sigma_0^2 = 0,4$ que la evidencia es abrumadora: la máquina es mucho más precisa de lo que afirma el proveedor.

Tarjeta de repaso

Frente: ¿Por qué la prueba χ^2 requiere dos valores críticos distintos en pruebas bilaterales?

Reverso: Porque χ^2 es **asimétrica** (sesgada a la derecha). No es simétrica alrededor de cero como Z . $\chi^2_{0,025,n-1} \neq \chi^2_{0,975,n-1}$ en magnitud. Para Z , en cambio, $z_{0,025} = -z_{0,975}$ (simetría perfecta).

Pregunta de autoevaluación

Una empresa afirma $\sigma_0 = 3$ min ($\sigma_0^2 = 9$) en atención telefónica. Auditor: $n = 20$, $\hat{\sigma}^2 = 14,4$. Prueba bilateral, $\alpha = 0,05$. $\chi^2_{0,025,19} = 8,907$, $\chi^2_{0,975,19} = 32,852$.

Respuesta: $\chi^2 = 19(14,4)/9 = 30,4$. Como $8,907 < 30,4 < 32,852$, no se rechaza. La varianza observada es mayor, pero no significativamente.

5.7. Prueba para diferencia de medias

Antes de leer: hazte esta pregunta

Card y Krueger compararon el empleo en Nueva Jersey (salario mínimo subió) vs. Pensilvania (no subió): $n_1 = 130$, $\bar{X}_1 = 9,017$ FTE; $n_2 = 80$, $\bar{X}_2 = 5,853$ FTE. ¿Destruyó empleo el aumento? ¿O la diferencia es abrumadoramente en la dirección opuesta?

5.7.1. Prueba t pooled (varianzas iguales, muestras pequeñas)

Caso Real: Control de calidad: durabilidad de pinturas

Dos marcas de pintura, $n_1 = n_2 = 4$ latas cada una:

Marca	n	$\bar{X}$ (cm ²)	$\hat{\sigma}$
Marca 1	4	1,650	93
Marca 2	4	1,488	78

¿Cubre la Marca 1 significativamente más área? $H_0 : \mu_1 = \mu_2$ vs. $H_a : \mu_1 > \mu_2$,

$$\alpha = 0,01.$$

La herramienta estadística

Estadístico t con varianza agrupada (pooled):

$$\hat{\sigma}_p^2 = \frac{(n_1 - 1)\hat{\sigma}_1^2 + (n_2 - 1)\hat{\sigma}_2^2}{n_1 + n_2 - 2}, \quad T = \frac{(\bar{X}_1 - \bar{X}_2) - \Delta_0}{\hat{\sigma}_p \sqrt{1/n_1 + 1/n_2}}$$

Bajo H_0 , $T \sim t_{n_1+n_2-2}$. El supuesto clave es $\sigma_1^2 = \sigma_2^2$.

Cuándo usar pooled vs. Welch:

- $\sigma_1^2 = \sigma_2^2$ (varianzas iguales) $\Rightarrow t$ pooled.
- $\sigma_1^2 \neq \sigma_2^2$ (varianzas distintas) $\Rightarrow t$ de Welch (grados de libertad de Satterthwaite).

¿Cómo saber cuál aplica? Con la **prueba F** — Sección 5.8.

Ejemplo trabajado: Prueba t pooled — Pinturas

Paso 1: Varianza agrupada:

$$\hat{\sigma}_p^2 = \frac{3(93^2) + 3(78^2)}{6} = \frac{3(8649) + 3(6084)}{6} = \frac{44,199}{6} = 7,366,5, \quad \hat{\sigma}_p = 85,83$$

Paso 2: Estadístico:

$$T = \frac{1,650 - 1,488}{85,83 \times \sqrt{1/4 + 1/4}} = \frac{162}{60,69} = 2,669$$

Paso 3: $t_{0,01,6} = 3,143$. Como $2,669 < 3,143$, **no se rechaza** al 1 %. p-value $\approx 0,019 > 0,01$.

Nota: Con $\alpha = 0,05$, $t_{0,05,6} = 1,943$. Como $2,669 > 1,943$, sí se rechazaría al 5 %. La conclusión depende del α elegido.

5.7.2. Prueba Z para diferencia de medias (muestras grandes)

Ejemplo trabajado: Prueba Z para diferencia de medias — Card & Krueger

$n_1 = 130$, $\bar{X}_1 = 9,017$, $\hat{\sigma}_1 = 2,162$; $n_2 = 80$, $\bar{X}_2 = 5,853$, $\hat{\sigma}_2 = 1,961$.

$H_0 : \mu_1 - \mu_2 = 0$ vs. $H_a : \mu_1 - \mu_2 > 0$ (NJ no cayó), $\alpha = 0,05$.

$$Z = \frac{9,017 - 5,853}{\sqrt{2,162^2/130 + 1,961^2/80}} = \frac{3,164}{\sqrt{35,956 + 48,069}} = \frac{3,164}{289,87} = 10,915$$

$z_{0,05} = 1,645$. $10,915 \gg 1,645 \Rightarrow$ rechazar contundentemente. p-value $\approx 10^{-27}$.

Conclusión: La evidencia es abrumadora. NJ no experimentó una caída de empleo

relativa a PA. Al contrario, el empleo en NJ fue significativamente mayor. Este resultado, contrario a la teoría neoclásica, convirtió a Card y Krueger (1994) en uno de los artículos más citados de la economía laboral.

Nota didáctica

Datos contruidos con fines pedagógicos. Los valores de este ejemplo son estilizados: no corresponden a las cifras originales del artículo de Card & Krueger (las medias reales oscilan alrededor de \$4–5/hora, no \$9,017 y \$5,853). El error estándar de 289,87 está en la misma escala que los datos del ejemplo. La lección relevante es que el estadístico Z resultante (10,915) captura una diferencia de 3,164 unidades entre medias que es aproximadamente 11 veces mayor que su error estándar — una señal estadística inequívoca. Para el análisis original de Card & Krueger, el diseño adecuado es diferencia-en-diferencias (no una simple diferencia de medias transversales), y el error estándar relevante incorpora la correlación temporal de las observaciones repetidas en los mismos establecimientos.

Tarjeta de repaso

Frente: Árbol de decisión para prueba de diferencia de medias.

Reverso:

1. ¿ $n_1, n_2 \geq 30$? **Sí** → usa Z . **No** → paso 2.
2. ¿Distribución normal? **No** → prueba no paramétrica. **Sí** → paso 3.
3. ¿Varianzas iguales? Verifica con prueba F (Sección 5.8). **Sí** → t pooled. **No** → t de Welch.

Pregunta de autoevaluación

IMSS regional: médicos generales ($n_1 = 60$, $\bar{X}_1 = 87$, $\hat{\sigma}_1 = 12$) vs. especialistas ($n_2 = 45$, $\bar{X}_2 = 82$, $\hat{\sigma}_2 = 15$). Prueba bilateral, $\alpha = 0,05$.

Respuesta: $Z = 5 / \sqrt{144/60 + 225/45} = 5 / \sqrt{7,4} = 1,838$. p-value = 0,066 > 0,05. No se rechaza. No hay evidencia suficiente de diferencia al 5 %.

5.8. Prueba para razón de varianzas y la secuencia $F \rightarrow t$

Antes de leer: hazte esta pregunta

Antes de comparar los salarios promedio de dos departamentos, un estadístico te dice: “primero necesito saber si la dispersión de sueldos es parecida.” ¿Por qué? ¿Qué cambiaría en la prueba de medias si las varianzas fueran muy distintas?

Caso Real: IPC México vs. S&P 500: ¿quién es más volátil? (2024)

Datos de Yahoo Finance, año 2024:

Índice	n	$\hat{\sigma}^2$ (% ² /día)	$\hat{\sigma}$ (%/día)
IPC México	249	0.9091	0.9535
S&P 500	250	0.6373	0.7983

$H_0 : \sigma_{\text{IPC}}^2 = \sigma_{\text{SP}}^2$ vs. $H_a : \sigma_{\text{IPC}}^2 > \sigma_{\text{SP}}^2$, $\alpha = 0,05$.

La herramienta estadística

Estadístico F para razón de varianzas:

$$F = \frac{\hat{\sigma}_1^2}{\hat{\sigma}_2^2} \sim F_{n_1-1, n_2-1} \text{ bajo } H_0 : \sigma_1^2 = \sigma_2^2$$

Regla práctica para pruebas unilaterales: Pon la varianza que sospechas mayor en el numerador. Si H_a dice $\sigma_1^2 > \sigma_2^2$, usa $F = \hat{\sigma}_1^2 / \hat{\sigma}_2^2$ y rechaza si $F \geq F_{\alpha, n_1-1, n_2-1}$.

Para pruebas bilaterales (convención): coloca la mayor varianza muestral en el numerador para que $F \geq 1$ y compara con $F_{\alpha/2}$.

Cálculo IPC vs. S&P:

$$F = \frac{0,9091}{0,6373} = 1,4265, \quad \nu_1 = 248, \nu_2 = 249$$

$F_{0,05,248,249} \approx 1,238$. $1,4265 > 1,238 \Rightarrow$ **rechazar**. p-value $\approx 0,004$.

Conclusión: El IPC México fue significativamente más volátil que el S&P 500 en 2024. La diferencia no es trivial: el IPC tuvo caídas de hasta $-6,11\%$ vs. $-3,00\%$ del S&P 500.

5.8.1. La secuencia $F \rightarrow t$: primero varianzas, luego medias

Caso Real: Umbral de dolor en hombres y mujeres (Ej. 3.3, Lab 4)

Un estudio mide el umbral de dolor en dos grupos. Antes de comparar medias, se verifica si las varianzas son iguales:

- Hombres: $n_1 = 14$, $\bar{Y}_1 = 16,2$, $\hat{\sigma}_1^2 = 12,7$
- Mujeres: $n_2 = 10$, $\bar{Y}_2 = 14,9$, $\hat{\sigma}_2^2 = 26,4$

Paso A — Prueba F (bilateral, $\alpha = 0,10$): $F = 26,4/12,7 = 2,079$, $\nu_1 = 9$, $\nu_2 = 13$. $F_{0,05,9,13} \approx 2,71$. $2,079 < 2,71 \Rightarrow$ **no se rechaza** igualdad de varianzas.

Paso B — Prueba t (decisión condicionada por Paso A): Como no se rechazó igualdad de varianzas, usamos t pooled:

$$\hat{\sigma}_p^2 = \frac{13(12,7) + 9(26,4)}{22} = 18,305, \quad T = \frac{16,2 - 14,9}{\sqrt{18,305(1/14 + 1/10)}} = 0,734$$

$t_{0,05,22} \approx 1,717$. $0,734 < 1,717 \Rightarrow$ no se rechaza $H_0 : \mu_1 = \mu_2$.

Conclusión integral: Ni las varianzas ni las medias difieren significativamente. Los datos son consistentes con igualdad entre grupos.

Tarjeta de repaso

Frente: La secuencia $F \rightarrow t$ en una línea.

Reverso:

1. **Prueba F :** ¿son iguales las varianzas? ($H_0 : \sigma_1^2 = \sigma_2^2$)
2. **Si no rechazas** $\rightarrow$ usa t pooled (`var.equal=TRUE`).
3. **Si rechazas** $\rightarrow$ usa t de Welch (`var.equal=FALSE`).

El resultado de la prueba F **determina** qué herramienta usas para comparar medias. Esta estructura anticipa el ANOVA: primero evalúas supuestos, luego comparas.

Nota didáctica

Precaución sobre la preprueba $F \rightarrow t$. La secuencia “prueba F para decidir pooled vs. Welch” es un procedimiento en dos etapas que introduce problemas conocidos: (1) la prueba F tiene baja potencia para detectar heterocedasticidad con muestras pequeñas, por lo que “no rechazar” no constituye evidencia positiva de igualdad de varianzas; (2) la decisión en dos etapas altera las propiedades del error Tipo I de la prueba t subsecuente. En la práctica contemporánea, muchos libros de texto y paquetes estadísticos (como R por defecto en `t.test`) recomiendan usar directamente la versión de Welch, que no asume varianzas iguales y tiene buen desempeño incluso cuando las varianzas *son* iguales. La secuencia $F \rightarrow t$ se presenta aquí por su valor pedagógico —ilustra la conexión entre ambas pruebas—, no como una recomendación incondicional para la práctica aplicada.

Pregunta de autoevaluación

Algoritmo A: $n_1 = 25$, $\bar{X}_1 = 120$, $\hat{\sigma}_1^2 = 400$. Algoritmo B: $n_2 = 30$, $\bar{X}_2 = 132$, $\hat{\sigma}_2^2 = 900$.

- (a) Prueba F bilateral al 10 %: $F_{0,05,29,24} \approx 2,10$. $F = 900/400 = 2,25 > 2,10 \Rightarrow$ rechazar. Varianzas distintas.
- (b) Según (a), usa t de Welch. $T = -1,769$, gl Satterthwaite ≈ 47 , $t_{0,025,47} \approx 2,01$. No se rechaza al 5 %. No hay diferencia significativa entre medias.

Mapa de decisiones: ¿qué prueba uso?

¿Qué pruebo?	Dist.	Ref.	Cola según H_a
Una media μ (σ conocida)	Z	μ_0	$<, >, \neq$
Una media μ (σ desc., n grande)	Z (TLC)	μ_0	$<, >, \neq$
Una media μ (σ desc., n chico)	t_{n-1}	μ_0	$<, >, \neq$
Diferencia de medias (grande)	Z	0	$<, >, \neq$
Diferencia de medias (chico, pooled)	t pooled	0	$<, >, \neq$
Una proporción θ	Z	θ_0	$<, >, \neq$
Una varianza σ^2	χ^2	σ_0^2	$<, >, \neq$
Razón de varianzas	F	1	$<, >, \neq$

Tarjeta de repaso**Reglas nemotécnicas:**

- **Diferencia:** referencia = 0. Si el 0 está lejos, hay diferencia.
- **Razón:** referencia = 1. Si el 1 está lejos, no son iguales.
- **Una cola:** cuando la pregunta es direccional (“mayor que”, “menor que”).
- **Dos colas:** cuando la pregunta es “distinto de” sin dirección.
- θ_0 en el **denominador** (proporciones): porque asumes H_0 cierta.
- α se **fija antes:** nunca elijas α después de ver los datos.

5.9. De la prueba t al ANOVA: cuando comparar dos grupos no es suficiente

Conexión: Lab 4 → Lab 5

Has pasado dos laboratorios enteros aprendiendo a comparar **dos** grupos. La prueba t para diferencia de medias, el IC para $\mu_1 - \mu_2$, la prueba F para razón de varianzas —todas operan sobre **pares**. Dos marcas de pintura. Dos estados (NJ vs. PA). Dos tipos de llantas. Hombres vs. mujeres.

Pero el mundo rara vez viene en pares.

El problema: cuando dejas de comparar dos grupos

Imagina que eres economista en CONEVAL y necesitas comparar la tasa de pobreza en las **cinco** regiones de México: Noroeste, Noreste, Centro, Occidente y Sur. Tienes datos de ingreso para cada región. Quieres saber: ¿el ingreso promedio difiere entre regiones?

Con las herramientas del Lab 4, tu instinto sería hacer pruebas t entre todos los pares posibles. ¿Cuántas pruebas? El número de combinaciones de 5 regiones tomadas de 2 en 2:

$$\binom{5}{2} = \frac{5 \times 4}{2} = 10 \text{ pruebas } t$$

Diez pruebas. Cada una con su propio $\alpha = 0,05$. ¿Cuál es la probabilidad de cometer **al menos un** Error Tipo I en esas 10 pruebas, asumiendo que todas las H_0 son verdaderas?

Si las pruebas fueran independientes:

$$P(\text{al menos un Error Tipo I}) = 1 - (1 - 0,95)^{10} = 1 - 0,95^{10} \approx 1 - 0,599 = 0,401$$

¡40 %! Tu probabilidad de encontrar una diferencia *falsa* (rechazar incorrectamente al menos una H_0) se ha inflado de 5 % a 40 %. Y esto es solo con 5 grupos. ¿Qué pasa con 32 estados de la República Mexicana?

$$\binom{32}{2} = 496 \text{ pruebas } t, \quad P(\text{al menos un Error Tipo I}) \approx 1 - 0,95^{496} \approx 1,000$$

Con 32 grupos, es **prácticamente seguro** que encontrarás diferencias “significativas” que son puro ruido. Este fenómeno se llama **inflación del error Tipo I por comparaciones múltiples**, y es la razón por la que no puedes simplemente hacer pruebas t por pares cuando tienes más de dos grupos.

La solución: ANOVA pregunta “¿son todos iguales?” con una sola prueba

El **Análisis de Varianza** (ANOVA) resuelve este problema de raíz. En vez de hacer $\binom{k}{2}$ pruebas t , ANOVA formula **una sola** pregunta con **una sola** prueba:

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_k \quad \text{vs.} \quad H_a : \text{al menos un } \mu_i \text{ es diferente}$$

Una sola prueba F responde si *alguna* región tiene un ingreso promedio distinto. Solo si ANOVA rechaza H_0 , entonces —y solo entonces— procedes a identificar *cuáles* pares son diferentes, usando métodos que corrigen por comparaciones múltiples (Tukey, Bonferroni).

La conexión profunda: para 2 grupos, $F = t^2$

Aquí está la sutura matemática más elegante entre el Lab 4 y el Lab 5. Cuando solo tienes **dos** grupos, la prueba F de ANOVA y la prueba t pooled producen **exactamente** el mismo veredicto. De hecho:

$$F = t^2 \quad \text{cuando } k = 2$$

En el ejemplo de las pinturas (Sección 5.8), obtuviste $T = 2,669$. Si aplicaras ANOVA a esos mismos datos, obtendrías $F = 2,669^2 = 7,124$, y el p-value sería idéntico. **ANOVA contiene a la prueba t como caso particular.** No son herramientas separadas: son una escalera conceptual.

De la varianza de $\bar{X}$ a la descomposición de varianza

En el Lab 1 aprendiste que $\text{Var}(\bar{X}) = \sigma^2/n$: la varianza del promedio muestral depende de la dispersión de los datos. Ese concepto es el ancestro directo de la idea central de ANOVA.

ANOVA descompone la variabilidad total de los datos en dos fuentes:

$$\underbrace{\text{SCT}}_{\text{variabilidad total}} = \underbrace{\text{SCE}}_{\text{variabilidad entre grupos}} + \underbrace{\text{SCR}}_{\text{variabilidad dentro de grupos}}$$

- **SC_Entre:** ¿qué tan distintas son las medias de los grupos entre sí? Si las medias regionales son muy diferentes, SCE es grande.
- **SC_Dentro:** ¿qué tanta variabilidad hay *dentro* de cada grupo? Incluso dentro de una misma región, los hogares tienen ingresos distintos.

La intuición es directa: si las diferencias *entre* regiones son grandes comparadas con la variabilidad *dentro* de cada región, entonces las regiones realmente difieren. Si la variabilidad dentro de cada región es enorme, las diferencias entre regiones podrían ser solo ruido. ANOVA formaliza esta intuición con el estadístico:

$$F = \frac{\text{SC_Entre}/(k-1)}{\text{SC_Dentro}/(n-k)} = \frac{\text{variabilidad entre grupos}}{\text{variabilidad dentro de grupos}}$$

Cuando F es grande (mucho mayor que 1), rechazas H_0 : las medias no son todas iguales.

Lo que te espera en el Lab 5

En el Lab 5 verás:

- La **tabla ANOVA**: cómo se organizan SCE, SCR, SCT, los grados de libertad y los cuadrados medios.
- El **estadístico F** y su interpretación: ¿las diferencias entre grupos son grandes relativo al ruido?
- Los **supuestos** de ANOVA: normalidad, homocedasticidad (igualdad de varianzas) e independencia. La prueba F para razón de varianzas que aprendiste en el Lab 3 (y usaste en la secuencia $F \rightarrow t$ de este capítulo) es exactamente la herramienta para verificar homocedasticidad.
- Las **comparaciones múltiples**: cuando ANOVA rechaza H_0 , ¿cómo identificas *cuáles* grupos difieren sin inflar el Error Tipo I? Métodos como Tukey HSD y Bonferroni controlan el error global.
- **Datos mexicanos reales**: ingresos por región (ENIGH), gasto en alimentos por decil, tasas de pobreza por tipo de municipio (CONEVAL).

La escalera conceptual:

Prueba t (2 grupos) $\subset$ ANOVA (k grupos) $\subset$ Regresión (variables continuas)

La prueba t compara dos medias. ANOVA extiende esa lógica a k grupos descomponiendo la varianza. La regresión extiende ANOVA a variables continuas, modelando la relación con una pendiente. El Lab 5 es el escalón que te lleva de “comparar” a “modelar”.

En resumen: El Lab 4 te enseñó a emitir veredictos sobre parámetros individuales y diferencias entre *dos* grupos. El Lab 5 toma esa maquinaria —las distribuciones t y F , la lógica de H_0 vs. H_a , el control del Error Tipo I— y la escala a *múltiples* grupos simultáneamente. No es una herramienta nueva: es la misma lógica, aplicada a una pregunta más ambiciosa.

Autoevaluación: ¿entiendes el veredicto, no solo el cálculo?

Pregunta de autoevaluación

Escenario A. Un investigador prueba $H_0 : \mu = 100$ vs. $H_a : \mu \neq 100$. Obtiene $Z = 1,88$ con $n = 50$. $\alpha = 0,05$.

- ¿Cuál es el p-value? ($2 \times P(Z \geq 1,88) \approx 0,060$.)
- ¿Se rechaza H_0 al 5 %? (No: $0,060 > 0,05$.)
- ¿Se rechazaría al 10 %? (Sí: $0,060 < 0,10$. La conclusión depende de α .)

- (d) El investigador dice: “El p-value de 0.06 significa que hay 6 % de probabilidad de que H_0 sea cierta.” ¿Es correcto? (No. El p-value es la probabilidad de los datos bajo H_0 , no la probabilidad de H_0 .)

Pregunta de autoevaluación

Escenario B. Comparas 4 regiones. Un colega sugiere hacer 6 pruebas t por pares con $\alpha = 0,05$ cada una.

- ¿Cuál es el problema con esta estrategia? (Inflación del Error Tipo I: $P(\text{al menos un falso positivo}) \approx 1 - 0,95^6 \approx 26\%$.)
- ¿Qué herramienta resuelve este problema? (ANOVA: una sola prueba F para $H_0 : \mu_1 = \mu_2 = \mu_3 = \mu_4$.)
- Si ANOVA rechaza H_0 , ¿cómo identificas qué pares difieren sin inflar el error? (Comparaciones múltiples con corrección: Tukey HSD, Bonferroni.)

Pregunta de autoevaluación

Escenario C. Un regulador prueba $H_0 : \sigma^2 = 9$ vs. $H_a : \sigma^2 > 9$ con $n = 25$, $\hat{\sigma}^2 = 14,4$, $\alpha = 0,05$. $\chi_{0,05,24}^2 = 36,415$.

Respuesta: $\chi^2 = 24(14,4)/9 = 38,4 > 36,415 \Rightarrow$ rechazar H_0 . La varianza es significativamente mayor que 9. El proceso es más variable de lo permitido.

✓ Verifica tu comprensión

Antes de pasar al Lab 5, asegúrate de poder responder:

- ¿Por qué “no rechazar H_0 ” no es lo mismo que “ H_0 es cierta”?
- ¿Qué mide el p-value? ¿Qué NO mide?
- ¿Por qué no puedes hacer pruebas t por pares cuando tienes más de 2 grupos?
- Para 2 grupos, ¿cuál es la relación entre F (ANOVA) y t (pooled)?
- ¿Qué descompone ANOVA: medias o varianzas?

Parte III

**Comparar y modelar: de una
variable a relaciones entre variables**

6. ANOVA de una vía: comparar muchos grupos sin inflar el error

Herencia conceptual: Del Lab 1: $\text{Var}(\bar{X})$ es la precursora de $\text{SC}_{\text{Dentro}}$. Del Lab 4: la prueba t se generaliza a F ($F = t^2$ para $k = 2$). Del Lab 3: el IC para diferencia de medias anticipa las comparaciones múltiples.

6.1. El problema de las muchas comparaciones

Antes de leer: hazte esta pregunta

El INEGI reporta el ingreso laboral trimestral promedio para cada uno de los 32 estados de la República Mexicana. Naturalmente, los promedios muestrales son distintos: Nuevo León \$72,000, Oaxaca \$38,000, CDMX \$65,000... La pregunta no es *si* son distintos en la muestra (siempre lo serán), sino: **¿son esas diferencias lo suficientemente grandes para afirmar que no todos los estados tienen el mismo ingreso medio poblacional?**

6.1.1. El costo de hacer demasiadas pruebas

Si tienes k grupos y quieres saber si alguno es diferente, podrías comparar todos los pares posibles con pruebas t . Con $k = 32$ estados, el número de pares es:

$$\binom{32}{2} = \frac{32 \times 31}{2} = 496$$

Ahora considera el efecto acumulado del error Tipo I. Si realizas m pruebas independientes, cada una con nivel de significancia α , la probabilidad de cometer **al menos un** error Tipo I es:

$$P(\text{al menos un error}) = 1 - (1 - \alpha)^m$$

Para $\alpha = 0,05$ y $m = 496$:

$$P(\text{al menos un error}) = 1 - (0,95)^{496} \approx 1 - 0,00000000000008 \approx 1,0$$

Es prácticamente seguro que encontrarás “diferencias significativas” que son puro ruido.

Definición: El problema de comparaciones múltiples

Si realizas m pruebas de hipótesis independientes, cada una con nivel α , la probabilidad de cometer **al menos un** error Tipo I es:

$$P(\text{al menos un error}) = 1 - (1 - \alpha)^m$$

Para $m = 10$ pruebas con $\alpha = 0,05$: $1 - (0,95)^{10} \approx 0,401$. Es decir, ¡hay 40 % de probabilidad de encontrar al menos una “diferencia significativa” falsa!

En español: Hacer muchas pruebas t es como tirar una moneda muchas veces: eventualmente sale cara. ANOVA resuelve esto haciendo **una sola prueba** que controla el error global.

Referencia formal: Wackerly §13.3; Casella & Berger §11.1–11.2; Notas de clase.

Caso Real: Desigualdad regional en México

El ingreso laboral promedio en México varía sustancialmente entre entidades federativas. De acuerdo con la ENOE (INEGI, 2023), el ingreso trimestral oscila entre aproximadamente \$35,000 en Chiapas y \$78,000 en Nuevo León. Pero estas son estimaciones muestrales: cada estado tiene variabilidad interna (hay personas de alto y bajo ingreso en todos los estados).

Si hicieras 496 pruebas t , la probabilidad de encontrar al menos un falso positivo es virtualmente 100 %. La pregunta ANOVA es: **¿la variación entre estados es mayor que la que esperaríamos solo por la variabilidad natural entre personas del mismo estado?** Una sola prueba responde.

Tarjeta de repaso

Frente: ¿Por qué no podemos hacer pruebas t entre todos los pares de grupos?

Reverso: Porque cada prueba t tiene probabilidad α de error Tipo I. Con m pruebas, la probabilidad de *al menos* un error es $1 - (1 - \alpha)^m$, que crece rápidamente. Con 32 grupos ($m = 496$), esta probabilidad es prácticamente 1. ANOVA resuelve esto con **una sola prueba** que controla el error global. Es como preguntar “¿son todos iguales?” en vez de preguntar 496 veces “¿son estos dos iguales?”.

Pregunta de autoevaluación

¿Cuántos pares de comparaciones hay con $k = 10$ grupos? Si haces todas las pruebas t al $\alpha = 0,05$ sin corregir, ¿cuál es la probabilidad de al menos un error Tipo I? ¿Qué pasaría con $k = 50$ grupos?

Respuesta: $\binom{10}{2} = 45$ pares. $P(\text{al menos un error}) = 1 - (0,95)^{45} \approx 0,90$. Con 50 grupos: $\binom{50}{2} = 1225$ pares, $P \approx 1,0$. La inflación del error es catastrófica incluso con pocos grupos: con solo 10 grupos ya tienes 90 % de probabilidad de un falso

positivo.

6.2. La intuición de ANOVA: señal contra ruido

Antes de leer: hazte esta pregunta

Si no puedes hacer 496 pruebas t , ¿cómo decides si los 32 estados tienen el mismo ingreso medio? La respuesta conceptual es elegante: comparas la variabilidad **entre** los grupos con la variabilidad **dentro** de los grupos.

6.2.1. La metáfora de la señal y el ruido

ANOVA se puede entender como un detector de señal:

- **Señal (variabilidad entre grupos):** ¿Qué tan separadas están las medias de los grupos? Si los 32 estados tienen ingresos medios muy distintos, hay una señal fuerte de desigualdad regional.
- **Ruido (variabilidad dentro de grupos):** ¿Qué tan dispersos están los individuos *dentro* de cada estado? En todos los estados hay personas de ingreso alto y bajo. Esa dispersión es el ruido de fondo.

Si la señal es fuerte comparada con el ruido, concluyes que los grupos son diferentes. Si la señal es débil (las medias están cerca) o el ruido es fuerte (mucha variabilidad interna), no puedes distinguir la señal del ruido.

Definición: La lógica fundamental de ANOVA

ANOVA compara dos estimadores independientes de la varianza poblacional σ^2 :

- CM_{Entre} : estima σ^2 a partir de la dispersión de las medias grupales alrededor de la media global. Bajo H_0 , estima σ^2 limpiamente; bajo H_a , se infla porque captura diferencias reales entre grupos.
- CM_{Dentro} : estima σ^2 a partir de la dispersión de los individuos alrededor de la media de su propio grupo. **Siempre** estima σ^2 , bajo H_0 o H_a .

El cociente $F = CM_{\text{Entre}}/CM_{\text{Dentro}}$ será cercano a 1 si H_0 es verdadera, y $\gg 1$ si H_0 es falsa.

En español: CM_{Dentro} es tu “vara de medir” del ruido. CM_{Entre} es la señal. Si la señal es mucho más fuerte que el ruido, los grupos no son iguales.

Nota didáctica

Conexión con el Lab 1. En el Laboratorio 1 aprendiste que $\text{Var}(\bar{X}) = \sigma^2/n$. La varianza de la media muestral es la precursora directa de SC_{Dentro} : ambas miden cómo fluctúan los datos alrededor de su centro. ANOVA generaliza esta idea: en vez

de una sola varianza, tienes varianzas agrupadas y las comparas. La descomposición $SCT = SCE + SCR$ de la regresión (Lab 7) a su vez generaliza la descomposición de ANOVA. Es una sola idea —partir la variabilidad total en fuentes— que recorre los Laboratorios 1, 5, 6 y 7.

Caso Real: Gasto en alimentos por decil de ingreso

La Encuesta Nacional de Ingresos y Gastos de los Hogares (ENIGH, INEGI 2022) clasifica a los hogares mexicanos en 10 deciles según su ingreso total. El gasto trimestral en alimentos varía entre deciles: el decil I (el 10 % más pobre) gasta en promedio \$4,200 mientras que el decil X gasta \$18,600. Con $n \approx 87,826$ hogares en total, hay mucha variabilidad *dentro* de cada decil (no todos los hogares del decil X gastan lo mismo) y mucha variabilidad *entre* deciles. ANOVA formaliza si la variabilidad entre deciles es mayor que la esperada por la variabilidad interna.

Tarjeta de repaso

Frente: ¿Qué compara ANOVA en esencia?

Reverso: ANOVA compara la variabilidad **entre** las medias de los grupos (señal) con la variabilidad **dentro** de cada grupo (ruido). Si la señal es grande relativa al ruido, rechazas H_0 : al menos un grupo difiere de los demás. La prueba F formaliza esta comparación: $F = CM_{\text{Entre}}/CM_{\text{Dentro}}$.

Analogía: Es como escuchar una conversación en un restaurante. La “señal” es la voz de tu interlocutor; el “ruido” es el murmullo del restaurante. Si la señal es mucho más fuerte que el ruido, entiendes. Si no, no.

Pregunta de autoevaluación

CONEVAL reporta el porcentaje de pobreza multidimensional en municipios clasificados como urbanos, rurales y mixtos. Los promedios muestrales son: urbano 28 %, rural 52 %, mixto 39 %. ¿Qué necesitarías saber —además de estos promedios— para determinar si las diferencias son estadísticamente significativas mediante ANOVA?

Respuesta: Necesitarías la variabilidad **dentro** de cada tipo de municipio (la desviación estándar de los porcentajes de pobreza entre municipios del mismo tipo) y el número de municipios en cada categoría. Si la variabilidad dentro de cada tipo es pequeña (los municipios urbanos son consistentemente $\sim 28\%$), incluso diferencias moderadas entre promedios serán significativas. Si la variabilidad dentro de cada tipo es enorme (hay municipios urbanos con 5 % y otros con 60 %), las diferencias entre promedios podrían deberse al azar.

6.3. El modelo de una vía y la descomposición de varianza

Antes de leer: hazte esta pregunta

Has visto que ANOVA descompone la variabilidad total en “entre” y “dentro”. ¿Pero cómo se calculan exactamente esas cantidades? ¿Y de dónde sale la identidad $SCT = SC_{\text{Entre}} + SC_{\text{Dentro}}$?

6.3.1. El modelo estadístico

El modelo ANOVA de una vía asume que cada observación es la media de su grupo más un error aleatorio:

$$X_{ij} = \mu_i + \varepsilon_{ij}, \quad \varepsilon_{ij} \sim N(0, \sigma^2) \text{ independientes}$$

donde:

- X_{ij} : observación j del grupo i ($i = 1, \dots, k$; $j = 1, \dots, n_i$)
- μ_i : media poblacional del grupo i
- ε_{ij} : error aleatorio, misma varianza σ^2 para todos los grupos (homocedasticidad)

Las hipótesis son:

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_k \quad (\text{todas las medias son iguales})$$

$$H_a : \text{al menos una } \mu_i \text{ es diferente}$$

6.3.2. La identidad fundamental

La herramienta estadística

Descomposición de la suma de cuadrados total:

$$\underbrace{\sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_{..})^2}_{SCT} = \underbrace{\sum_{i=1}^k n_i (\bar{X}_{i.} - \bar{X}_{..})^2}_{SC_{\text{Entre}}} + \underbrace{\sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_{i.})^2}_{SC_{\text{Dentro}}}$$

En español:

- SC_{Entre} : ¿Qué tan lejos está la media de cada grupo de la media global? Ponderado por el tamaño del grupo. Mide la variación *explicada* por las diferencias entre grupos.
- SC_{Dentro} : ¿Qué tan dispersas están las observaciones individuales alrededor de la media de su propio grupo? Mide la variación *no explicada* (ruido).
- SCT: Variabilidad total de todos los datos alrededor de la media global. **Siempre** se cumple: $SCT = SC_{\text{Entre}} + SC_{\text{Dentro}}$.

Tabla ANOVA:

Fuente de variación	SC	gl	CM	F
Entre grupos	SC_{Entre}	$k - 1$	$CM_{\text{Entre}} = \frac{SC_{\text{Entre}}}{k-1}$	$F = \frac{CM_{\text{Entre}}}{CM_{\text{Dentro}}}$
Dentro de grupos	SC_{Dentro}	$N - k$	$CM_{\text{Dentro}} = \frac{SC_{\text{Dentro}}}{N-k}$	
Total	SCT	$N - 1$		

La lógica del estadístico F :

- Si H_0 es verdadera: CM_{Entre} y CM_{Dentro} estiman la misma σ^2 . Su cociente $F \approx 1$.
- Si H_0 es falsa: CM_{Entre} estima σ^2 más un término positivo que refleja las diferencias entre medias. El cociente $F > 1$.
- Rechazas H_0 si $F > F_{\alpha, k-1, N-k}$ (el valor crítico de la tabla F).

Referencia formal: Wackerly §13.3–13.5; Casella & Berger §11.2; Notas de clase, Teorema de Cochran.

6.3.3. Notación y reglas nemotécnicas

La herramienta estadística

Guía rápida de notación.	Símbolo	Significado	Ejemplo con datos mexicanos
	k	Número de grupos o tratamientos	32 entidades federativas
	n_i	Observaciones en el grupo i	$n_1 = 100$ hogares en CDMX
	N	Total de observaciones: $N = \sum n_i$	$N = 3,200$ hogares
	$\bar{X}_i$	Media del grupo i	Ingreso promedio en Jalisco
	$\bar{X}_{..}$	Media global (todos los datos)	Ingreso promedio nacional
	SC_{Entre}	SC entre grupos	Variación atribuible a diferencias entre estados
	SC_{Dentro}	SC dentro de grupos	Variación entre hogares de mismo estado
	SCT	SC total	$SCT = SC_{\text{Entre}} + SC_{\text{Dentro}}$
	CM_{Entre}	Cuadrado Medio entre grupos	$SC_{\text{Entre}}/(k-1)$
	CM_{Dentro}	Cuadrado Medio dentro de grupos	$SC_{\text{Dentro}}/(N-k)$
	F	Estadístico de prueba	$F = CM_{\text{Entre}}/CM_{\text{Dentro}}$

Reglas nemotécnicas:

- El punto en el subíndice indica sobre qué índice se promedió: $\bar{X}_{i\cdot}$ = “promedio sobre todas las observaciones del grupo i .”
- SC = Suma de Cuadrados. CM = Cuadrado Medio = SC / grados de libertad.
- La F SIEMPRE es $CM_{\text{Entre}}/CM_{\text{Dentro}}$ (el numerador es lo que quieres detectar; el denominador es el ruido).

En R**ANOVA de una vía en R (datos ENIGH 2022):**

```
# Fuente: INEGI, ENIGH 2022
# Gasto trimestral en alimentos por decil de ingreso
# decil, media_gasto, de_gasto, n_hogares (k=10, N~87,826)
datos_decil <- read.csv("datos_reales/enigh2022_gasto_decil.csv")

# ANOVA a partir de estadísticos publicados
k <- nrow(datos_decil)           # k = 10 deciles
N <- sum(datos_decil$n_hogares)  # N total de hogares
grand_mean <- weighted.mean(datos_decil$media_gasto, datos_decil$n_hogares)

SC_entre <- sum(datos_decil$n_hogares *
                (datos_decil$media_gasto - grand_mean)^2)
SC_dentro <- sum((datos_decil$n_hogares - 1) * datos_decil$de_gasto^2)

CM_entre <- SC_entre / (k - 1)
CM_dentro <- SC_dentro / (N - k)
F_stat <- CM_entre / CM_dentro
p_val <- pf(F_stat, df1 = k - 1, df2 = N - k, lower.tail = FALSE)
eta2 <- SC_entre / (SC_entre + SC_dentro)

cat(sprintf("F(%d, %d) = %.1f, p < 2.2e-16\n", k-1, N-k, F_stat))
cat(sprintf("eta^2 = %.3f\n", eta2))
# Output: F(9, 87817) = 12334.8, p < 2.2e-16, eta^2 = 0.558
```

Interpretación: $F(9, 87,817) = 12,334.8$, $p < 2.2 \times 10^{-16}$. Rechazas H_0 contundentemente: el gasto medio en alimentos NO es igual en todos los deciles. $\eta^2 = 0.558$: el 55.8 % de la variabilidad en el gasto alimentario es explicada por el decil de ingreso —un efecto enorme (Cohen 1988).

Tarjeta de repaso

Frente: ¿Qué mide CM_{Dentro} y por qué es crucial?

Reverso: $CM_{\text{Dentro}} = SC_{\text{Dentro}}/(N - k)$ es un estimador insesgado de σ^2 , la varianza común a todos los grupos. Mide la variabilidad “natural” o “no explicada” dentro

de cada grupo. Es el denominador del estadístico F : la vara contra la que mides las diferencias entre grupos. Su insesgamiento NO depende de H_0 : siempre estima σ^2 . Esto lo convierte en el ancla confiable del contraste.

Conexión con Lab 1: CM_{Dentro} es una versión agrupada de la varianza muestral s^2 que estudiaste en el Lab 1. La propiedad de insesgamiento que demostraste para s^2 se hereda directamente a CM_{Dentro} .

Pregunta de autoevaluación

Un investigador realiza un ANOVA de una vía con $k = 5$ grupos, $N = 100$ observaciones totales, y obtiene $SC_{Entre} = 240$ y $SC_{Dentro} = 760$.

- Completa la tabla ANOVA (gl, CM, F).
- Con $\alpha = 0,05$, ¿rechazas H_0 ? El valor crítico es $F_{0,05,4,95} \approx 2,47$.
- Interpreta el resultado.

Respuesta: (a) $gl_{Entre} = 4$, $gl_{Dentro} = 95$, $CM_{Entre} = 60$, $CM_{Dentro} = 8$, $F = 7,5$. (b) $7,5 > 2,47 \Rightarrow$ rechazas H_0 . (c) Hay evidencia de que al menos un grupo tiene media diferente. Las diferencias entre grupos son 7.5 veces mayores que la variabilidad dentro de los grupos —mucho más de lo esperable por azar.

6.4. La prueba F: el corazón de ANOVA

Antes de leer: hazte esta pregunta

Ya sabes que ANOVA compara variabilidad entre y dentro de grupos mediante el cociente F . ¿Pero por qué usamos la distribución F ? ¿Qué tiene que ver una razón de varianzas con comparar medias?

6.4.1. ¿Por qué el estadístico F es un cociente de varianzas?

Bajo $H_0 : \mu_1 = \dots = \mu_k$, las k muestras provienen de la misma población. Entonces:

- CM_{Entre} y CM_{Dentro} son **dos estimadores independientes** de la misma σ^2 .
- Su cociente $F = CM_{Entre}/CM_{Dentro}$ sigue una distribución $F_{k-1, N-k}$.

Si H_0 es **falsa**, CM_{Entre} sobreestima σ^2 (porque incorpora las diferencias reales entre μ_i), mientras que CM_{Dentro} sigue estimando σ^2 limpiamente. El cociente F se infla, y cae en la cola derecha de la distribución F .

La herramienta estadística

La distribución F de Fisher. Sean $U \sim \chi_{\nu_1}^2$ y $V \sim \chi_{\nu_2}^2$ independientes. Entonces:

$$F = \frac{U/\nu_1}{V/\nu_2} \sim F_{\nu_1, \nu_2}$$

donde ν_1 son los grados de libertad del numerador y ν_2 los del denominador. La

distribución F es **asimétrica** (empieza en 0 y tiene cola a la derecha) y **depende de dos** grados de libertad.

En ANOVA: Bajo H_0 y normalidad, $SC_{\text{Entre}}/\sigma^2 \sim \chi^2_{k-1}$ y $SC_{\text{Dentro}}/\sigma^2 \sim \chi^2_{N-k}$, y son independientes (Teorema de Cochran). Por tanto:

$$F = \frac{(SC_{\text{Entre}}/\sigma^2)/(k-1)}{(SC_{\text{Dentro}}/\sigma^2)/(N-k)} = \frac{CM_{\text{Entre}}}{CM_{\text{Dentro}}} \sim F_{k-1, N-k}$$

Las σ^2 se cancelan —por eso no necesitas conocer σ^2 para hacer ANOVA.

La región de rechazo:

$$\text{Rechazar } H_0 \text{ si } F > F_{\alpha, k-1, N-k}$$

¿Por qué la cola derecha? Porque F solo puede ser $\gg 1$ si H_0 es falsa. Si H_0 es verdadera, $F \approx 1$. Valores de F muy por debajo de 1 no contradicen H_0 . Por eso la prueba F en ANOVA es **siempre de una cola (derecha)**.

Referencia formal: Wackerly §7.3, §13.5; Casella & Berger §5.3, §11.2.3; Notas de clase, Teorema de Cochran.

6.4.2. Conexión con la prueba t

Nota didáctica

Del Lab 4 al Lab 5: $F = t^2$ para $k = 2$. Cuando solo tienes dos grupos ($k = 2$), la prueba t de dos muestras y el ANOVA de una vía producen **exactamente** la misma conclusión. De hecho, $F = t^2$: el estadístico F del ANOVA es el cuadrado del estadístico t de la prueba de dos muestras. El valor p es idéntico. Esto no es coincidencia: ambas pruebas comparan la diferencia entre medias contra la variabilidad interna. La diferencia es que t está diseñada para exactamente 2 grupos, mientras que F se generaliza a $k \geq 2$ grupos. ANOVA *contiene* a la prueba t como caso particular.

Caso Real: ¿Son iguales las tasas de informalidad por sector?

La ENOE clasifica a los trabajadores en tres sectores: primario (agricultura, minería), secundario (manufactura, construcción) y terciario (servicios, comercio). La tasa de informalidad laboral en México es notoriamente alta (más del 50 %), pero ¿es igual en todos los sectores?

Supón que el ingreso como proporción del salario mínimo tiene promedios: primario 1,2, secundario 2,1, terciario 1,8. Estos tres números son distintos en la muestra, pero ¿reflejan diferencias estructurales o variabilidad natural dentro de cada sector? ANOVA responde con una sola prueba F . Si $k = 2$ (solo primario vs. terciario), $t^2 = F$ y obtienes exactamente el mismo veredicto.

En R**La distribución F en R:**

```
# Visualizar la distribución F
curve(df(x, df1 = 3, df2 = 97), from = 0, to = 5,
      main = "Distribución F(3, 97)",
      xlab = "F", ylab = "Densidad")
# Valor crítico para alpha = 0.05
qf(0.95, df1 = 3, df2 = 97) # aprox 2.70
# p-value de un F observado
1 - pf(7.5, df1 = 3, df2 = 97) # aprox 0.0001

# Verificar  $F = t^2$  para  $k=2$  grupos
t_stat <- 2.5 # estadístico t de dos muestras
F_stat <- t_stat^2 #  $F = t^2$ 
# Ambos dan el mismo p-value (two-sided t vs one-sided F)
2 * pt(-abs(t_stat), df = 30) # p-value de la t
pf(F_stat, df1 = 1, df2 = 30, lower.tail = FALSE) # mismo p-value
```

Tarjeta de repaso

Frente: ¿Por qué la prueba F en ANOVA es de una cola?

Reverso: Porque solo los valores grandes de F (cola derecha) indican que las diferencias entre grupos son mayores que lo esperable por azar. Valores de F cercanos a 1 (o menores) son consistentes con H_0 . La hipótesis alternativa es “al menos una media difiere”, lo que siempre infla el numerador, nunca lo reduce. En contraste, la t de dos colas rechaza en ambas direcciones porque compara una diferencia que puede ser positiva o negativa. Pero $F = t^2$, así que al elevar al cuadrado, las dos colas de la t se colapsan en la cola derecha de la F .

Pregunta de autoevaluación

Un ANOVA con $k = 4$ grupos y $N = 40$ observaciones produce $F = 1.8$. El valor crítico al 5 % es $F_{0.05,3,36} \approx 2.87$.

(a) ¿Rechazas H_0 ?

(b) Interpreta: ¿qué significa un F de 1.8?

(c) Si el mismo estudio tuviera $N = 400$ (mismos grupos, mismas medias, misma varianza dentro), ¿el F sería mayor, menor o igual? ¿Por qué?

Respuesta: (a) No, $1.8 < 2.87$. (b) La variabilidad entre grupos es solo 1.8 veces la variabilidad dentro de grupos. Con tan pocos datos, esa diferencia no es estadísticamente significativa. (c) El F sería mayor. Con más observaciones, CM_{Entre} se estima con mayor precisión y los grados de libertad del denominador aumentan, reduciendo el valor crítico. La potencia aumenta con N .

6.5. Los supuestos de ANOVA y qué hacer si fallan

Antes de leer: hazte esta pregunta

ANOVA asume tres cosas: normalidad, homocedasticidad e independencia. ¿Son solo tecnicismos, o realmente importan? Y si tus datos no las cumplen, ¿qué haces?

6.5.1. Los tres supuestos, en orden de importancia

1. **Independencia** (EL MÁS CRÍTICO). Las observaciones deben ser independientes entre sí. Si hay dependencia (datos anidados, series de tiempo, clusters), los errores estándar están mal calculados y el valor p es inválido. *Ejemplo*: estudiantes dentro de la misma escuela no son independientes.
2. **Homocedasticidad** (MUY IMPORTANTE). $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2$. Si las varianzas son muy desiguales y los tamaños de muestra también, el nivel real de la prueba se distorsiona. Se verifica con la prueba de Levene y gráficos de residuos vs. ajustados.
3. **Normalidad** (LA MENOS PREOCUPANTE). Los errores $\varepsilon_{ij} \sim N(0, \sigma^2)$. ANOVA es **robusto** a la no-normalidad cuando los tamaños de muestra son razonables (TLC). Con muestras muy pequeñas y colas pesadas, considerar Kruskal-Wallis.

La herramienta estadística

Diagnóstico en R y remedios:

```
modelo <- aov(gasto ~ decil, data = datos)

# 1. Normalidad: Q-Q plot
qqnorm(residuals(modelo)); qqline(residuals(modelo), col = "red")

# 2. Homocedasticidad: residuos vs ajustados
plot(fitted(modelo), residuals(modelo))
abline(h = 0, col = "red", lty = 2)

# 3. Prueba de Levene (más robusta que Bartlett)
library(car)
leveneTest(gasto ~ decil, data = datos)
```

¿Y si fallan los supuestos?

- **No normalidad + muestra grande**: ANOVA es robusto por TLC.
- **No normalidad + muestra pequeña**: Kruskal-Wallis (alternativa no paramétrica).
- **No homocedasticidad**: Corrección de Welch (`oneway.test(var.equal = FALSE)`).

- **No independencia:** ANOVA no es apropiado. Necesitas modelos mixtos, GEE o series de tiempo.

Referencia formal: Wackerly §13.6; Casella & Berger §11.3.

Nota didáctica

Herencia del Lab 4. Los mismos tres supuestos aplican para la prueba t de dos muestras. De hecho, la prueba t con varianzas iguales asume normalidad, homocedasticidad e independencia —exactamente lo mismo que ANOVA. La diferencia es que en ANOVA los verificas para k grupos en vez de 2, y usas herramientas de diagnóstico gráfico más generales (residuos vs. ajustados en vez de simplemente comparar dos desviaciones estándar).

Caso Real: Diagnóstico con datos de informalidad estatal

Supón que obtienes datos de la tasa de informalidad laboral para cada entidad federativa (ENOE, 2023) y clasificas los estados en 5 regiones (Noroeste, Noreste, Centro, Sur, Sureste). Antes de correr ANOVA debes verificar:

- **Independencia:** ¿La tasa de informalidad de un estado afecta la de otro? Posiblemente sí, por efectos de vecindad o mercados laborales integrados. Si es el caso, ANOVA subestimaría el error.
- **Homocedasticidad:** ¿La varianza de la tasa de informalidad es similar en todas las regiones? Los estados del Norte tienden a ser más homogéneos que los del Sur (mayor varianza en el Sur). Gráfico de residuos vs. ajustados.
- **Normalidad:** Con 32 estados, tienes de 5 a 8 por región. Con muestras tan pequeñas, la normalidad sí importa. Q-Q plot de los residuos.

Tarjeta de repaso

Frente: ¿Cuál es el supuesto más importante de ANOVA y por qué?

Reverso: La **independencia**. Si las observaciones no son independientes (ej. mediciones repetidas del mismo sujeto, datos agrupados por escuela/hospital/estado), los errores estándar están mal calculados y el valor p es inválido —puede ser mucho menor de lo que debería, llevándote a rechazar H_0 incorrectamente. Los otros supuestos (normalidad, homocedasticidad) tienen correcciones disponibles; la dependencia requiere cambiar de modelo por completo.

Pregunta de autoevaluación

Un investigador aplica ANOVA a datos de rendimiento académico de estudiantes agrupados por escuela (5 escuelas, 30 estudiantes cada una). Obtiene $F = 4.2$, $p = 0.004$, y concluye que las escuelas tienen rendimientos diferentes.

- ¿Qué supuesto de ANOVA podría estar violado?
- ¿Cómo afecta esto a la conclusión del investigador?

Respuesta: (a) El supuesto de **independencia**. Los estudiantes dentro de la misma escuela comparten profesores, recursos y entorno que inducen correlación intra-grupo. (b) La correlación intra-escuela reduce la varianza *efectiva* dentro de grupos, inflando artificialmente F y produciendo un p -valor menor del que correspondería. Se necesita un modelo que ajuste por el efecto escuela (modelo jerárquico o ANOVA anidado).

6.6. Más allá del rechazo: comparaciones múltiples

Antes de leer: hazte esta pregunta

ANOVA te dice que *al menos un grupo es diferente*. Pero, ¿cuál? Si rechazas H_0 con 32 estados, necesitas identificar *cuáles* estados son distintos. ¿Cómo lo haces sin inflar el error Tipo I?

6.6.1. El dilema post-ANOVA

Rechazar H_0 en ANOVA es solo el primer paso. La pregunta de política pública no es “¿son todos los estados iguales?”, sino “¿qué estados están significativamente por debajo del promedio nacional?” Para responder, necesitas comparaciones por pares **con corrección**.

La herramienta estadística

Corrección de Bonferroni: La idea más simple y general: divide α entre el número de comparaciones m .

$$p_{\text{ajustado}} = \min(m \cdot p_{\text{original}}, 1)$$

Ventaja: Funciona para *cualquier* conjunto de pruebas, no solo pares de medias.

Desventaja: Conservadora —pierde potencia rápidamente con muchas comparaciones.

Método de Tukey (HSD — Honestly Significant Difference): Diseñado específicamente para comparar todos los pares de medias después de ANOVA. Controla el error *family-wise* exactamente.

$$|\bar{X}_i - \bar{X}_j| > q_{\alpha, k, N-k} \cdot \sqrt{\frac{\text{CM}_{\text{Dentro}}}{n}} \quad (\text{si } n_i = n_j = n)$$

donde $q_{\alpha, k, N-k}$ es el valor crítico de la distribución del rango estudentizado.

Ventaja: Más potente que Bonferroni para comparaciones de pares.

Desventaja: Solo sirve para pares; asume varianzas iguales.

¿Cuándo usar cuál?

- **Tukey:** cuando comparas **todos los pares** de medias (el caso más común).

- **Bonferroni**: cuando tienes un conjunto **arbitrario** de comparaciones (ej. solo cada tratamiento contra un control), o cuando las varianzas no son iguales (con `pairwise.t.test`).

Referencia formal: Wackerly §13.7; Casella & Berger §11.2.4.

Caso Real: ¿Qué estados son diferentes en ingreso medio?

Regresamos al ejemplo de ingreso laboral por entidad federativa. ANOVA rechaza H_0 : no todos los estados tienen el mismo ingreso medio. Ahora la pregunta es: **¿qué estados están significativamente por debajo del promedio nacional?** Esos estados serían candidatos prioritarios para programas de desarrollo regional.

Con 32 estados, hay $\binom{32}{2} = 496$ pares. Si hicieras 496 pruebas t al 5 % sin corregir, esperarías $496 \times 0,05 \approx 25$ rechazos **falsos** —estados que parecen diferentes pero no lo son. Con Bonferroni, cada prueba individual requeriría $p < 0,05/496 \approx 0,0001$ para ser declarada significativa. Con Tukey, el control es menos conservador y mantiene más potencia.

Usando datos reales de la ENOE (2023) con Tukey HSD, los resultados típicamente muestran que los estados del Sur (Chiapas, Oaxaca, Guerrero) forman un grupo homogéneo de bajo ingreso, los estados del Norte (Nuevo León, Baja California, Chihuahua) forman un grupo de alto ingreso, y el Centro es un grupo intermedio con CDMX como outlier superior.

En R

Comparaciones múltiples en R:

```
modelo <- aov(ingreso ~ estado, data = enoe)

# Tukey HSD
TukeyHSD(modelo, conf.level = 0.95)
plot(TukeyHSD(modelo)) # Visualización

# Bonferroni
pairwise.t.test(enoe$ingreso, enoe$estado,
                p.adjust.method = "bonferroni")

# También disponible: "holm" (menos conservador que Bonferroni)
pairwise.t.test(enoe$ingreso, enoe$estado,
                p.adjust.method = "holm")
```

Tarjeta de repaso

Frente: ¿Cuándo usar Bonferroni vs. Tukey?

Reverso: Usa **Tukey** para comparar **todos los pares** de medias (el caso más común). Es más potente porque está diseñado exactamente para eso. Usa **Bonferroni** para conjuntos **arbitrarios** de comparaciones (no necesariamente todos los pares), o cuando las varianzas no sean iguales. Bonferroni es más general pero menos potente: con muchas comparaciones, puede ser demasiado conservador y perder diferencias reales.

Pregunta de autoevaluación

Un ANOVA con $k = 5$ grupos rechaza H_0 . El investigador realiza las 10 comparaciones por pares con $\alpha = 0,05$ sin corregir.

- (a) ¿Cuál es la probabilidad de cometer al menos un error Tipo I?
- (b) Si usa Bonferroni, ¿a qué nivel debe probar cada comparación individual?
- (c) ¿Qué método recomendarías y por qué?

Respuesta: (a) $1 - (0,95)^{10} \approx 0,401$. ¡40 % de probabilidad de al menos un falso positivo! (b) $\alpha_{\text{Bonf}} = 0,05/10 = 0,005$. (c) Tukey HSD, porque compara todos los pares y es más potente que Bonferroni para este propósito.

6.7. ANOVA en la práctica: flujo completo

Antes de leer: hazte esta pregunta

Ya tienes todas las piezas: el modelo, la tabla ANOVA, los supuestos y las comparaciones múltiples. ¿Cómo se integran en un flujo completo de análisis?

6.7.1. Los 7 pasos del análisis ANOVA

- Paso 1. Define la pregunta.** ¿Qué grupos comparas? ¿Cuál es tu variable de respuesta?
Ej: “¿El ingreso laboral medio difiere entre las 5 regiones de México?”
- Paso 2. Explora los datos.** Boxplots por grupo, medias y DE por grupo, tamaño de muestra por grupo.
- Paso 3. Verifica supuestos.** Q-Q plot (normalidad), residuos vs. ajustados + Levene (homocedasticidad), diseño del estudio (independencia).
- Paso 4. Ajusta el modelo.** Calcula la tabla ANOVA: SC, gl, CM, F , valor p .
- Paso 5. Interpreta F .** ¿Rechazas H_0 ? Si no, termina: no hay evidencia de diferencias. Reporta η^2 como tamaño del efecto.
- Paso 6. Si rechazas: comparaciones múltiples.** Identifica qué grupos difieren con Tukey HSD o Bonferroni.
- Paso 7. Comunica resultados.** Reporta: $F(\text{gl}_{\text{Entre}}, \text{gl}_{\text{Dentro}}) = \text{valor}, p, \eta^2$, y las diferencias específicas.

6.7.2. El tamaño del efecto: η^2

Definición: Eta cuadrado (η^2)

$$\eta^2 = \frac{SC_{\text{Entre}}}{SCT} = \frac{SC_{\text{Entre}}}{SC_{\text{Entre}} + SC_{\text{Dentro}}}$$

η^2 mide la **proporción de la variabilidad total** explicada por las diferencias entre grupos. A diferencia del valor p , η^2 no depende del tamaño de muestra. Según Cohen (1988): $\eta^2 \approx 0,01$ efecto pequeño, $\approx 0,06$ mediano, $\approx 0,14$ grande.

En español: Con muestras enormes puedes tener $p < 0,001$ pero $\eta^2 = 0,001$ (diferencia real pero minúscula). Siempre reporta η^2 junto con p .

Caso Real: Reporte ANOVA estilo paper — datos reales de homicidios

Un reporte típico de ANOVA en un artículo de seguridad pública se ve así:

“Se realizó un ANOVA de una vía para comparar la tasa de homicidios dolosos entre las cinco regiones de México para el período 2015–2017 ($N = 1,152$ observaciones estado-mes; SESNSP/INEGI). Los resultados mostraron diferencias significativas entre regiones, $F(4, 1,147) = 75,4$, $p < 2 \times 10^{-16}$, $\eta^2 = 0,208$. Comparaciones post-hoc con Tukey HSD indicaron que el Noroeste ($M = 32,8$, $DE = 15,9$) presentó tasas significativamente mayores que Noreste ($M = 15,4$, $DE = 9,8$, $p < 0,001$) y Sureste ($M = 9,3$, $DE = 6,9$, $p < 0,001$). No se encontraron diferencias significativas entre Noroeste y Sur ($p = 0,996$).”

Elementos del reporte:

- $F(gl_{\text{Entre}}, gl_{\text{Dentro}}) = \text{valor}, p$
- Tamaño del efecto: η^2
- Post-hoc: método, qué grupos difieren, medias y DE por grupo

En R

Flujo completo ANOVA en R (homicidios por región):

```
# Datos: SESNSP/INEGI, tasa de homicidios por 100k, 2015–2017
homicidios <- read.csv("datos_reales/homicidios_mensuales_region.csv")

# Paso 1-2: Exploración
boxplot(tasa_100k ~ region, data = homicidios,
        main = "Tasa de homicidios por región (2015–2017)")

# Paso 3: Supuestos
modelo <- aov(tasa_100k ~ region, data = homicidios)
qqnorm(residuals(modelo)); qqline(residuals(modelo), col = "red")
```

```
plot(fitted(modelo), residuals(modelo)); abline(h = 0, col = "red")
library(car); leveneTest(tasa_100k ~ region, data = homicidios)
```

```
# Paso 4-5: ANOVA
```

```
summary(modelo)
```

```
#           Df Sum Sq Mean Sq F value Pr(>F)
# region      4  75868   18967    75.4 <2e-16
# Residuals 1147 288598     252
```

```
# Paso 6: Post-hoc
```

```
TukeyHSD(modelo); plot(TukeyHSD(modelo))
```

```
# Paso 7: Tamaño del efecto
```

```
library(effectsize)
```

```
eta_squared(modelo) # eta^2 = 0.208
```

Interpretación: $F(4, 1,147) = 75,4$, $p < 2 \times 10^{-16}$, $\eta^2 = 0,208$. La región explica el 20.8 % de la variabilidad en homicidios. El Noroeste y Sur son significativamente más violentos que el Noreste y Sureste.

Tarjeta de repaso

Frente: ¿Qué es η^2 y para qué sirve?

Reverso: $\eta^2 = SC_{\text{Entre}}/SCT$ mide el **tamaño del efecto**: qué proporción de la variabilidad total es explicada por los grupos. A diferencia del valor p , no depende del tamaño de muestra. Con N enorme puedes tener $p < 0,001$ y $\eta^2 = 0,001$ (diferencia real pero insignificante). Siempre reporta ambos. Cohen (1988): 0,01 pequeño, 0,06 mediano, 0,14 grande.

Conexión con Lab 7: η^2 es el análogo del R^2 en regresión. Ambos miden “proporción de varianza explicada”. De hecho, si corres la regresión con dummies, $\eta^2 = R^2$.

Pregunta de autoevaluación

Dos estudios aplican ANOVA a datos de salario por sector económico. Estudio A: $N = 300$, $F = 8,2$, $p = 0,0004$, $\eta^2 = 0,05$. Estudio B: $N = 30,000$, $F = 4,1$, $p = 0,016$, $\eta^2 = 0,0003$.

(a) ¿Cuál estudio encontró diferencias *más grandes* entre sectores?

(b) ¿Por qué el Estudio B tiene un p mayor a pesar de tener 100 veces más datos?

Respuesta: (a) Estudio A ($\eta^2 = 0,05$, efecto mediano) vs. Estudio B ($\eta^2 = 0,0003$, minúsculo). (b) El p -valor no mide el tamaño del efecto sino la evidencia contra H_0 . El Estudio B tiene un efecto real pero tan pequeño que incluso con $N = 30,000$ la evidencia no es abrumadora. El Estudio A tiene un efecto 167 veces mayor. Siempre reporta η^2 junto con p .

6.8. Anexo: ANOVA con variables dummy es regresión

Antes de leer: hazte esta pregunta

¿Qué tienen en común comparar medias de grupos y estimar una recta de regresión? Mucho más de lo que parece. ANOVA y regresión lineal con variables dummy son **matemáticamente equivalentes**.

6.8.1. La equivalencia fundamental

La herramienta estadística

ANOVA como regresión con dummies. El modelo ANOVA de una vía con k grupos puede escribirse como un modelo de regresión con $k - 1$ variables indicadoras (dummy):

$$X_{ij} = \beta_0 + \beta_1 D_{1,ij} + \beta_2 D_{2,ij} + \cdots + \beta_{k-1} D_{k-1,ij} + \varepsilon_{ij}$$

donde $D_{r,ij} = 1$ si la observación pertenece al grupo $r + 1$ y 0 en otro caso (el grupo 1 es la categoría de referencia).

Interpretación de los coeficientes:

- $\beta_0 = \mu_1$ (media del grupo de referencia).
- $\beta_r = \mu_{r+1} - \mu_1$ (diferencia entre el grupo $r + 1$ y el grupo 1).
- $H_0 : \mu_1 = \mu_2 = \cdots = \mu_k$ equivale a $H_0 : \beta_1 = \beta_2 = \cdots = \beta_{k-1} = 0$.

En español: ANOVA y regresión con dummies son la **misma herramienta** con distinto nombre. La tabla ANOVA del modelo `aov(y ~ grupo)` es **idéntica** a la tabla de análisis de varianza de `lm(y ~ grupo)`. Misma SCE, misma SC_{Dentro} , mismo F , mismo p . Lo que cambia es el lenguaje: en ANOVA hablas de “diferencias entre grupos”; en regresión hablas de “coeficientes de variables dummy.”

Referencia formal: Wackerly §13.8; Casella & Berger §11.4; Angrist & Pischke (2009, §3.1.3, “Regression Meets ANOVA”).

6.8.2. La unificación de la estadística

Nota didáctica

La revelación: $SCT = SC_{\text{Entre}} + SC_{\text{Dentro}}$ (ANOVA) y $SCT = SCE + SCR$ (regresión) son la **misma idea**. En ambas:

- SCT: variabilidad total de Y alrededor de su media.
- Parte explicada: variabilidad capturada por el modelo (grupos en ANOVA, X en regresión).

- Parte no explicada: lo que el modelo no captura (error/residual).

La única diferencia es la naturaleza de X :

- En ANOVA, X es **categorica**: tomas valores discretos (pertenecer a un grupo).
- En regresión, X es **numérica**: tomas valores continuos (años de escolaridad, precio, temperatura).

Pero con dummies, la categórica se vuelve numérica (0/1). Y entonces ANOVA = regresión. Esta unificación es una de las ideas más poderosas de la estadística: **no hay una frontera real entre comparar grupos y modelar relaciones**. Ambas son regresión; la diferencia está en la métrica de X .

Ejemplo trabajado: ANOVA = Regresión con dummies

Comparas el ingreso medio en 3 sectores (primario = referencia, secundario, terciario). El modelo en R:

```
# Ambos dan EXACTAMENTE la misma tabla ANOVA
modelo_aov <- aov(ingreso ~ sector, data = datos)
modelo_lm  <- lm(ingreso ~ sector, data = datos)

summary(modelo_aov)  # Tabla ANOVA tradicional
anova(modelo_lm)     # Misma tabla ANOVA desde regresión

# Los coeficientes de lm() te dan:
# (Intercept) = media del sector primario
# sectorSecundario = media(secundario) - media(primario)
# sectorTerciario = media(terciario) - media(primario)
summary(modelo_lm)
```

Verificación:

- El F -test de `summary(modelo_lm)` prueba $H_0 : \beta_1 = \beta_2 = 0$ conjuntamente.
- Es **exactamente** la misma prueba que $H_0 : \mu_1 = \mu_2 = \mu_3$ en ANOVA.
- Mismo estadístico F , mismos grados de libertad, mismo valor p .

6.8.3. Lo que esto significa para tu formación

- **Econometría (Lab 7):** En MCO, cada variable cualitativa (región, género, sector, nivel educativo) se modela con dummies. Saber que “incluir dummies y probar F ” es ANOVA te permite interpretar cualquier tabla de regresión.
- **Extensiones naturales:** Puedes añadir variables continuas (ANCOVA = ANOVA + regresión), o interacciones (¿el efecto del sector es distinto por género?). Todo es regresión con dummies e interacciones.

- **Unificación conceptual:** ANOVA no es una “técnica separada”. Es un caso particular de regresión. Entender esto es ver la estadística como un edificio unificado.

✓ Verifica tu comprensión

- ✓ Si tienes 4 grupos, ¿cuántas dummies necesitas? (Tres: $k - 1 = 3$. La cuarta queda capturada por el intercepto β_0 .)
- ✓ ¿Son iguales el F de `aov()` y el F de `lm()` para el mismo modelo? (Sí. Produce exactamente la misma tabla ANOVA.)
- ✓ η^2 en ANOVA, ¿a qué equivale en regresión? (A R^2 . Ambos miden proporción de varianza explicada: $\eta^2 = R^2$.)

Tarjeta de repaso

Frente: ¿Son ANOVA y regresión herramientas diferentes?

Reverso: No. Son **matemáticamente equivalentes**. ANOVA es regresión con variables dummy (0/1) como predictores. La tabla ANOVA y la tabla de análisis de varianza de la regresión son idénticas. El estadístico F de ANOVA es el mismo F que prueba si todos los coeficientes son cero en la regresión. $\eta^2 = R^2$. La diferencia es solo de lenguaje y tradición, no de matemáticas.

Pregunta de autoevaluación

Un investigador corre `lm(salario ~ educacion + genero, data = datos)` donde `educacion` tiene 4 niveles (sin preparatoria, preparatoria, licenciatura, posgrado). ¿Cuántas dummies crea R automáticamente? ¿Qué prueba F aparece en el output y qué hipótesis evalúa?

Respuesta: R crea 3 dummies ($4 - 1 = 3$) para educación y 1 para género. La prueba F conjunta evalúa H_0 : todos los coeficientes (excepto el intercepto) son cero —es decir, ni educación ni género afectan el salario. Esta es exactamente la misma lógica que el F de ANOVA: probar si el modelo con predictores explica más varianza que un modelo sin predictores (solo intercepto).

6.9. Autoevaluación del capítulo

1. **(Sección 1)** Explica con tus palabras qué problema resuelve ANOVA que las pruebas t no pueden. ¿Por qué no basta con hacer pruebas t entre todos los pares?
2. **(Sección 2)** ¿Qué compara ANOVA? Da un ejemplo con datos mexicanos donde la variabilidad dentro de grupos sea tan grande que oculte diferencias reales entre grupos.
3. **(Sección 3)** Si $SC_{\text{Entre}} = 500$ y $SC_{\text{Dentro}} = 500$ con $k = 3$ y $N = 30$, completa la tabla ANOVA. ¿Rechazarías H_0 aproximadamente? ($F_{0,05,2,27} \approx 3,35$)

4. **(Sección 4)** ¿Por qué la prueba F en ANOVA es de una cola derecha si la hipótesis alternativa es “al menos una media es diferente”?
5. **(Sección 5)** Un colega corre ANOVA en datos de salarios de 5 empresas con 20 empleados por empresa. ¿Qué supuesto podría estar violado y cómo afecta sus conclusiones?
6. **(Sección 6)** ANOVA rechaza H_0 con $k = 6$ grupos. ¿Cuántas comparaciones por pares son posibles? Si haces todas sin corregir al 5 %, ¿cuál es la probabilidad de al menos un error Tipo I?
7. **(Sección 7)** Interpreta: $F(3, 196) = 12,4$, $p < 0,001$, $\eta^2 = 0,16$. ¿Qué significa cada número? ¿El efecto es grande o pequeño?
8. **(Sección 8)** Si codificas los grupos de un ANOVA con variables dummy y corres una regresión, ¿qué obtienes? ¿Son iguales los resultados?

Mapa de decisiones: ¿Qué herramienta uso?

Tengo...	¿Qué comparo?	Herramienta	Nota clave
1 grupo, 1 muestra	Media vs. valor referencia	Prueba t una muestra (Lab 4)	σ desconocida $\rightarrow t$
2 grupos	Medias de dos poblaciones	Prueba t dos muestras (Lab 4)	Verificar homocedasticidad
3+ grupos	Medias de k poblaciones	ANOVA una vía + Tukey	Una prueba; si rechazas, post-hoc
2 grupos, pareados	Medias antes/después	Prueba t pareada (Lab 4)	Diferencias normales
k grupos, no normales	Medianas	Kruskal-Wallis	Alternativa no paramétrica
2 factores categóricos	Efecto de cada factor	ANOVA dos vías (Lab 6)	Requiere bloques

Regla de oro: Si tienes exactamente 2 grupos, t y ANOVA producen el mismo p -valor ($t^2 = F$). Si tienes 3 o más grupos, **no hagas pruebas t por pares** sin corregir: usa ANOVA primero, y solo si es significativo, procede a comparaciones múltiples con corrección.

Conexión: Lab 5 $\rightarrow$ Lab 6

¿Qué agrega el Laboratorio 6?

El ANOVA de una vía responde: “¿hay diferencias entre estos k grupos?” Pero en

el mundo real, rara vez tienes *un solo* factor que afecta tu variable de respuesta. El ingreso laboral no solo depende del estado donde vives, sino también de tu edad, tu nivel educativo, el sector en el que trabajas...

El Laboratorio 6 agrega una **segunda variable**: el **bloque**. En el ANOVA de dos vías, descompones la variabilidad total en **tres** fuentes:

$$SCT = SC_{\text{Trat}} + SC_{\text{Bloques}} + SC_{\text{Error}}$$

Esto te permite **controlar** por una variable adicional que introduce ruido pero que no es tu foco de interés. Al separar la variabilidad del bloque, reduces el error experimental y aumentas la potencia para detectar diferencias en el tratamiento. Es como limpiar una ventana: quitas la suciedad que corresponde al bloque (edad, período, región) y ves con más nitidez el efecto del tratamiento.

Además, el Lab 6 introduce una herramienta completamente nueva: la prueba χ^2 de bondad de ajuste. Mientras ANOVA compara **medias**, χ^2 compara **distribuciones completas**. Con χ^2 puedes preguntar: “¿siguen estas declaraciones fiscales la Ley de Benford?” —una pregunta que ANOVA no puede responder porque no es sobre medias, sino sobre la forma de la distribución.

La progresión natural: Lab 4: prueba t (2 grupos) → Lab 5: ANOVA de una vía (k grupos) → Lab 6: ANOVA de dos vías (k grupos + bloques) y χ^2 (distribuciones completas) → Lab 7: regresión (variables continuas). Cada paso agrega una dimensión: más grupos, luego control por covariables, luego distribuciones, luego relaciones continuas.

7. ANOVA de dos vías y pruebas χ^2 : controlando factores y probando distribuciones

Herencia conceptual: Del Lab 5: la descomposición de varianza se extiende de dos a tres fuentes. Del Lab 4: la misma lógica de rechazo de H_0 — comparar un estadístico contra su distribución bajo H_0 . Del Lab 3: la distribución χ^2 que ya usamos para varianzas ahora se usa para bondad de ajuste.

7.1. Del ANOVA de una vía al de dos vías: la intuición de los bloques

Antes de leer: hazte esta pregunta

En el Laboratorio 5 comparaste el ingreso medio entre los 32 estados. Pero sabes que el ingreso también depende de la edad del jefe de hogar: hogares jóvenes ganan menos, hogares en su *peak* laboral ganan más. Si ignoras la edad, parte de la diferencia que atribuyes a “estado” en realidad es diferencia de edad. **¿Cómo controlas por esa segunda variable para aislar el efecto puro del estado?**

7.1.1. ¿Por qué controlar? El sesgo de variable omitida

En el Lab 1 aprendiste sobre sesgo: un estimador está sesgado si sistemáticamente apunta lejos del valor verdadero. El ANOVA de una vía puede sufrir un sesgo análogo si omite una variable relevante. Si comparas el ingreso entre el Sur y el Norte sin controlar por edad, y resulta que el Sur tiene una población más joven, atribuirás a la región un efecto que en parte es de la edad.

Definición: Diseño de bloques aleatorizados

Un **bloque** es un conjunto de unidades experimentales homogéneas entre sí respecto a una característica que afecta la respuesta pero *no es el tratamiento que te interesa*.

Al “bloquear”, **separas** la variabilidad de esa característica del error, reduciendo el ruido y aumentando la precisión para detectar diferencias en el tratamiento.

En español: Bloquear es como comparar manzanas con manzanas. Si comparas el ingreso de Chiapas (población más joven) con el de CDMX (población más vieja), parte de la diferencia viene de la edad, no del estado. Al controlar por edad (el bloque), obtienes una comparación del ingreso entre estados **ajustada por diferencias de edad**: la diferencia que permanece ya no es atribuible a la composición etaria de cada estado. Conviene precisar que, con datos observacionales, este ajuste es **descriptivo** —no aísla un efecto causal del estado, porque pueden persistir otras diferencias no observadas entre regiones (infraestructura, inversión, calidad institucional). Lo que el ANOVA de dos vías te da es una comparación más limpia que el ANOVA de una vía, pero no una identificación causal.

Referencia formal: Wackerly §13.8; Notas de clase, §10.4–10.5.

Nota didáctica

Conexión con el Lab 1: sesgo de variable omitida. En el Lab 1 viste que $E[\bar{X}] = \mu$: la media muestral es insesgada para la media poblacional. Pero ese resultado asume que tu muestra es representativa. Si sistemáticamente comparas grupos que difieren en una variable no observada (edad, educación, acceso a servicios), tu conclusión sobre el “efecto del estado” estará contaminada. El ANOVA de dos vías con bloques es una primera defensa contra este problema: controlas *explícitamente* por la variable de bloque, separando su efecto del efecto del tratamiento. En econometría (Lab 7), esta misma idea se generaliza a los **efectos fijos**: incluir dummies por entidad y por año para controlar por características no observadas constantes en el tiempo.

Caso Real: Ingreso laboral por entidad y grupo de edad

La ENOE (INEGI, 2023) reporta el ingreso laboral trimestral de los trabajadores mexicanos. Clasificamos a los trabajadores en 5 regiones (Noroeste, Noreste, Centro, Sur, Sureste) —el **tratamiento**— y en 3 grupos de edad (18–30, 31–50, 51+) —el **bloque**—. Para cada combinación región×edad calculamos el ingreso medio. Si hicieras un ANOVA de una vía solo por región, la variabilidad **dentro** de cada región incluiría diferencias por edad: dentro del Sur hay jóvenes (ingreso bajo) y adultos mayores (ingreso medio). Pero si *bloqueas* por edad, esa variabilidad se separa:

$$\text{Antes: } SCT = SC_{\text{Región}} + \underbrace{SC_{\text{Error (incluye edad)}}}_{\text{grande}}$$

$$\text{Después: } SCT = SC_{\text{Región}} + SC_{\text{Edad}} + \underbrace{SC_{\text{Error (sin edad)}}}_{\text{más pequeño}}$$

El resultado: CM_{Error} se reduce, $F_{\text{Región}}$ aumenta, y tienes **más potencia** para detectar diferencias regionales. Además, obtienes *gratis* una prueba de si la edad

realmente importa (F_{Edad}).

La herramienta estadística

ANOVA de dos vías sin interacción (modelo aditivo con bloques).

Modelo:

$$X_{ij} = \mu + \alpha_i + \beta_j + \varepsilon_{ij}, \quad \varepsilon_{ij} \sim N(0, \sigma^2) \text{ independientes}$$

donde:

- X_{ij} : observación en tratamiento i ($i = 1, \dots, k$) y bloque j ($j = 1, \dots, b$)
- μ : media global
- α_i : efecto del tratamiento i (con $\sum \alpha_i = 0$)
- β_j : efecto del bloque j (con $\sum \beta_j = 0$)
- ε_{ij} : error aleatorio

Hipótesis:

$$H_0^{\text{Trat}} : \alpha_1 = \alpha_2 = \dots = \alpha_k = 0 \quad (\text{no hay efecto del tratamiento})$$

$$H_0^{\text{Bloq}} : \beta_1 = \beta_2 = \dots = \beta_b = 0 \quad (\text{no hay efecto del bloque})$$

¿Cuándo usar bloques? Cuando sospechas que hay una variable que induce variabilidad en tu respuesta pero *no es el tratamiento que quieres estudiar*. Ejemplos: edad, género, región, período, lote de producción, centro hospitalario.

Referencia formal: Wackerly §13.8–13.9; Casella & Berger §11.3.

En R

ANOVA de dos vías en R: ingreso por región y edad (ENOE):

```
# Datos con estructura realista mexicana (ENOE, 2023)
# Tratamiento: 5 regiones. Bloque: 3 grupos de edad
ingreso <- data.frame(
  region = rep(c("Noroeste", "Noreste", "Centro", "Sur", "Sureste"), each=3),
  edad = rep(c("18-30", "31-50", "51+"), times=5),
  ingreso_miles = c(
    28, 45, 38, # Noroeste
    32, 48, 41, # Noreste
    26, 52, 42, # Centro
    18, 30, 25, # Sur
    20, 33, 27 # Sureste
  )
)
modelo <- aov(ingreso_miles ~ region + edad, data = ingreso)
summary(modelo)
#           Df Sum Sq Mean Sq F value Pr(>F)
```

```
# region      4  766.3   191.6   22.08 0.00023 ***
# edad        2  664.5   332.2   38.29 8.3e-05 ***
# Residuals    8    69.4     8.7
```

Interpretación: Ambas pruebas son significativas. El ingreso difiere entre regiones incluso después de controlar por edad ($F = 22,08$, $p < 0,001$), y difiere entre edades incluso después de controlar por región ($F = 38,29$, $p < 0,001$).

Tarjeta de repaso

Frente: ¿Qué gano al usar bloques en vez de un ANOVA de una vía?

Reverso: Dos cosas: (1) **Más potencia:** reduces CM_{Error} al extraer la variabilidad del bloque. El denominador de F_{Trat} se hace más pequeño, F crece, y es más fácil detectar diferencias reales. (2) **Una prueba gratuita:** F_{Bloques} te dice si la variable de bloqueo realmente importa. Si es significativa, validaste tu diseño. Si no, igual controlaste —no hace daño.

Analogía: Es como limpiar una ventana. Sin bloques miras a través del vidrio sucio (error grande). Con bloques limpias la suciedad de la edad (la apartas en SC_{Bloques}). Lo que queda es más nítido: ves mejor el efecto del tratamiento.

Pregunta de autoevaluación

Un investigador compara el rendimiento de 4 variedades de maíz en 6 parcelas con diferentes tipos de suelo. ¿Por qué usaría parcelas como bloques en vez de ignorarlas? ¿Qué pasaría si una variedad rinde más pero solo porque se plantó en las mejores parcelas?

Respuesta: Al bloquear por parcela, controla por calidad del suelo: la variabilidad entre parcelas se separa del error. Si ignorara las parcelas (ANOVA de una vía), la variabilidad del suelo se mezclaría con el error, inflando CM_{Error} y reduciendo la potencia. Peor aún: si la asignación no fue aleatoria, podría atribuir erróneamente a la variedad un efecto del suelo (sesgo por confusión). El bloqueo previene ambas cosas.

7.2. La tabla ANOVA de dos vías: tres fuentes de variación

Antes de leer: hazte esta pregunta

En el Lab 5 descompusiste SCT en dos fuentes. Ahora tienes tres: tratamientos, bloques y error. ¿Cómo se ve la tabla ANOVA y cómo se calculan las sumas de cuadrados?

La herramienta estadística

Descomposición de la suma de cuadrados total:

$$\underbrace{\sum_{i=1}^k \sum_{j=1}^b (X_{ij} - \bar{X}_{..})^2}_{\text{SCT}} = \underbrace{b \sum_{i=1}^k (\bar{X}_{i.} - \bar{X}_{..})^2}_{\text{SC}_{\text{Trat}}} + \underbrace{k \sum_{j=1}^b (\bar{X}_{.j} - \bar{X}_{..})^2}_{\text{SC}_{\text{Bloques}}} + \underbrace{\sum_{i=1}^k \sum_{j=1}^b (X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2}_{\text{SC}_{\text{Error}}}$$

En español:

- SC_{Trat} : ¿Qué tan lejos está la media de cada tratamiento de la media global? Efecto del tratamiento.
- $\text{SC}_{\text{Bloques}}$: ¿Qué tan lejos está la media de cada bloque de la media global? Efecto del bloque.
- SC_{Error} : Lo que queda después de descontar tratamiento y bloque. Ruido puro.

Tabla ANOVA de dos vías (sin interacción):

Fuente de variación	SC	gl	CM	F
Tratamientos	SC_{Trat}	$k - 1$	$\text{CM}_{\text{Trat}} = \frac{\text{SC}_{\text{Trat}}}{k-1}$	$F_{\text{Trat}} = \frac{\text{CM}_{\text{Trat}}}{\text{CM}_{\text{Error}}}$
Bloques	$\text{SC}_{\text{Bloques}}$	$b - 1$	$\text{CM}_{\text{Bloques}} = \frac{\text{SC}_{\text{Bloques}}}{b-1}$	$F_{\text{Bloques}} = \frac{\text{CM}_{\text{Bloques}}}{\text{CM}_{\text{Error}}}$
Error	SC_{Error}	$(k - 1)(b - 1)$	$\text{CM}_{\text{Error}} = \frac{\text{SC}_{\text{Error}}}{(k-1)(b-1)}$	
Total	SCT	$kb - 1$		

Puntos clave:

- **gl del error:** $(k - 1)(b - 1)$. Con una observación por casilla, esto puede ser pequeño (con $k = 3$, $b = 5$ tienes solo 8 gl para el error). Si es posible, incluye réplicas.
- **Mismo denominador:** Ambas F usan CM_{Error} . Es la vara común contra la que mides ambos efectos.
- **Los gl cuadran:** $(k - 1) + (b - 1) + (k - 1)(b - 1) = kb - 1$.

Referencia formal: Wackerly §13.9; Notas de clase, Teoremas 10.1–10.3.

Caso Real: Gasto en alimentos por decil y región

La ENIGH (INEGI, 2022) clasifica a los hogares por decil de ingreso y por región. Supón que tienes el gasto trimestral en alimentos para 3 deciles (I, V, X) $\times$ 3 regio-

nes (Norte, Centro, Sur). La pregunta: **¿el gasto medio difiere entre deciles, controlando por la región?** Porque hogares del Norte podrían gastar más en alimentos que hogares del Sur por diferencias en precios regionales, no por su nivel de ingreso. El ANOVA de dos vías separa el efecto decil del efecto región.

En R

ANOVA de dos vías: gasto en alimentos ENIGH 2022:

```
# Fuente: INEGI, ENIGH 2022
# Tratamiento: decil (I, V, X). Bloque: región (Norte, Centro, Sur)
gasto <- data.frame(
  decil = rep(c("I","V","X"), each=3),
  region = rep(c("Norte","Centro","Sur"), times=3),
  gasto_miles = c(4.8, 4.2, 3.9, 9.2, 8.6, 7.9, 19.8, 18.6, 16.4)
)

modelo <- aov(gasto_miles ~ decil + region, data = gasto)
summary(modelo)
```

#		Df	Sum Sq	Mean Sq	F value	Pr(>F)
# decil		2	307.36	153.68	750.53	7.1e-06 ***
# region		2	5.26	2.63	12.85	0.018 *
# Residuals		4	0.82	0.20		

Interpretación: $F_{\text{decil}}(2,4) = 750,5$, $p < 0,001$: el gasto difiere enormemente entre deciles, incluso controlando por región. El decil X gasta 4.5 veces más que el decil I. $F_{\text{region}}(2,4) = 12,85$, $p = 0,018$: hay evidencia de diferencias regionales al 5 %.

Tarjeta de repaso

Frente: ¿Por qué los gl del error son $(k-1)(b-1)$?

Reverso: En un diseño de bloques sin réplicas tienes una observación por combinación tratamiento×bloque. gl totales: $kb-1$. gl tratamientos: $k-1$. gl bloques: $b-1$. Lo que sobra: $(kb-1) - (k-1) - (b-1) = kb - k - b + 1 = (k-1)(b-1)$. Con $k=3$, $b=5$ tienes solo 8 gl para el error —eso limita la potencia. Si puedes, incluye réplicas (r observaciones por celda) para tener $kb(r-1)$ gl para el error.

Pregunta de autoevaluación

Un ANOVA de dos vías con $k=4$ tratamientos y $b=6$ bloques produce: $SC_{\text{Trat}} = 120$, $SC_{\text{Bloques}} = 85$, $SC_{\text{Error}} = 45$.

(a) Completa la tabla ANOVA (gl, CM, F para tratamientos y bloques).

(b) Si $F_{0,05,3,15} \approx 3,29$ y $F_{0,05,5,15} \approx 2,90$, ¿rechazas H_0 para tratamientos? ¿Y para bloques?

(c) Interpreta ambos resultados.

Respuesta: (a) gl: Trat = 3, Bloq = 5, Error = 15, Total = 23. CM: Trat = 40, Bloq = 17, Error = 3. $F_{\text{Trat}} = 13,33$, $F_{\text{Bloq}} = 5,67$. (b) $13,33 > 3,29$: rechazar H_0^{Trat} . $5,67 > 2,90$: rechazar H_0^{Bloq} . (c) Ambos factores son significativos: hay diferencias entre tratamientos y entre bloques.

7.3. Las dos pruebas F: interpretación dual

Antes de leer: hazte esta pregunta

En ANOVA de una vía tenías UNA prueba F . Ahora tienes DOS. ¿Cómo las leo? ¿Qué significa que una sea significativa y la otra no? ¿Me importa el F de los bloques o solo es un trámite?

7.3.1. Qué significa cada F

La herramienta estadística

Las dos pruebas F y su interpretación:

1. $F_{\text{Trat}} = \text{CM}_{\text{Trat}}/\text{CM}_{\text{Error}}$: ¿Hay diferencias entre los tratamientos, después de controlar por los bloques? Esta es tu **pregunta principal**. Si es significativa, concluyes que no todos los tratamientos son iguales — controlando por el bloque.
2. $F_{\text{Bloques}} = \text{CM}_{\text{Bloques}}/\text{CM}_{\text{Error}}$: ¿Hay diferencias entre los bloques, después de controlar por los tratamientos? Esta es una **pregunta secundaria** pero informativa.

Escenarios posibles:

- **Ambos significativos:** Ambos factores importan. Reporta los dos. Tu decisión de bloquear fue acertada y además tienes un hallazgo sobre los bloques.
- **Solo F_{Trat} significativo:** El escenario más común. Los bloques cumplieron su función (reducir error) aunque no sean significativos por sí mismos. Tus conclusiones sobre tratamientos son válidas.
- **Solo F_{Bloques} significativo:** Los bloques importan pero los tratamientos no. Posiblemente los tratamientos son homogéneos, o el tamaño de muestra es insuficiente.
- **Ninguno significativo:** No hay evidencia de diferencias en tratamientos ni en bloques. Posiblemente el fenómeno es homogéneo, o necesitas más datos.

Región de rechazo:

$$\text{Rechazar } H_0^{\text{Trat}} \text{ si } F_{\text{Trat}} > F_{\alpha, k-1, (k-1)(b-1)}$$

$$\text{Rechazar } H_0^{\text{Bloques}} \text{ si } F_{\text{Bloques}} > F_{\alpha, b-1, (k-1)(b-1)}$$

Referencia formal: Wackerly §13.9; Notas de clase, Teoremas 10.2–10.3.

Caso Real: Tasa de homicidios por región y período

El Secretariado Ejecutivo del SENSP reporta tasas de homicidio doloso por entidad federativa. Agrupamos 5 regiones (tratamiento) y 3 años: 2015, 2016, 2017 (bloque). Queremos saber: **¿la tasa de homicidios difiere entre regiones, incluso después de controlar por el año?**

Esto es crucial porque la violencia en México tuvo un pico alrededor de 2017. Si no controlas por período, podrías concluir erróneamente que una región es más violenta simplemente porque sus datos son del año más violento.

Datos reales del SESNSP (2015–2017):

- Noroeste: 88, 110, 165 (por 100k) —la más violenta, con pico en 2017
- Noreste: 34, 42, 47
- Centro: 44, 51, 59
- Sur: 41, 53, 60
- Sureste: 20, 19, 25 —la menos violenta

$F_{\text{region}}(4, 8) = 18,45, p < 0,001$: diferencias enormes entre regiones. $F_{\text{año}}(2, 8) = 3,68, p = 0,074$: evidencia marginal de aumento temporal. La región explica mucha más variabilidad ($SC = 17,064$) que el año ($SC = 1,700$).

En R

ANOVA dos vías: homicidios región $\times$ año (SESNSP):

```
# Fuente: SESNSP, Incidencia Delictiva 2015-2017
region <- rep(c("Noroeste", "Noreste", "Centro", "Sur", "Sureste"), each=3)
anio <- rep(c("2015", "2016", "2017"), times=5)
tasa <- c(88,110,165, 34,42,47, 44,51,59, 41,53,60, 20,19,25)

modelo <- aov(tasa ~ region + anio,
              data = data.frame(region, anio, tasa))
summary(modelo)
```

#	Df	Sum Sq	Mean Sq	F value	Pr(>F)
# region	4	17064	4266	18.45	0.00042 ***
# anio	2	1700	850	3.68	0.07369 .
# Residuals	8	1850	231		

Interpretación: La región es el factor dominante. Incluso controlando por el aumento temporal de la violencia, el Noroeste tiene tasas entre 4 y 8 veces las del Sureste. El efecto del año es marginalmente significativo al 10 %: hay evidencia del aumento de violencia entre 2015 y 2017 documentado ampliamente.

Tarjeta de repaso

Frente: ¿Me importa F_{Bloques} si mi pregunta es sobre tratamientos?

Reverso: Sí, por dos razones. (1) **Validación del diseño:** si F_{Bloques} es significativo, tu decisión de bloquear fue correcta y ganaste potencia. Si no, los bloques no eran necesarios pero no invalidan nada. (2) **Información sustantiva:** a veces el “bloque” es una segunda pregunta de investigación. Que el período sea significativo en homicidios te dice que la violencia cambió en el tiempo —un hallazgo relevante. Nunca ignores F_{Bloques} ; repórtalo junto con F_{Trat} .

Pregunta de autoevaluación

Un ANOVA de dos vías produce: $F_{\text{Trat}}(3, 12) = 8,5, p = 0,003$; $F_{\text{Bloques}}(4, 12) = 1,2, p = 0,36$.

(a) ¿Qué concluyes sobre los tratamientos y los bloques?

(b) ¿Debió el investigador usar ANOVA de una vía? ¿Por qué?

Respuesta: (a) Los tratamientos difieren significativamente; no hay evidencia de diferencias entre bloques. (b) No necesariamente. Controlar por bloques fue una decisión válida si había razones teóricas. Con ANOVA de una vía, el error habría

tenido más gl pero un CM_{Error} mayor (absorbiendo la variabilidad de los bloques). El diseño de dos vías es más conservador y transparente: separa explícitamente lo que es tratamiento de lo que es bloque.

7.4. Los supuestos del ANOVA de dos vías y el nuevo: aditividad

Antes de leer: hazte esta pregunta

El ANOVA de una vía pide normalidad, homocedasticidad e independencia. El de dos vías pide lo mismo... ¿pero hay algún supuesto nuevo? Sí: **aditividad**. ¿Qué es y por qué importa?

7.4.1. El modelo aditivo y sus límites

El modelo $X_{ij} = \mu + \alpha_i + \beta_j + \varepsilon_{ij}$ asume que el efecto del tratamiento y el del bloque se **soman**, no interactúan. Esto significa que el efecto de la región sobre el ingreso es el mismo para jóvenes, adultos y mayores. Pero ¿y si no es así? ¿Y si la brecha regional es mayor para los jóvenes que para los adultos? Eso sería una **interacción**: el efecto del tratamiento *depende* del bloque.

La herramienta estadística

El supuesto de aditividad:

- **Definición:** $E[X_{ij}] = \mu + \alpha_i + \beta_j$. El efecto del tratamiento NO depende del bloque, y viceversa.
- **Si se cumple:** el modelo es correcto y CM_{Error} estima σ^2 limpiamente.
- **Si se viola (hay interacción):** el término de interacción no modelado es absorbido por SC_{Error} , inflando CM_{Error} y reduciendo artificialmente la potencia. Peor aún: tus estimaciones de α_i y β_j están sesgadas porque el modelo atribuye incorrectamente la variabilidad.

¿Cómo verifico aditividad?

- **Gráfico de interacción:** Grafica las medias por tratamiento contra bloques. Si las líneas son **paralelas**, la aditividad es razonable. Si se **cruzan**, hay interacción.
- **Prueba de Tukey para no-aditividad:** particiona la SC del error en un componente de no-aditividad y un residual puro. Si el componente es significativo, el modelo aditivo es inadecuado.

¿Y si falla? Si tienes réplicas, usa el modelo con interacción: $X_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk}$. Sin réplicas: (a) transforma la respuesta, (b) acepta el modelo como aproximación, o (c) recolecta más datos.

Referencia formal: Wackerly §13.10; Tukey (1949), *Biometrics*, 5(3), 232–242.

En R**Diagnóstico de aditividad en R:**

```
# Gráfico de interacción
interaction.plot(x.factor = edad, trace.factor = region,
                 response = ingreso_miles,
                 main = "¿Hay interacción región × edad?",
                 xlab = "Grupo de edad", ylab = "Ingreso (miles MXN)",
                 legend = TRUE, col = 2:6)

# Líneas paralelas → aditividad OK
# Líneas que se cruzan → interacción

# Prueba de Tukey para no-aditividad
library(agricolae)
modelo <- aov(ingreso_miles ~ region + edad, data = ingreso)
tukey.add.test(modelo)
```

7.4.2. “Controlando por” en español

Nota didáctica

¿Qué significa exactamente “controlando por”? Es una de las frases más usadas y menos explicadas en estadística.

En su sentido **algebraico**, “controlar por” el bloque significa: el modelo $X_{ij} = \mu + \alpha_i + \beta_j + \varepsilon_{ij}$ estima simultáneamente los α_i (efectos de región) y los β_j (efectos de edad). Al estimar α_{Noroeste} , el modelo descuenta la asociación lineal con la edad: la variabilidad atribuible al bloque se asigna a β_j , no a α_i . Matemáticamente, $\hat{\alpha}_i = \bar{X}_{i.} - \bar{X}_{..}$ después de ajustar por el efecto promedio de los bloques. En este sentido, la diferencia estimada entre regiones está **ajustada** por diferencias en la composición etaria.

En su sentido **interpretativo**, conviene ser cauteloso. Con datos observacionales, este ajuste es **descriptivo**: remueve la porción de la diferencia regional que está linealmente asociada con la edad, pero **no** aísla un efecto causal de la región. Pueden persistir otras diferencias no observadas entre regiones (infraestructura, inversión, calidad institucional) que no están en el modelo. La frase “como si ambas regiones tuvieran la misma distribución de edades” es una metáfora pedagógica útil, no una afirmación de identificación causal.

Conexión con econometría (Lab 7): En regresión múltiple $y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + u$, el coeficiente β_1 se interpreta como la asociación de X_1 con y , **ajustando por** X_2 . La misma cautela aplica: el ajuste es descriptivo a menos que se satisfagan supuestos de identificación más fuertes (exogeneidad condicional, ausencia de variables omitidas). El ANOVA de dos vías es una regresión con dummies para tratamiento y dummies para bloque: $y = \beta_0 + \sum \gamma_i D_i^{\text{Trat}} + \sum \delta_j D_j^{\text{Bloq}} + u$. Los $\hat{\gamma}_i$ estiman las diferencias entre tratamientos ajustando por el bloque.

Tarjeta de repaso

Frente: ¿Qué es el supuesto de aditividad?

Reverso: El efecto del tratamiento y del bloque se suman, no interactúan. Formalmente: $E[X_{ij}] = \mu + \alpha_i + \beta_j$, sin término $\alpha\beta_{ij}$. Si hay interacción, el modelo es inadecuado: CM_{Error} absorbe la interacción, inflándose y reduciendo potencia. Verifica con gráfico de interacción: líneas paralelas = OK; líneas que se cruzan = problema.

En español: “Controlando por edad” significa “comparo las regiones como si tuvieran la misma distribución de edades.” Lo que queda de diferencia es atribuible a la región.

Pregunta de autoevaluación

Un investigador compara 3 fertilizantes en 4 tipos de suelo. Solo una parcela por combinación. El gráfico de interacción muestra que el Fertilizante A es el mejor en suelo arenoso pero el peor en arcilloso, mientras B es consistente.

- (a) ¿Se cumple la aditividad?
 (b) ¿Qué implicaciones tiene?
 (c) ¿Qué debería hacer?

Respuesta: (a) No —las líneas se cruzan. (b) El modelo aditivo atribuye la interacción al error, inflando CM_{Error} y pudiendo ocultar diferencias reales. (c) (i) Recolectar réplicas para ajustar un modelo con interacción, (ii) analizar cada suelo por separado con ANOVA de una vía, o (iii) reportar los resultados con la advertencia de posible interacción no modelada.

7.5. χ^2 bondad de ajuste: más allá de comparar medias

Antes de leer: hazte esta pregunta

Hasta ahora todas tus pruebas evaluaban parámetros: ¿son iguales estas medias? ¿Es cero esta diferencia? Pero ¿y si tu hipótesis es sobre la *distribución completa* de los datos? Por ejemplo: ¿siguen estas declaraciones fiscales la Ley de Benford? Para eso necesitas χ^2 de bondad de ajuste.

7.5.1. El salto conceptual: de parámetros a distribuciones

ANOVA y las pruebas t comparan medidas de tendencia central (medias). Pero una distribución es mucho más que su media: dos conjuntos de datos pueden tener la misma media y ser radicalmente distintos (uno simétrico, otro con cola pesada; uno unimodal, otro bimodal). La χ^2 de bondad de ajuste te permite comparar la **forma completa** de la distribución contra un modelo teórico.

Definición: Prueba χ^2 de bondad de ajuste

Hipótesis:

H_0 : Los datos siguen una distribución específica (Benford, Poisson, Normal, Uniforme...)

H_a : Los datos NO siguen esa distribución

Estadístico de prueba:

$$Q = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

donde:

- k : número de categorías (ej. 9 para el primer dígito)
- O_i : frecuencia **observada** en la categoría i
- E_i : frecuencia **esperada** bajo H_0 . Para Benford: $E_i = n \times \log_{10}(1 + 1/d_i)$.

Bajo H_0 y n grande, $Q \sim \chi^2_{k-1-m}$, donde m es el número de parámetros estimados de los datos.

Regla de dedo: La aproximación χ^2 es razonable si **todas** las $E_i \geq 5$. Si alguna $E_i < 5$, colapsa categorías.

¿Qué mide Q ? Es una “distancia” entre lo observado y lo esperado bajo H_0 . Si H_0 es verdadera, $(O_i - E_i)$ son fluctuaciones muestrales y Q es pequeño. Si H_0 es falsa, alguna categoría está sistemáticamente lejos de lo esperado y Q es grande.

Referencia formal: Wackerly §14.3; Casella & Berger §8.2–8.3.

7.5.2. La Ley de Benford: el 1 no es como los demás

La herramienta estadística

La Ley de Benford (primer dígito). En muchos conjuntos de datos reales que abarcan varios órdenes de magnitud —poblaciones, facturas, declaraciones fiscales, resultados electorales— el primer dígito NO se distribuye uniformemente (1/9 cada uno). Sigue:

$$P(\text{primer dígito} = d) = \log_{10} \left(1 + \frac{1}{d} \right), \quad d = 1, 2, \dots, 9$$

Dígito d	1	2	3	4	5	6	7	8	9
Probabilidad	0.301	0.176	0.125	0.097	0.079	0.067	0.058	0.051	0.046

El 1 aparece como primer dígito el **30.1 %** de las veces —tres veces más que el 11.1 % que esperarías si los dígitos fueran uniformes. El 9 aparece solo el 4.6 % de las veces.

¿Por qué funciona? Porque en datos que crecen multiplicativamente (poblaciones, ingresos, precios de acciones), hay más números que empiezan con dígitos pequeños. Para pasar de 1000 a 2000 necesitas duplicar; para pasar de 9000 a 10000 solo necesitas crecer 11 %. Los números “pasan más tiempo” en el rango de los dígitos bajos.

Aplicación forense: Datos fabricados por humanos tienden a tener demasiados dígitos 5, 6, 7 (porque la gente cree que los dígitos son uniformes) y muy pocos 1. La χ^2 detecta esta desviación. El SAT, la ASF y auditores forenses usan esto para seleccionar contribuyentes a auditar.

Caso Real: Detección de fraude fiscal en México

El Servicio de Administración Tributaria (SAT) procesa millones de facturas electrónicas cada año. Los montos declarados —si son genuinos— deberían seguir aproximadamente la Ley de Benford (abarcan desde facturas de \$100 hasta con-

tratos de \$500 millones). Cuando un contribuyente inventa montos, típicamente los distribuye demasiado uniformemente entre dígitos.

Un auditor selecciona 500 facturas de una empresa constructora. Bajo Benford, espera ver:

- ≈ 150 facturas con primer dígito 1 (30.1 % de 500)
- ≈ 88 facturas con primer dígito 2 (17.6 %)
- ≈ 23 facturas con primer dígito 9 (4.6 %)

Si en cambio observa 80 facturas con dígito 1 (un déficit de 70) y 80 con dígito 5 (un exceso de 40), el estadístico Q se infla. La χ^2 formaliza: ¿es esta discrepancia mayor que la esperable por azar?

En R

Prueba χ^2 de Benford en R:

```
# Parámetros
n_facturas <- 500
benford_prob <- log10(1 + 1/(1:9)) # prob. teóricas de Benford

# Escenario A: datos que SÍ siguen Benford
datos_reales <- sample(1:9, n_facturas, replace=TRUE, prob=benford_prob)
obs_reales <- table(factor(datos_reales, levels=1:9))
chisq.test(obs_reales, p = benford_prob)
# X-squared  $\approx$  3-8, df=8, p > 0.05 → NO rechazar H0

# Escenario B: datos fabricados (distribución uniforme)
datos_fab <- sample(1:9, n_facturas, replace=TRUE)
obs_fab <- table(factor(datos_fab, levels=1:9))
chisq.test(obs_fab, p = benford_prob)
# X-squared  $\approx$  40-55, df=8, p < 0.001 → RECHAZAR H0

# Visualización
barplot(rbind(obs_reales/n_facturas, obs_fab/n_facturas, benford_prob),
        beside=TRUE, col=c("steelblue","tomato","gray60"),
        names.arg=1:9, main="Ley de Benford: observado vs esperado",
        xlab="Primer dígito", ylab="Proporción")
legend("topright", c("Datos reales","Datos fabricados","Benford"),
        fill=c("steelblue","tomato","gray60"))
```

Interpretación: En el Escenario A, $Q(8)$ es pequeño y $p > 0,05$: los datos son compatibles con Benford. En el Escenario B, $Q(8)$ es grande y $p < 0,001$: los datos se desvían fuertemente. Este es el tipo de análisis que usan el SAT y la ASF para seleccionar auditorías (Nigrini 2012, Cap. 7).

Tarjeta de repaso

Frente: ¿Qué mide Q en χ^2 de bondad de ajuste?

Reverso: $Q = \sum (O_i - E_i)^2 / E_i$ mide la **discrepancia global** entre lo observado y lo esperado bajo H_0 . Es una “distancia” entre tus datos y la teoría. Q grande $\Rightarrow$ los datos no se parecen a lo que H_0 predice. Bajo H_0 , $Q \sim \chi^2_{k-1-m}$. La regla de dedo: todas las $E_i \geq 5$.

¿En qué se diferencia de ANOVA? ANOVA compara **medias** entre grupos. χ^2 compara la **forma completa** de la distribución. Puedes tener dos muestras con la misma media y distribuciones totalmente distintas: ANOVA no lo detecta, χ^2 sí.

Pregunta de autoevaluación

Un auditor examina 200 facturas. Benford predice $E_1 = 60,2$ facturas con primer dígito 1. Observa $O_1 = 45$. ¿Cuánto contribuye esta categoría al estadístico Q ? Si el Q total con 8 gl es 10,0 y $\chi^2_{0,05,8} \approx 15,51$, ¿rechaza H_0 al 5 %? Interpreta.

Respuesta: Contribución del dígito 1: $(45 - 60,2)^2 / 60,2 = 231,04 / 60,2 \approx 3,84$. El Q total es $10,0 < 15,51$: **no** se rechaza H_0 al 5 %. Hay un déficit de dígitos 1 (típico de datos fabricados), pero con solo 200 facturas, la discrepancia global no es estadísticamente significativa. El auditor necesitaría una muestra más grande o un patrón más extremo. *Moraleja:* la intuición visual no basta; la prueba χ^2 protege contra el sobrediagnóstico.

7.6. χ^2 de independencia: asociación entre variables categóricas

Antes de leer: hazte esta pregunta

La χ^2 de bondad de ajuste compara una distribución observada contra una teórica. Pero hay otra pregunta igualmente importante: ¿están asociadas dos variables categóricas? Por ejemplo: ¿el nivel educativo y la formalidad laboral son independientes, o existe una asociación?

7.6.1. De bondad de ajuste a independencia

La χ^2 de independencia es una extensión natural. En vez de comparar una distribución univariada contra una teórica, comparas la distribución **conjunta** de dos variables contra la que esperarías si fueran independientes.

La herramienta estadística

Prueba χ^2 de independencia.

Hipótesis:

H_0 : Las dos variables son independientes

H_a : Las dos variables NO son independientes (están asociadas)

Estadístico de prueba (mismo Q):

$$Q = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

donde r son las filas y c las columnas de la tabla de contingencia. Las frecuencias esperadas bajo independencia son:

$$E_{ij} = \frac{(\text{total fila } i) \times (\text{total columna } j)}{n}$$

Bajo H_0 , $Q \sim \chi^2_{(r-1)(c-1)}$.

En español: Si las variables son independientes, la proporción en cada celda debería ser el producto de las proporciones marginales. $E_{ij} = n \times \hat{p}_i \times \hat{p}_j$. Cualquier desviación sistemática de este patrón infla Q y sugiere asociación.

Referencia formal: Wackerly §14.4; Casella & Berger §8.4.

Caso Real: ¿Están asociados el nivel educativo y la formalidad laboral en México?

La ENOE (INEGI, 2023) clasifica a los trabajadores por nivel educativo (sin primaria, primaria, secundaria, media superior, superior) y por condición de formalidad (formal, informal). La tabla de contingencia (con datos reales aproximados para 2023, en miles de trabajadores):

Nivel educativo	Formal	Informal	Total
Sin primaria	1,200	3,800	5,000
Primaria	3,500	7,500	11,000
Secundaria	6,000	9,000	15,000
Media superior	5,500	5,500	11,000
Superior	6,800	2,200	9,000
Total	23,000	28,000	51,000

A simple vista, la formalidad aumenta con la educación (del 24 % en “sin primaria” al 76 % en “superior”). La χ^2 de independencia formaliza: ¿es esta asociación estadísticamente significativa?

Bajo independencia, esperaríamos que todas las filas tuvieran la misma proporción de formales ($23,000/51,000 = 45,1\%$). Pero no es así: los datos muestran un gradiente claro. Con 4 gl, Q será enorme y $p < 0,0001$: rechazas H_0 contundentemente. Educación y formalidad no son independientes.

En R χ^2 de independencia en R:

```
# Tabla de contingencia: educación × formalidad (ENOE, 2023)
educ_formal <- matrix(
  c(1200, 3800, 3500, 7500, 6000, 9000,
    5500, 5500, 6800, 2200),
  nrow = 5, byrow = TRUE,
  dimnames = list(
    Educacion = c("Sin primaria", "Primaria", "Secundaria",
                  "Media superior", "Superior"),
    Condicion = c("Formal", "Informal")
  )
)

# Prueba chi-cuadrada de independencia
chisq.test(educ_formal)
# X-squared  $\approx$  8760, df = 4, p-value < 2.2e-16

# Ver frecuencias esperadas bajo independencia
chisq.test(educ_formal)$expected

# Contribución de cada celda al estadístico Q (residuos)
chisq.test(educ_formal)$residuals
```

Interpretación: $Q(4) \approx 8,760$, $p < 2,2 \times 10^{-16}$. Rechazas H_0 : hay una asociación fuertísima entre educación y formalidad. Los residuos estandarizados muestran que los trabajadores con educación superior están sobrerrepresentados en el sector formal (residuo positivo grande) y los de baja educación en el informal.

Tarjeta de repaso

Frente: ¿En qué se diferencia χ^2 de bondad de ajuste de χ^2 de independencia?

Reverso: La **bondad de ajuste** compara una distribución observada (univariada) contra una distribución teórica (H_0 especifica las probabilidades). La **independencia** compara la distribución **conjunta** de dos variables contra la que esperarías si fueran independientes (H_0 : las variables no están asociadas). El estadístico Q es el mismo en ambas; lo que cambia es cómo calculas E_i : en bondad de ajuste vienen de la teoría (Benford, Poisson), en independencia vienen del producto de marginales.

Pregunta de autoevaluación

Un investigador cruza región (Norte, Centro, Sur) con percepción de inseguridad (Alta, Media, Baja) en una encuesta de $n = 1,200$ personas. Obtiene $Q(4) = 28,5$, $\chi^2_{0,05,4} \approx 9,49$. ¿Qué concluye? Interpreta.

Respuesta: $28,5 > 9,49$, $p < 0,001$. Rechaza H_0 : hay una asociación significativa entre región y percepción de inseguridad. La percepción de inseguridad no se distribuye igual en las tres regiones: al menos una región tiene una proporción de personas que se sienten inseguras distinta a las demás. Esto NO implica causalidad (no sabemos si es la región la que causa la percepción, o si hay otros factores), solo asociación.

7.7. Flujo completo: integrando ANOVA dos vías y χ^2

Antes de leer: hazte esta pregunta

Tienes dos herramientas nuevas: ANOVA de dos vías y χ^2 (bondad de ajuste e independencia). ¿Cómo decides cuál usar? ¿Y cómo integras todo en un flujo reproducible?

La herramienta estadística

Flujo de 7 pasos para análisis integrados:

- Paso 1. Define las preguntas.** ¿Variable respuesta continua? → ANOVA. ¿Categorica? → χ^2 . ¿Tienes una variable de bloque? → ANOVA dos vías. ¿Hipótesis sobre distribución completa? → χ^2 bondad de ajuste.
- Paso 2. Explora los datos.** Boxplots por tratamiento y bloque (ANOVA). Tablas de contingencia y frecuencias observadas vs. esperadas (χ^2).
- Paso 3. Verifica supuestos.** ANOVA dos vías: normalidad, homocedasticidad, independencia, aditividad. χ^2 : $E_i \geq 5$ para todas las celdas.
- Paso 4. Ajusta el modelo.** `aov(y ~trat + bloque)` o `chisq.test()`.
- Paso 5. Interpreta las pruebas.** ANOVA: ambos F con sus gl y p . Reporta η^2 parcial. χ^2 : Q , gl, p .
- Paso 6. Si rechazas H_0 , profundiza.** ANOVA: Tukey HSD para tratamientos. χ^2 bondad de ajuste: residuos estandarizados para identificar categorías desviadas. χ^2 independencia: residuos para identificar celdas con asociación fuerte.
- Paso 7. Comunica resultados.** Estadísticos de prueba, gl, p , tamaño del efecto, y conclusión sustantiva en español.

Referencia formal: Wackerly §13.9–13.10, §14.3–14.4.

Caso Real: ¿Influyen la región y el trimestre en la inversión extranjera directa?

La Secretaría de Economía reporta la IED trimestral por entidad federativa. Un investigador quiere saber si la IED media difiere entre 5 regiones (tratamiento), controlando por trimestre (bloque). Adicionalmente, quiere verificar si los montos de IED reportados siguen la Ley de Benford —una desviación podría indicar reportes inflados en ciertas regiones. Este caso integra ANOVA de dos vías y χ^2 en un solo análisis.

En R

Flujo integrado en R:

```
# === PARTE A: ANOVA de dos vías (IED por región y trimestre) ===
ied <- data.frame(
  region = rep(c("Norroeste", "Noreste", "Centro", "Sur", "Sureste"), each=3),
  trimestre = rep(c("Q1", "Q2", "Q3"), times=5),
  ied_millones = c(450,520,480, 380,410,390, 720,810,750, 120,140,130, 90,105,95)
)
modelo_ied <- aov(ied_millones ~ region + trimestre, data = ied)
summary(modelo_ied)
# region: F(4,8)=62.71, p<0.001 → diferencias regionales enormes
# trimestre: F(2,8)=1.04, p=0.396 → sin efecto trimestral

# === PARTE B: chi^2 Benford sobre los montos ===
montos <- ied$ied_millones
primer_digito <- as.numeric(substr(as.character(montos), 1, 1))
obs_digitos <- table(factor(primer_digito, levels = 1:9))
benford_prob <- log10(1 + 1/(1:9))
chisq.test(obs_digitos, p = benford_prob)
# Con solo 15 obs, Ei < 5 para varias celdas | solo ilustrativo.
# En la práctica, se necesitan n >= 100 montos.
```

Interpretación integrada: La IED difiere radicalmente entre regiones ($F = 62,7$, $p < 0,001$) pero no entre trimestres. La región Centro concentra la mayor IED (promedio \$760M), el Sureste la menor (\$97M). La prueba Benford con 15 montos es ilustrativa; en la práctica se requieren al menos 100 observaciones para que la aproximación χ^2 sea confiable.

Tarjeta de repaso

Frente: ¿Cuándo usar ANOVA de dos vías y cuándo χ^2 ?

Reverso: Usa **ANOVA de dos vías** cuando tu variable respuesta es **continua** y quieres comparar medias entre tratamientos controlando por una variable de bloque. Usa χ^2 **bondad de ajuste** cuando tu variable es **categorica** y evalúas si su distribución sigue un modelo teórico (Benford, Poisson, etc.). Usa χ^2 **de indepen-**

dencia cuando tienes **dos variables categóricas** y preguntas si están asociadas. No son intercambiables: ANOVA compara medias, χ^2 compara distribuciones.

Pregunta de autoevaluación

Un investigador tiene datos de salarios en 4 sectores (tratamiento) y 3 niveles educativos (bloque). También quiere verificar si los primeros dígitos de los salarios siguen Benford. Diseña el flujo de análisis completo.

Respuesta: (1) Preguntas: ¿El salario difiere entre sectores controlando por educación? (ANOVA dos vías). ¿Los primeros dígitos siguen Benford? (χ^2). (2) Explorar: medias por sector y educación, tabla de primeros dígitos. (3) Supuestos ANOVA: Q-Q, Levene, independencia, aditividad (gráfico de interacción). χ^2 : verificar $E_i \geq 5$. (4) `aov(salario ~ sector + educacion)` y `chisq.test()`. (5) Interpretar ambos F y Q . (6) Si ANOVA rechaza: Tukey HSD por sector. Si χ^2 rechaza: identificar dígitos con mayores residuos. (7) Reportar todo en formato paper.

7.8. Autoevaluación del capítulo

- (Sección 1) Explica con tus palabras qué ganas al usar bloques en un ANOVA. Da un ejemplo mexicano donde controlar por una segunda variable cambie la conclusión.
- (Sección 2) En un ANOVA de dos vías con $k = 5$ tratamientos y $b = 4$ bloques: ¿cuántos gl tiene el error? Si $SC_{\text{Trat}} = 200$, $SC_{\text{Bloques}} = 60$, $SC_{\text{Error}} = 48$, completa la tabla ANOVA y calcula ambos F .
- (Sección 3) ¿Qué significa que F_{Trat} sea significativo pero F_{Bloques} no lo sea? ¿Debí haber usado ANOVA de una vía?
- (Sección 4) ¿Qué es el supuesto de aditividad? ¿Cómo lo verificas visualmente? Si falla, ¿qué haces?
- (Sección 5) Un auditor examina 300 facturas. Benford predice 90.3 con primer dígito 1, pero observa 72. ¿Qué contribución hace esta categoría a Q ? Si $Q = 15,3$ con 8 gl, ¿rechaza H_0 al 5% ($\chi^2_{0,05,8} \approx 15,51$)?
- (Sección 6) ¿En qué se diferencia χ^2 de independencia de χ^2 de bondad de ajuste? Da un ejemplo mexicano para cada una.

Mapa de decisiones ampliado (Labs 4–6)

Tengo...	¿Qué comparo?	Herramienta	Nota clave
1 grupo continuo	Media vs. referencia	t una muestra (Lab 4)	σ desconocida
2 grupos continuos	Medias	t dos muestras (Lab 4)	Verificar homocedasticidad
3+ grupos, 1 factor	Medias k grupos	ANOVA una vía + Tukey	Una prueba; post-hoc si rechaza
3+ grupos + bloque	Medias controlando por bloque	ANOVA dos vías	Dos pruebas F ; verificar aditividad
1 variable categórica	Distribución vs. teoría	χ^2 bondad de ajuste	Benford, Poisson; $E_i \geq 5$
2 variables categóricas	Asociación entre variables	χ^2 independencia	Tabla de contingencia

Regla de oro: Variable respuesta **continua** $\rightarrow$ mundo ANOVA/ t (comparas medias). Variable respuesta **categórica** $\rightarrow$ mundo χ^2 (comparas distribuciones). El ANOVA de dos vías extiende el de una vía cuando tienes una variable adicional que controlar.

Conexión: Lab 6 $\rightarrow$ Lab 7

ANOVA y regresión **NO** son herramientas diferentes. Son la misma herramienta con distinto nombre.

La revelación que unifica el curso

En el Lab 5 viste que ANOVA de una vía es regresión con variables dummy. En el Lab 6 extendiste esa lógica a dos factores (tratamiento + bloque). El Laboratorio 7 completa la escalera: ¿qué pasa cuando tu variable predictora X no es categórica sino **continua**?

La respuesta es la **regresión lineal simple**:

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

Y aquí está la revelación: la **descomposición de varianza** es exactamente la misma.

La identidad que lo conecta todo

ANOVA (Labs 5–6)	Regresión (Lab 7)	¿Qué significa?
SCT SC _{Entre} / SC _{Trat} SC _{Dentro} / SC _{Error}	SCT SCE (Suma de Cuadrados de la Regresión) SCR (Suma de Cuadrados de los Residuos)	Variabilidad total de Variabilidad explicada por Variabilidad NO explicada

$$\underbrace{\sum (Y_i - \bar{Y})^2}_{\text{SCT}} = \underbrace{\sum (\hat{Y}_i - \bar{Y})^2}_{\text{SCE}} + \underbrace{\sum (Y_i - \hat{Y}_i)^2}_{\text{SCR}}$$

Es la misma identidad. En ANOVA, $\hat{Y}_i = \bar{X}_{\text{grupo}}$ (la media del grupo al que pertenece la observación). En regresión, $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ (la recta ajustada). En ambos casos, $\hat{Y}_i$ es tu mejor predicción de Y_i dado el modelo.

La prueba F es la misma

- **En ANOVA:** $F = \text{CM}_{\text{Entre}} / \text{CM}_{\text{Dentro}}$ evalúa H_0 : todas las medias son iguales.
- **En regresión:** $F = \text{CM}_{\text{Regresión}} / \text{CM}_{\text{Error}}$ evalúa H_0 : $\beta_1 = 0$ (la pendiente es cero; X no explica Y).

Ambas pruebas preguntan: **¿el modelo explica más variabilidad que el azar?**
El estadístico F , su distribución bajo H_0 , y la lógica de rechazo son **idénticos**.

De X categórica a X numérica: el salto final

Lab	Naturaleza de X	Modelo
Lab 4	X binaria (2 grupos)	t -test = regresión con 1 dummy
Lab 5	X categórica (k grupos)	ANOVA una vía = regresión con $k - 1$ dummies
Lab 6	X_1 categórica + X_2 categórica	ANOVA dos vías = regresión con dummies para ambos
Lab 7	X continua (numérica)	Regresión lineal simple

El salto del Lab 6 al Lab 7 es **conceptual**, no matemático. Las matemáticas ya las tienes: descomposición de varianza, prueba F , $R^2 = \eta^2$. Lo nuevo es la **interpretación**: en vez de decir “el grupo A difiere del grupo B en 5 unidades”, dices “por cada unidad adicional de X , Y cambia en $\hat{\beta}_1$ unidades”. La pendiente $\hat{\beta}_1$ es la generalización natural de la diferencia entre medias.

Lo que viene en el Laboratorio 7

- **El modelo:** $Y_i = \beta_0 + \beta_1 X_i + u_i$. Estimamos $\hat{\beta}_0$ y $\hat{\beta}_1$ por Mínimos Cuadrados Ordinarios (MCO).
- **La pendiente:** $\hat{\beta}_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2}$. Es la “diferencia en Y por unidad de cambio en X .”

- **La bondad de ajuste:** $R^2 = \text{SCE}/\text{SCT}$. Es exactamente η^2 con otro nombre: la proporción de varianza de Y explicada por X .
- **La prueba t para β_1 :** $H_0 : \beta_1 = 0$. ¿La pendiente es cero? Para regresión simple, $t^2 = F$ —igual que en ANOVA para $k = 2$.
- **Los supuestos:** Linealidad, independencia, homocedasticidad, normalidad de los errores. Son los mismos supuestos de ANOVA, más el de linealidad.
- **La generalización:** Puedes añadir más X 's (regresión múltiple), X 's categóricas (dummies) y continuas en el mismo modelo (ANCOVA), e interacciones. Todo es regresión.

La escalera completa:

Prueba $t \subset$ ANOVA una vía $\subset$ ANOVA dos vías $\subset$ Regresión lineal

Cada paso contiene a los anteriores. La prueba t es ANOVA para $k = 2$. ANOVA es regresión con dummies. La regresión es la generalización a variables continuas. No hay fronteras reales: hay una sola lógica —descomponer varianza y comparar señal contra ruido— que se viste con distintos trajes según la naturaleza de tus variables.

Referencia formal: Wackerly §11.3–11.6 (regresión lineal simple); Casella & Berger §11.3 (modelos lineales); Angrist & Pischke (2009, Cap. 3, “Regression Makes Me Feel Funny” —el capítulo que conecta regresión con todo lo anterior).

8. Regresión lineal simple: modelando relaciones entre variables

“La regresión es el martillo del economista. Con él, todo problema parece un clavo. Este capítulo te enseña cuándo el clavo es real y cuándo te estás golpeando el pulgar.”

Ruta de lectura

Este capítulo cierra la Parte III del curso. Si vienes de los Labs 5 y 6 (ANOVA), aquí verás que la regresión es la generalización natural: donde ANOVA compara medias entre grupos definidos por una variable categórica, la regresión modela la relación entre dos variables numéricas. Y —esto es lo importante— la regresión **contiene** a ANOVA como caso particular: una regresión con variables dummy es matemáticamente equivalente a un ANOVA. Si no has leído los capítulos anteriores, las cajas de **sutura** (azul claro) te indicarán exactamente qué necesitas recuperar de cada lab.

8.1. Herencia de todo el curso: lo que los seis laboratorios anteriores construyeron para este momento

Herencia conceptual: De los 6 laboratorios anteriores al Lab 7

Este capítulo no empieza de cero. Cada concepto que usarás en regresión fue construido, pieza por pieza, en los seis laboratorios anteriores. Esta sección te muestra el mapa completo de esas herencias. Si algo no te suena familiar, el número de laboratorio te dice exactamente dónde repasar.

Lab 1 → Lab 7: Inssegamiento y eficiencia. El Teorema de Gauss-Markov dice que MCO es MELI (Mejor Estimador Lineal Inssegado, o BLUE por sus siglas en inglés: *Best Linear Unbiased Estimator*). Cada palabra de ese acrónimo es un concepto del Lab 1. “Inssegado” significa $E[\hat{\beta}_1] = \beta_1$: en promedio, el estimador acierta. Es exactamente la misma propiedad que estudiaste para $\bar{X}$ en el Lab 1. “Mejor” significa mínima varianza dentro de la clase de estimadores lineales e inssegados

—la eficiencia relativa que aprendiste a comparar con el ECM (Error Cuadrático Medio) del Lab 1—. La fórmula de $\text{Var}(\hat{\beta}_1) = \sigma^2/S_{xx}$ depende de σ^2 , la varianza del error, que estimaste por primera vez en el Lab 1 con $\hat{\sigma}^2$. Sin el Lab 1, Gauss-Markov sería un conjuro; con el Lab 1, es una consecuencia.

Lab 2 → Lab 7: MCO = MLE bajo normalidad. El método de Máxima Verosimilitud (MLE) que aprendiste en el Lab 2 produce estimadores maximizando la probabilidad conjunta de los datos. Bajo el supuesto de normalidad de los errores ($u \sim \mathcal{N}(0, \sigma^2)$), el MLE de (β_0, β_1) coincide **exactamente** con el estimador MCO. La función de verosimilitud normal tiene en el exponente $\sum (y_i - \beta_0 - \beta_1 x_i)^2$, y maximizarla es equivalente a minimizar esa suma de cuadrados. MCO no es un método alternativo al MLE; es un **caso particular** del MLE cuando los errores son normales. Cada vez que corres `lm(y ~ x)` en R, estás calculando el MLE bajo normalidad, aunque no lo sepas. El Lab 2 te dio el marco general; aquí ves su instanciación más importante.

Lab 3 → Lab 7: El intervalo de confianza para β_1 . El IC para β_1 es un intervalo t : $\hat{\beta}_1 \pm t_{\alpha/2, n-2} \cdot \text{EE}(\hat{\beta}_1)$. La estructura es idéntica a la del IC para μ que construiste en el Lab 3: estimador puntual $\pm$ valor crítico $\times$ error estándar. Lo único que cambia es el parámetro de interés (β_1 en vez de μ) y los grados de libertad ($n - 2$ en vez de $n - 1$). La lógica es la misma: en vez de dar un solo número, das una banda que captura el verdadero valor poblacional con probabilidad $1 - \alpha$. Y la dualidad IC–prueba de hipótesis que aprendiste en el Lab 3 se mantiene intacta: si el IC del 95 % para β_1 no contiene al cero, la prueba t rechaza $H_0 : \beta_1 = 0$ al 5 %.

Lab 4 → Lab 7: La prueba t para β_1 . La prueba $H_0 : \beta_1 = 0$ usa la misma lógica que las pruebas del Lab 4: comparas un estadístico de prueba con un valor crítico de la distribución t . El estadístico $t = \hat{\beta}_1/\text{EE}(\hat{\beta}_1)$ es la razón señal/ruido. Rechazas si $|t| > t_{\alpha/2, n-2}$. La interpretación del valor p es idéntica: la probabilidad de observar un estadístico tan o más extremo que el obtenido, si H_0 fuera cierta. Todo lo que aprendiste sobre errores Tipo I y Tipo II, potencia, y tamaño de prueba en el Lab 4 aplica directamente aquí. Solo cambian los grados de libertad ($n - 2$ en vez de $n - 1$) y el parámetro bajo prueba.

Lab 5 → Lab 7: La descomposición de la varianza. La identidad fundamental de la regresión, $\text{SCT} = \text{SCE} + \text{SCR}$, es la misma idea que la descomposición de ANOVA: $\text{SC}_{\text{Total}} = \text{SC}_{\text{Entre}} + \text{SC}_{\text{Dentro}}$. En ANOVA, descompones la variabilidad total de y en variabilidad *entre grupos* (explicada por la variable categórica) y variabilidad *dentro de grupos* (residual). En regresión, descompones la variabilidad total en variabilidad *explicada por la recta* (SCE) y variabilidad *residual* (SCR). La estructura matemática es idéntica. Y $R^2 = \text{SCE}/\text{SCT}$ en regresión es el análogo directo de η^2 en ANOVA.

Lab 6 → Lab 7: Regresión con dummies = ANOVA. El Lab 6 te mostró el ANOVA de dos vías y la prueba χ^2 de independencia. Pero hay una conexión más profunda que el Lab 6 sembró y que aquí cosechamos: cuando todas tus variables independientes son dummies (variables indicadoras que codifican pertenencia a grupos), la regresión múltiple **es** un ANOVA. La prueba F global de la regresión

$(H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0)$ es matemáticamente equivalente a la prueba F de ANOVA. Esta conexión se explora a fondo en el Lab 8, pero la semilla está plantada aquí: ANOVA y regresión no son herramientas separadas, son dos caras de la misma moneda. El Lab 6 como “ANOVA dos vías” reaparece en el Lab 8 como “regresión múltiple con interacciones”.

✓ Verifica tu comprensión

Antes de seguir, verifica que entiendes cada una de las seis conexiones anteriores. Si alguna te parece oscura, repasa el capítulo correspondiente. La regresión no se aprende de una sola sentada: se construye sobre capas. Estas seis herencias son las capas.

8.2. El dataset: escolaridad e ingreso en 32 estados mexicanos

Antes de leer: hazte esta pregunta

Imagina que eres analista en la Secretaría de Hacienda. Tienes dos números para cada uno de los 32 estados de México: cuántos años estudia en promedio su población ocupada, y cuánto gana en promedio al mes. ¿Están relacionados estos dos números? ¿Un estado con más escolaridad tiende a tener mayor ingreso laboral? ¿Qué tan fuerte es esa relación?

Caso Real: Escolaridad promedio vs. Ingreso laboral mensual en México

Trabajamos con datos de las **32 entidades federativas** de México. Para cada estado tenemos dos variables numéricas:

- x = **escolaridad promedio** de la población ocupada (años de estudio, aproximación basada en patrones de la ENOE-INEGI).
- y = **ingreso laboral mensual promedio** (miles de pesos corrientes, aproximación basada en patrones ENOE-ENIGH).

La pregunta es directa —y es exactamente el tipo de pregunta que un economista responde con datos—: ¿en qué medida la escolaridad promedio de un estado está **asociada** con el ingreso laboral de su población? No es una pregunta causal con estos datos (Sección 7), pero medir la asociación es el primer paso indispensable de cualquier análisis económico serio.

¿Por qué estos datos y no microdatos? Porque los datos agregados por estado permiten ver patrones que los datos individuales oscurecen con ruido. A nivel estado, la correlación entre escolaridad e ingreso es mucho más alta que a nivel individuo ($R^2 \approx 0,93$ vs. $R^2 \approx 0,15$ – $0,25$ en datos individuales de la ENOE). Esto no significa

que el modelo agregado sea “mejor”: significa que la agregación elimina variabilidad individual y captura factores estructurales comunes. Entender esta diferencia entre correlación agregada e individual es parte de lo que distingue a un economista que *usa* datos de uno que *entiende* lo que está haciendo.

Cómputo

La tabla siguiente muestra los datos completos de las 32 entidades. $n = 32$, $\bar{x} = 9,52$ años, $\bar{y} = 8,15$ miles de pesos. El rango de escolaridad va de 7.5 años (Oaxaca) a 11.5 años (Ciudad de México). El rango de ingreso va de 4.2 (Oaxaca) a 13.5 miles de pesos (Ciudad de México).

Estado	x	y	Estado	x	y
Aguascalientes	10.2	9.8	Morelos	9.6	7.9
Baja California	10.5	11.2	Nayarit	9.3	7.0
Baja California Sur	10.3	9.9	Nuevo León	11.0	12.8
Campeche	9.5	8.2	Oaxaca	7.5	4.2
Chiapas	7.8	4.5	Puebla	8.8	6.5
Chihuahua	9.8	9.1	Querétaro	10.4	10.8
Ciudad de México	11.5	13.5	Quintana Roo	10.0	8.9
Coahuila	10.3	10.2	San Luis Potosí	9.1	7.2
Colima	10.0	8.8	Sinaloa	9.8	8.4
Durango	9.4	7.5	Sonora	10.4	10.0
Guanajuato	8.9	7.8	Tabasco	9.5	7.1
Guerrero	8.1	4.8	Tamaulipas	10.1	9.3
Hidalgo	9.0	6.9	Tlaxcala	9.3	6.0
Jalisco	10.1	9.5	Veracruz	8.6	7.4
México	9.4	7.6	Yucatán	9.2	6.2
Michoacán	8.3	5.8	Zacatecas	8.8	6.0

Estadísticos descriptivos:

$$\begin{aligned}\bar{x} &= 9,52, & s_x &= 0,89, & \min(x) &= 7,5, & \max(x) &= 11,5 \\ \bar{y} &= 8,15, & s_y &= 2,22, & \min(y) &= 4,2, & \max(y) &= 13,5\end{aligned}$$

Intuición

Leer la tabla como un economista. No te limites a ver números. Pregúntate: ¿qué estados son los extremos? Oaxaca (7.5 años, \$4,200) y CDMX (11.5 años, \$13,500) definen las esquinas del scatterplot. La diferencia es brutal: 4 años más de escolaridad promedio se asocian con \$9,300 más de ingreso mensual. ¿Es lineal esa relación? ¿O hay rendimientos decrecientes? ¿Qué pasa con estados intermedios como Nuevo León (11.0, \$12,800) o Querétaro (10.4, \$10,800)? La regresión nos da una respuesta cuantitativa a estas preguntas. Pero antes de correr una regresión, **mira los datos**. Un scatterplot (mental o dibujado) te dice más que cualquier tabla de coeficientes.

En contexto mexicano

Los datos en el contexto de la economía mexicana. La brecha educativa entre el norte y el sur de México es uno de los hechos estilizados más documentados de la economía regional mexicana. Los estados del norte (Nuevo León, Baja California, Chihuahua, Sonora) tienen sistemáticamente mayor escolaridad e ingreso que los del sur (Oaxaca, Chiapas, Guerrero). La pregunta es: ¿cuánto de la brecha de ingreso se “explica” por la brecha educativa? La regresión nos da una métrica: aproximadamente \$2,380 pesos por año de escolaridad. Pero —y esto es crucial— la brecha Norte-Sur NO es solo educativa. Hay infraestructura, cercanía a EUA, inversión extranjera, calidad institucional, estructura productiva. La regresión simple captura la asociación bruta, no el efecto causal de la educación. Si controláramos por todas esas variables (regresión múltiple, Lab 8), el coeficiente de escolaridad probablemente bajaría. Ese cambio en el coeficiente al agregar controles ES la evidencia de sesgo por variables omitidas.

Tarjeta de repaso

El dataset en una línea: 32 estados mexicanos. x = escolaridad promedio (años), y = ingreso laboral mensual (miles \$). Rango: Oaxaca (7.5, 4.2) a CDMX (11.5, 13.5). Pregunta: ¿está asociada la escolaridad con el ingreso a nivel estatal?

8.3. El modelo poblacional: $y = \beta_0 + \beta_1 x + u$ **Antes de leer: hazte esta pregunta**

Si tuvieras que resumir la relación entre escolaridad e ingreso con una línea recta, ¿qué pendiente le pondrías? ¿Pasaría por el origen? ¿Qué significa que NO pase por el origen? ¿Qué factores —además de la escolaridad— afectan el ingreso de un estado, y dónde quedan en el modelo?

Intuición

La idea fundamental en una frase. El modelo de regresión lineal simple dice: el ingreso de un estado se puede descomponer en dos partes —una parte **sistemática** que depende linealmente de la escolaridad ($\beta_0 + \beta_1 x$), y una parte **idiosincrática** que captura todo lo demás (u).

Esta descomposición no es un truco matemático: es una forma de pensar sobre el mundo. Cada vez que dices “en igualdad de condiciones”, estás haciendo regresión mental. “En igualdad de condiciones, un estado con más escolaridad gana más” —eso es β_1 . “En igualdad de condiciones” es la cláusula *ceteris paribus* que los economistas usan todo el tiempo, y la regresión es la herramienta que intenta aproximarla con datos.

β_1 es la pendiente: cuánto cambia y , en promedio, cuando x aumenta en una unidad. En nuestro caso: ¿cuántos miles de pesos más de ingreso mensual se asocian con un

año adicional de escolaridad promedio?

β_0 es el intercepto: el valor esperado de y cuando $x = 0$. En nuestro caso: ¿qué ingreso tendría un estado con cero años de escolaridad? Esta pregunta es contrafactual y, para nuestros datos, absurda —ningún estado tiene escolaridad cero—. Pero β_0 es matemáticamente necesario para trazar la recta. No todos los parámetros de un modelo tienen interpretación sustantiva; algunos son auxiliares geométricos. El término u (llamado *error* o *perturbación*) no es un “error” en el sentido de equivocación: es todo aquello que afecta el ingreso de un estado **además de** la escolaridad. La regresión no pretende que u sea cero; pretende que u sea **no sistemático** con respecto a x . Ese es el supuesto clave que discutiremos en la Sección 5.

Cómputo

Formalmente:

$$y_i = \beta_0 + \beta_1 x_i + u_i, \quad i = 1, \dots, n \quad (8.1)$$

donde:

- y_i : variable dependiente o **regresando** (ingreso laboral mensual) para la observación i .
- x_i : variable independiente, **regresora** o **covariable** (escolaridad promedio) para la observación i .
- β_0, β_1 : parámetros poblacionales desconocidos, fijos.
- u_i : término de error o perturbación, inobservable.

La **función de regresión poblacional** (FRP) es:

$$E[y \mid x] = \beta_0 + \beta_1 x$$

Esta ecuación dice: el valor esperado del ingreso, *dado* un nivel de escolaridad x , es una función lineal de x . La FRP existe en la población; nosotros no la conocemos y debemos estimarla con una muestra.

Notación: la convención del gorrito. A lo largo de TODO el curso:

- β_0, β_1 = parámetros poblacionales (sin gorrito, cantidades fijas desconocidas)
- $\hat{\beta}_0, \hat{\beta}_1$ = estimadores (con gorrito, variables aleatorias que calculamos con los datos)
- $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ = valor ajustado (lo que el modelo predice para la observación i)
- $\hat{u}_i = y_i - \hat{y}_i$ = residuo (diferencia entre el valor observado y el ajustado)

El gorrito distingue lo que conocemos (la estimación) de lo que quisiéramos conocer (el parámetro). Esa distinción es la columna vertebral de la inferencia estadística.

En contexto mexicano

¿Qué está en u para nuestros 32 estados? El término de error en nuestro modelo incluye, como mínimo:

- **Cercanía a Estados Unidos:** La frontera norte genera empleo manufacturero (maquila), comercio transfronterizo, y turismo que elevan el ingreso independientemente de la escolaridad.
- **Recursos naturales:** El petróleo de Campeche y Tabasco, la minería de Zacatecas y Sonora, el turismo de Quintana Roo —todos afectan el ingreso por canales distintos a la educación.
- **Calidad institucional:** Dos estados con 10 años de escolaridad pueden tener ingresos muy distintos si uno tiene un gobierno estatal eficiente y el otro no.
- **Estructura productiva histórica:** El Bajío industrial (Guanajuato, Querétaro, Aguascalientes) tiene una base manufacturera que el sureste no tiene, por razones que preceden a las diferencias educativas actuales.
- **Calidad de la educación:** No todos los años de escolaridad son iguales. Un año en una escuela de Nuevo León puede producir más capital humano que un año en una escuela de Chiapas, y esa diferencia de calidad va a parar a u .

Esto no invalida el modelo. Simplemente nos obliga a ser cuidadosos con la interpretación: $\hat{\beta}_1$ captura la asociación **bruta** entre escolaridad e ingreso, no el efecto causal de la educación. Para aislar ese efecto necesitaríamos controlar por las variables en u (regresión múltiple) o usar un diseño cuasi-experimental (econometría).

Conexión: Lab 1 → Lab 7

Insesgamiento y el modelo poblacional. En el Lab 1 aprendiste que un estimador $\hat{\theta}$ es insesgado si $E[\hat{\theta}] = \theta$. Para que $\hat{\beta}_1$ sea insesgado ($E[\hat{\beta}_1] = \beta_1$), necesitamos que $E[u \mid x] = 0$ (RLS.4). Si este supuesto falla —porque la calidad institucional está en u y correlacionada con x — entonces $E[\hat{\beta}_1] \neq \beta_1$: el estimador es **sesgado**. Es el mismo concepto de sesgo del Lab 1, aplicado a un parámetro nuevo. Y la lección del Lab 1 se mantiene: el sesgo no desaparece con más datos. Un estimador sesgado es **inconsistente** (no converge al verdadero valor poblacional aunque $n \rightarrow \infty$). Esta es la razón por la que el supuesto RLS.4 es el más importante de todo el modelo.

Conexión: Lab 2 → Lab 7

MCO como caso particular de MLE. En el Lab 2 aprendiste a construir estimadores por Máxima Verosimilitud: planteas la densidad conjunta de los datos, tomas logaritmo, derivas e igualas a cero. Si asumimos que los errores son normales,

$u_i \sim \mathcal{N}(0, \sigma^2)$, la función de log-verosimilitud es:

$$\ln L(\beta_0, \beta_1, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Maximizar esta función respecto a (β_0, β_1) es **exactamente equivalente** a minimizar la suma de cuadrados de los residuos. Los estimadores MCO y MLE coinciden. Bajo normalidad, cada vez que corres `lm()` en R, estás calculando el MLE, aunque el output no lo diga. Esta equivalencia es una de las razones por las que MCO es tan ubicuo en econometría: no solo es MELI (Gauss-Markov), sino que también es el estimador de máxima verosimilitud bajo el supuesto más común sobre los errores.

Definición: Función de regresión poblacional

La **función de regresión poblacional** (FRP) de y sobre x es la esperanza condicional:

$$E[y \mid x] = \beta_0 + \beta_1 x$$

Es una función determinística de x (no contiene el error u) y representa el valor *promedio* de y para cada nivel de x en la población.

Tarjeta de repaso

El modelo poblacional en una línea: $y = \beta_0 + \beta_1 x + u$ separa la relación sistemática (la recta) de todo lo demás (el error). β_1 es el cambio promedio en y por unidad de x *en la población*. β_0 es el valor esperado de y cuando $x = 0$. $E[u \mid x] = 0$ es el supuesto que hace que MCO sea insesgado.

Ejemplo trabajado: Interpretación económica de los parámetros

Un colega te dice: “Estimé una regresión del salario por hora (y) sobre años de educación (x) y obtuve $\hat{\beta}_0 = -5,2$ y $\hat{\beta}_1 = 1,8$. ¿Qué significa esto?”

1. $\hat{\beta}_1 = 1,8$: En mi muestra, un año adicional de educación está **asociado** con \$1.80 más de salario por hora, en promedio.
2. $\hat{\beta}_0 = -5,2$: Si una persona tuviera cero años de educación, el modelo predice un salario de -\$5.20 por hora. Pero en mi muestra, la escolaridad mínima es 6 años. $\hat{\beta}_0$ es una extrapolación: no le doy interpretación sustantiva.
3. **¿Es $\hat{\beta}_1$ el retorno causal a la educación?** No necesariamente. Si la habilidad innata está en u y correlacionada con la educación, $\hat{\beta}_1$ está sesgado al alza (captura parte del efecto de la habilidad). Este es el clásico “sesgo de habilidad” en la ecuación de Mincer.

8.4. Mínimos Cuadrados Ordinarios (MCO): encontrar la recta óptima

Antes de leer: hazte esta pregunta

Tienes 32 puntos en un plano (escolaridad, ingreso). Hay **infinitas** rectas que podrías trazar. ¿Cuál es la “mejor”? ¿Qué criterio usarías para decidir? ¿Por qué no simplemente dibujar una recta “a ojo” y ya?

Intuición

MCO como problema de optimización. Imagina que eres un sastre y tienes 32 clientes (los estados). Cada cliente tiene una medida de escolaridad (x) y una de ingreso (y). Quieres confeccionar una recta que le quede “lo mejor posible” a todos. Pero no puedes hacer una recta a la medida de cada quien: tienes que elegir UNA sola recta para todos.

El criterio MCO es: elige la recta que minimiza la **suma de los cuadrados de las distancias verticales** entre cada punto y la recta. ¿Por qué verticales? Porque queremos predecir y dado x ; el error que nos importa es cuánto nos equivocamos en y , no en x . ¿Por qué al cuadrado? Por tres razones:

1. **Penaliza más los errores grandes:** Un residuo de 3 aporta 9 a la suma, no 3. Esto evita que la recta “tolere” un error enorme en un punto a cambio de ajustar perfectamente los demás.
2. **Solución única y cerrada:** La función objetivo es convexa (una parábola en β_0 y β_1); el mínimo global es único y tiene una fórmula explícita.
3. **Propiedades estadísticas deseables:** Bajo los supuestos de Gauss-Markov, MCO produce el estimador lineal insesgado de menor varianza (BLUE).

Piensa en MCO como un problema de optimización restringida. En microeconomía eliges cantidades para maximizar utilidad sujeta a una restricción presupuestal. En estadística eliges $\hat{\beta}_0, \hat{\beta}_1$ para minimizar $\sum \hat{u}_i^2$ sujeta a que la relación sea lineal. La estructura lógica es idéntica: función objetivo, variables de decisión, condiciones de primer orden.

Cómputo

El problema de minimización:

$$\min_{\hat{\beta}_0, \hat{\beta}_1} Q(\hat{\beta}_0, \hat{\beta}_1) = \sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

Los estimadores MCO (obtenidos de las condiciones de primer orden):

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\widehat{\text{Cov}}(x, y)}{\widehat{\text{Var}}(x)} = \frac{S_{xy}}{S_{xx}} \quad (8.2)$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad (8.3)$$

donde $S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$ es la “covarianza muestral escalada” y $S_{xx} = \sum (x_i - \bar{x})^2$ es la “varianza muestral escalada” de x .

Propiedades algebraicas de MCO (se cumplen SIEMPRE, sin necesidad de supuestos estadísticos):

1. $\sum_{i=1}^n \hat{u}_i = 0$ (los residuos suman cero: la recta “equilibra” errores positivos y negativos)
2. $\sum_{i=1}^n x_i \hat{u}_i = 0$ (x y los residuos son ortogonales: no hay correlación muestral entre x y $\hat{u}$)
3. $\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$ (la recta pasa por el centro de gravedad de los datos $(\bar{x}, \bar{y})$)
4. $\sum_{i=1}^n \hat{y}_i \hat{u}_i = 0$ (valores ajustados y residuos son ortogonales)

La propiedad 3 es particularmente útil: te dice que **siempre** puedes calcular $\hat{\beta}_0$ una vez que tienes $\hat{\beta}_1$, sin necesidad de volver a los datos. La propiedad 2 es la que garantiza la descomposición SCT = SCE + SCR (Sección 4): el término cruzado $\sum (\hat{y}_i - \bar{y}) \hat{u}_i$ es cero precisamente por esta ortogonalidad.

En contexto mexicano

Resultados para los 32 estados mexicanos. Aplicando las fórmulas MCO a nuestro dataset:

$$\hat{y} = -14,53 + 2,38 x \quad (8.4)$$

Interpretación de $\hat{\beta}_1 = 2,38$: En nuestra muestra de 32 estados, un año adicional de escolaridad promedio está **asociado** con aproximadamente \$2,380 pesos más de ingreso laboral mensual, en promedio.

Interpretación de $\hat{\beta}_0 = -14,53$: El modelo predice que un estado con cero años de escolaridad tendría un ingreso de $-\$14,530$ pesos mensuales. Esto es un sinsentido económico: ningún estado tiene (ni tendrá) cero años de escolaridad, y un ingreso negativo es imposible. $\hat{\beta}_0$ es una extrapolación muy fuera del rango de los datos (el mínimo de x es 7.5). Lo usamos para trazar la recta, no para hacer inferencia

sustantiva.

¿Es 2.38 un número grande o chico? Depende del contexto. \$2,380 pesos al mes son \$28,560 al año. Si el ingreso promedio es \$8,150, un aumento de \$2,380 representa un 29 % de incremento por año de escolaridad. Para ponerlo en perspectiva: la literatura de retornos a la educación en México (usando ecuaciones de Mincer en logaritmos) encuentra retornos de 7–10 % por año de escolaridad. Nuestro coeficiente en niveles (no en logs) no es directamente comparable, pero sugiere una asociación económicamente sustancial.

Advertencia sobre el intercepto: No todos los números de una regresión tienen interpretación. $\hat{\beta}_0$ es un auxiliar geométrico. Forzar una interpretación sustantiva de un intercepto fuera de rango es un error de principiante. En economía aplicada, es perfectamente aceptable reportar “el intercepto no tiene interpretación económica en este contexto” y seguir adelante.

En R

La regresión más simple en R:

```
# Datos: vectores x (escolaridad) e y (ingreso)
modelo <- lm(y ~ x)
summary(modelo)
```

```
# Para obtener solo los coeficientes:
coef(modelo)
```

```
# Para el intervalo de confianza del 95%:
confint(modelo)
```

```
# Para los valores ajustados y residuos:
fitted(modelo)
resid(modelo)
```

`lm()` significa *linear model*. La fórmula `y ~ x` se lee “*y* en función de *x*” o “*y* regresado sobre *x*”. R incluye automáticamente el intercepto; si quisieras forzar una recta por el origen, usarías `lm(y ~ x - 1)` o `lm(y ~ 0 + x)`.

Conexión: Lab 2 → Lab 7

OLS = MLE bajo normalidad. Esta es una de las suturas más profundas del curso. En el Lab 2 derivaste el MLE para μ y σ^2 bajo normalidad. El procedimiento era: escribir la densidad conjunta, tomar logaritmo, derivar, igualar a cero. Si aplicas exactamente ese procedimiento al modelo $y_i = \beta_0 + \beta_1 x_i + u_i$ con $u_i \sim \mathcal{N}(0, \sigma^2)$, las condiciones de primer orden para β_0 y β_1 son **idénticas** a las condiciones de primer orden de MCO. La única diferencia está en el estimador de σ^2 : MLE usa n en el denominador (sesgado), mientras que el estimador insesgado usa $n - 2$. Pero para β_0

y β_1 , MLE y MCO coinciden **exactamente**. Esta equivalencia es la razón por la que MCO hereda las propiedades asintóticas del MLE bajo normalidad: consistencia, normalidad asintótica, y eficiencia asintótica.

Definición: Residuo vs. Error

- **Error** (u_i): la diferencia entre y_i y la *función de regresión poblacional*. Es inobservable. $u_i = y_i - \beta_0 - \beta_1 x_i$.
- **Residuo** ($\hat{u}_i$): la diferencia entre y_i y la *recta de regresión estimada*. Es observable (lo calculamos con los datos). $\hat{u}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$.

El residuo es una **estimación** del error, de la misma forma que $\hat{\beta}_1$ es una estimación de β_1 . Nunca confundas residuo con error: el error pertenece a la población, el residuo a la muestra.

Tarjeta de repaso

MCO en una línea: $\hat{\beta}_1 = S_{xy}/S_{xx}$ es la pendiente que minimiza $\sum \hat{u}_i^2$. La recta siempre pasa por $(\bar{x}, \bar{y})$, los residuos suman cero, y x y $\hat{u}$ son ortogonales. $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ es un auxiliar geométrico; no siempre tiene interpretación sustantiva.

Pregunta de autoevaluación

Un estudiante corre $\text{lm}(y \sim x)$ y obtiene $\hat{\beta}_0 = 3,2$, $\hat{\beta}_1 = 0,8$. Afirma: “El modelo predice que cuando $x = 0$, $y = 3,2$. Por lo tanto, si x representa años de educación, una persona sin educación gana 3.2 unidades de ingreso.” ¿Es correcta esta interpretación? ¿Qué condiciones deben cumplirse para que $\hat{\beta}_0$ tenga interpretación sustantiva?

Ejemplo trabajado: Cálculo manual de $\hat{\beta}_1$ con un subconjunto pequeño

Para entender la mecánica, calculamos $\hat{\beta}_1$ a mano con solo 5 estados: CDMX (11.5, 13.5), Nuevo León (11.0, 12.8), Oaxaca (7.5, 4.2), Chiapas (7.8, 4.5), y Sonora (10.4, 10.0).

$$\bar{x} = 9,64, \quad \bar{y} = 9,00$$

$$S_{xy} = (11,5 - 9,64)(13,5 - 9,00) + \dots + (10,4 - 9,64)(10,0 - 9,00) = 32,85$$

$$S_{xx} = (11,5 - 9,64)^2 + \dots + (10,4 - 9,64)^2 = 13,85$$

$$\hat{\beta}_1 = \frac{32,85}{13,85} \approx 2,37$$

Con solo 5 estados, la pendiente estimada es 2.37 (vs. 2.38 con los 32). La estimación es notablemente estable: incluso con una fracción de la muestra completa, $\hat{\beta}_1$ se sitúa muy cerca del valor obtenido con los 32 estados. Esto no es casualidad: bajo los

supuestos de Gauss-Markov (Sección 5), el estimador MCO es insesgado, de modo que el valor con 5 observaciones y el valor con 32 **oscilan alrededor del mismo β_1 poblacional**. Lo que cambia es la **precisión**: con $n = 5$, el error estándar es mucho mayor que con $n = 32$. Esa diferencia de precisión —no de estimación puntual— es exactamente la razón por la que necesitamos errores estándar e inferencia (Secciones 5–6): un solo número no nos dice qué tan precisa es la estimación.

8.5. Bondad de ajuste: R^2 y la descomposición de la varianza

Antes de leer: hazte esta pregunta

La recta $\hat{y} = -14,53 + 2,38x$ es la mejor según MCO. Pero ¿qué tan buena es? ¿Qué porcentaje de la variabilidad en ingresos entre estados está asociado linealmente con la escolaridad? Si el modelo solo “explica” el 10 % de la variabilidad, ¿sirve para algo?

Intuición

La metáfora de la pizza. Imagina que la variabilidad total del ingreso entre los 32 estados es una pizza entera (SCT, Suma de Cuadrados Totales). La regresión “reparte” esa pizza en dos porciones:

- La porción que la recta **explica**: la variabilidad de los valores ajustados $\hat{y}_i$ alrededor de la media $\bar{y}$. Esta es SCE (Suma de Cuadrados Explicada). Mide qué tanto se mueven las predicciones del modelo.
- La porción que queda **sin explicar**: la variabilidad de los residuos $\hat{u}_i$. Esta es SCR (Suma de Cuadrados de Residuos). Mide qué tanto se equivoca el modelo.

R^2 es simplemente la fracción de la pizza que corresponde a SCE:

$$R^2 = \frac{\text{SCE}}{\text{SCT}} = 1 - \frac{\text{SCR}}{\text{SCT}}$$

$R^2 \in [0, 1]$. $R^2 = 0$ significa que la recta es horizontal ($\hat{\beta}_1 = 0$): la escolaridad no explica nada de la variabilidad en el ingreso. $R^2 = 1$ significa que todos los puntos caen exactamente sobre la recta ($\hat{u}_i = 0$ para toda i): la escolaridad determina perfectamente el ingreso. En la práctica, con datos sociales, $R^2 > 0,30$ ya es respetable; $R^2 > 0,70$ es muy bueno; $R^2 > 0,90$ es excepcionalmente alto —y potencialmente sospechoso—.

¿Por qué “explicada” va entre comillas? Porque R^2 mide asociación lineal, no causalidad. Un R^2 alto no significa que x *cause* y . Puede reflejar variables omitidas que están correlacionadas tanto con x como con y . Puede ser artificialmente alto por datos agregados (como los nuestros). Y en regresión múltiple, R^2 siempre aumenta al agregar variables, incluso si son ruido puro.

Cómputo

La identidad fundamental de la regresión:

$$\underbrace{\sum_{i=1}^n (y_i - \bar{y})^2}_{\text{SCT}} = \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{\text{SCE}} + \underbrace{\sum_{i=1}^n \hat{u}_i^2}_{\text{SCR}} \quad (8.5)$$

Esta descomposición es posible gracias a la ortogonalidad entre $\hat{y}$ y $\hat{u}$ (propiedad 4 de MCO). El término cruzado $\sum (\hat{y}_i - \bar{y})\hat{u}_i = 0$ porque $\sum \hat{y}_i \hat{u}_i = 0$ y $\bar{y} \sum \hat{u}_i = 0$.

Para nuestro dataset de 32 estados mexicanos:

$$\text{SCT} = 152,88 \quad (8.6)$$

$$\text{SCE} = 142,55 \quad (8.7)$$

$$\text{SCR} = 10,33 \quad (8.8)$$

$$R^2 = \frac{142,55}{152,88} = 0,9324 \quad (8.9)$$

Interpretación: El 93,24% de la variabilidad en el ingreso laboral entre los 32 estados mexicanos está **asociada linealmente** con la escolaridad promedio. Solo el 6,76% de la variabilidad queda sin explicar por el modelo lineal simple.

Una propiedad adicional: En regresión lineal simple, R^2 es exactamente el cuadrado del coeficiente de correlación muestral entre x e y :

$$R^2 = r_{xy}^2 = \left(\frac{S_{xy}}{\sqrt{S_{xx} \cdot S_{yy}}} \right)^2$$

Para nuestros datos, $r_{xy} \approx 0,9656$, y $r_{xy}^2 = 0,9324 = R^2$. Esta equivalencia **solo** se cumple en regresión simple con intercepto.

En contexto mexicano

¿Es creíble un R^2 de 0.93? Sí y no.

Por qué SÍ es creíble: A nivel agregado (estados, no individuos), las variables socioeconómicas tienden a estar muy correlacionadas. La escolaridad promedio de un estado no es solo una medida educativa: es un *proxy* del nivel de desarrollo general. Estados con alta escolaridad también tienen mejor infraestructura, más inversión, mejores instituciones. La escolaridad “absorbe” la variabilidad de todos esos factores correlacionados, produciendo un R^2 artificialmente alto. Esto es un fenómeno bien conocido en econometría: las regresiones con datos agregados (promedios estatales) producen R^2 mucho más altos que las regresiones con microdatos.

Por qué NO debemos interpretarlo como “la educación causa el 93% del ingreso”: Precisamente porque la escolaridad está correlacionada con otras variables omitidas. Si todas esas variables afectan el ingreso y están correlacionadas

con la escolaridad, el R^2 de la regresión simple refleja la asociación conjunta de todas ellas, no solo de la educación. Es el mismo problema de sesgo por variables omitidas que discutimos en el contexto de $\hat{\beta}_1$ (Sección 5).

Datos individuales vs. agregados: Con datos individuales de la ENOE, una regresión del ingreso sobre escolaridad típicamente produce $R^2 \approx 0,10\text{--}0,25$ en niveles, o $R^2 \approx 0,20\text{--}0,35$ en logaritmos (ecuación de Mincer). La diferencia entre 0.93 (agregado) y 0.20 (individual) ilustra dramáticamente el efecto de la agregación. No es que el modelo agregado sea “mejor”: es que mide algo distinto (asociación entre promedios, no entre individuos).

Moraleja: R^2 es una medida descriptiva útil, pero no es un certificado de calidad del modelo. Un R^2 alto no implica que el modelo sea correcto, que las predicciones sean buenas fuera de muestra, o que la relación sea causal. En palabras de un econometrista experimentado: “He visto regresiones espurias con R^2 de 0.99 y modelos correctos con R^2 de 0.05. El R^2 te dice qué tan bien la recta se ajusta a los puntos, no qué tan bien el modelo se ajusta a la realidad.”

Conexión: Lab 5 → Lab 7

SCT = SCE + SCR es la misma descomposición que ANOVA. En el Lab 5 aprendiste que la variabilidad total de una variable numérica y a través de k grupos se descompone como:

$$SC_{\text{Total}} = SC_{\text{Entre}} + SC_{\text{Dentro}}$$

En regresión, la descomposición es:

$$SCT = SCE + SCR$$

Donde SCE juega el papel de la variabilidad “entre” (explicada por x) y SCR juega el papel de la variabilidad “dentro” (residual). La identidad matemática es la misma; lo que cambia es qué variable “explica” la variabilidad. En ANOVA es una variable categórica (los grupos); en regresión es una variable numérica (la x). R^2 en regresión es el análogo de η^2 (eta cuadrado) en ANOVA: la proporción de la variabilidad total explicada por el modelo. Y así como en ANOVA comparas SC_{Entre} con SC_{Dentro} vía el estadístico F , en el Lab 8 harás lo mismo con SCE y SCR en la prueba F global de la regresión.

Conexión: Lab 6 → Lab 7

Regresión con dummies es ANOVA. El Lab 6 extendió ANOVA al caso de dos factores y te introdujo la prueba χ^2 de independencia. Pero también sentó las bases para una conexión más profunda: cuando codificas una variable categórica con k categorías usando $k - 1$ variables dummy (indicadoras 0/1) y las usas como regresores en una regresión múltiple, el modelo resultante es **matemáticamente equivalente** a un ANOVA de una vía. La prueba F de significancia global de esa regresión es la misma prueba F del ANOVA. Esta equivalencia te dice que ANOVA y regresión no son dos mundos separados: ANOVA es regresión con variables

categorías; regresión es ANOVA con variables numéricas. En el Lab 8 explorarás esta equivalencia en detalle con la regresión múltiple.

Tarjeta de repaso

R^2 en una línea: $R^2 = \text{SCE}/\text{SCT} = 1 - \text{SCR}/\text{SCT}$ mide la proporción de la variabilidad de y asociada linealmente con x . Va de 0 a 1. En regresión simple, $R^2 = r_{xy}^2$. Alto $R^2 \neq$ causalidad $\neq$ buen modelo.

Pregunta de autoevaluación

En un estudio con datos agregados por estado, un investigador reporta: $R^2 = 0,95$ para la regresión de criminalidad sobre desempleo. Concluye: “El desempleo explica el 95 % de la criminalidad.” Identifica al menos dos problemas con esta afirmación.

Ejemplo trabajado: Descomposición $\text{SCT} = \text{SCE} + \text{SCR}$ con 3 estados

Para verificar que la descomposición funciona, usamos 3 estados: CDMX (11.5, 13.5), Nuevo León (11.0, 12.8), Oaxaca (7.5, 4.2).

$$\bar{y} = 10,17$$

$$\text{SCT} = (13,5 - 10,17)^2 + (12,8 - 10,17)^2 + (4,2 - 10,17)^2 = 11,09 + 6,92 + 35,64 = 53,65$$

Usando $\hat{y} = -14,53 + 2,38x$:

$$\hat{y}_{\text{CDMX}} = -14,53 + 2,38(11,5) = 12,84$$

$$\hat{y}_{\text{NL}} = -14,53 + 2,38(11,0) = 11,65$$

$$\hat{y}_{\text{Oax}} = -14,53 + 2,38(7,5) = 3,35$$

$$\text{SCE} = (12,84 - 10,17)^2 + (11,65 - 10,17)^2 + (3,35 - 10,17)^2 = 7,13 + 2,19 + 46,51 = 55,83$$

Nota que SCE puede ser mayor que SCT con una recta que no es la de MCO (esta recta se estimó con 32 estados, no con 3). Con la recta MCO calculada solo con estos 3 estados, se cumpliría $\text{SCT} = \text{SCE} + \text{SCR}$ exactamente. La moraleja: la descomposición solo se cumple para la recta estimada con los mismos datos. Si aplicas una recta estimada con una muestra a otra muestra distinta, la descomposición no necesariamente se cumple.

8.6. Los supuestos que hacen que MCO funcione: Gauss-Markov

Antes de leer: hazte esta pregunta

Las fórmulas $\hat{\beta}_1 = S_{xy}/S_{xx}$ y $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}$ **siempre** se pueden calcular —son operaciones algebraicas—. Pero ¿bajo qué condiciones esos números significan algo sobre la población? ¿Qué puede salir mal? ¿Qué pasa si mi x y mi u están correlacionados?

Intuición

MCO es una herramienta, no un hechizo. Puedes meter cualquier par de columnas de números en R, correr `lm()`, y obtener $\hat{\beta}_0$ y $\hat{\beta}_1$. R no te va a decir “espera, tus supuestos no se cumplen”. Simplemente escupe números. Pero para que esos números **signifiquen algo** sobre la población —para que $\hat{\beta}_1$ sea un estimador razonable de β_1 — necesitas que se cumplan ciertas condiciones.

Los **supuestos de Gauss-Markov** (RLS.1 a RLS.5 en Wooldridge) son el paquete mínimo que garantiza que MCO es MELI: el **M**ejor **E**stimador **L**ineal **I**nesgado (BLUE en inglés). Vamos a descomponer el acrónimo:

- **Lineal:** $\hat{\beta}_1$ y $\hat{\beta}_0$ son combinaciones lineales de las y_i . Puedes escribir $\hat{\beta}_1 = \sum w_i y_i$ con pesos $w_i = (x_i - \bar{x})/S_{xx}$. Esto no es un supuesto; es una propiedad de la fórmula MCO.
- **Inesgado:** $E[\hat{\beta}_1] = \beta_1$. En promedio (sobre muchas muestras), el estimador acierta. Esto requiere RLS.1–RLS.4.
- **Mejor:** Dentro de la clase de estimadores lineales e inesgados, MCO tiene la menor varianza. Esto requiere los 5 supuestos.

Piensa en una balanza de laboratorio. Si está calibrada (inesgamiento: RLS.1–RLS.4), la aguja se mueve poco entre mediciones (eficiencia: RLS.5), y las mediciones no dependen de cómo coloques el objeto (linealidad: RLS.1), tienes un buen instrumento. Los supuestos de Gauss-Markov son la calibración de MCO.

Cómputo

Los cinco supuestos de Gauss-Markov (RLS.1 a RLS.5):

1. **RLS.1 — Linealidad en parámetros.** El modelo poblacional es $y = \beta_0 + \beta_1 x + u$. Los parámetros β_0, β_1 entran linealmente. Podemos transformar x e y (logaritmos, cuadrados, raíces), pero los *parámetros* deben ser lineales. Por ejemplo, $\ln(y) = \beta_0 + \beta_1 \ln(x) + u$ cumple RLS.1; $y = \beta_0 + \beta_1^2 x + u$ no (el parámetro β_1 entra al cuadrado).
2. **RLS.2 — Muestreo aleatorio.** Tenemos una muestra aleatoria de tamaño n

de la población: $\{(x_i, y_i) : i = 1, \dots, n\}$. Cada observación es independiente de las demás. Esto es lo que permite tratar a los datos como variables aleatorias i.i.d.

3. **RLS.3 — Variación muestral en x .** Los valores de x_i no son todos iguales. Si x no varía, no podemos estimar una pendiente (estaríamos dividiendo entre cero). Formalmente: $S_{xx} = \sum (x_i - \bar{x})^2 > 0$. En nuestro dataset mexicano, $S_{xx} \approx 25,08 > 0$, así que este supuesto se cumple.
4. **RLS.4 — Esperanza condicional cero del error.** $E[u | x] = 0$. **Este es EL supuesto clave.** Significa que, para cualquier valor de x , el valor esperado del error es cero. En español: no hay factores en u que estén sistemáticamente correlacionados con x . Si RLS.4 falla, $\hat{\beta}_1$ es **sesgado** e **inconsistente**: el sesgo no desaparece aunque $n \rightarrow \infty$.
5. **RLS.5 — Homocedasticidad.** $\text{Var}(u | x) = \sigma^2$ (constante). La varianza del error no depende de x . Si la dispersión de los ingresos es mayor en estados con más escolaridad (algo plausible), este supuesto falla. La violación se llama **heterocedasticidad**. Bajo heterocedasticidad, MCO sigue siendo insesgado, pero deja de ser eficiente (no es el de mínima varianza), y lo más grave: los errores estándar que reporta R son incorrectos, lo que invalida pruebas t e IC.

El Teorema de Gauss-Markov: Bajo RLS.1–RLS.5, los estimadores MCO $\hat{\beta}_0$ y $\hat{\beta}_1$ son los **Mejores Estimadores Lineales Insesgados** (MELI / BLUE): tienen la menor varianza entre todos los estimadores que son combinaciones lineales de y_i y son insesgados.

¿Qué pasa si añadimos normalidad? RLS.6 (opcional): $u \sim \mathcal{N}(0, \sigma^2)$, independiente de x . Bajo normalidad, los estadísticos t siguen **exactamente** una distribución t de Student. Sin normalidad, el Teorema del Límite Central asegura que son aproximadamente normales en muestras grandes, y la inferencia es **asintóticamente** válida.

En contexto mexicano

¿Se cumplen los supuestos en nuestro dataset mexicano? Seamos brutalmente honestos:

- **RLS.1 (linealidad):** Probablemente sí, como aproximación. La relación entre escolaridad e ingreso no es perfectamente lineal (posiblemente tenga rendimientos decrecientes), pero una recta es una primera aproximación razonable.
- **RLS.2 (muestreo aleatorio):** Técnicamente sí, porque usamos las 32 entidades federativas (no es una muestra, es la “población” de estados). Pero si pensamos en los estados como realizaciones de un proceso generador de datos, el supuesto es defendible.

- **RLS.3 (variación en x):** Sí, $S_{xx} > 0$. Hay variación sustancial en escolaridad entre estados.
- **RLS.4 ($E[u \mid x] = 0$):** Casi seguro que **NO se cumple**. La escolaridad promedio de un estado captura su nivel de desarrollo general. Estados con más escolaridad también tienen mejor infraestructura, más inversión extranjera, mejor calidad institucional, y todos esos factores están en u y correlacionados con x . $E[u \mid x] \neq 0$ casi con certeza.
- **RLS.5 (homocedasticidad):** Probablemente **NO se cumple**. Es plausible que la varianza del ingreso sea mayor en estados con mayor escolaridad (más heterogeneidad económica en estados desarrollados).

¿Significa esto que nuestra regresión no sirve? No. Significa que:

1. **No podemos interpretar $\hat{\beta}_1$ como efecto causal.** Lo interpretamos como asociación condicional: la diferencia promedio en ingreso entre estados que difieren en un año de escolaridad, sin controlar por otros factores.
2. **La inferencia (errores estándar, pruebas t) puede ser incorrecta** si hay heterocedasticidad severa. Afortunadamente, existen correcciones (errores estándar robustos de Huber-White) que verán en econometría.
3. **El R^2 probablemente sobreestima** la verdadera capacidad predictiva del modelo porque la escolaridad “absorbe” el efecto de variables omitidas correlacionadas.

Este tipo de razonamiento —preguntarse si los supuestos se cumplen, y ajustar la interpretación en consecuencia— es lo que distingue a un economista que *usa* regresiones de uno que *entiende* lo que hace. Angrist & Pischke (2009) lo llaman “the econometric turn”: pasar de calcular números a preguntarse qué significan.

Conexión: Lab 1 → Lab 7

El insesgamiento de $\hat{\beta}_1$ es el mismo concepto del Lab 1. En el Lab 1 definiste el sesgo de un estimador como $\text{Sesgo}(\hat{\theta}) = E[\hat{\theta}] - \theta$. Para $\hat{\beta}_1$, bajo RLS.1–RLS.4, $E[\hat{\beta}_1] = \beta_1$, así que $\text{Sesgo}(\hat{\beta}_1) = 0$. La demostración usa la linealidad de la esperanza y el supuesto RLS.4, exactamente como usaste $E[\bar{X}] = \mu$ en el Lab 1. Si RLS.4 falla, $E[\hat{\beta}_1] \neq \beta_1$ y el sesgo no desaparece con más datos: el estimador es inconsistente. La lección del Lab 1 —un estimador sesgado no se corrige solo con tamaño muestral grande— es la razón por la que RLS.4 es el supuesto más importante de todo el modelo de regresión.

Nota didáctica

Sobre la notación de los supuestos. Wooldridge (2020) etiqueta los supuestos como RLS.1–RLS.5 (Regresión Lineal Simple). Otros textos usan notación diferente

(A1–A5, GM1–GM5). Lo importante no es la etiqueta sino el contenido. En este curso usamos la notación de Wooldridge por ser el texto canónico en econometría aplicada.

Definición: Sesgo por variables omitidas

El **sesgo por variables omitidas** ocurre cuando una variable relevante que afecta a y está correlacionada con x pero no se incluye en el modelo. En ese caso, esa variable omitida “contamina” a u , violando RLS.4 ($E[u \mid x] \neq 0$), y $\hat{\beta}_1$ es un estimador sesgado de β_1 . La dirección del sesgo depende del signo de la correlación entre la variable omitida y x , y del signo de su efecto sobre y .

Nota didáctica

¿Qué mide MCO cuando RLS.4 falla? La condición $E[u \mid x] = 0$ tiene dos lecturas. En su sentido **algebraico**, es el supuesto que garantiza que MCO estima consistentemente los coeficientes de la *proyección lineal poblacional* de y sobre x —es decir, la mejor aproximación lineal a $E[y \mid x]$ en el sentido de error cuadrático medio. En su sentido **estructural**, es el supuesto que permite interpretar β_1 como el efecto causal de x sobre y (bajo linealidad). Cuando RLS.4 falla, MCO sigue estimando una proyección lineal válida —simplemente no es la proyección que correspondería al modelo *completo* que incluye las variables omitidas. El coeficiente $\hat{\beta}_1$ no es “basura”: es la pendiente de la mejor recta que puedes trazar con la variable x que tienes. Pero no es el efecto causal si hay variables omitidas correlacionadas con x . Esta distinción —proyección lineal vs. parámetro estructural— es central en econometría y se retoma en el Lab 8 con la regresión múltiple.

Tarjeta de repaso

Gauss-Markov en una línea: Bajo RLS.1–RLS.5, MCO es MELI (BLUE): el estimador lineal insesgado de mínima varianza. RLS.4 ($E[u \mid x] = 0$) es el supuesto crítico: si falla, $\hat{\beta}_1$ es sesgado e inconsistente.

Pregunta de autoevaluación

Un investigador estima el efecto de la inversión en infraestructura (x) sobre el crecimiento del PIB estatal (y) usando datos de las 32 entidades. Obtiene $\hat{\beta}_1 = 0,45$ ($p < 0,01$) y concluye que la inversión en infraestructura causa crecimiento. Un colega señala que los estados con mayor crecimiento también atraen más inversión (causalidad inversa) y que ambos están correlacionados con la calidad institucional (variable omitida). ¿Qué supuesto(s) de Gauss-Markov se viola(n)? ¿En qué dirección esperarías que esté sesgado $\hat{\beta}_1$?

8.7. Inferencia sobre $\hat{\beta}_1$: ¿es la asociación estadísticamente distinguible de cero?

Antes de leer: hazte esta pregunta

Obtuvimos $\hat{\beta}_1 = 2,38$. Pero esto es una estimación puntual basada en 32 estados. Si tomáramos otra muestra de 32 estados (o los mismos estados en otro año), ¿obtendríamos exactamente 2.38? Casi seguro que no. ¿Qué tan precisa es nuestra estimación? ¿Podemos descartar que el verdadero β_1 sea cero?

Intuición

La lógica de la inferencia: señal vs. ruido. $\hat{\beta}_1$ es una variable aleatoria: cambia de muestra a muestra. Bajo los supuestos de Gauss-Markov **más normalidad** (RLS.6), su distribución muestral es:

$$\hat{\beta}_1 \sim \mathcal{N}\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right)$$

Es decir, $\hat{\beta}_1$ se distribuye normalmente alrededor del verdadero valor poblacional β_1 , con una varianza que depende de σ^2 (el ruido) y de S_{xx} (la variación en x).

La inferencia funciona como un detector de señal:

Señal = $\hat{\beta}_1$ (lo que estimamos) Ruido = $EE(\hat{\beta}_1) = \sqrt{\widehat{\text{Var}}(\hat{\beta}_1)}$ (qué tanto fluctúa)

El estadístico t es simplemente la razón señal/ruido:

$$t = \frac{\hat{\beta}_1}{EE(\hat{\beta}_1)}$$

Si la señal es grande relativa al ruido ($|t|$ grande), concluimos que $\beta_1 \neq 0$: la asociación es “estadísticamente significativa”. Si la señal es chica ($|t|$ pequeño), no podemos descartar que $\beta_1 = 0$.

¿Por qué $n - 2$ grados de libertad? Porque estimamos 2 parámetros (β_0, β_1) con n observaciones. Perdemos un grado de libertad por cada parámetro estimado. En el Lab 3, para μ perdías 1 grado de libertad ($n - 1$). Aquí pierdes 2.

Cómputo

La varianza de $\hat{\beta}_1$ y su estimación: Bajo RLS.1–RLS.5:

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{S_{xx}}$$

Como σ^2 es desconocida, la estimamos con el **estimador insesgado de la varian-**

za del error:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n-2} = \frac{\text{SCR}}{n-2}$$

El divisor es $n-2$ (no n) porque “perdemos” 2 grados de libertad al estimar β_0 y β_1 . Con esto:

$$\widehat{\text{Var}}(\hat{\beta}_1) = \frac{\hat{\sigma}^2}{S_{xx}}, \quad \text{EE}(\hat{\beta}_1) = \sqrt{\widehat{\text{Var}}(\hat{\beta}_1)}$$

El estadístico t : Bajo $H_0 : \beta_1 = 0$ (y asumiendo normalidad de los errores):

$$t = \frac{\hat{\beta}_1 - 0}{\text{EE}(\hat{\beta}_1)} \sim t_{n-2}$$

La distribución t de Student con $n-2$ grados de libertad es la distribución de referencia. Es más ancha que la normal (colas más pesadas) para muestras pequeñas, y converge a la normal conforme n crece.

Para nuestro dataset de 32 estados mexicanos:

$$\hat{\beta}_1 = 2,3840 \quad (8.10)$$

$$\text{EE}(\hat{\beta}_1) = 0,1172 \quad (8.11)$$

$$t = \frac{2,3840}{0,1172} = 20,35 \quad (8.12)$$

Prueba de hipótesis bilateral:

- $H_0 : \beta_1 = 0$ (no hay asociación lineal entre escolaridad e ingreso en la población)
- $H_a : \beta_1 \neq 0$ (existe asociación lineal)
- $\alpha = 0,05$, $gl = n - 2 = 30$
- Valor crítico: $t_{0,025,30} = 2,042$
- Regla de decisión: Rechazar H_0 si $|t| > 2,042$
- $|t| = 20,35 > 2,042 \implies$ **Rechazamos H_0 .**

Intervalo de confianza al 95 % para β_1 :

$$\hat{\beta}_1 \pm t_{0,025,30} \cdot \text{EE}(\hat{\beta}_1) = 2,3840 \pm 2,0423 \times 0,1172 = [2,14, 2,62]$$

Interpretación: Con 95 % de confianza, el verdadero β_1 poblacional está entre 2.14 y 2.62 miles de pesos por año adicional de escolaridad. Es decir, entre \$2,140 y \$2,620 pesos mensuales.

Inferencia para $\hat{\beta}_0$ (aunque no tenga interpretación sustantiva):

$$\hat{\beta}_0 = -14,53 \quad (8.13)$$

$$\text{EE}(\hat{\beta}_0) = 1,14 \quad (8.14)$$

$$t = -12,75 \quad (8.15)$$

$$\text{IC}_{95\%} : [-16,86, -12,20] \quad (8.16)$$

En contexto mexicano**¿Qué aprendemos de estos números?**

- **La asociación es fuerte:** $\hat{\beta}_1 = 2,38$ está a 20.35 errores estándar del cero. Esto no es marginalmente significativo; es abrumadoramente significativo. La probabilidad de observar una asociación tan fuerte por puro azar muestral, si β_1 fuera realmente cero, es infinitesimal ($p < 0,0001$).
- **La estimación es precisa:** El IC $[2,14, 2,62]$ es relativamente estrecho. Incluso en el extremo inferior, un año más de escolaridad está asociado con \$2,140 más de ingreso mensual, una cantidad económicamente relevante.
- **Significancia estadística $\neq$ significancia económica $\neq$ causalidad:** Que podamos rechazar $H_0 : \beta_1 = 0$ con enorme confianza NO significa que la educación *cause* el mayor ingreso. Significa que la asociación es tan fuerte que es extremadamente improbable que sea producto del azar muestral. La causalidad requiere supuestos adicionales que nuestros datos observacionales no satisfacen (Sección 7).
- **El tamaño muestral importa:** Con $n = 32$, tenemos suficiente potencia para detectar la asociación. Si n fuera 5, el error estándar sería mayor y posiblemente no rechazaríamos H_0 aunque la asociación poblacional fuera la misma. Esto es un caso particular del principio general del Lab 1: a mayor tamaño muestral, menor varianza del estimador.

Conexión: Lab 4 $\rightarrow$ Lab 7

La prueba t para β_1 es la misma que aprendiste en el Lab 4. En el Lab 4 probaste $H_0 : \mu = \mu_0$ usando:

$$t = \frac{\bar{X} - \mu_0}{\text{EE}(\bar{X})} \sim t_{n-1}$$

Aquí pruebas $H_0 : \beta_1 = 0$ usando:

$$t = \frac{\hat{\beta}_1 - 0}{\text{EE}(\hat{\beta}_1)} \sim t_{n-2}$$

La estructura es **idéntica**: estimador puntual menos valor hipotético, dividido entre el error estándar. Lo único que cambia es:

- El parámetro de interés (β_1 en vez de μ)
- Los grados de libertad ($n - 2$ en vez de $n - 1$, porque estimamos 2 parámetros)
- La fórmula del error estándar (depende de S_{xx} y n , no solo de n)

Pero la lógica de decisión —comparar el estadístico con un valor crítico, rechazar si la señal supera el ruido— es **exactamente** la que internalizaste en el Lab 4. Todo lo que aprendiste sobre errores Tipo I/II, potencia, tamaño de prueba y valor p aplica directamente aquí.

Conexión: Lab 3 → Lab 7

El IC para β_1 es un intervalo t , igual que en el Lab 3. En el Lab 3 construiste intervalos de confianza de la forma:

$$\text{IC}_{1-\alpha}(\mu) = \bar{X} \pm t_{\alpha/2, n-1} \cdot \frac{s}{\sqrt{n}}$$

El IC para β_1 tiene la misma estructura:

$$\text{IC}_{1-\alpha}(\beta_1) = \hat{\beta}_1 \pm t_{\alpha/2, n-2} \cdot \text{EE}(\hat{\beta}_1)$$

En ambos casos: estimador puntual $\pm$ valor crítico $\times$ error estándar. La lógica es la misma: en vez de dar un solo número, produces una banda que, con probabilidad $1 - \alpha$, contiene al verdadero valor del parámetro. Y la dualidad IC–prueba de hipótesis que viste en el Lab 3 se mantiene intacta: si el IC del 95 % para β_1 no contiene al 0, la prueba bilateral rechaza $H_0 : \beta_1 = 0$ al 5 %. En nuestro caso: IC = $[2,14, 2,62]$, no contiene al 0 $\implies$ rechazamos H_0 .

Tarjeta de repaso

Inferencia sobre β_1 en una línea: Prueba t : $t = \hat{\beta}_1 / \text{EE}(\hat{\beta}_1) \sim t_{n-2}$ bajo $H_0 : \beta_1 = 0$. IC: $\hat{\beta}_1 \pm t_{\alpha/2, n-2} \cdot \text{EE}(\hat{\beta}_1)$. Rechazo si $|t| > t_{\alpha/2, n-2}$ o si el IC no contiene al 0. Significancia estadística $\neq$ causalidad.

Pregunta de autoevaluación

Un analista estima dos regresiones. En la primera, con $n = 30$, obtiene $\hat{\beta}_1 = 0,50$ y $t = 1,80$. En la segunda, con $n = 300$, obtiene $\hat{\beta}_1 = 0,10$ y $t = 4,50$. ¿Cuál de las dos asociaciones es estadísticamente significativa al 5 %? ¿Cuál es, a tu juicio, económicamente más relevante? ¿Son contradictorios estos resultados con la idea de que significancia estadística y significancia económica son conceptos distintos?

8.8. Asociación no es causalidad: el error más común —y más grave— en regresión

Antes de leer: hazte esta pregunta

Nuestra regresión dice que los estados con un año más de escolaridad tienen, en promedio, \$2,380 más de ingreso mensual. ¿Significa esto que si un estado **augmenta** su escolaridad en un año, su ingreso **subiría** en \$2,380? ¿Por qué sí o por qué no?

Intuición

La distinción fundamental. Hay una diferencia abismal entre:

- “Los estados con mayor escolaridad **tienen** mayor ingreso” (afirmación descriptiva/asociacional — CORRECTA con nuestros datos)
- “Mayor escolaridad **causa** mayor ingreso” (afirmación causal — INCORRECTA con nuestros datos)

La primera es una afirmación sobre lo que *observamos* en la muestra. La segunda es una afirmación sobre lo que *pasaría* si interviniéramos para cambiar la escolaridad (un contrafactual). Para pasar de la primera a la segunda necesitamos supuestos muy fuertes que nuestros datos no satisfacen.

La metáfora del incendio y los bomberos. En una ciudad, a más bomberos enviados a un incendio, mayores son los daños materiales. ¿Significa esto que los bomberos *causan* los daños? No: los incendios más graves atraen más bomberos (causalidad inversa). La correlación es positiva; la causalidad no. En nuestro caso: ¿los estados más ricos invierten más en educación (causalidad inversa)? ¿O la educación causa riqueza? O —lo más probable— ¿ambas cosas son causadas por un tercer factor (desarrollo institucional, inversión, geografía)? Con datos observacionales de corte transversal, **no podemos distinguir** entre estas explicaciones.

Cómputo

Tres amenazas a la interpretación causal de $\hat{\beta}_1$:

1. **Variables omitidas (sesgo por variables omitidas).** Si existe una variable z que:
 - Afecta a y (el ingreso), Y
 - Está correlacionada con x (la escolaridad), Y
 - NO está incluida en el modelo (está en u)
 entonces $E[u \mid x] \neq 0$ (viola RLS.4) y $\hat{\beta}_1$ es un estimador **sesgado** del efecto causal de x sobre y . $\hat{\beta}_1$ captura no solo el efecto de x , sino también parte del efecto de z . En nuestro caso: calidad institucional, inversión extranjera, infraestructura, geografía —todas afectan el ingreso, todas están correlacionadas con la escolaridad, y ninguna está en el modelo—.
2. **Causalidad inversa (simultaneidad).** No solo la educación puede afectar el ingreso; el ingreso puede afectar la educación. Estados más ricos pueden invertir más en sus sistemas educativos, contratar mejores maestros, retener a su población más educada. Si la causalidad va en ambas direcciones, $\hat{\beta}_1$ no estima el efecto causal de educación sobre ingreso; estima una mezcla de ambos efectos.
3. **Datos observacionales (no experimentales).** Para identificar un efecto causal, el “estándar de oro” es un experimento aleatorizado: asignas aleatoriamente

niveles de x a las unidades de observación. En nuestro caso, eso significaría asignar aleatoriamente niveles de escolaridad a los estados —algo imposible. Con datos observacionales, la asignación de x no es aleatoria: los estados “eligen” su nivel de escolaridad (o este es determinado por factores históricos, políticos y económicos), y esa “elección” puede estar correlacionada con u .

Formalmente, el sesgo por variables omitidas: Si el modelo verdadero es $y = \beta_0 + \beta_1 x + \beta_2 z + v$ con $E[v \mid x, z] = 0$, pero estimamos $y = \beta_0 + \beta_1 x + u$ (omitiendo z), entonces:

$$E[\hat{\beta}_1^{\text{MCO}}] = \beta_1 + \beta_2 \cdot \frac{\text{Cov}(x, z)}{\text{Var}(x)}$$

El sesgo es $\beta_2 \cdot \frac{\text{Cov}(x, z)}{\text{Var}(x)}$. Si $\beta_2 > 0$ (la variable omitida afecta positivamente a y) y $\text{Cov}(x, z) > 0$ (correlacionada positivamente con x), el sesgo es positivo: $\hat{\beta}_1$ sobreestima β_1 .

En contexto mexicano

¿Qué hacer entonces? La ruta hacia la causalidad.

Con datos observacionales, no podemos “probar” causalidad, pero podemos *acercarnos* usando estrategias de identificación:

- **Agregar controles (regresión múltiple, Lab 8):** Si podemos medir las variables omitidas y agregarlas al modelo, reducimos el sesgo. En nuestro caso: agregar inversión extranjera, calidad institucional, porcentaje de población urbana, etc. El coeficiente de escolaridad *cambiará* (típicamente bajará) al agregar estos controles, y ese cambio nos da información sobre la magnitud del sesgo.
- **Variables instrumentales (IV):** Encontrar una variable z que afecte la escolaridad pero no tenga efecto directo sobre el ingreso (excepto a través de la escolaridad). Ejemplo clásico: la distancia a la universidad más cercana, o leyes de escolaridad obligatoria (Angrist & Krueger, 1991).
- **Diferencias en diferencias (DiD):** Comparar el cambio en el ingreso de estados que experimentaron una reforma educativa con el cambio en estados que no la experimentaron.
- **Regresión discontinua (RDD):** Aprovechar umbrales arbitrarios (como la fecha de corte para entrar a la primaria) que generan variación cuasi-experimental en la escolaridad.

Estas estrategias son el núcleo de la econometría aplicada moderna (Angrist & Pischke, 2009) y se cubren en cursos avanzados. El Lab 7 te da la herramienta fundamental (regresión); los cursos de econometría te enseñan a usarla para identificar efectos causales.

Nota didáctica

El error plantado del Quiz 4. En el quiz de este laboratorio, la Parte A contiene un error deliberado: una afirmación que confunde asociación con causalidad. La tarea es detectarlo y corregirlo. Este no es un “truco” de examen: es una simulación de lo que ocurre todos los días en periódicos, reportes gubernamentales y —lamentablemente— papers académicos. Aprender a detectar afirmaciones causales no justificadas es una de las habilidades más valiosas que este curso te puede dar.

Tarjeta de repaso

Asociación $\neq$ causalidad en una línea: $\hat{\beta}_1$ mide asociación, no efecto causal. Tres amenazas: variables omitidas, causalidad inversa, y no aleatorización. Para causalidad necesitas un diseño de identificación (controles, IV, DiD, RDD). Si escribes “la educación **causa** mayor ingreso”, estás afirmando algo que tus datos no pueden probar.

Pregunta de autoevaluación

Lee el siguiente párrafo (adaptado de un reporte real de política pública) y encuentra el error:

“Nuestra regresión muestra que, por cada año adicional de escolaridad promedio, el ingreso laboral mensual aumenta en \$2,380. Por lo tanto, una política que incrementa la escolaridad promedio en un año generaría un aumento de \$2,380 en el ingreso mensual de los trabajadores. El gobierno debe invertir en educación para aumentar los salarios.”

Identifica: (a) la afirmación causal no justificada, (b) al menos un mecanismo por el cual esta inferencia podría ser inválida, y (c) cómo reformularías la conclusión en lenguaje correlacional correcto.

8.9. Síntesis PPDAC: el ciclo completo de nuestro análisis

El ciclo PPDAC aplicado a la regresión de ingreso sobre escolaridad

El marco PPDAC (Problem–Plan–Data–Analysis–Conclusion), desarrollado por Wild & Pfannkuch (1999), estructura todo análisis estadístico riguroso. No es un adorno pedagógico: es la columna vertebral de cualquier investigación empírica seria. Aquí mostramos cómo nuestro análisis de los 32 estados mexicanos instancia cada etapa.

Intuición

PPDAC como hábito mental. La mayoría de la gente empieza por los datos (“tengo esta base, ¿qué puedo hacer con ella?”). Un buen analista empieza por el Problema (“¿qué quiero saber?”). La diferencia es todo. Si empiezas por los datos, terminas pescando correlaciones espurias y torturando los datos hasta que confiesen lo que quieres oír. Si empiezas por el problema, los datos son un medio para responder una pregunta, no un fin en sí mismos.

En nuestro caso: la pregunta no era “¿qué correlaciones interesantes hay en los datos de la ENOE?” sino “¿está asociada la escolaridad con el ingreso a nivel estatal, y con qué magnitud?”. Esa pregunta determinó qué datos usar, qué modelo estimar, y —crucialmente— cómo interpretar los resultados.

Cómputo

Las cinco etapas de nuestro análisis:

1. **P — Problem (Problema).** *¿Está asociada la escolaridad promedio de un estado mexicano con su ingreso laboral mensual? ¿Cuál es la magnitud de esa asociación?*

Esta es una pregunta descriptiva, no causal. Está acotada (una x , una y , 32 unidades de observación) y es respondible con los datos disponibles.

2. **P — Plan (Plan).** *Modelo lineal bivariado $y = \beta_0 + \beta_1 x + u$. Estimación por MCO. Inferencia sobre β_1 con prueba t e IC al 95 %. Bondad de ajuste con R^2 . Evaluación de supuestos Gauss-Markov.*

El plan se define ANTES de tocar los datos. Sabemos exactamente qué modelo vamos a estimar, qué hipótesis vamos a probar ($H_0 : \beta_1 = 0$), y con qué criterio vamos a evaluar los resultados.

3. **D — Data (Datos).** *32 entidades federativas mexicanas. x = escolaridad promedio (años), y = ingreso laboral mensual (miles de pesos). Fuente: patrones ENOE-INEGI.*

Datos observacionales (no experimentales), agregados por estado. Conocemos las limitaciones: $n = 32$ es chico, los datos son agregados (no individuales), y hay variables omitidas relevantes. Esto no invalida el análisis; condiciona su interpretación.

4. **A — Analysis (Análisis).**

- Recta estimada: $\hat{y} = -14,53 + 2,38 x$
- $R^2 = 0,9324$: el 93.24 % de la variabilidad en ingreso está asociada con la escolaridad
- $EE(\hat{\beta}_1) = 0.1172$, $t = 20,35$, $p < 0,0001$
- $IC_{95\%}(\beta_1) = [2,14, 2,62]$

- Rechazamos $H_0 : \beta_1 = 0$ al 5 %

5. **C — Conclusion (Conclusión).** *Existe una asociación fuerte, positiva y estadísticamente significativa entre la escolaridad promedio y el ingreso laboral a nivel estatal en México. Un año adicional de escolaridad está asociado con entre \$2,140 y \$2,620 más de ingreso mensual (IC 95 %).*

Pero: con datos observacionales agregados, no podemos atribuir causalidad a esta asociación. Variables omitidas (calidad institucional, inversión extranjera, geografía), causalidad inversa (estados más ricos invierten más en educación), y la naturaleza no experimental de los datos impiden una interpretación causal. La asociación es un hecho; la explicación es una hipótesis.

En contexto mexicano

Por qué la conclusión es matizada, no triunfalista. Un error común — especialmente en policy briefs y reportes ejecutivos— es terminar con una conclusión contundente que ignora las limitaciones del análisis. “La educación aumenta los salarios: ¡inviertan en educación!” es un *slogan*, no una conclusión estadística. Una buena conclusión es matizada: reconoce lo que los datos dicen (asociación fuerte), lo que NO dicen (causalidad), y las limitaciones (variables omitidas, datos agregados). Este tipo de honestidad intelectual es lo que separa al analista riguroso del charlatán estadístico.

Tarjeta de repaso

PPDAC en una línea: Problema → Plan → Datos → Análisis → Conclusión. El orden importa: el problema define el plan; el plan determina qué datos necesitas; los datos alimentan el análisis; el análisis produce la conclusión. Invertir el orden (datos → problema) es la receta para el *p-hacking* y las correlaciones espurias.

8.10. Lo que sigue: sutura al Laboratorio 8 y más allá

Conexión: Lab 7 → Lab 8+

De la regresión simple a la regresión múltiple y la econometría.

El Lab 7 te dio la base. El Lab 8 construye el edificio. Esto es lo que viene:

1. **Regresión múltiple:** $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + u$. Más variables permiten “controlar” por factores observables, acercándonos a una interpretación *ceteris paribus*. Si en nuestro modelo agregamos inversión extranjera, calidad institucional y cercanía a EUA, el coeficiente de escolaridad β_1 cambiará. Ese cambio es evidencia del sesgo por variables omitidas en la regresión simple.
2. **Formas funcionales no lineales:** Logaritmos (elasticidades), cuadráticas (rendimientos decrecientes), interacciones (¿el retorno a la educación es distinto en

el norte que en el sur?). La linealidad estricta es una aproximación; la realidad es más rica.

3. **Prueba F global:** La prueba t evalúa un coeficiente a la vez. La prueba F evalúa si **todos** los coeficientes (excepto el intercepto) son conjuntamente cero. Es la generalización de la prueba F de ANOVA que viste en el Lab 5.
4. **Máxima verosimilitud en regresión:** El MCO que usamos aquí es, bajo normalidad, el estimador de máxima verosimilitud (MLE). En el Lab 8 verás la derivación formal de esta equivalencia con notación matricial.
5. **R^2 ajustado:** En regresión múltiple, agregar variables SIEMPRE aumenta R^2 (incluso si la variable es ruido puro). El R^2 ajustado penaliza por el número de regresores, permitiendo comparar modelos con distinto número de variables. Esta es una limitación importante del R^2 simple que viste aquí.
6. **El puente a la econometría:** La regresión múltiple con datos observacionales sigue sin garantizar causalidad. Pero combinada con estrategias de identificación (variables instrumentales, diferencias en diferencias, regresión discontinua, efectos fijos), forma el núcleo de la econometría aplicada moderna. Lo que aprendiste en este lab —el modelo, MCO, inferencia, la distinción asociación/causalidad— es el primer paso de un camino que lleva a Angrist, Krueger, Card, Duflo, y el resto de la “credibility revolution” en economía.

Lo que NO debes olvidar del Lab 7 al entrar al Lab 8:

- $\hat{\beta}_1 = S_{xy}/S_{xx}$ es la fórmula fundamental. En regresión múltiple se generaliza a $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$, pero la intuición es la misma.
- $SCT = SCE + SCR$ sigue valiendo. La prueba F global se construye a partir de esta descomposición.
- Los supuestos de Gauss-Markov se extienden naturalmente: RLS.4 sigue siendo el crítico ($E[u \mid x_1, \dots, x_k] = 0$).
- Asociación $\neq$ causalidad. Agregar más variables reduce el sesgo por omitidas, pero no lo elimina a menos que incluyas **todas** las variables relevantes —algo imposible en la práctica—.

Conexión con los ejercicios

Conexión con el Lab 8. En el Lab 8 retomarás el dataset mexicano pero con múltiples variables: agregarás pobreza (CONEVAL), inversión extranjera directa, porcentaje de población urbana, y tasa de homicidios. Verás cómo el coeficiente de escolaridad cambia al incluir estos controles. También trabajarás con la ecuación de Mincer ($\ln(\text{ingreso}) \sim \text{escolaridad} + \text{experiencia} + \text{experiencia}^2$) usando microdatos de la ENOE. Y conectarás explícitamente la prueba F global de la regresión con la

prueba F de ANOVA del Lab 5, cerrando el círculo entre las dos herramientas.

8.11. Autoevaluación: ¿entiendes la regresión o solo la calculas?

Pregunta de autoevaluación

Pregunta 1 (Interpretación de $\hat{\beta}_1$). Un investigador estima $\hat{y} = 5,2 + 0,8x$ con $n = 45$. x son años de educación, y es salario por hora en dólares. Escribe la interpretación correcta de $\hat{\beta}_1 = 0,8$.

Pregunta de autoevaluación

Pregunta 2 (Interpretación de $\hat{\beta}_0$). En la misma regresión de la Pregunta 1, $\hat{\beta}_0 = 5,2$. ¿Tiene interpretación sustantiva? ¿Qué condiciones deben cumplirse para que el intercepto sea interpretable?

Pregunta de autoevaluación

Pregunta 3 (R^2 y sus limitaciones). Un analista reporta $R^2 = 0,97$ para la regresión del PIB estatal sobre el número de iglesias. Concluye que las iglesias “generan” el 97 % del PIB. Identifica al menos dos problemas con esta conclusión.

Pregunta de autoevaluación

Pregunta 4 (Prueba t). Para un modelo con $n = 20$, obtienes $\hat{\beta}_1 = 1,5$ y $EE(\hat{\beta}_1) = 0,6$. Realiza la prueba $H_0 : \beta_1 = 0$ vs. $H_a : \beta_1 \neq 0$ al $\alpha = 0,05$. $t_{0,025,18} = 2,101$. ¿Rechazas H_0 ? Interpreta el resultado.

Pregunta de autoevaluación

Pregunta 5 (Asociación vs. causalidad). Un periódico reporta: “Un estudio encuentra que las personas que beben vino tinto viven en promedio 3 años más. Los investigadores recomiendan beber vino tinto para alargar la vida.” Explica, usando los conceptos de este capítulo, por qué esta recomendación podría ser inválida. Menciona al menos dos mecanismos alternativos.

Pregunta de autoevaluación

Pregunta 6 (Gauss-Markov). Enumera los cinco supuestos de Gauss-Markov. Para cada uno, indica: (a) qué significa en lenguaje no técnico, y (b) qué consecuencias tiene su violación sobre las propiedades de MCO.

Pregunta de autoevaluación

Pregunta 7 (Síntesis). En una sola frase para cada uno, explica qué hereda el Lab 7 de: (a) Lab 1, (b) Lab 2, (c) Lab 3, (d) Lab 4, (e) Lab 5, (f) Lab 6.

✓ Verifica tu comprensión

Si puedes responder estas 7 preguntas sin consultar el texto, entiendes la regresión. Si no, vuelve a la sección correspondiente. La regresión no se domina en una lectura: se domina cuando puedes explicarle a alguien más *por qué* $\hat{\beta}_1 = S_{xy}/S_{xx}$, *qué significa* $R^2 = 0,93$, y *por qué* no puedes decir que la educación “causa” el ingreso.

Mapa conceptual del capítulo: Laboratorio 7

El laboratorio 7 cubre el modelo de regresión lineal simple en 6 bloques conceptuales encadenados:

1. **Datos:** 32 estados mexicanos, x = escolaridad, y = ingreso. $\bar{x} = 9,52$, $\bar{y} = 8,15$.
2. **Modelo poblacional:** $y = \beta_0 + \beta_1 x + u$. $E[y | x] = \beta_0 + \beta_1 x$. β_1 = pendiente poblacional.
3. **Estimación (MCO):** $\hat{\beta}_1 = S_{xy}/S_{xx}$, $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$. Minimiza $\sum \hat{u}_i^2$. $\hat{y} = -14,53 + 2,38x$.
4. **Bondad de ajuste (R^2):** $SCT = SCE + SCR$. $R^2 = SCE/SCT = 0,9324$. En regresión simple: $R^2 = r_{xy}^2$.
5. **Supuestos (Gauss-Markov):** RLS.1–RLS.5. RLS.4 ($E[u | x] = 0$) es el crítico: si falla, $\hat{\beta}_1$ es sesgado e inconsistente.
6. **Inferencia:** $t = \hat{\beta}_1/EE(\hat{\beta}_1) \sim t_{n-2}$. $IC_{95\%} = [2,14, 2,62]$. Rechaza $H_0 : \beta_1 = 0$.

Las 6 herencias:

- Lab 1 → 7: Insesgamiento y eficiencia (Gauss-Markov es BLUE)
- Lab 2 → 7: MCO = MLE bajo normalidad de los errores
- Lab 3 → 7: IC para β_1 es un intervalo t , igual que para μ
- Lab 4 → 7: Prueba t para β_1 usa la misma lógica que para μ
- Lab 5 → 7: $SCT = SCE + SCR$ es la misma descomposición de ANOVA
- Lab 6 → 7: Regresión con dummies = ANOVA. Lo del Lab 6 como “ANOVA dos vías” reaparece como “regresión múltiple con interacciones” en Lab 8

La advertencia central: Asociación $\neq$ causalidad. $\hat{\beta}_1$ mide asociación. Para causalidad necesitas un diseño de identificación (controles, IV, DiD, RDD).

9. Epílogo: El arco completo

9.1. Las 4 preguntas, respondidas desde la cima

Al inicio de este documento te planteamos cuatro preguntas que organizan la estadística. Siete laboratorios después, tenemos respuestas —no respuestas finales, sino métodos para encontrarlas.

9.1.1. Pregunta 1: ¿Apunto al valor correcto?

Respuesta (Lab 1): El sesgo de un estimador es $E[\hat{\theta}] - \theta$. Si es cero, tu estimador acierta en promedio. Aprendiste a calcularlo, a interpretarlo (el *Literary Digest* no falló por mala suerte: falló por sesgo de selección), y a reconocerlo en contextos que van desde encuestas electorales hasta la estimación de la inflación.

Pero el sesgo no es lo único que importa. Dos estimadores insesgados pueden tener varianzas muy distintas. Por eso necesitas la segunda pregunta.

9.1.2. Pregunta 2: ¿Con cuánta precisión?

Respuesta (Lab 1, Sección 2): La eficiencia compara varianzas. La Cota de Cramér-Rao te da un piso teórico: ningún estimador insesgado puede tener varianza menor que $1/[nI(\theta)]$. Si tu estimador la alcanza, es el más preciso posible. Si no, la pregunta queda abierta —la cota puede ser inalcanzable.

Esta pregunta viaja a todos los laboratorios posteriores: la precisión de un intervalo de confianza (Lab 3), la potencia de una prueba de hipótesis (Lab 4), y la varianza de $\hat{\beta}_1$ en regresión (Lab 7) dependen de qué tan eficiente es tu estimador.

9.1.3. Pregunta 3: ¿Cómo construyo un buen estimador?

Respuesta (Lab 2): Máxima Verosimilitud y Método de Momentos son dos recetas sistemáticas. MLE maximiza la probabilidad de observar los datos que viste; MOM iguala momentos teóricos con muestrales. Ambos producen estimadores que, bajo condiciones razonables, son consistentes y asintóticamente normales.

Y aquí está la conexión que recorre el resto del curso: MCO, el estimador de regresión del Lab 7, es MLE bajo normalidad de los errores. El trabajo que hiciste derivando log-verosimilitudes en el Lab 2 es exactamente lo que tu software ejecuta cuando corres `lm(y ~ x)`.

9.1.4. Pregunta 4: ¿Qué tan seguro estoy?

Respuesta (Labs 3–4): Un estimador puntual sin medida de incertidumbre es incompleto. Los intervalos de confianza (Lab 3) te dan una banda: “con 95 % de confianza, el parámetro está entre L y U .” Las pruebas de hipótesis (Lab 4) te dan un veredicto: “los datos rechazan H_0 con $p = 0,02$.”

Y son dos caras de la misma moneda: si μ_0 no está en el IC del 95 %, la prueba bilateral rechaza $H_0 : \mu = \mu_0$ al 5 %. Esta dualidad es el puente entre los Labs 3 y 4, y se extiende a todos los laboratorios posteriores: el IC para β_1 (Lab 7) es el dual de la prueba t para β_1 .

9.1.5. La quinta pregunta: ¿Cómo se relacionan las variables?

Respuesta (Labs 5–7): Cuando dejas de mirar una variable aislada y preguntas por relaciones, las herramientas cambian:

- Si tu X es categórica y tu Y es numérica: **ANOVA** (Labs 5–6). Una sola prueba F te dice si las medias de Y difieren entre categorías de X .
- Si tu X es numérica y tu Y es numérica: **Regresión** (Lab 7). La pendiente β_1 te dice cuánto cambia Y , en promedio, por cada unidad de cambio en X .

Y no son herramientas separadas: ANOVA con variables dummy es regresión. La descomposición de varianza $SCT = SCE + SCR$ de la regresión es la misma idea que $SC_{Total} = SC_{Entre} + SC_{Dentro}$ de ANOVA. El estadístico F de ANOVA es el F de significancia global de la regresión. Es una escalera, no herramientas aisladas.

9.2. El mapa de decisiones completo

¿Qué herramienta uso? — Mapa de decisiones completo

Mi problema	Mi variable	Herramienta	Lab
Estimar un parámetro	Una variable numérica	Estimador puntual (MLE, MOM)	1–2
Medir incertidumbre de una estimación	Una variable numérica	Intervalo de confianza	3
Decidir si un parámetro es igual a cierto valor	Una variable numérica	Prueba de hipótesis (z , t)	4
Comparar medias de varios grupos	Una categórica + una numérica	ANOVA de una vía	5
Comparar medias controlando por otra variable	Una categórica + una de bloque + una numérica	ANOVA de dos vías	6
Probar si unos datos siguen una distribución	Una variable (frecuencias)	χ^2 bondad de ajuste	6
Modelar relación entre dos variables numéricas	Dos variables numéricas	Regresión lineal simple	7

9.3. La tabla de herencia conceptual (versión completa)

Cuadro 9.1: Matriz completa de herencia conceptual. Leer por filas: el laboratorio de la izquierda aporta al de arriba el concepto indicado.

	Lab 3	Lab 4	Lab 5–6	Lab 7
Lab 1	$\text{Var}(\bar{X})$ determina ancho del IC	Insesgamiento justifica H_0 ; consistencia garantiza convergencia	$\text{Var}(\bar{X})$ es la base de $\text{SC}_{\text{Dentro}}$	Gauss-Markov: “Unbiased” es insesgamiento; R^2 es descomposición de varianza
Lab 2	MLE/MOM proveen estimadores puntuales para el IC	MLE $\rightarrow$ prueba de razón de verosimilitudes	MOM para varianzas entre/dentro grupos	MCO = MLE bajo normalidad
Lab 3	—	Dualidad IC $\leftrightarrow$ prueba	IC para diferencia de medias $\rightarrow$ ANOVA; IC para $\sigma^2 \rightarrow \chi^2$	IC para β_1 : $\hat{\beta}_1 \pm t_{\alpha/2, n-2} \cdot \text{EE}(\hat{\beta}_1)$
Lab 4	—	—	Prueba t para 2 grupos $\rightarrow$ prueba F para k grupos ($F = t^2$)	Prueba t para β_1 (misma lógica y distribución)
Lab 5–6	—	—	—	ANOVA con dummies = regresión; $R^2 = \eta^2$; prueba F global

Esta tabla es el resumen de todas las suturas que escribiste (o leíste) en este documento. Cada celda tiene su desarrollo completo en el capítulo correspondiente.

Nota didáctica

La naturaleza de las suturas: no todas las conexiones son del mismo tipo. A lo largo del documento, las suturas (cajas azul claro) tejen puentes entre laboratorios. Estos puentes no son todos iguales, y conviene saber distinguirlos:

- **Analogía pedagógica:** “Así como la varianza de $\bar{X}$ determina el ancho del IC, la varianza de $\hat{\beta}_1$ determina el ancho de su IC.” Es una semejanza conceptual útil para transferir intuición, pero no implica que una fórmula se deduzca formalmente de la otra. Ejemplo típico: la sutura Lab 3 $\rightarrow$ Lab 7 sobre el IC para

β_1 .

- **Caso particular:** “La prueba t para dos grupos es un caso particular del ANOVA de una vía con $k = 2$.” Es una *equivalencia formal* donde ambas pruebas comparten el mismo estadístico subyacente y el mismo modelo: $t_{n-2}^2 = F_{1,n-2}$, y las fórmulas producen exactamente el mismo p -valor. Ejemplo: sutura Lab 4 → Lab 5.
- **Identidad algebraica:** “ $R^2 = \eta^2$ cuando el ANOVA se escribe con dummies.” Es una *igualdad numérica verificable*: la suma de cuadrados de la regresión de Y sobre dummies para k grupos es exactamente la SC_Entre del ANOVA. Ejemplo: sutura Lab 5–6 → Lab 7.
- **Comparten distribución muestral asintótica:** “El estadístico de prueba para β_1 se distribuye t_{n-2} ; el estadístico para $\mu_x - \mu_y$ se distribuye $t_{n_1+n_2-2}$.” Comparten la familia de distribuciones (t de Student) pero con distintos grados de libertad y bajo distintos supuestos. La sutura enfatiza que usan *la misma lógica inferencial*, no que sean algebraicamente equivalentes.

Reconocer de qué tipo es cada conexión te ayuda a no sobreinterpretarlas: una analogía pedagógica no es una demostración, y una identidad algebraica no es una mera semejanza. En cada capítulo, la sutura está redactada usando el registro apropiado (“*comparte la misma lógica que*” para analogías, “*es exactamente el mismo estadístico que*” para equivalencias). Presta atención a esas frases: son la clave para distinguir qué tipo de puente estás cruzando.

9.4. La escalera conceptual




Figura 9.1: La escalera conceptual de Estadística II. Cada nivel construye sobre el anterior. No son herramientas aisladas: son capas de abstracción que se acumulan.

9.5. Lo que falta: hacia el Lab 8 y la econometría

Este documento cubre los Laboratorios 1 al 7. Pero la estadística no termina aquí. El Laboratorio 8 y los cursos de econometría que tomarás en 5º y 6º semestre extienden estas herramientas:

- **Regresión múltiple:** $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + u$. La interpretación de β_1 cambia: ahora es “controlando por $x_2, \dots, x_k$.” Es la extensión natural del ANOVA de dos vías con bloques (Lab 6).
- **Formas no lineales:** logaritmos (elasticidades), cuadráticas (rendimientos decrecientes), interacciones (efectos heterogéneos).
- **Prueba F global:** ¿el modelo en su conjunto explica algo? Generaliza la prueba t para β_1 .

- **Inferencia causal:** Variables instrumentales, diferencias en diferencias, regresión discontinua, experimentos aleatorizados. El salto de “asociación” a “causalidad” que anticipaste en el Lab 7, Sección 6.
- **Máxima Verosimilitud en regresión:** La conexión MCO $\leftrightarrow$ MLE que viste en el Lab 7 se generaliza a modelos no lineales (logit, probit, Poisson).

La buena noticia: todo lo que aprendiste en estos 7 laboratorios es el fundamento. La prueba t , el intervalo de confianza, la descomposición de varianza, la lógica de “rechazar H_0 ”, la distinción entre significancia estadística y relevancia práctica —nada de eso se desecha. Se generaliza.

9.6. Limitaciones y trabajo futuro

Este documento es una **propuesta de diseño curricular**, no un estudio empírico de su efectividad. Es importante que —como autor y como lector— tengas claras sus fronteras:

- **No hay evidencia de aprendizaje.** El marco de suturas y la tabla de herencia conceptual no han sido evaluados formalmente en el aula. No sabemos aún si los estudiantes que usan este documento obtienen mejores resultados que los que usan materiales tradicionales, ni si las conexiones explícitas entre laboratorios mejoran la retención a largo plazo o la transferencia a problemas nuevos. La literatura en educación estadística recomienda que las innovaciones curriculares se acompañen de evaluación formativa (Garfield y Ben-Zvi 2008; GAISE 2016, recomendación 6). Este documento proporciona la estructura para esa evaluación futura (las autoevaluaciones de cada capítulo pueden servir como *pretest-posttest*), pero no reporta resultados.
- **El diseño es específico a un contexto.** Los ejemplos usan datos mexicanos y el documento está escrito para estudiantes de 4º semestre de la Licenciatura en Economía del CIDE. La arquitectura conceptual (la secuencia de laboratorios, las suturas, la tabla de herencia) es potencialmente transferible a otros contextos, pero esa transferencia requeriría adaptar los casos reales y verificar que las conexiones entre laboratorios son igualmente pertinentes en otros planes de estudio.
- **La implementación computacional está incompleta.** Varias secciones hacen referencia a archivos de datos externos o vectores hard-codeados que no se distribuyen con el documento. Una versión lista para el aula requeriría empaquetar los datos (o el código para simularlos) junto con el material, siguiendo la recomendación GAISE de analizar datos con tecnología de manera activa.

La hoja de ruta para una segunda edición incluye: (1) implementar un estudio de evaluación de aprendizaje con grupos control y experimental en el CIDE, usando las autoevaluaciones como instrumentos de medición; (2) empaquetar los conjuntos de datos y scripts de R como material complementario descargable; (3) someter el manuscrito a revisión por pares en una revista de educación estadística como el *Journal of Statistics and Data Science Education* (JSDSE) o el *Statistics Education Research Journal* (SERJ), donde el diseño curricular con fundamento pedagógico explícito es valorado como contribución.

9.7. Cierre: el economista frente a los datos, una vez más

Al inicio de este documento te preguntamos: eres economista en el Banco de México, tienes los datos, tienes una pregunta. ¿Qué haces?

Siete laboratorios después, tienes una respuesta:

1. **Identifica el parámetro** que necesitas estimar (media, proporción, varianza, pendiente).
2. **Construye un estimador** con buenas propiedades (insesgado, eficiente, consistente) usando MLE, MOM o MCO.
3. **Cuantifica la incertidumbre** con un intervalo de confianza o una prueba de hipótesis.
4. **Si hay grupos, compáralos** con ANOVA en vez de inflar el error con múltiples pruebas t .
5. **Si hay relaciones entre variables, modélalas** con regresión.
6. **Interpreta con cautela:** asociación no es causalidad. La significancia estadística no es relevancia práctica.

No hay un solo camino. Pero este documento te dio el mapa.

Tarjeta de repaso

El arco completo en siete verbos:

1. **Verificar** (Lab 1): ¿mi estimador es bueno?
2. **Construir** (Lab 2): ¿cómo fabrico un estimador?
3. **Acotar** (Lab 3): ¿entre qué valores está el parámetro?
4. **Decidir** (Lab 4): ¿los datos apoyan mi hipótesis?
5. **Comparar** (Lab 5): ¿son iguales estos grupos?
6. **Controlar** (Lab 6): ¿y si hay más de un factor?
7. **Modelar** (Lab 7): ¿cómo se relacionan estas variables?

Pregunta de autoevaluación

Pregunta final de autoevaluación:

1. Explica, con tus propias palabras, por qué la descomposición de varianza es el hilo conductor que atraviesa los Labs 1, 5 y 7.
2. Un colega te dice: “ANOVA y regresión son cosas completamente distintas.” ¿Qué le respondes?
3. ¿En qué laboratorio aprendiste el concepto que justifica que OLS sea insesgado? ¿Y el que justifica que sea el de mínima varianza?

4. ¿Cuál es la diferencia entre un intervalo de confianza del 95 % y una prueba de hipótesis al 5 %? ¿Son herramientas diferentes o dos caras de la misma moneda?

A. Tabla de notación unificada

Nota sobre esta tabla

Esta tabla de notación es la referencia canónica para todo el documento. La notación es consistente con las notas de clase (Casella & Berger, Wooldridge) y con las guías de lectura previa de cada laboratorio. Si encuentras una discrepancia entre esta tabla y algún capítulo, esta tabla tiene prioridad.

A.1. Símbolos generales

Símbolo	Significado	Uso típico
n	Tamaño de muestra	Número de observaciones
N	Tamaño de población (cuando difiere de n)	Muestreo sin reemplazo
k	Número de grupos (ANOVA) o parámetros	ANOVA: k grupos; regresión: k regresores
α	Nivel de significancia	$\alpha = 0,05$ para pruebas al 5 %
$1 - \alpha$	Nivel de confianza	$1 - \alpha = 0,95$ para IC del 95 %

A.2. Parámetros poblacionales

Símbolo	Significado	Uso típico
μ	Media poblacional	$\mu = E[X]$
σ^2	Varianza poblacional	$\sigma^2 = \text{Var}(X) = E[(X - \mu)^2]$
σ	Desviación estándar poblacional	$\sigma = \sqrt{\sigma^2}$
π	Proporción poblacional	$\pi = P(\text{éxito})$ en Bernoulli
θ	Parámetro genérico	Parámetro de interés en cualquier distribución

Símbolo	Significado	Uso típico
λ	Tasa (Exponencial, Poisson)	$f(x \lambda) = \lambda e^{-\lambda x}$ para Exponencial; $P(X = k \lambda) = \frac{e^{-\lambda} \lambda^k}{k!}$ para Poisson
β	Escala (Exponencial, Gamma)	$f(x \beta) = \frac{1}{\beta} e^{-x/\beta}$ para Exponencial (parametrización alternativa)
α (Gamma)	Parámetro de forma (Gamma)	$f(x \alpha, \beta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$
β_0	Intercepto poblacional (regresión)	$E[y x = 0] = \beta_0$
β_1	Pendiente poblacional (regresión)	$\Delta E[y]/\Delta x = \beta_1$

A.3. Estimadores y estadísticos

Símbolo	Significado	Uso típico
$\bar{X}$	Media muestral	$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
S^2	Varianza muestral (insesgada)	$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$
$\hat{\theta}$	Estimador de θ	Genérico: $\hat{\theta}_{\text{MLE}}, \hat{\theta}_{\text{MOM}}$
$\hat{\mu}$	Estimador de μ	$\hat{\mu} = \bar{X}$
$\hat{\sigma}^2$	Estimador de σ^2	$\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$; $\hat{\sigma}_{\text{insesgado}}^2 = S^2$
$\hat{\pi}$	Estimador de π	$\hat{\pi} = \bar{X}$ para Bernoulli
$\hat{\beta}_0, \hat{\beta}_1$	Estimadores MCO de β_0, β_1	$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$, $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$
$\hat{y}_i$	Valor ajustado (regresión)	$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$
$\hat{u}_i$	Residual (regresión)	$\hat{u}_i = y_i - \hat{y}_i$

A.4. Operadores y funciones

Símbolo	Significado	Uso típico
$E[X]$	Esperanza matemática	$E[X] = \sum x f(x)$ o $\int x f(x) dx$
$\text{Var}(X)$	Varianza	$\text{Var}(X) = E[(X - E[X])^2]$
$\text{Cov}(X, Y)$	Covarianza	$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])]$
$\text{Corr}(X, Y)$	Correlación	$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$

Símbolo	Significado	Uso típico
$EE(\hat{\theta})$	Error estándar de $\hat{\theta}$	$EE(\hat{\theta}) = \sqrt{\text{Var}(\hat{\theta})}$
$MSE(\hat{\theta})$	Error cuadrático medio	$MSE(\hat{\theta}) = \text{Var}(\hat{\theta}) + (\text{Sesgo}(\hat{\theta}))^2$
$I(\theta)$	Información de Fisher	$I(\theta) = E \left[\left(\frac{\partial}{\partial \theta} \log f(X \theta) \right)^2 \right]$
$L(\theta)$	Función de verosimilitud	$L(\theta) = \prod_{i=1}^n f(x_i \theta)$
$\ell(\theta)$	Log-verosimilitud	$\ell(\theta) = \log L(\theta)$

A.5. Distribuciones

Símbolo	Distribución	Parámetros
$N(\mu, \sigma^2)$	Normal	μ : media, σ^2 : varianza
$Z \sim N(0, 1)$	Normal estándar	—
t_ν	t de Student	ν : grados de libertad
χ_ν^2	Chi-cuadrado	ν : grados de libertad
F_{ν_1, ν_2}	F de Fisher	ν_1 : gl numerador, ν_2 : gl denominador
Bernoulli(π)	Bernoulli	π : probabilidad de éxito
Binomial(n, π)	Binomial	n : ensayos, π : prob. de éxito
Poisson(λ)	Poisson	λ : tasa de ocurrencia
Exponencial(λ)	Exponencial (tasa)	λ : tasa, $f(x \lambda) = \lambda e^{-\lambda x}$, $E[X] = 1/\lambda$
Gamma(α, β)	Gamma (escala)	α : forma, β : escala, $E[X] = \alpha\beta$

A.6. Descomposición de varianza (ANOVA y regresión)

Símbolo	Significado	Uso
SC_{Total} / SCT	Suma de cuadrados total	ANOVA y regresión
$SC_{\text{Entre}} / SC_{\text{Trat}}$	Suma de cuadrados entre grupos (tratamientos)	ANOVA
$SC_{\text{Dentro}} / SC_{\text{Error}}$	Suma de cuadrados dentro de grupos (error)	ANOVA
SC_{Bloques}	Suma de cuadrados de bloques	ANOVA dos vías
SCE	Suma de cuadrados explicada (modelo)	Regresión
SCR	Suma de cuadrados de residuales	Regresión
CM_{Entre}	Cuadrado medio entre grupos	ANOVA: $SC_{\text{Entre}}/(k-1)$

Símbolo	Significado	Uso
CM_{Dentro}	Cuadrado medio dentro de grupos	ANOVA:
R^2 / R^2	Coefficiente de determinación	$SC_{\text{Dentro}}/(n - k)$ SCE/SCT o $1 - SCR/SCT$
η^2	Tamaño del efecto (ANOVA)	$SC_{\text{Entre}}/SC_{\text{Total}} = R^2$ cuando X son dum- mies

A.7. Valores críticos y notación de inferencia

Símbolo	Significado	Ejemplo
$z_{\alpha/2}$	Valor crítico normal estándar	$z_{0,025} = 1,96$
$t_{\alpha/2,\nu}$	Valor crítico t de Student	$t_{0,025,30} \approx 2,042$
$\chi^2_{\alpha,\nu}$	Valor crítico chi-cuadrado	$\chi^2_{0,05,10} \approx 18,307$
F_{α,ν_1,ν_2}	Valor crítico F	$F_{0,05,3,20} \approx 3,098$
H_0	Hipótesis nula	$H_0 : \mu = \mu_0$
H_a / H_1	Hipótesis alternativa	$H_a : \mu \neq \mu_0$
p -valor	Probabilidad de observar un estadístico tan o más extremo que el obtenido, bajo H_0	$p = P(T > t_{\text{obs}} \mid H_0)$

Nota didáctica

Convención de colas para valores críticos. En este documento, todos los valores críticos siguen la convención de **cola superior**:

- $z_{\alpha/2}$ y $t_{\alpha/2,\nu}$: denotan el cuantil $1 - \alpha/2$ de $N(0, 1)$ y t_ν , respectivamente. Por ejemplo, $z_{0,025} = 1,96$ satisface $P(Z > 1,96) = 0,025$. Esta convención es la estándar para intervalos de confianza bilaterales y pruebas de dos colas.
- $\chi^2_{\alpha,\nu}$: denota el cuantil $1 - \alpha$ de χ^2_ν , es decir, $P(\chi^2_\nu > \chi^2_{\alpha,\nu}) = \alpha$. Esta convención se usa para la región de rechazo de la cola derecha en pruebas sobre σ^2 . **Atención:** para pruebas bilaterales sobre σ^2 se requieren *dos* valores críticos: $\chi^2_{1-\alpha/2,\nu}$ y $\chi^2_{\alpha/2,\nu}$ (cuantiles inferior y superior, respectivamente).
- F_{α,ν_1,ν_2} : denota el cuantil $1 - \alpha$ de F_{ν_1,ν_2} , es decir, $P(F_{\nu_1,\nu_2} > F_{\alpha,\nu_1,\nu_2}) = \alpha$. En ANOVA, la región de rechazo es siempre la cola derecha (valores grandes de F indican señal fuerte relativa al ruido).

Esta convención es consistente con las tablas de valores críticos estándar (las tablas de χ^2 y F típicamente reportan cuantiles superiores) y con la salida de R (`qchisq(0.95, df=10) ≈ 18,307`).

B. Referencias bibliográficas

Referencias

Estadística matemática y econometría

- Angrist, Joshua D., y Jörn-Steffen Pischke. 2009. *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton: Princeton University Press.
- Casella, George, y Roger L. Berger. 2002. *Statistical Inference*. 2ª ed. Pacific Grove: Duxbury.
- Fisher, Ronald A. 1922. “On the Mathematical Foundations of Theoretical Statistics.” *Philosophical Transactions of the Royal Society A* 222: 309–368.
- 1925. *Statistical Methods for Research Workers*. Edinburgh: Oliver and Boyd.
- Hansen, Lars Peter. 1982. “Large Sample Properties of Generalized Method of Moments Estimators.” *Econometrica* 50 (4): 1029–1054.
- Stock, James H., y Mark W. Watson. 2020. *Introduction to Econometrics*. 4ª ed. Boston: Pearson.
- Wackerly, Dennis D., William Mendenhall III, y Richard L. Scheaffer. 2010. *Estadística Matemática con Aplicaciones*. 7ª ed. México: Cengage Learning.
- Wooldridge, Jeffrey M. 2020. *Introductory Econometrics: A Modern Approach*. 7ª ed. Boston: Cengage.

Didáctica de la estadística y ciencias del aprendizaje

- Bjork, Elizabeth L., y Robert A. Bjork. 2011. “Making Things Hard on Yourself, But in a Good Way: Creating Desirable Difficulties to Enhance Learning.” En *Psychology and the Real World: Essays Illustrating Fundamental Contributions to Society*, editado por M. A. Gernsbacher, R. W. Pew, L. M. Hough, y J. R. Pomerantz, 56–64. New York: Worth Publishers.
- Borkovec, Thomas D., Elwood Robinson, Thomas Pruzinsky, y James A. DePree. 1983. “Preliminary Exploration of Worry: Some Characteristics and Processes.” *Behaviour Research and Therapy* 21 (1): 9–16.

- Cepeda, Nicholas J., Harold Pashler, Edward Vul, John T. Wixted, y Doug Rohrer. 2006. “Distributed Practice in Verbal Recall Tasks: A Review and Quantitative Synthesis.” *Psychological Bulletin* 132 (3): 354–380.
- Chance, Beth L. 2002. “Components of Statistical Thinking and Implications for Instruction and Assessment.” *Journal of Statistics Education* 10 (3).
- Cobb, George W. 2015. “Mere Renovation Is Too Little Too Late: We Need to Rethink Our Undergraduate Curriculum from the Ground Up.” *The American Statistician* 69 (4): 266–282.
- delMas, Robert C. 2002. “Statistical Literacy, Reasoning, and Learning: A Commentary.” *Journal of Statistics Education* 10 (3).
- Dunlosky, John, Katherine A. Rawson, Elizabeth J. Marsh, Mitchell J. Nathan, y Daniel T. Willingham. 2013. “Improving Students’ Learning with Effective Learning Techniques: Promising Directions from Cognitive and Educational Psychology.” *Psychological Science in the Public Interest* 14 (1): 4–58.
- GAISE College Report ASA Revision Committee. 2016. *Guidelines for Assessment and Instruction in Statistics Education (GAISE) College Report 2016*. Alexandria: American Statistical Association.
- Garfield, Joan, y Dani Ben-Zvi. 2008. *Developing Students’ Statistical Reasoning: Connecting Research and Teaching Practice*. Dordrecht: Springer.
- Jamieson, Jeremy P., Wendy Berry Mendes, Erin Blackstock, y Toni Schmader. 2010. “Turning the Knots in Your Stomach into Bows: Reappraising Arousal Improves Performance on the GRE.” *Journal of Experimental Social Psychology* 46 (1): 208–212.
- Novak, Joseph D., y Alberto J. Cañas. 2008. “The Theory Underlying Concept Maps and How to Construct and Use Them.” Technical Report IHMC CmapTools 2006-01 Rev 01-2008. Pensacola: Florida Institute for Human and Machine Cognition.
- Novak, Joseph D., y D. Bob Gowin. 1984. *Learning How to Learn*. Cambridge: Cambridge University Press.
- Roediger, Henry L., y Jeffrey D. Karpicke. 2006. “Test-Enhanced Learning: Taking Memory Tests Improves Long-Term Retention.” *Psychological Science* 17 (3): 249–255.
- Wild, Chris J., y Maxine Pfannkuch. 1999. “Statistical Thinking in Empirical Enquiry.” *International Statistical Review* 67 (3): 223–265.

Artículos aplicados y datos mexicanos

- Banco de México. Varios años. *Series históricas de inflación, tipo de cambio y PIB*. Ciudad de México: Banxico.

- Bertrand, Marianne, y Sendhil Mullainathan. 2004. “Are Emily and Greg More Employable than Lakisha and Jamal? A Field Experiment on Labor Market Discrimination.” *American Economic Review* 94 (4): 991–1013.
- Card, David, y Alan B. Krueger. 1994. “Minimum Wages and Employment: A Case Study of the Fast-Food Industry in New Jersey and Pennsylvania.” *American Economic Review* 84 (4): 772–793.
- CONEVAL. 2022. *Medición de la Pobreza Multidimensional en México: Tabulados e indicadores*. Ciudad de México: Consejo Nacional de Evaluación de la Política de Desarrollo Social.
- Deaton, Angus. 2010. “Price Indexes, Inequality, and the Measurement of World Poverty.” *American Economic Review* 100 (1): 5–34.
- INEGI. Varios años. *Encuesta Nacional de Ocupación y Empleo (ENOE)*. Aguascalientes: Instituto Nacional de Estadística y Geografía.
- Varios años. *Encuesta Nacional de Ingresos y Gastos de los Hogares (ENIGH)*. Aguascalientes: INEGI.
- 2020. *Censo de Población y Vivienda 2020*. Aguascalientes: INEGI.
- IMSS. 2022–2023. *Datos de accidentes laborales*. Ciudad de México: Instituto Mexicano del Seguro Social.
- Markowitz, Harry. 1952. “Portfolio Selection.” *Journal of Finance* 7 (1): 77–91.
- Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública (SESNSP). Varios años. *Incidencia delictiva por entidad federativa*. Ciudad de México: SESNSP.
- Timmermann, Allan. 2006. “Forecast Combinations.” En *Handbook of Economic Forecasting*, vol. 1, editado por Graham Elliott, Clive W.J. Granger, y Allan Timmermann, 135–196. Amsterdam: Elsevier.
- Wasserstein, Ronald L., y Nicole A. Lazar. 2016. “The ASA’s Statement on p -Values: Context, Process, and Purpose.” *The American Statistician* 70 (2): 129–133.
- Yahoo Finance. 2026. *Datos históricos de cierre ajustado: IPC México ($\sim MXX$) y S&P 500 ($\sim GSPC$)*. Descargado 2026-04-23.

Casos históricos y divulgación

- Bryson, Maurice C. 1976. “The *Literary Digest* Poll: Making of a Statistical Myth.” *The American Statistician* 30 (4): 184–185.
- Silver, Nate. 2012. *The Signal and the Noise: Why So Many Predictions Fail — But Some Don’t*. New York: Penguin Press.